چکیده:

آلودگی ناشی از پسماندهای دریایی، به‌ویژه مواد پلاستیکی و سایر پسماندهای جامد، یکی از چالش‌های مهم زیست‌محیطی در مقیاس جهانی است. تنوع بالای پسماندها از نظر شکل، اندازه، رنگ و وضعیت ظاهری و همچنین تغییرپذیری شرایط تصویربرداری، استفاده از روش‌های خودکار و قابل‌اعتماد برای شناسایی و مکان‌یابی این اشیا را ضروری ساخته است. در این میان، روش‌های مبتنی بر یادگیری عمیق و تشخیص شیء می‌توانند امکان پردازش خودکار حجم زیادی از تصاویر دریایی و ساحلی را فراهم کنند. با این حال، عملکرد مطلوب یک مدل در شرایط پایه الزاماً به معنای پایداری مناسب آن در برابر تخریب‌های تصویری و تغییر دامنه نیست.

هدف این پژوهش، مقایسه کنترل‌شده عملکرد سه معماری تشخیص شیء شامل YOLOv8n، RT-DETR-L و RTMDet-Tiny در مسئله تشخیص پسماندهای دریایی و بررسی رفتار آن‌ها در شرایط مختلف تصویری و دامنه‌ای است. برای این منظور، داده‌های مورد استفاده پس از هماهنگ‌سازی ساختار و طبقه‌بندی، در یک چارچوب آزمایشی مشترک و با تقسیم‌بندی ثابت مورد استفاده قرار گرفتند. سه مدل با اندازه ورودی 640×640 و Seed برابر 42 ارزیابی شدند و معیار mAP@0.50:0.95 به‌عنوان معیار اصلی انتخاب checkpoint در نظر گرفته شد. در بخش آزمون فرضیه‌ها، مقایسه عملکرد بر مبنای F1 در سطح تصویر و شاخص Degradation انجام شد.

نتایج نشان داد که در شرایط پایه، YOLOv8n با میانگین F1 برابر 0.754021 بالاترین عملکرد را در میان سه مدل به دست آورد .آزمون فریدمن وجود تفاوت معنادار میان عملکرد مدل‌ها را نشان داد و مقایسه‌های زوجی نیز پس از اصلاح Holm معنادار بودند .در آزمون تخریب‌های مصنوعی شامل تغییر روشنایی، کنتراست، نویز گاوسی، تاری گاوسی، تاری حرکتی و فشرده‌سازیJPEG ، RT-DETR-L کمترین میانگین افت عملکرد را نشان داد .در آزمون تغییر دامنه نیز RT-DETR-L با میانگین Degradation برابر 0.076483 نسبت به RTMDet-Tiny با 0.105260و YOLOv8n با 0.117336 پایداری بیشتری داشت.

بر اساس نتایج سه مرحله نخست، YOLOv8n برای آزمایش سازگارسازی دامنه انتخاب شد. سازگارسازی با داده‌های مصنوعی و تحت یک پروتکل کنترل‌شده انجام گرفت. میانگین F1 پس از سازگارسازی از 0.757359 به

0.723990 کاهش یافت. آزمون ویلکاکسون زوجی این تغییر را از نظر آماری معنادار نشان داد و فاصله اطمینان Bootstrap نیز افت عملکرد را تأیید کرد. بنابراین، پروتکل سازگارسازی مورد استفاده در این پژوهش نه‌تنها موجب بهبود عملکرد نشد، بلکه به Negative Transfer منجر شد.

در مجموع، یافته‌های پژوهش نشان دادند که هیچ یک از سه معماری مورد بررسی در تمامی ابعاد ارزیابی برتری مطلق ندارند YOLOv8n .از نظر عملکرد پایه مزیت بیشتری نشان داد، در حالی که RT-DETR-L در برابر خرابی های مصنوعی و تغییر دامنه پایدارتر بود .همچنین، نتیجه سازگارسازی نشان داد که استفاده از داده‌های مصنوعی بدون تطبیق کافی با ویژگی‌های واقعی دامنه هدف می‌تواند به افت عملکرد منجر شود .بر این اساس، ارزیابی مدل‌های تشخیص پسماند دریایی باید به‌صورت چندبعدی و با درنظرگرفتن دقت، استحکام، تعمیم‌پذیری و شرایط واقعی کاربرد انجام شود.

واژگان کلیدی: پسماند دریایی، تشخیص شیء، یادگیری عمیق، YOLOv8n، RT-DETR-L، RTMDet-Tiny، Robustness، Domain Shift، Domain Adaptation، F1-score

پیشگفتار:

آلودگی محیط‌های دریایی در سال‌های اخیر به یکی از مسائل مهم محیط‌زیستی تبدیل شده است. افزایش ورود پسماندهای انسانی، به‌ویژه پلاستیک، تجهیزات ماهیگیری و سایر مواد جامد، در کنار پویایی محیط دریایی، موجب شده است که شناسایی و پایش این پسماندها به یک فرایند مستمر و پیچیده تبدیل شود. در چنین شرایطی، استفاده از روش‌های خودکار مبتنی بر بینایی ماشین و یادگیری عمیق می‌تواند ظرفیت پایش و تحلیل داده‌های تصویری را افزایش دهد و بخشی از محدودیت‌های روش‌های دستی را کاهش دهد. با این حال، دشواری محیط‌های دریایی و تغییرپذیری شرایط تصویربرداری باعث می‌شود ارزیابی یک مدل تنها بر اساس عملکرد آن در تصاویر استاندارد، برای قضاوت درباره قابلیت اعتماد آن کافی نباشد.

انگیزه اصلی انجام این پژوهش از همین مسئله شکل گرفت؛ یعنی این پرسش که آیا یک مدل تشخیص شیء که در شرایط پایه عملکرد بهتری دارد، لزوماً در برابر تغییرات تصویری و انتقال به شرایط متفاوت نیز عملکرد مطلوب‌تری خواهد داشت یا خیر. از این منظر، مقایسه سه معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny صرفاً یک مقایسه عددی میان سه مدل نیست، بلکه تلاشی برای بررسی تفاوت رفتار آن‌ها در چند سطح از عملکرد است. در طراحی پژوهش، علاوه بر عملکرد پایه، مقاومت در برابر تخریب‌های مصنوعی، پایداری در تغییر دامنه و اثر یک راهبرد کنترل‌شده سازگارسازی دامنه نیز مورد توجه قرار گرفته است. این رویکرد با ساختار روش‌شناسی پژوهش که بر کنترل داده، تقسیم‌بندی مشترک، پروتکل آموزشی و ارزیابی یکسان تأکید دارد، هماهنگ است.

یکی از ملاحظات مهم در انجام این پژوهش، ایجاد امکان مقایسه منصفانه میان معماری‌های متفاوت بود. برای این منظور، تقسیم‌بندی داده‌ها، اندازه ورودی و Seed ثابت در نظر گرفته شد و معیار مشخصی برای انتخاب checkpoint تعریف گردید. بر اساس روش پژوهش، بهترین checkpoint هر مدل بر مبنای بیشترین mAP@0.50:0.95 روی مجموعه Validation انتخاب شد و مجموعه Test در این تصمیم‌گیری دخالت داده نشد.

در بخش تحلیل نتایج نیز تلاش شد میان مفاهیم مختلف عملکرد تمایز روشنی ایجاد شود. عملکرد پایه نشان‌دهنده رفتار مدل در شرایط مرجع است؛ Robustness بیانگر میزان حفظ عملکرد در برابر تغییرات کنترل‌شده ورودی است و Domain Shift به تغییر توزیع داده میان شرایط مبدأ و مقصد اشاره دارد. همچنین، Domain Adaptation مسئله‌ای متفاوت است که در آن داده یا اطلاعاتی از دامنه هدف در فرایند سازگارسازی مورد استفاده قرار می‌گیرد. این تمایزها برای جلوگیری از برداشت نادرست از نتایج و تفسیر دقیق یافته‌ها اهمیت اساسی دارند.

نتایج به‌دست‌آمده نشان دادند که انتخاب مدل مناسب، وابسته به شرایط کاربرد است. YOLOv8n در شرایط پایه و در مجموعه خرابی‌های مصنوعی مورد بررسی عملکرد مطلوب‌تری داشت، در حالی که RT-DETR-L در شرایط تغییر دامنه افت کمتری نشان داد. از سوی دیگر، سازگارسازی مصنوعی انجام‌شده برای YOLOv8n به بهبود منجر نشد و حتی افت معنادار عملکرد ایجاد کرد. این یافته از یک سو محدودیت روش مورد استفاده را نشان می‌دهد و از سوی دیگر اهمیت طراحی دقیق داده‌های سازگارسازی و میزان شباهت آن‌ها با دامنه واقعی هدف را برجسته می‌کند.

این پایان‌نامه در پنج فصل تنظیم شده است. فصل اول به کلیات پژوهش، بیان مسئله، اهمیت و ضرورت، اهداف، پرسش‌ها، فرضیه‌ها و ساختار کلی پژوهش اختصاص دارد. فصل دوم مبانی نظری و پیشینه مرتبط با پسماندهای دریایی، تشخیص شیء، معماری‌های مورد مطالعه، Domain Shift،Robustness و Domain Adaptation را بررسی می‌کند. فصل سوم روش‌شناسی پژوهش، آماده‌سازی داده‌ها، معماری مدل‌ها، تنظیمات آموزش، معیارهای ارزیابی و روش آزمون فرضیه‌ها را تشریح می‌کند. فصل چهارم به ارائه و تحلیل یافته‌های تجربی اختصاص دارد و فصل پنجم نتیجه‌گیری، محدودیت‌ها و پیشنهادهای پژوهش را ارائه می‌کند.

در پایان، امید است این پژوهش بتواند گامی در جهت ارزیابی واقع‌بینانه‌تر مدل‌های تشخیص شیء برای کاربردهای مرتبط با پایش پسماندهای دریایی بردارد و نشان دهد که برای انتخاب یک مدل مناسب، توجه هم‌زمان به دقت، استحکام، تعمیم‌پذیری و شرایط واقعی بهره‌برداری ضروری است.

فهرست مطالب

فهرست نمودارها ۳۴

فهرست جداول ۳۲

فهرست مطالب ۵

1-1 مقدمه ۳۴

1-2 بیان مسئله ۳۸

1-3 اهمیت و ضرورت پژوهش ۴۳

1-3-1 اهمیت زیست‌محیطی ۴۳

1-3-2 اهمیت فنی ۴۴

1-3-3 اهمیت روش‌شناختی ۴۴

1-3-4 اهمیت کاربردی ۴۵

1-4 هدف کلی پژوهش ۴۵

1-5 اهداف اختصاصی پژوهش ۴۵

1-6 سؤالات پژوهش ۴۶

1-7 فرضیه‌های پژوهش ۴۷

1-8 متغیرهای پژوهش ۴۸

1-8-1 متغیرهای مستقل ۴۸

1-8-2 متغیرهای وابسته ۴۸

1-8-3 متغیرهای کارایی محاسباتی ۴۹

1-8-4 متغیرهای کنترل‌شده ۴۹

1-9 چارچوب مفهومی پژوهش ۴۹

1-10 نوآوری و سهم علمی پژوهش ۵۰

1-10-1 یکپارچه‌سازی داده‌های چندمنبعی ۵۱
1-10-2 تفکیک عملکرد پایه، مقاومت و انتقال بین‌دامنه‌ای ۵۱
1-10-3 کمی‌سازی افت عملکرد ۵۱
1-10-4 پیوند ارزیابی domain shift و adaptation ۵۱
1-10-5 انتخاب مدل بر اساس شواهد چندبعدی ۵۲
1-11 محدودیت‌های پژوهش..... ۵۲
1-12 ساختار پایان‌نامه ۵۳
فصل اول به کلیات پژوهش اختصاص دارد و زمینه مسئله، بیان مسئله، اهمیت و ضرورت، اهداف، سؤالات، فرضیه‌ها، متغیرها، چارچوب مفهومی، سهم علمی و محدودیت‌های پژوهش را تشریح می‌کند. ۵۳
فصل دوم به مبانی نظری و پیشینه پژوهش اختصاص دارد. در این فصل، مباحث مرتبط با پسماندهای دریایی، تشخیص شیء، یادگیری عمیق، معماری‌های YOLO، RT-DETR-L و RTMDet-Tiny، مجموعه‌داده‌های زیرآبی، robustness، domain shift، domain adaptation و مطالعات پیشین بررسی و تحلیل خواهند شد. ..۵۳
فصل سوم روش‌شناسی پژوهش را ارائه می‌کند. جزئیات مربوط به داده‌ها، آماده‌سازی و اعتبارسنجی annotation، تقسیم‌بندی داده‌ها، معماری‌ها، تنظیمات آموزش، معیارهای ارزیابی، طراحی آزمون‌های robustness، ارزیابی cross-domain، سازگارسازی و روش تحلیل آماری در این فصل ارائه می‌شود. ۵۳
فصل چهارم به ارائه و تحلیل نتایج اختصاص دارد. نتایج عملکرد پایه، مقاومت در برابر اختلالات، تغییر دامنه، سازگارسازی و کارایی محاسباتی مدل‌ها در این فصل گزارش و مقایسه می‌شوند. ۵۳
فصل پنجم شامل بحث، نتیجه‌گیری و پیشنهادهای پژوهش است. یافته‌های اصلی با توجه به سؤالات پژوهش و مطالعات پیشین تفسیر شده و محدودیت‌ها و مسیرهای پیشنهادی برای تحقیقات آینده ارائه می‌شوند. ۵۳
1-13 جمع‌بندی فصل..... ۵۴
منابع لاتین فصل اول: ۵۴
مبانی نظری و پیشینه پژوهش ۵۷
2-1 مبانی نظری پسماند دریایی و ضرورت پایش هوشمند ۵۷

2-2 بینایی ماشین و تشخیص شیء ۵۸
2-2-1 مفهوم تشخیص شیء ۵۸
2-2-2 آشکارسازهای دومرحله‌ای و تک‌مرحله‌ای ۵۹
2-3 چالش‌های تشخیص شیء در محیط‌های دریایی و زیرآبی ۵۹
2-3-1 ویژگی‌های خاص تصاویر زیرآبی ۵۹
2-3-2 کوچک بودن و تغییر مقیاس اشیا ۶۰
2-3-3 پیچیدگی پس‌زمینه ۶۰
2-3-4 عدم توازن کلاس‌ها ۶۱
2-4 مجموعه‌داده‌های پسماند دریایی ۶۱
2-4-1 نقش مجموعه‌داده در یادگیری عمیق ۶۱
2-4-2 مجموعه‌داده Trash-ICRA19 ..... ۶۱
2-4-3 مجموعه‌داده TrashCan ۶۲
2-4-4 داده‌های سطحی و گسترش تنوع دامنه تصویری ۶۲
2-5 یکپارچه‌سازی داده‌های چندمنبعی ۶۳
2-5-1 مفهوم و چارچوب یکپارچه‌سازی داده ۶۳
2-5-1-1 منطق استفاده از منابع چندگانه ۶۴
2-5-2 هماهنگ‌سازی Taxonomy و منطق شکل‌گیری ۱۳ کلاس نهایی ۶۵
جدول 2-1. ساختار نهایی ۱۳ کلاس مورد استفاده در پژوهش ۶۶
منطق حضور کلاس‌های جانوری ۶۷
منطق حضور کلاس plant ۶۷
منطق حضور کلاس‌های گروه trash ۶۷
منطق کلی انتخاب ۱۳ کلاس ۶۸

2-5-3 کیفیت Annotation و کنترل سازگاری برچسب‌ها ۶۹
2-5-3-1 خطاهای مکانی ۶۹
2-5-3-2 خطاهای طبقه‌بندی ۷۰
2-5-3-3 سازگاری قالب annotation ۷۰
2-5-3-4 کنترل نمونه‌های مبهم ۷۰
2-5-3-5 کنترل کیفیت و اثر آن بر مقایسه مدل‌ها ۷۱
2-6 یادگیری عمیق در تشخیص پسماند دریایی ۷۱
۲-۱۶- تحول آشکارسازهای عمیق در مسئله پسماند دریایی ۷۲
۲-۶-۲ ضرورت مقایسه معماری‌ها در یک چارچوب کنترل‌شده ۷۳
۲-۶-۳ گذار از تشخیص پایه به ارزیابی Robustness و تعمیم‌پذیری ۷۴
۲-۶-۴ جایگاه RT-DETR-L،YOLOv8n و RTMDet-Tiny در پژوهش حاضر ۷۴
۲-۶-۵ جمع‌بندی ۷۵
۲-۷ معماری YOLO و YOLOv8n ۷۵
۲-۷-۱ تکامل خانواده YOLO ۷۵
۲-۷-۲ ساختار کلی YOLOv8n ۷۶
۲-۷-۳ Backbone و ماژول C2f ۷۷
۲-۷-۴ ماژول SPPF ۷۸
۲-۷-۵ Neck و ساختار FPN–PAN ۷۸
۲-۷-۶ Detection Head؛ ساختار Anchor-Free و تفکیک‌شده ۷۹
۲-۷-۷ تخصیص نمونه‌ها با Task-Aligned Assigner ۸۰
۲-۷-۸ توابع زیان YOLOv8n ۸۱
۲-۷-۸-۱ زیان طبقه‌بندی ۸۱

۲-۷-۸-۲ زیان مکان‌یابی و CIoU ۸۱
۲-۷-۸-۳ Distribution Focal Loss ۸۲
۲-۷-۹ تشخیص چندمقیاسی ۸۲
۲-۷-۱۰ پس‌پردازش و Non-Maximum Suppression ۸۳
۲-۷-۱۱ مزایا و محدودیت‌های YOLOv8n در تشخیص پسماند دریایی ۸۳
۲-۷-۱۲ جایگاه YOLOv8n در پژوهش حاضر ۸۴
۲-۷-۱۳ جمع‌بندی ۸۵
۲-۸ معماری RT-DETR-L ۸۵

معماری‌های مبتنی بر Transformer در سال‌های اخیر به یکی از مسیرهای مهم توسعه سامانه‌های تشخیص شیء تبدیل شده‌اند. نقطه عطف این مسیر، معرفی خانواده DETR بود که مسئله تشخیص شیء را با استفاده از معماری Transformer و در قالب یک فرایند End-to-End صورت‌بندی کرد. در این رویکرد، برخلاف آشکارسازهای متداول که معمولاً به مجموعه‌ای از قواعد و مراحل پس‌پردازشی مانند Non-Maximum Suppression وابسته هستند، تشخیص اشیا به‌صورت مستقیم‌تر و با استفاده از مجموعه‌ای از Object Queryها انجام می‌شود (Carion et al., 2020). ۸۵

با وجود مزیت‌های مفهومی DETR، نسخه‌های اولیه آن از نظر هزینه محاسباتی و سرعت استنتاج برای کاربردهای بلادرنگ محدودیت‌هایی داشتند. RT-DETR-L با هدف رفع این مسئله توسعه یافت و تلاش کرد معماری Transformer را با یک طراحی کارآمدتر برای استخراج و ادغام ویژگی‌های چندمقیاسی ترکیب کند. در مقاله اصلی، RT-DETR-L به‌عنوان یک آشکارساز End-to-End بلادرنگ معرفی شده است که با طراحی یک Encoder ترکیبی کارآمد و سازوکار انتخاب Query، هزینه پردازشی را کاهش می‌دهد و در عین حال مزیت حذف NMS را حفظ می‌کند (Zhao et al., 2024). ۸۵

از دیدگاه پژوهش حاضر، RT-DETR-L اهمیت ویژه‌ای دارد؛ زیرا در کنار YOLOv8n و RTMDet-Tiny امکان مقایسه سه رویکرد معماری متفاوت را فراهم می‌کند: ۸۶
CNN-basedYOLOv8nvs.Transformer-basedRT-DETR-Lvs.CNN-basedRTMDet-Tiny ۸۶

در این نمایش، RT-DETR-L نماینده رویکردهای مبتنی بر Transformer در چارچوب مقایسه‌ای پژوهش است. ۸۶

۲-۸-۱ گذار از DETR به RT-DETR-L ۸۶

معماری DETR توسط Carion و همکاران (2020) با هدف تبدیل تشخیص شیء به یک مسئله پیش‌بینی مجموعه‌ای معرفی شد. ایده اصلی این بود که مدل بتواند مجموعه‌ای از اشیای موجود در تصویر را مستقیماً پیش‌بینی کند و وابستگی به فرایندهای سنتی مانند Anchor Design و NMS را کاهش دهد. ۸۶

ساختار کلی DETR را می‌توان به‌صورت زیر نمایش داد: ۸۶

Image→CNN Backbone→Transformer Encoder→Transformer Decoder→Object Queries→Detections ۸۶

با وجود این طراحی ساده و End-to-End، استفاده مستقیم از Transformer برای پردازش ویژگی‌های تصویری با وضوح بالا می‌تواند هزینه محاسباتی قابل توجهی ایجاد کند. به همین دلیل، استفاده از DETRهای اولیه در کاربردهای بلادرنگ دشوار بود. ۸۶

RT-DETR-L با بازطراحی بخش استخراج و پردازش ویژگی تلاش می‌کند این مشکل را کاهش دهد. ایده اصلی آن، تفکیک تعاملات درون‌مقیاسی از ادغام بین‌مقیاسی در Encoder است تا محاسبات غیرضروری کاهش یابد. علاوه بر این، انتخاب Queryهای باکیفیت برای Decoder موجب می‌شود بخش Transformer از مجموعه‌ای مناسب‌تر از کاندیداهای اولیه استفاده کند (Zhao et al., 2024). ۸۶

بنابراین، مسیر مفهومی تحول را می‌توان به صورت زیر خلاصه کرد: DETR→Efficient Transformer-based DETectors→RT-DETR-L ۸۶

هدف این تحول، حفظ ویژگی End-to-End بودن در کنار رسیدن به سرعت مناسب برای کاربردهای بلادرنگ است. ۸۷

۲-۸-۲ ساختار کلی RT-DETR-L ۸۷

ساختار کلی RT-DETR-L را می‌توان در چند بخش اصلی شامل Backbone، Hybrid Encoder، Query Selection و Transformer Decoder تقسیم‌بندی کرد. ۸۷

نمایش ساده فرایند پردازش به شکل زیر است: ۸۷

Input Image→Backbone→Multi-scale Features→Hybrid Encoder→Object Query Selection→Transformer Decoder→Final Predictions ۸۷

Backbone وظیفه استخراج ویژگی‌های تصویری را بر عهده دارد. ویژگی‌های حاصل از چند سطح شبکه سپس وارد Hybrid Encoder می‌شوند. این Encoder به‌جای اعمال یک Transformer Encoder سنگین بر تمام ویژگی‌های چندمقیاسی، تعاملات درون هر مقیاس و ادغام بین مقیاس‌ها را به‌شکل تفکیک‌شده پردازش می‌کند. ۸۷

پس از آن، مجموعه‌ای از ویژگی‌ها برای ایجاد Object Queryهای اولیه مورد استفاده قرار می‌گیرند. Queryهای انتخاب‌شده وارد Decoder می‌شوند و Decoder در چند مرحله به اصلاح مکان و کلاس اشیا می‌پردازد. ۸۷

در نتیجه، می‌توان جریان اصلی معماری را چنین خلاصه کرد: Input Image→Feature Extraction→Hybrid Encoder→Query Selection/Initialization→Transformer Decoder→Iterative Refinement→Final Detections ۸۷

این ساختار، RT-DETR-L را از آشکارسازهای متداولی مانند YOLOv8n متمایز می‌کند. ۸۷

۲-۸-۳ استخراج ویژگی و نمایش چندمقیاسی ۸۷

مانند بسیاری از آشکارسازهای مدرن، RT-DETR-L نیز برای تشخیص اشیای دارای اندازه‌های متفاوت به نمایش ویژگی چندمقیاسی نیاز دارد. Backbone ویژگی‌هایی را از سطوح مختلف استخراج می‌کند که هرکدام دارای وضوح مکانی و سطح معنایی متفاوت هستند. ۸۷

ویژگی‌های سطح پایین‌تر معمولاً اطلاعات مکانی دقیق‌تری دارند، در حالی که ویژگی‌های عمیق‌تر دارای اطلاعات معنایی غنی‌تری هستند. بنابراین، استفاده هم‌زمان از این ویژگی‌ها برای تشخیص اشیای کوچک و بزرگ اهمیت دارد. ۸۷

در مسئله پسماند دریایی، این موضوع اهمیت ویژه‌ای دارد. برای مثال، قطعات کوچک پلاستیک یا اجزای باریک تور ممکن است تنها بخش کوچکی از تصویر را اشغال کنند، در حالی که یک قطعه بزرگ پسماند یا یک مجموعه متراکم از اشیا ممکن است در مقیاس بسیار بزرگ‌تر ظاهر شود. ۸۸

بنابراین، RT-DETR-L نیز همانند YOLOv8n باید بتواند اطلاعات چندمقیاسی را به‌گونه‌ای مؤثر ترکیب کند؛ اما روش انجام این کار در این دو معماری یکسان نیست. ۸۸

۲-۸-۴ Hybrid Encoder ۸۸

یکی از مهم‌ترین اجزای RT-DETR-L، **Hybrid Encoder** است. طراحی این Encoder با هدف کاهش هزینه محاسباتی Transformer و در عین حال حفظ توانایی مدل در برقراری ارتباط میان ویژگی‌های مختلف انجام شده است. ۸۸

در معماری Transformer، محاسبه Self-Attention در نگاشت‌های ویژگی با تعداد زیاد توکن می‌تواند هزینه محاسباتی بالایی داشته باشد. اگر وضوح مکانی ویژگی افزایش یابد، تعداد توکن‌ها نیز افزایش پیدا می‌کند و در نتیجه هزینه تعامل میان آن‌ها بیشتر می‌شود. ۸۸

RT-DETR-L برای کاهش این مشکل، فرایند پردازش ویژگی را به دو نوع تعامل اصلی تفکیک می‌کند: ۸۸

1. **تعامل درون‌مقیاسی (Intra-scale Interaction)** ۸۸
2. **ادغام بین‌مقیاسی (Cross-scale Fusion)** ۸۸

در بخش اول، روابط موجود در یک مقیاس مشخص مورد پردازش قرار می‌گیرند. در بخش دوم، اطلاعات سطوح مختلف با یکدیگر ترکیب می‌شوند. ۸۸

به‌صورت مفهومی: ۸۸

Multi-scale FeaturesIntra-scale TransformerEnhanced FeaturesCross-scale Feature FusionEncoded Features ۸۸

این تفکیک، یکی از عوامل اصلی طراحی RT-DETR-L برای رسیدن به سرعت بالاتر نسبت به استفاده مستقیم از Encoderهای Transformer سنگین است. مقاله اصلی RT-DETR-L صراحتاً Hybrid Encoder را برای پردازش سریع ویژگی‌های چندمقیاسی و جداسازی این دو نوع تعامل معرفی می‌کند. ۸۸

۲-۸-۵ تعامل درون‌مقیاسی ۸۹

در تعامل درون‌مقیاسی، هدف مدل یادگیری روابط موجود میان بخش‌های مختلف ویژگی در یک سطح مشخص است. این قابلیت به Transformer اجازه می‌دهد وابستگی‌هایی را که ممکن است در یک پنجره محلی یا در یک عملیات کانولوشنی ساده به‌راحتی قابل مدل‌سازی نباشند، مورد توجه قرار دهد. ۸۹

این ویژگی می‌تواند در محیط‌های دریایی مفید باشد؛ زیرا ظاهر یک پسماند ممکن است تنها از اطلاعات محلی قابل تشخیص نباشد. برای نمونه، تشخیص یک جسم ممکن است به رابطه آن با بخش‌های اطراف، ساختار پس‌زمینه و الگوی کلی تصویر وابسته باشد. ۸۹

با این حال، Self-Attention در وضوح‌های بالا هزینه محاسباتی قابل توجهی دارد. ازاین‌رو، RT-DETR-L از یک طراحی انتخابی برای استفاده مؤثرتر از Transformer بهره می‌گیرد و تلاش می‌کند پردازش پرهزینه را به بخش‌هایی محدود کند که بیشترین ارزش را برای نمایش معنایی دارند. ۸۹

۲-۸-۶ ادغام بین‌مقیاسی ۸۹

ویژگی‌های حاصل از سطوح مختلف Backbone باید در نهایت با یکدیگر ترکیب شوند. این فرایند در RT-DETR-L به‌گونه‌ای طراحی شده است که اطلاعات مکانی و معنایی سطوح مختلف در اختیار Decoder قرار گیرد.۸۹

می‌توان این فرایند را به‌صورت زیر نمایش داد: ۸۹

$F_1, F_2, F_3 \rightarrow$ Cross-scale Fusion $\rightarrow$ F_encoded ۸۹

در این رابطه، F1,F2,F3F_1,F_2,F_3 نمایش‌های ویژگی در مقیاس‌های مختلف هستند. ۸۹

ادغام بین‌مقیاسی به مدل اجازه می‌دهد ویژگی‌های کم‌وضوح اما معنایی را با ویژگی‌های دارای وضوح مکانی بیشتر ترکیب کند. این موضوع برای تشخیص اشیای کوچک اهمیت زیادی دارد. ۸۹

در داده‌های پسماند دریایی، چنین قابلیتی می‌تواند برای شناسایی اشیایی که از نظر اندازه کوچک هستند اما در زمینه پیچیده‌ای قرار گرفته‌اند مفید باشد. ۸۹

۲-۸-۷ Object Query و انتخاب Query ۸۹

یکی از تفاوت‌های بنیادی RT-DETR-L با آشکارسازهای CNN متداول، استفاده از **Object Query** است. Query را می‌توان به‌عنوان یک نمایش آموختنی یا استخراج‌شده در نظر گرفت که وظیفه آن تمرکز بر یک شیء بالقوه در تصویر و تولید پیش‌بینی متناظر است. ۸۹

در DETRهای اولیه، Queryها به‌صورت قابل‌آموزش وارد Decoder می‌شوند. RT-DETR-L از یک راهبرد **Query Selection** استفاده می‌کند تا Queryهای اولیه با کیفیت بالاتری انتخاب شوند. ۸۹

این مسئله از آن جهت اهمیت دارد که اگر Queryهای اولیه اطلاعات ضعیفی درباره مکان یا وجود اشیا داشته باشند، Decoder مجبور خواهد بود مراحل بیشتری را صرف اصلاح آن‌ها کند. ۹۰

RT-DETR-L از **Uncertainty-Minimal Query Selection** برای انتخاب Queryهای مناسب استفاده می‌کند. ایده اصلی این است که Queryهایی که اطلاعات مکانی و معنایی قابل اعتمادتری دارند، به‌عنوان ورودی اولیه Decoder انتخاب شوند (Zhao et al., 2024). ۹۰

به‌صورت مفهومی: ۹۰
۹۰ Encoder Features→Candidate Queries→Query Selection→High-quality Queries
این طراحی یکی از عناصر مهم در دستیابی RT-DETR-L به تعادل میان دقت و سرعت محسوب می‌شود. ۹۰
۸-۸-۲ Transformer Decoder ۹۰
پس از انتخاب Queryها، آن‌ها وارد Transformer Decoder می‌شوند. Decoder وظیفه دارد اطلاعات مربوط به هر Query را با ویژگی‌های تصویر ترکیب کرده و پیش‌بینی نهایی را تولید کند. ۹۰
در هر مرحله از Decoder،Query ها می‌توانند اطلاعات مربوط به کلاس و مکان شیء را اصلاح کنند. این فرایند را می‌توان به‌صورت یک روند تکرارشونده در نظر گرفت: ۹۰
$Q_0 \rightarrow Q_1 \rightarrow Q_2 \rightarrow \cdots \rightarrow Q_n$ ۹۰
که در آن Query Q0Q_0 اولیه و QnQ_n نمایش اصلاح‌شده پس از چند لایه Decoder است. ۹۰
هر Query در نهایت می‌تواند به یک پیش‌بینی شامل کلاس و جعبه محدودکننده متناظر شود. ۹۰
$Q_i \rightarrow (\hat{c}_i, \hat{b}_i)$ ۹۰
که c^i\hatc_i کلاس پیش‌بینی‌شده و b^i\hatb_i جعبه پیش‌بینی‌شده است. ۹۰
این ساختار یکی از تفاوت‌های بنیادی RT-DETR-L با YOLOv8n محسوب می‌شود. در YOLOv8n، پیش‌بینی‌ها مستقیماً از نگاشت‌های ویژگی چندمقیاسی تولید و سپس با NMS پالایش می‌شوند، در حالی که RT-DETR-L از Query و Decoder برای تولید مجموعه نهایی تشخیص‌ها استفاده می‌کند. ۹۰
۹-۸-۲ End-to-End Detection و حذف NMS ۹۰
یکی از مهم‌ترین ویژگی‌های RT-DETR-L، ماهیت **End-to-End** آن است. در آشکارسازهای متداول مانند YOLO، شبکه تعداد زیادی پیش‌بینی تولید می‌کند و پس از آن NMS برای حذف پیش‌بینی‌های تکراری اجرا می‌شود. ۹۰
در RT-DETR-L، معماری به‌گونه‌ای طراحی شده است که مجموعه‌ای محدود از Queryها مستقیماً برای تولید تشخیص‌ها مورد استفاده قرار گیرند. بنابراین، نیاز به NMS به‌عنوان مرحله استاندارد پس‌پردازش حذف می‌شود. ۹۱

فرایند دو رویکرد را می‌توان به شکل زیر مقایسه کرد: YOLOv8n:Multi-scale Features→Detection Head→Dense Predictions→NMS→Final Detections ۹۱

در مقابل Backbone/Hybrid Encoder→Multi-scale Features→Transformer Decoder + Object Queries→Final: Detections ۹۱

مطابق مقاله اصلی RT-DETR-L، یکی از انگیزه‌های اصلی طراحی آن، حذف اثر منفی NMS بر سرعت و دقت سامانه‌های بلادرنگ بوده است. ۹۱

این تفاوت برای پژوهش حاضر بسیار مهم است؛ زیرا هنگام مقایسه Latency و FPS، نباید صرفاً زمان عبور داده از شبکه عصبی در نظر گرفته شود. تعریف دقیق معیار سرعت باید مشخص کند که آیا زمان پیش‌پردازش و پس‌پردازش نیز در اندازه‌گیری لحاظ شده است یا خیر. ۹۱

۲-۸-۱۰ تطبیق Queryها با اشیای واقعی ۹۱

آموزش مدل‌های DETR-based به یک مسئله مهم دیگر نیز وابسته است: تعیین اینکه هر Query باید با کدام شیء واقعی متناظر شود. ۹۱

در این خانواده از مدل‌ها، مسئله Assignment معمولاً به‌صورت تطبیق مجموعه‌ای میان پیش‌بینی‌ها و Ground Truthها صورت‌بندی می‌شود. در نتیجه، برخلاف روش‌های متراکم که تعداد زیادی Anchor یا موقعیت مکانی را به‌صورت مستقل بررسی می‌کنند، هر Query در نهایت به یک پیش‌بینی مشخص مربوط می‌شود. ۹۱

این ساختار می‌تواند باعث کاهش پیش‌بینی‌های تکراری شود و در عین حال فرآیند تشخیص را به یک مسئله مجموعه‌ای نزدیک کند. ۹۱

در داده‌های دریایی، چنین رویکردی می‌تواند در صحنه‌های متراکم که چند شیء در مجاورت یکدیگر قرار دارند اهمیت داشته باشد. بااین‌حال، عملکرد نهایی همچنان به کیفیت Annotation و تفکیک دقیق اشیای نزدیک به یکدیگر وابسته است. ۹۱

۲-۸-۱۱ Auxiliary Loss و نظارت در طول Decoder ۹۱

در معماری‌های DETR-based، نظارت آموزشی می‌تواند در چند مرحله Decoder اعمال شود تا شبکه علاوه بر خروجی نهایی، در مراحل میانی نیز بازخورد دریافت کند. این سازوکار به مدل کمک می‌کند فرآیند اصلاح Queryها را به‌صورت تدریجی یاد بگیرد. ۹۱

به‌صورت مفهومی: ۹۲

$\cdots \rightarrow Q_0 \rightarrow D_1 \rightarrow D_2 \rightarrow D_3$ ۹۲

و در هر مرحله می‌توان پیش‌بینی‌هایی تولید کرد که برای ایجاد سیگنال آموزشی مورد استفاده قرار گیرند. ..۹۲

این نوع نظارت مرحله‌ای می‌تواند به بهبود فرایند یادگیری و تسهیل همگرایی مدل کمک کند؛ هرچند مقدار و نحوه استفاده از Lossهای کمکی به پیاده‌سازی و پیکربندی دقیق مدل وابسته است. ۹۲

بنابراین، در توصیف علمی RT-DETR-L باید میان **ساختار معماری اصلی** و **تنظیمات آموزشی یک پیاده‌سازی خاص** تمایز قائل شد. این تفکیک در پژوهش حاضر اهمیت دارد، زیرا هدف مقایسه معماری‌هاست و جزئیات تنظیمات آموزش باید به‌صورت شفاف در فصل سوم گزارش شوند. ۹۲

۲-۸-۱۲ مقیاس‌پذیری RT-DETR-L ۹۲

RT-DETR-L در چند اندازه معماری ارائه شده است و امکان استفاده از Backboneها و پیکربندی‌های مختلف را فراهم می‌کند. این ویژگی اجازه می‌دهد مدل متناسب با محدودیت‌های سخت‌افزاری و نیازهای کاربردی انتخاب شود. ۹۲

در پژوهش اصلی، نسخه‌های مختلف RT-DETR-L از جمله مدل‌های مبتنی بر R18، R50، R101 و نسخه‌های مقیاس‌پذیرتر بررسی شده‌اند. همچنین، نویسندگان نشان داده‌اند که تعداد لایه‌های Decoder را می‌توان برای تنظیم سرعت و دقت تغییر داد، بدون آنکه نیاز به آموزش مجدد کل مدل وجود داشته باشد (Zhao et al., 2024). ۹۲

این ویژگی برای سامانه‌هایی با منابع محاسباتی محدود اهمیت دارد؛ زیرا امکان ایجاد تعادل میان دقت و سرعت را فراهم می‌کند. ۹۲

در پژوهش حاضر نیز انتخاب نسخه مشخص RT-DETR-L باید بر اساس محدودیت حافظه GPU، هزینه محاسباتی و ضرورت مقایسه منصفانه انجام شود. بااین‌حال، انتخاب یک نسخه سبک‌تر نباید با کاهش اندازه تصویر ورودی جبران شود؛ زیرا اندازه ورودی یکی از عوامل مؤثر بر عملکرد تشخیص اشیای کوچک است و تغییر آن می‌تواند قابلیت مقایسه میان مدل‌ها را تحت تأثیر قرار دهد. ۹۲

۲-۸-۱۳ RT-DETRv2 و توسعه معماری ۹۲

پس از معرفی RT-DETR-L، نسخه بهبودیافته‌ای با عنوان **RT-DETRv2** ارائه شد. این نسخه با هدف افزایش انعطاف‌پذیری و عملکرد RT-DETR-L، تغییراتی در استخراج ویژگی چندمقیاسی، روش نمونه‌برداری و راهبرد آموزش ایجاد کرد. ۹۲

یکی از تغییرات مهم RT-DETRv2 استفاده از تعداد متفاوت نقاط نمونه‌برداری در مقیاس‌های مختلف Deformable Attention است. همچنین یک اپراتور نمونه‌برداری گسسته به‌صورت اختیاری معرفی شده است تا برخی محدودیت‌های مربوط به استقرار عملیاتی کاهش یابد. علاوه بر این، راهبردهای آموزشی مانند Dynamic Data Augmentation و Scale-Adaptive Hyperparameters نیز مورد استفاده قرار گرفته‌اند. ۹۳

با وجود این توسعه‌ها، در پژوهش حاضر باید دقیقاً مشخص شود که کدام نسل و کدام پیاده‌سازی از RT-DETR-L مورد استفاده قرار گرفته است. زیرا RT-DETR-L و RT-DETRv2 را نمی‌توان صرفاً با یک نام عمومی در گزارش نتایج جایگزین یکدیگر کرد. ۹۳

این موضوع به‌خصوص در مقایسه علمی اهمیت دارد؛ زیرا تفاوت در معماری، وزن‌های پیش‌آموزش‌دیده یا راهبرد آموزش می‌تواند بر عملکرد نهایی اثر بگذارد. ۹۳

۲-۸-۱۴ مزایا و محدودیت‌های RT-DETR-L در تشخیص پسماند دریایی ۹۳

RT-DETR-L چند ویژگی دارد که آن را برای مسئله تشخیص پسماند دریایی به گزینه‌ای مهم تبدیل می‌کند. نخست، استفاده از Transformer امکان مدل‌سازی روابط گسترده میان بخش‌های مختلف تصویر را فراهم می‌کند. این قابلیت می‌تواند در محیط‌هایی با پس‌زمینه پیچیده مفید باشد. دوم، ماهیت End-to-End مدل موجب حذف وابستگی به NMS می‌شود. سوم، استفاده از ویژگی‌های چندمقیاسی امکان پردازش اشیای دارای اندازه‌های متفاوت را فراهم می‌کند. چهارم، طراحی Query-based می‌تواند به کاهش پیش‌بینی‌های تکراری کمک کند. ۹۳

بااین‌حال، RT-DETR-L محدودیت‌هایی نیز دارد. معماری Transformer معمولاً نسبت به برخی آشکارسازهای CNN به منابع محاسباتی بیشتری نیاز دارد، به‌خصوص زمانی که ویژگی‌های با وضوح بالا پردازش می‌شوند. علاوه بر این، آموزش مدل‌های DETR-based ممکن است نسبت به برخی آشکارسازهای سنتی حساسیت بیشتری به طراحی Training Pipeline داشته باشد. ۹۳

در مسئله پسماند دریایی، این محدودیت‌ها زمانی اهمیت بیشتری پیدا می‌کنند که تصاویر شامل اشیای کوچک، کنتراست پایین یا تعداد زیادی شیء نزدیک به یکدیگر باشند. در چنین شرایطی، توانایی معماری در حفظ اطلاعات مکانی و انتخاب Queryهای مناسب نقش مهمی در عملکرد نهایی دارد. ۹۳

از سوی دیگر، RT-DETR-L می‌تواند در صحنه‌هایی که روابط زمینه‌ای و ساختار کلی تصویر اهمیت دارند، مزیت بالقوه‌ای داشته باشد. بنابراین، ارزیابی تجربی آن در کنار مدل‌های CNN می‌تواند اطلاعات ارزشمندی درباره مناسب‌ترین نوع معماری برای این حوزه فراهم کند. ۹۳

۲-۸-۱۵ جایگاه RT-DETR-L در پژوهش حاضر ۹۴

در پژوهش حاضر، RT-DETR-L به‌عنوان نماینده رویکردهای Transformer-based در مقایسه با دو معماری CNN-based مورد استفاده قرار می‌گیرد. هدف از این انتخاب، بررسی این پرسش است که آیا استفاده از معماری Transformer می‌تواند در تشخیص پسماند دریایی نسبت به آشکارسازهای CNN مزیت قابل اندازه‌گیری ایجاد کند یا خیر. ۹۴

چارچوب مفهومی مقایسه به شکل زیر تعریف می‌شود -YOLOv8CNN-basedRT-DETR LTransformer-basedRTMDet-TinyCNN-based:.....۹۴

در این مقایسه، هدف صرفاً تعیین بالاترین mAP نیست. عملکرد هر مدل از منظر مجموعه‌ای از شاخص‌ها شامل Precision،Recall، mAP@0.50، mAP@0.50:0.95 ، سرعت استنتاج، Latency و پایداری در شرایط تغییریافته مورد بررسی قرار می‌گیرد. ۹۴

به‌ویژه، حذف NMS در RT-DETR-L باید هنگام تفسیر معیارهای سرعت مورد توجه قرار گیرد. اگر FPS سه مدل مقایسه شود، باید مشخص شود که معیار گزارش‌شده مربوط به زمان کل Inference Pipeline است یا فقط زمان Forward Pass شبکه. در غیر این صورت، مقایسه سرعت ممکن است به نفع یا ضرر یک معماری خاص سوگیری پیدا کند. ۹۴

از طرف دیگر، برای حفظ اعتبار مقایسه، تغییر اندازه تصویر، تفاوت در داده آموزشی، تغییر Taxonomy یا استفاده از مجموعه آزمون متفاوت نباید به‌عنوان بخشی از تفاوت معماری تلقی شود. بنابراین، RT-DETR-L در این پژوهش در همان چارچوب داده‌ای و ارزیابی مورد استفاده برای YOLOv8n و RTMDet-Tiny قرار می‌گیرد.....۹۴

۲-۸-۱۶ مقایسه مفهومی YOLOv8n و RT-DETR-L ۹۴

تفاوت اصلی دو معماری را می‌توان در سطح جریان پردازش خلاصه کرد:.....۹۴

ویژگی ۹۴

YOLOv8n.....۹۴

RT-DETR-L.....۹۴

خانواده معماری ۹۴

CNN-based.....۹۴

Transformer-based ۹۴
نوع آشکارساز ۹۴
One-stage ۹۴
End-to-End ۹۴
تولید پیش‌بینی ۹۴
Dense prediction ۹۴
Query-based prediction ۹۴
Anchor ۹۴
Anchor-Free ۹۴
Query-based ۹۴
NMS ۹۵
مورد استفاده ۹۵
حذف شده در طراحی End-to-End ۹۵
پردازش ویژگی ۹۵
Backbone + Neck ۹۵
Backbone + Hybrid Encoder ۹۵
سازوکار اصلی تشخیص ۹۵
Detection Head ۹۵
Transformer Decoder ۹۵
ویژگی چندمقیاسی ۹۵
FPN–PAN ۹۵
Multi-scale features + Hybrid Encoder ۹۵

اصلاح پیش‌بینی ۹۵
Head-based prediction ۹۵
Decoder-based refinement ۹۵
هدف طراحی ۹۵
تعادل سرعت و دقت ۹۵
دقت و سرعت End-to-End ۹۵

این جدول نشان می‌دهد که تفاوت YOLOv8n و RT-DETR-L صرفاً در نام مدل یا نوع Backbone خلاصه نمی‌شود، بلکه این دو مدل از دو منطق متفاوت برای تولید تشخیص استفاده می‌کنند. ۹۵

در YOLOv8n، پیش‌بینی‌ها از نگاشت‌های ویژگی چندمقیاسی استخراج شده و سپس با یک مرحله پس‌پردازشی پالایش می‌شوند؛ در RT-DETR-L، مجموعه Queryها در Decoder پردازش شده و تشخیص‌ها به‌صورت مستقیم‌تر تولید می‌شوند. ۹۵

از این منظر، مقایسه این دو معماری می‌تواند برای بررسی اثر نوع معماری بر عملکرد تشخیص پسماند دریایی ارزشمند باشد. ۹۵

۲-۸-۱۷ جمع‌بندی ۹۵

RT-DETR-L یک آشکارساز شیء مبتنی بر Transformer است که با هدف ایجاد یک چارچوب End-to-End و در عین حال مناسب برای کاربردهای بلادرنگ توسعه یافته است. این معماری با استفاده از Hybrid Encoder، پردازش کارآمد ویژگی‌های چندمقیاسی را دنبال می‌کند و با استفاده از Query Selection و Transformer Decoder، پیش‌بینی اشیا را بدون نیاز به NMS انجام می‌دهد. ۹۵

مهم‌ترین تمایز RT-DETR-L نسبت به آشکارسازهای CNN مانند YOLOv8n در نحوه تولید و پالایش پیش‌بینی‌هاست. YOLOv8n بر استخراج و ادغام ویژگی‌های کانولوشنی و تولید متراکم پیش‌بینی‌ها تکیه دارد، در حالی که RT-DETR-L مسئله تشخیص را در قالب پیش‌بینی مجموعه‌ای مبتنی بر Query صورت‌بندی می‌کند. ۹۵

از منظر تشخیص پسماند دریایی، RT-DETR-L ظرفیت بالقوه‌ای برای مدل‌سازی روابط گسترده تصویری و کاهش پیش‌بینی‌های تکراری دارد؛ اما در مقابل، هزینه محاسباتی و حساسیت آن به طراحی مناسب Pipeline آموزشی می‌تواند از عوامل محدودکننده باشد. ۹۵

در نتیجه، قرار دادن RT-DETR-L در کنار YOLOv8n و RTMDet-Tiny امکان بررسی تجربی این مسئله را فراهم می‌کند که آیا تفاوت بنیادین میان معماری‌های CNN و Transformer در شرایط یکسان داده‌ای، به تفاوت معناداری در دقت، سرعت و پایداری تشخیص پسماندهای دریایی منجر می‌شود یا خیر. ۹۶

در این چارچوب، جزئیات نسخه دقیق مدل، وزن‌های پیش‌آموزش‌دیده، اندازه ورودی، تنظیمات آموزش، Batch Size، تعداد دوره‌های آموزش و سایر پارامترهای اجرایی در فصل سوم گزارش خواهند شد تا بخش نظری حاضر از جزئیات روش‌شناختی تفکیک شود. ۹۶

۲-۹ معماری RTMDet-Tiny ۹۶

۲-۹-۱ جایگاه RTMDet-Tiny در آشکارسازهای بلادرنگ ۹۶

۲-۹-۲ فلسفه طراحی و معماری کلی RTMDet-Tiny ۹۷

۲-۹-۳ Backbone مبتنی بر CSPNeXt ۹۷

۲-۹-۴ Neck مبتنی بر CSPNeXtPAFPN ۹۸

۲-۹-۵ Detection Head و ساختار تفکیک‌شده ۹۸

۲-۹-۶ Dynamic Soft Label Assigner ۹۹

۲-۹-۷ توابع زیان در RTMDet-Tiny ۱۰۰

۲-۹-۸ راهبردهای بهینه‌سازی و Bag-of-Freebies ۱۰۰

۲-۹-۹ مزایا و محدودیت‌های RTMDet-Tiny در تشخیص پسماند دریایی ۱۰۱

۲-۹-۱۰ جایگاه RTMDet-Tiny در پژوهش حاضر ۱۰۱

۲-۹-۱۱ مقایسه مفهومی RT-DETR-L،YOLOv8n و RTMDet-Tiny ۱۰۲

۲-۹-۱۲ جمع‌بندی ۱۰۳

۲-۱۰ معیارهای ارزیابی عملکرد آشکارسازهای شیء ۱۰۳

۲-۱۰-۱ ماتریس درهم‌ریختگی و مفاهیم TP، FP و FN ۱۰۴

۲-۱۰-۲ معیار Precision ۱۰۵

۲-۱۰-۳ معیار Recall ۱۰۶

۲-۱۰-۴ معیار Intersection over Union (IoU) ۱۰۶
۲-۱۰-۵ منحنی Precision–Recall ۱۰۷
۲-۱۰-۶ معیار Average Precision (AP) ۱۰۸
۲-۱۰-۷ معیار mAP@0.50 ..... ۱۰۹
۲-۱۰-۸ معیار mAP@0.50:0.95 ..... ۱۰۹
۲-۱۰-۹ مقایسه mAP@0.50 و mAP@0.50:0.95 ..... ۱۱۰
۲-۱۰-۱۰ ارزیابی عملکرد در سطح کلاس ۱۱۱
۲-۱۰-۱۱ معیارهای سرعت: FPS ۱۱۲
۲-۱۰-۱۲ معیار Latency ۱۱۳
۲-۱۰-۱۳ اهمیت یکسان‌سازی شرایط اندازه‌گیری سرعت ۱۱۳
۲-۱۰-۱۴ مفهوم Robustness در آشکارسازهای شیء ۱۱۴
۲-۱۰-۱۵ مفهوم Domain Shift ۱۱۵
۲-۱۰-۱۶ تفاوت Robustness، Domain Shift و Domain Generalization ۱۱۶
۲-۱۰-۱۷ ارزیابی افت عملکرد تحت شرایط تغییریافته ۱۱۷
۲-۱۰-۱۸ شاخص حفظ عملکرد ۱۱۸
۲-۱۰-۱۹ مقایسه منصفانه مدل‌ها با استفاده از چند معیار ۱۱۸
۲-۱۰-۲۰ مسئله Trade-off میان دقت و سرعت ۱۱۹
۲-۱۰-۲۱ اهمیت mAP به‌عنوان معیار اصلی دقت ۱۲۰
۲-۱۰-۲۲ اهمیت تحلیل اختلاف mAP@0.50 و mAP@0.50:0.95 ..... ۱۲۰
۲-۱۰-۲۳ ارتباط معیارها با انواع خطا ۱۲۱
۲-۱۰-۲۴ ارزیابی Robustness در چارچوب پژوهش حاضر ۱۲۱
۲-۱۰-۲۵ ارزیابی چندمعیاره به‌عنوان چارچوب نهایی ۱۲۲

۲-۱۰-۲۶ معیارهای اصلی مورد استفاده در پژوهش حاضر ۱۲۲
۲-۱۰-۲۷ ملاحظات مربوط به مقایسه منصفانه مدل‌ها ۱۲۳
۲-۱۰-۲۸ جمع‌بندی معیارهای ارزیابی ۱۲۴
۲-۱۱ مطالعات و پژوهش‌های پیشین در تشخیص پسماند دریایی ۱۲۵
۲-۱۱-۱ مطالعات اولیه مبتنی بر یادگیری عمیق و تشخیص پسماند دریایی ۱۲۵
۲-۱۱-۲ شکل‌گیری داده‌مجموعه TrashCan ۱۲۶
۲-۱۱-۳ مطالعات مبتنی بر آشکارسازهای تک‌مرحله‌ای ۱۲۷
۲-۱۱-۴ مطالعات مبتنی بر YOLOv5 و معماری‌های اصلاح‌شده ۱۲۸
۲-۱۱-۵ مطالعات مبتنی بر EfficientDet و توجه به کارایی محاسباتی ۱۲۹
۲-۱۱-۶ مطالعات مبتنی بر YOLOv8n ۱۳۰
۲-۱۱-۷ مطالعات مربوط به YOLOv8n-Seg و تفکیک نمونه‌ای ۱۳۱
۲-۱۱-۸ مطالعات مبتنی بر MLDet و آشکارسازهای اختصاصی پسماند ۱۳۱
۲-۱۱-۹ مطالعات جدید مبتنی بر معماری‌های Transformer ۱۳۲
۲-۱۱-۱۰ جایگاه RTMDet-Tiny در مطالعات تشخیص بلادرنگ ۱۳۳
۲-۱۱-۱۱ مطالعات مربوط به داده‌های TrashCan و مسئله تنوع داده ۱۳۴
۲-۱۱-۱۲ مطالعات مربوط به ادغام داده‌های چندمنبعی ۱۳۴
۲-۱۱-۱۳ مسئله هماهنگ‌سازی Taxonomy در مطالعات پیشین ۱۳۵
۲-۱۱-۱۴ محدودیت‌های مشترک مطالعات پیشین ۱۳۶
۲-۱۱-۱۵ مقایسه انتقادی مطالعات پیشین ۱۳۷
۲-۱۱-۱۶ تحلیل شکاف اول: نبود مقایسه کنترل‌شده بین خانواده‌های معماری ۱۳۸
۲-۱۱-۱۷ تحلیل شکاف دوم: نبود یک داده‌مجموعه یکپارچه با Taxonomy مشترک ۱۳۹
۲-۱۱-۱۸ تحلیل شکاف سوم: تفاوت میان عملکرد پایه و Robustness ۱۴۰

۲-۱۱-۱۹ تحلیل شکاف چهارم: عدم توجه کافی به هم‌زمانی Accuracy و Efficiency ۱۴۰
۲-۱۱-۲۰ تحلیل شکاف پنجم: ضرورت کنترل متغیرهای آزمایش ۱۴۱
۲-۱۱-۲۱ جایگاه پژوهش حاضر در ادبیات ۱۴۲
۲-۱۱-۲۲ تفاوت پژوهش حاضر با مطالعات بهبوددهنده مدل ۱۴۲
۲-۱۱-۲۳ جدول نهایی شکاف پژوهشی ۱۴۳
۲-۱۱-۲۴ جمع‌بندی مطالعات پیشین ۱۴۴
2-12 جمع‌بندی فصل دوم و استخراج چارچوب نظری پژوهش ۱۴۵
2-12-1 جمع‌بندی مبانی داده و یکپارچه‌سازی اطلاعات ۱۴۶
2-12-2 جمع‌بندی مبانی معماری آشکارسازها ۱۴۷
2-12-3 جمع‌بندی معیارهای ارزیابی ۱۴۸
2-12-4 جمع‌بندی مفهوم Robustness و Domain Shift ۱۴۹
2-12-5 استخراج چارچوب نظری پژوهش ۱۵۱
2-12-6 منطق مقایسه منصفانه مدل‌ها ۱۵۲
2-12-7 رابطه میان Efficiency، Localization،Accuracy و Robustness ۱۵۳
2-12-8 مدل مفهومی نهایی پژوهش ۱۵۴
2-12-9 ارتباط چارچوب نظری با شکاف پژوهشی ۱۵۴
2-12-10 جمع‌بندی نهایی فصل دوم ۱۵۵
2-13 تغییر دامنه ۱۵۶
2-13-1 مفهوم Domain Shift ۱۵۶
2-13-2 Domain Adaptation ۱۵۷
2-13-3 Domain Generalization ۱۵۷
2-14 رابطه Robustness و Domain Shift ۱۵۸

2-15 سازگارسازی محدود دامنه ۱۵۸
2-16 کارایی محاسباتی و کاربردهای نزدیک به بلادرنگ ۱۵۹
2-17 پیشینه پژوهش ۱۵۹
2-17-1 پژوهش‌های مرتبط با مجموعه‌داده‌های پسماند دریایی ۱۵۹
2-17-2 پژوهش‌های مرتبط با تشخیص شیء زیرآبی ۱۶۰
2-17-3 پژوهش‌های مرتبط با Transformer در تشخیص شیء ۱۶۰
2-17-4 پژوهش‌های مرتبط با آشکارسازهای بلادرنگ ۱۶۱
2-17-5 پژوهش‌های مرتبط با مقاومت مدل‌ها ۱۶۱
2-17-6 پژوهش‌های مرتبط با انتقال بین‌دامنه‌ای ۱۶۱
2-18 جمع‌بندی پیشینه و خلأ پژوهشی ۱۶۲
2-19 جایگاه پژوهش حاضر در میان مطالعات پیشین ۱۶۳
2-20 جمع‌بندی فصل ۱۶۴
منابع فصل دوم ۱۶۴
3-1 مقدمه ۱۶۷
3-2 طرح کلی پژوهش ۱۶۷
3-3 مجموعه‌داده پژوهش ۱۶۸
3-3-1 نسخه نهایی داده ۱۶۸
3-3-2 کنترل نسخه‌های داده و annotation ۱۶۸
3-3-3 کنترل بصری و ممیزی داده ۱۶۹
3-4 فضای طبقه‌بندی ۱۶۹
3-4-1 کلاس‌های نهایی ۱۶۹
3-4-2 گروه‌بندی تحلیلی کلاس‌ها ۱۷۱

3-5 آماده‌سازی و کنترل کیفیت داده ۱۷۱
3-5-1 استقلال splitها و جلوگیری از leakage ۱۷۲
3-6 طراحی مقایسه کنترل‌شده ۱۷۲
3-7 اندازه ورودی و preprocessing ۱۷۲
3-8 ساختار معماری YOLOv8n ۱۷۳
3-8-1 نمای کلی ۱۷۳
3-8-2 Backbone ۱۷۳
3-8-3 Neck ۱۷۳
3-8-4 Detection Head ۱۷۳
3-8-5 جریان کلی پردازش ۱۷۴
3-9 تنظیمات YOLOv8n ۱۷۴
3-9-1 افزایش داده YOLOv8n ۱۷۵
3-10 ساختار معماری RT-DETR-L ۱۷۵
3-10-1 جایگاه معماری ۱۷۵
3-10-2 Backbone و hybrid encoder ۱۷۵
3-10-3 Query selection ۱۷۶
3-10-4 Transformer decoder و خروجی ۱۷۶
3-11 تنظیمات RT-DETR-L ۱۷۶
3-11-1 AMP و حافظه ۱۷۷
3-11-2 Resume ۱۷۷
3-12 ساختار معماری RTMDet-Tiny ۱۷۷
3-12-1 نمای کلی ۱۷۷

3-12-2 Backbone: CSPNeXt ۱۷۸
3-12-3 Neck: CSPNeXtPAFPN ۱۷۸
3-12-4 Detection Head ۱۷۸
3-13 تنظیمات RTMDet-Tiny ۱۷۸
3-13-1 تجمع گرادیان ۱۷۹
3-13-2 Scheduler ۱۷۹
3-13-3 افزایش داده و inference ۱۷۹
3-14 جدول مقایسه معماری و تنظیمات اصلی ۱۷۹
3-15 انتخاب بهترین checkpoint ۱۸۰
3-16 معیارهای ارزیابی ۱۸۱
3-16-1 Precision و Recall ۱۸۱
3-16-2 IoU ۱۸۱
3-16-3 AP و mAP ۱۸۱
3-16-4 mAP@0.50 و mAP@0.50:0.95 ..... ۱۸۲
3-17 روش آزمون فرضیه‌های پژوهش ۱۸۲
3-17-1 آزمون فرضیه اول (H1): مقایسه عملکرد پایه ۱۸۲
3-17-2 آزمون فرضیه دوم (H2): ارزیابی پایداری در برابر اغتشاشات کنترل‌شده ۱۸۳
3-17-3 آزمون فرضیه سوم (H3): ارزیابی تغییر دامنه ۱۸۳
3-17-4 قاعده انتخاب مدل برای مرحله H4 ..... ۱۸۳
3-17-5 آزمون فرضیه چهارم (H4): سازگارسازی محدود دامنه ۱۸۴
3-17-6 روش تحلیل آماری و تصمیم‌گیری درباره فرضیه‌ها ۱۸۴
3-18 تحلیل عملکرد کلاس‌به‌کلاس ۱۸۴

3-19 ارزیابی robustness ۱۸۴
3-20 ارزیابی تغییر دامنه ۱۸۵
3-21 سازگارسازی محدود دامنه ۱۸۵
3-22 انتخاب مدل برای adaptation ۱۸۶
3-23 کارایی محاسباتی ۱۸۶
3-24 محیط سخت‌افزاری ۱۸۶
3-25 محیط نرم‌افزاری Ultralytics ۱۸۶
3-26 محیط نرم‌افزاری MMDetection ۱۸۷
3-27 کنترل بازتولیدپذیری ۱۸۷
3-28 کنترل تصادفی‌بودن ۱۸۷
3-29 استقلال مجموعه آزمون ۱۸۸
3-30 پروتکل ارزیابی نهایی ۱۸۸
3-31 تحلیل آماری و محدودیت روش‌شناسی ۱۸۸
3-32 جدول خلاصه پروتکل تجربی ۱۸۸
3-33 جمع‌بندی فصل ۱۸۹
یافته‌ها، تحلیل نتایج و آزمون فرضیه‌ها ۱۹۰
4-1مقدمه ۱۹۰
4-2کنترل و ساختار داده‌های مورد استفاده در تحلیل ۱۹۰
4-3نتایج فرضیه اول: مقایسه عملکرد پایه مدل‌ها(H1) ۱۹۱
4-3-1هدف H1 ..... ۱۹۱
4-3-2آمار توصیفی عملکرد مدل‌ها ۱۹۱
4-3-3آزمون فریدمن ۱۹۲

4-3-4مقایسه‌های زوجی ۱۹۳
4-3-5 Precisionو Recall کلی ۱۹۳
4-3-6جمع‌بندیH1 ..... ۱۹۴
4-4نتایج فرضیه دوم: مقاومت در برابر تخریب‌های تصویری(H2) ۱۹۴
4-4-1هدفH2 ..... ۱۹۴
4-4-2تفسیر نتایجH2 ..... ۱۹۵
4-4-3جمع‌بندیH2 ..... ۱۹۶
4-5نتایج فرضیه سوم: جابه‌جایی دامنه و تغییر شرایط تصویری(H3) ۱۹۶
4-5-1شرایط ارزیابیH3 ..... ۱۹۶
4-5-2نتیجه کلیH3 ..... ۱۹۶
4-5-3تحلیل شرط‌به‌شرط ۱۹۷
4-5-4تفسیر علمیH3 ..... ۱۹۸
4-5-5جمع‌بندیH3 ..... ۱۹۸
4-6انتخاب مدل برای مرحله سازگارسازی ۱۹۹
4-7نتایج فرضیه چهارم: سازگارسازی دامنه کنترل‌شده(H4) ۲۰۰
4-7-1طراحی آزمایشH4 ..... ۲۰۰
4-7-2مقایسه پیش و پس از سازگارسازی ۲۰۱
4-7-3آزمون آماریH4 ..... ۲۰۳
4-7-4روند آموزشadaptation ۲۰۳
4-7-5تفسیر نتیجهH4 ..... ۲۰۴
4-8مقایسه نهایی نتایج H1 تاH4 ..... ۲۰۴
4-9وضعیت فرضیه‌های پژوهش ۲۰۵

4-10بحث نتایج ۲۰۶
4-11ملاحظات مربوط به تفسیر و اعتبار نتایج..... ۲۰۶
4-12کارایی محاسباتی و محدودیتbenchmark ۲۰۷
4-13جمع‌بندی فصل..... ۲۰۷
منابع فنی مورد استفاده در تدوین بخش معماری..... ۲۰۷
نتیجه‌گیری، محدودیت‌ها و پیشنهادهای پژوهش ۲۰۹
5-1مقدمه ۲۰۹
5-2جمع‌بندی روند اجرای پژوهش ۲۰۹
5-3نتیجه‌گیری نهایی بر اساس فرضیه اول..... ۲۱۰
5-3-1مقایسه عملکرد پایه مدل‌ها..... ۲۱۰
5-4نتیجه‌گیری نهایی بر اساس فرضیه دوم ۲۱۲
5-4-1ارزیابی استحکام در برابر خرابی‌های مصنوعی..... ۲۱۲
5-5نتیجه‌گیری نهایی بر اساس فرضیه سوم..... ۲۱۳
5-5-1ارزیابی پایداری در برابر تغییر دامنه و شرایط تصویربرداری ۲۱۳
5-6جمع‌بندی انتخاب مدل برای سازگارسازی دامنه..... ۲۱۳
5-7نتیجه‌گیری نهایی بر اساس فرضیه چهارم ۲۱۴
5-7-1اجرای سازگارسازی کنترل‌شده..... ۲۱۴
5-7-2نتایج پیش و پس از سازگارسازی ۲۱۴
5-7-3تفسیر نتیجه منفی سازگارسازی ۲۱۵
5-8پاسخ نهایی به پرسش‌های اصلی پژوهش ۲۱۶
5-9جمع‌بندی علمی یافته‌های پژوهش ۲۱۶
5-10محدودیت‌های پژوهش..... ۲۱۷

5-11پیشنهادهای پژوهشی برای تحقیقات آینده ۲۱۹
5-12پیشنهادهای کاربردی ۲۲۰
5-13ملاحظات مربوط به اعتبار نتایج ۲۲۱
5-14جمع‌بندی نهایی فصل ۲۲۱
5-15نتیجه نهایی ۲۲۱

فهرست جداول

جدول 2-1. ساختار نهایی ۱۳ کلاس مورد استفاده در پژوهش ۶۶

جدول 2-2. مقایسه مفهومی ویژگی‌های YOLOv8n و RT-DETR-L ۹۴

جدول 2-3. مقایسه معماری و ویژگی‌های YOLOv8n ، RT-DETR-L و
RTMDet-Tiny ۱۰۲

جدول 2-4. مقایسه معیارهای mAP@0.50 و mAP@0.50:0.95 ..... ۱۱۰

جدول 2-5. معیارهای اصلی ارزیابی و هدف از به‌کارگیری آن‌ها ۱۲۳

جدول ۲-۶. خلاصه‌ای از مسیر اصلی مطالعات ۱۳۷

جدول ۲-۷. جمع‌بندی شکاف‌های پژوهشی و رویکرد پژوهش حاضر ۱۴۳

جدول 3-1. ساختار مجموعه‌داده و کارکرد اجزای آن ۱۶۸

جدول 3-2. شناسه و کلاس‌های نهایی ۱۶۹

جدول 3-3. قواعد طراحی مقایسه کنترل‌شده ۱۷۲

جدول 3-4. تنظیمات اصلی آموزش YOLOv8n ۱۷۴

جدول 3-5. تنظیمات افزایش داده YOLOv8n ۱۷۵

جدول 3-6. تنظیمات اصلی آموزش RT-DETR-L ۱۷۶

جدول 3-7. تنظیمات اصلی آموزش RTMDet-Tiny ۱۷۸

جدول 3-8. مقایسه معماری و تنظیمات اصلی سه مدل ۱۷۹

جدول 3-9. نسخه‌های محیط نرم‌افزاری Ultralytics و PyTorch ۱۸۶

جدول 3-10. نسخه‌های محیط نرم‌افزاری MMDetection وMMEngine ۱۸۷

جدول 3-11. خلاصه پروتکل و تصمیم‌های روش‌شناختی پژوهش ۱۸۸

جدول ۴-۱. Precision، Recall و mAP مدل‌ها در ارزیابی H1 ..... ۱۹۱

جدول ۴-۲. آمار توصیفی F1 در شرایط پایه ۱۹۲

جدول ۴-۳. مقایسه‌های زوجی H1 ..... ۱۹۳

جدول ۴-۴. Precision، Recall و F1 کلی در H1 ..... ۱۹۳

جدول ۴-۵. میانگین Degradation در H2 ..... ۱۹۵

جدول ۴-۶. نتیجه کلی H3 ..... ۱۹۶

جدول ۴-۷. مدل برتر در هر شرط H3 ..... ۱۹۷

جدول ۴-۸. رتبه‌بندی تجمیعی مدل‌ها در مراحل H1 تا H3 ..... ۱۹۹

جدول ۴-۹. پیکربندی adaptation در H4 ..... ۲۰۰

جدول ۴-۱۰. مقایسه عملکرد YOLOv8n پیش و پس از سازگارسازی ۲۰۱

جدول ۴-۱۱. نقاط کلیدی لاگ validation در H4 ..... ۲۰۴

جدول ۴-۱۲. جمع‌بندی عملکرد مدل‌ها در چهار مرحله پژوهش ۲۰۴

جدول ۴-۱۳. وضعیت نهایی فرضیه‌های پژوهش ۲۰۵

فهرست نمودارها

نمودار 4-1. مقایسه میانگین F1 مدل‌ها در شرایط پایه(H1) ۱۹۲

نمودار 4-2. مقایسهMicro Precision ، Micro Recall و Micro F1 مدل‌ها درH1 ..... ۱۹۴

نمودار 4-3. مقایسه میانگین Degradation مدل‌ها درH2 ..... ۱۹۵

نمودار 4-4. مقایسه میانگین Degradation مدل‌ها درH3 ..... ۱۹۷

نمودار .5-4 مقایسه میانگین Degradation **مدل‌ها در**uav_coastal_domain_shift ۱۹۸

نمودار .6-4 پروفایل رتبه‌ای مدل‌ها در H1 **تا** H3 **بر اساس نتایج بسته**results2 ..... ۱۹۹

نمودار 4-7. **مقایسه میانگین** F1 **پیش و پس از سازگارسازی**H4 ..... ۲۰۲

نمودار 4-8. **توزیع تغییرات** F1 **در سطح تصویر در**H4 ..... ۲۰۳

نمودار 4-9. **روند معیارهای** validation **در طول آموزش**adaptation H4 ..... ۲۰۳

فصل اول

کلیات پژوهش

1-1 مقدمه

آلودگی محیط‌های دریایی ناشی از ورود، انتقال و تجمع پسماندهای انسانی، به‌ویژه مواد پلاستیکی و سایر اشکال پسماند جامد، به یکی از مسائل مهم زیست‌محیطی در مقیاس جهانی تبدیل شده است. مفهوم پسماند دریایی دامنه وسیعی از مواد ساخته‌شده یا فرآوری‌شده توسط انسان را دربرمی‌گیرد که به‌صورت ناخواسته یا عمدی وارد محیط‌های دریایی شده‌اند؛ از جمله پلاستیک‌ها، فلزات، لاستیک، کاغذ، منسوجات، تجهیزات ماهیگیری، شناورها و سایر اقلام ازدست‌رفته یا رهاشده (National Oceanic and Atmospheric Administration Marine Debris

Program, 2025). گستردگی این مواد و تفاوت چشمگیر در ابعاد، شکل، جنس، رنگ و میزان تخریب آن‌ها، شناسایی و پایش خودکار پسماندهای دریایی را به مسئله‌ای چندوجهی تبدیل کرده است.

اهمیت این مسئله صرفاً به وجود فیزیکی پسماند در آب محدود نمی‌شود. پسماندهای دریایی می‌توانند از طریق بلع، درهم‌تنیدگی، تخریب یا تغییر زیستگاه‌ها و ایجاد مخاطرات برای فعالیت‌های انسانی و ناوبری، بر سامانه‌های دریایی اثرگذار باشند. در میان انواع پسماند، پلاستیک‌ها به دلیل ماندگاری بالا، قابلیت انتقال در مسافت‌های طولانی و دشواری جمع‌آوری و تجزیه، جایگاه ویژه‌ای در ادبیات آلودگی دریایی دارند. گزارش برنامه محیط‌زیست سازمان ملل متحد نشان می‌دهد که پلاستیک‌ها دست‌کم 85 درصد از پسماند دریایی را تشکیل می‌دهند و آثار این آلودگی از سطح اکوسیستم تا ابعاد اجتماعی و اقتصادی امتداد می‌یابد (United Nations Environment Programme [UNEP], 2021).

یکی از ویژگی‌های مهم پسماند دریایی، پویایی مکانی و زمانی آن است. جریان‌های دریایی، باد، امواج و سایر فرایندهای فیزیکی می‌توانند پسماند را از محل ورود اولیه جابه‌جا کرده و موجب تجمع یا پراکنش آن در مناطق مختلف شوند. در نتیجه، توزیع مشاهده‌شده پسماند الزاماً بازتاب مستقیمی از محل تولید یا ورود آن نیست و الگوی مکانی آن می‌تواند در طول زمان تغییر کند (National Oceanic and Atmospheric Administration Marine Debris Program, 2024, 2025). از این رو، پایش منظم و تکرارشونده برای برآورد مقدار، نوع، منشأ و تغییرات زمانی و مکانی پسماند اهمیت دارد.

در روش‌های متعارف، بخشی از فرایند پایش از طریق مشاهده مستقیم، نمونه‌برداری و بررسی دستی تصاویر انجام می‌شود. اگرچه این روش‌ها همچنان برای مطالعات محیط‌زیستی و اعتبارسنجی داده‌ها اهمیت دارند، رشد سامانه‌های تصویربرداری زیرآبی و سطحی، دوربین‌های ثابت، وسایل نقلیه هدایت‌پذیر زیرآبی (ROV)، وسایل نقلیه خودکار زیرآبی (AUV) و پهپادها، حجم داده‌های تصویری قابل‌پردازش را به‌طور قابل‌توجهی افزایش داده است. در چنین شرایطی، اتکا به تحلیل دستی تصاویر در مقیاس بزرگ می‌تواند از نظر زمان، هزینه و مقیاس‌پذیری محدودکننده باشد و ضرورت استفاده از روش‌های خودکار تحلیل تصویر را افزایش دهد.

بینایی ماشین و یادگیری عمیق در سال‌های اخیر به یکی از رویکردهای اصلی برای استخراج خودکار اطلاعات از داده‌های تصویری تبدیل شده‌اند. در مسئله تشخیص شیء، هدف تنها تعیین وجود یک کلاس در تصویر نیست؛ بلکه مدل باید کلاس شیء و موقعیت مکانی آن را نیز به‌صورت هم‌زمان تعیین کند. این ویژگی، تشخیص شیء را به گزینه‌ای مناسب برای سامانه‌هایی تبدیل می‌کند که باید اشیای متعدد و با اندازه‌ها و موقعیت‌های متفاوت را در یک تصویر شناسایی کنند. تحول تشخیص شیء از روش‌های مبتنی بر ویژگی‌های دستی به آشکارسازهای عمیق، تک‌مرحله‌ای و end-to-end، زمینه را برای توسعه سامانه‌های سریع‌تر و دقیق‌تر فراهم کرده است (Zou et al., 2023).

با این حال، محیط زیرآبی یکی از دشوارترین محیط‌ها برای کاربرد بینایی ماشین محسوب می‌شود. جذب و پراکندگی نور، کاهش کنتراست، تغییر رنگ، نویز، تاری ناشی از حرکت، ذرات معلق، انسداد جزئی و تغییرات شرایط نوری می‌توانند ظاهر بصری اشیا را تغییر دهند. افزون بر این، پسماندهای دریایی ممکن است در پس‌زمینه‌های پیچیده، در فاصله‌های متفاوت از دوربین و با ابعاد بسیار کوچک ظاهر شوند. مرورهای تخصصی در حوزه تشخیص اشیای دریایی زیرآبی نیز کیفیت پایین تصاویر، اشیای کوچک، مسئله تعمیم‌پذیری و الزامات بلادرنگ را از جمله چالش‌های اصلی این حوزه معرفی کرده‌اند (Er et al., 2023; Sun et al., 2026).

این مسئله یک پیامد مهم برای ارزیابی مدل‌های یادگیری عمیق دارد: عملکرد مطلوب در یک مجموعه‌داده ثابت الزاماً به معنای عملکرد مطلوب در تمام شرایط تصویربرداری نیست. مدل ممکن است در داده‌هایی که از نظر توزیع، کیفیت تصویر و ویژگی‌های محیطی به داده‌های آموزشی نزدیک هستند، عملکرد بالایی داشته باشد، اما با تغییر شرایط تصویربرداری یا انتقال به محیطی متفاوت، افت عملکرد نشان دهد. بنابراین، ارزیابی یک مدل صرفاً بر اساس عملکرد آن در داده‌های بدون اختلال، تصویر کاملی از قابلیت اعتماد و کاربردپذیری آن ارائه نمی‌کند.

در میان آشکارسازهای معاصر، خانواده YOLO، معماری RT-DETR-L و RTMDet-Tiny سه رویکرد متفاوت را برای ایجاد توازن میان دقت و سرعت ارائه می‌کنند. YOLOv8n به‌عنوان یکی از پیاده‌سازی‌های شناخته‌شده خانواده YOLO توسط Ultralytics ارائه شده است (Jocher et al., 2023). از آنجا که YOLOv8n به‌صورت یک مقاله پژوهشی مستقل و داوری‌شده منتشر نشده است، در این پژوهش استناد به آن به‌عنوان یک محصول نرم‌افزاری و نسخه مشخص از چارچوب Ultralytics انجام می‌شود.

RT-DETR-L رویکردی متفاوت را دنبال می‌کند و یک آشکارساز end-to-end مبتنی بر Transformer است که با هدف دستیابی به تشخیص بلادرنگ توسعه یافته است. این معماری با بازطراحی بخش encoder و سازوکار انتخاب query، تلاش می‌کند هزینه محاسباتی مرتبط با آشکارسازهای Transformer را کاهش داده و سرعت آن‌ها را به سطح قابل‌مقایسه با آشکارسازهای بلادرنگ نزدیک کند (Zhao et al., 2024). در مقابل، RTMDet-Tiny بر طراحی یک آشکارساز بلادرنگ کارآمد و ایجاد توازن میان ظرفیت شبکه، هزینه محاسباتی و دقت تمرکز دارد و مجموعه‌ای از طراحی‌های معماری و راهبردهای آموزشی را برای دستیابی به این هدف بررسی می‌کند (Lyu et al., 2022).

وجود تفاوت معماری میان این مدل‌ها، مقایسه آن‌ها را از یک سو علمی و معنادار و از سوی دیگر حساس به طراحی آزمایش می‌کند. اگر مدل‌ها با داده‌های متفاوت، تقسیم‌بندی متفاوت یا پروتکل‌های آموزشی و ارزیابی ناسازگار مقایسه شوند، تفاوت مشاهده‌شده الزاماً ناشی از معماری نخواهد بود. بنابراین، مقایسه منصفانه مستلزم آن است که

عوامل اصلی مؤثر بر آزمایش تا حد امکان کنترل شوند و تفاوت‌های اجرایی ناشی از ویژگی معماری‌ها به‌صورت شفاف گزارش شوند.

از سوی دیگر، حتی یک مقایسه کنترل‌شده در شرایط پایه نیز برای پاسخ به مسئله کاربردپذیری مدل‌ها کافی نیست. سه مفهوم «عملکرد پایه»، «مقاومت در برابر اختلالات» و «رفتار تحت تغییر دامنه» باید از یکدیگر تفکیک شوند. عملکرد پایه نشان می‌دهد مدل در شرایط تعریف‌شده و بدون اختلال چگونه عمل می‌کند؛ مقاومت در برابر اختلالات نشان می‌دهد این عملکرد در مواجهه با تغییرات کنترل‌شده ورودی تا چه اندازه حفظ می‌شود؛ و ارزیابی بین‌دامنه‌ای مشخص می‌کند مدل در مواجهه با تغییر توزیع داده‌ها میان محیط مبدأ و محیط هدف چه میزان افت خواهد داشت.

مطالعات مربوط به robustness نشان داده‌اند که مدل‌های بینایی عمیق می‌توانند نسبت به تغییراتی که برای انسان نسبتاً قابل‌تحمل به نظر می‌رسند، حساس باشند. چارچوب ImageNet-C و ImageNet-P که توسط Hendrycks و Dietterich (2019) معرفی شد، یکی از تلاش‌های مهم برای ارزیابی نظام‌مند مقاومت مدل‌های بینایی در برابر فسادها و اغتشاشات متداول است. با وجود این، این چارچوب اساساً برای طبقه‌بندی تصویر طراحی شده و انتقال مستقیم آن به مسئله تشخیص شیء نیازمند تعریف پروتکل متناسب با ماهیت این وظیفه است.

مفهوم دیگری که برای سامانه‌های تشخیص پسماند دریایی اهمیت دارد، تغییر دامنه یا domain shift است. هنگامی که داده‌های آموزشی و داده‌های مورد استفاده در محیط هدف از نظر توزیع آماری یا ویژگی‌های تصویری متفاوت باشند، فرض هم‌توزیعی داده‌های آموزش و آزمون دیگر برقرار نیست. تفاوت دوربین، شرایط نور، محیط، عمق، زاویه دید، کیفیت تصویر، پس‌زمینه و حتی ویژگی‌های فیزیکی اشیای مشاهده‌شده می‌تواند چنین اختلافی ایجاد کند. مسئله domain adaptation با هدف کاهش اثر چنین اختلافی میان دامنه مبدأ و هدف مورد مطالعه قرار گرفته است (Ganin et al., 2016; Li et al., 2020).

در این زمینه، domain adaptation باید از domain generalization متمایز شود. در سازگارسازی دامنه، اطلاعاتی از دامنه هدف در فرایند انتقال یا سازگارسازی مورد استفاده قرار می‌گیرد؛ در حالی که domain generalization به دنبال افزایش قابلیت تعمیم مدل به دامنه‌های مشاهده‌نشده بدون استفاده مستقیم از داده‌های هدف در فرایند آموزش است (Zhou et al., 2023). این تمایز از نظر طراحی آزمایش اهمیت دارد، زیرا استفاده از داده‌های هدف برای آموزش، انتخاب مدل یا تنظیم پارامترها می‌تواند ماهیت ارزیابی بین‌دامنه‌ای را تغییر دهد.

بر این اساس، پژوهش حاضر از مقایسه ساده سه معماری بر مبنای یک مقدار mAP فراتر می‌رود. ابتدا عملکرد پایه RT-DETR-L،YOLOv8n و RTMDet-Tiny در یک چارچوب داده‌ای هماهنگ و تحت یک پروتکل کنترل‌شده بررسی می‌شود. سپس مقاومت مدل‌ها در برابر اختلالات تصویری کنترل‌شده ارزیابی می‌شود. در مرحله بعد،

عملکرد مدل‌ها در برابر انتقال از دامنه مبدأ به دامنه هدف مورد بررسی قرار می‌گیرد. در نهایت، در صورت مشاهده افت عملکرد، امکان بازیابی بخشی از این افت از طریق یک راهبرد سازگارسازی محدود بررسی خواهد شد.

بنابراین، مسئله اصلی تنها این نیست که کدام مدل در شرایط استاندارد عملکرد بالاتری دارد؛ بلکه این است که **آیا برتری مشاهده‌شده در شرایط پایه در مواجهه با اختلالات ورودی و تغییر توزیع داده‌ها نیز حفظ می‌شود و آیا مدل منتخب می‌تواند با سازگارسازی محدود، بخشی از افت عملکرد خود را در دامنه هدف جبران کند؟**

1-2 بیان مسئله

آلودگی محیط‌های دریایی به‌وسیله پسماندهای انسانی، به‌ویژه مواد پلاستیکی، ادوات صیادی، طناب، تور، منسوجات و سایر اشیای جامد، صرفاً یک مسئله زیست‌محیطی محدود به افزایش حجم زباله در دریا نیست، بلکه پدیده‌ای چندبعدی است که پیامدهای آن در مقیاس اکولوژیک، اقتصادی و اجتماعی قابل مشاهده است. پسماندهای دریایی می‌توانند در ستون آب، بستر دریا و مناطق ساحلی تجمع یابند و تحت تأثیر جریان‌های دریایی، باد و فرایندهای هیدرودینامیکی جابه‌جا شوند. از سوی دیگر، ماندگاری طولانی بسیاری از مواد، به‌ویژه پلاستیک‌ها، موجب می‌شود که مسئله شناسایی و پایش آن‌ها به یک نیاز مستمر و نه یک مسئله مقطعی تبدیل شود (United Nations Environment Programme [UNEP], 2021; National Oceanic and Atmospheric Administration [NOAA], 2025).

اهمیت این مسئله زمانی بیشتر آشکار می‌شود که فرایند شناسایی پسماندهای دریایی در محیط زیرآب مورد توجه قرار گیرد. برخلاف تصاویر حاصل از محیط‌های کنترل‌شده، تصاویر زیرآب معمولاً تحت تأثیر کاهش کنتراست، پراکندگی و جذب نور، تغییرات رنگ، کدورت آب، ذرات معلق، پس‌زمینه‌های پیچیده، پوشش زیستی و تغییرات مقیاس قرار دارند. در چنین شرایطی، اشیای مورد نظر ممکن است از نظر رنگ، بافت و شکل ظاهری شباهت زیادی به محیط پیرامون خود داشته باشند. علاوه بر این، بسیاری از پسماندها در وضعیت‌های مختلفی نظیر نیمه‌مدفون بودن در رسوبات، پوشیده‌شدن توسط زیست‌توده، تغییر شکل یا قرارگرفتن در فاصله زیاد از دوربین مشاهده می‌شوند. در نتیجه، تشخیص خودکار پسماند دریایی را نمی‌توان صرفاً به مسئله طبقه‌بندی اشیا در تصاویر طبیعی تقلیل داد؛ بلکه این مسئله شامل چالش هم‌زمانِ مکان‌یابی، طبقه‌بندی و حفظ دقت تشخیص در شرایط متغیر تصویری است.

در سال‌های اخیر، پیشرفت روش‌های یادگیری عمیق، به‌ویژه شبکه‌های عصبی کانولوشنی و معماری‌های مبتنی بر Transformer، مسیر جدیدی برای خودکارسازی تشخیص اشیای زیرآبی ایجاد کرده است. مرورهای جدید نشان می‌دهند که بخش قابل توجهی از پژوهش‌های مرتبط با تشخیص پسماند دریایی در سال‌های اخیر به سمت

آشکارسازهای تک‌مرحله‌ای، به‌خصوص خانواده YOLO، حرکت کرده‌اند؛ زیرا این معماری‌ها امکان ایجاد توازن میان دقت تشخیص و سرعت پردازش را فراهم می‌کنند. با وجود این، ادبیات پژوهش همچنان با مشکلاتی از جمله محدودیت داده‌های برچسب‌گذاری‌شده، ناهمگونی مجموعه‌داده‌ها، تفاوت در نظام‌های طبقه‌بندی، نبود پروتکل‌های ارزیابی استاندارد و دشواری مقایسه مستقیم مدل‌ها مواجه است (Moorton et al., 2024; Moorton et al., 2025).

یکی از مسائل اساسی در این حوزه، مسئله داده است. عملکرد مدل‌های یادگیری عمیق به‌شدت به کیفیت، تنوع و نحوه برچسب‌گذاری داده‌های آموزشی وابسته است. در حوزه پسماند دریایی، مجموعه‌داده‌هایی نظیر TrashCan و Trash-ICRA19 نقش مهمی در توسعه روش‌های تشخیص و بخش‌بندی ایفا کرده‌اند؛ بااین‌حال، این مجموعه‌داده‌ها از نظر منبع تصویری، توزیع کلاس‌ها، نوع حاشیه‌نویسی، تعریف طبقات و ویژگی‌های محیطی یکسان نیستند (Hong et al., 2020; Fulton et al., 2019, 2020). بنابراین، استفاده مستقیم از چند مجموعه‌داده بدون بررسی سازگاری معنایی کلاس‌ها و کیفیت برچسب‌ها می‌تواند موجب ورود نویز، ابهام معنایی و سوگیری به فرایند آموزش شود. به بیان دیگر، افزایش حجم داده به‌تنهایی الزاماً به معنای افزایش کیفیت داده نیست؛ بلکه ادغام داده‌های چندمنبعی زمانی می‌تواند به بهبود قابلیت یادگیری منجر شود که تفاوت‌های موجود میان منابع از نظر ساختار، برچسب‌گذاری و توزیع داده مدیریت شود.

این مسئله در مطالعات پیشین نیز به‌عنوان یکی از چالش‌های اساسی مطرح شده است. مرورهای جدید حوزه تشخیص پسماند دریایی نشان می‌دهند که هنوز یک چارچوب کاملاً استاندارد و مورد توافق برای مقایسه مدل‌های بینایی ماشین در محیط‌های دریایی وجود ندارد و تفاوت در مجموعه‌داده، تقسیم‌بندی داده، معیارهای ارزیابی، شرایط آموزش و نحوه گزارش نتایج، مقایسه مستقیم مطالعات را دشوار می‌کند (Moorton et al., 2025). از این منظر، بخشی از تفاوت مشاهده‌شده میان عملکرد مدل‌ها ممکن است نه ناشی از برتری واقعی معماری، بلکه ناشی از تفاوت در داده، پیش‌پردازش، افزایش داده، تقسیم‌بندی مجموعه‌ها یا تنظیمات آموزشی باشد. در نتیجه، برای تعیین اینکه کدام معماری واقعاً در مسئله تشخیص پسماند دریایی عملکرد مناسب‌تری دارد، مقایسه باید در یک چارچوب کنترل‌شده و تا حد امکان همسان انجام شود.

در کنار مسئله داده، مسئله انتخاب معماری تشخیص نیز اهمیت دارد. معماری‌های خانواده YOLO به دلیل ساختار نسبتاً ساده، سرعت بالا و قابلیت استفاده در کاربردهای بلادرنگ، جایگاه قابل توجهی در سامانه‌های تشخیص زیرآبی پیدا کرده‌اند. در مقابل، معماری‌های مبتنی بر DETR با استفاده از سازوکارهای Attention و مدل‌سازی روابط سراسری میان اجزای تصویر، رویکرد متفاوتی نسبت به آشکارسازهای متعارف ارائه می‌کنند. RT-DETR-L به‌عنوان یکی از تلاش‌های مهم برای ترکیب مزایای DETR با نیازهای تشخیص بلادرنگ، نشان داده است که معماری‌های Transformer-based می‌توانند بدون وابستگی به مراحل متعارف NMS در ساختار اصلی، به عملکرد رقابتی در

تشخیص بلادرنگ دست یابند (Zhao et al., 2024). از سوی دیگر، RTMDet-Tiny نیز با تأکید بر طراحی تجربی یک آشکارساز real-time، چارچوبی متفاوت برای دستیابی هم‌زمان به دقت و کارایی محاسباتی ارائه می‌کند (Lyu et al., 2022).

با وجود این پیشرفت‌ها، یک پرسش مهم همچنان مطرح است: آیا برتری گزارش‌شده برای یک معماری در مطالعات مختلف، واقعاً ناشی از ماهیت معماری آن است یا تحت تأثیر تفاوت در داده و پروتکل آزمایش قرار دارد؟ پاسخ به این پرسش با مقایسه نتایج مطالعاتی که از داده‌ها و تنظیمات متفاوت استفاده کرده‌اند، به‌سادگی امکان‌پذیر نیست. برای مثال، مقایسه یک مدل YOLO آموزش‌دیده روی یک مجموعه‌داده خاص با یک مدل Transformer آموزش‌دیده روی مجموعه‌داده‌ای متفاوت، حتی در صورت استفاده از معیار مشترک mAP، مقایسه‌ای کاملاً کنترل‌شده محسوب نمی‌شود. بنابراین، یکی از خلأهای روش‌شناختی مهم در این حوزه، نیاز به مقایسه منصفانه و کنترل‌شده چند خانواده معماری تحت یک محیط آزمایشی مشترک است.

این خلأ در پژوهش‌های جدید نیز مورد تأکید قرار گرفته است. یک مرور نظام‌مند منتشرشده در سال 2026 که مطالعات تشخیص پلاستیک و پسماند زیرآبی را بررسی کرده است، نشان می‌دهد که اگرچه آشکارسازهای تک‌مرحله‌ای و معماری‌های Transformer-based به نتایج قابل توجهی دست یافته‌اند، اما تفاوت در معماری، داده، معیارها و شرایط آزمایش همچنان ارزیابی یکپارچه عملکرد و کارایی را دشوار می‌کند. این مرور همچنین بر اهمیت بررسی هم‌زمان دقت و قابلیت استقرار در سامانه‌های دارای محدودیت محاسباتی تأکید دارد (Deep learning-based detection of submerged debris and plastics in underwater environments, 2026). ازاین‌رو، صرف گزارش یک مقدار mAP بالا برای یک مدل نمی‌تواند به‌تنهایی نشان‌دهنده مناسب‌بودن آن برای کاربردهای واقعی باشد؛ زیرا در سامانه‌های رباتیک و پایش زیرآب، سرعت استنتاج، تأخیر، مصرف منابع محاسباتی و پایداری عملکرد نیز اهمیت دارند.

از سوی دیگر، دقت بالا در شرایط آزمایشگاهی یا داده‌های هم‌توزیع، الزاماً به معنای عملکرد پایدار در شرایط واقعی نیست. تغییر کیفیت آب، عمق تصویربرداری، میزان روشنایی، نوع دوربین، زاویه دید، نوع بستر، چگالی ذرات معلق و تفاوت‌های محیطی می‌توانند توزیع داده‌های آزمون واقعی را از داده‌های آموزشی تغییر دهند. چنین اختلافی در توزیع، در ادبیات یادگیری ماشین تحت عنوان *Domain Shift* شناخته می‌شود. پژوهش‌های حوزه سازگارسازی دامنه نشان داده‌اند که اختلاف میان دامنه مبدأ و مقصد می‌تواند موجب کاهش محسوس عملکرد مدل‌های تشخیص شیء شود و بنابراین، ارزیابی صرفاً درون‌دامنه‌ای برای سنجش قابلیت تعمیم مدل کافی نیست (Ganin et al., 2016; Li et al., 2020).

این موضوع در تشخیص پسماند دریایی اهمیت بیشتری دارد؛ زیرا تصاویر جمع‌آوری‌شده از یک مجموعه‌داده عمومی الزاماً نماینده تمام شرایط محیطی مورد انتظار در کاربردهای واقعی نیستند. حتی اگر مدل روی داده‌های آزمون

همان مجموعه‌داده عملکرد مناسبی داشته باشد، ممکن است هنگام مواجهه با تصاویر یک محیط جغرافیایی، دوربین یا شرایط نوری متفاوت، افت عملکرد قابل توجهی نشان دهد. پژوهش‌های جدید نیز به سمت ارزیابی انتقال بین مجموعه‌داده‌ها حرکت کرده‌اند. برای نمونه، مطالعه Li و همکاران (2026) علاوه بر ارزیابی مدل پیشنهادی روی TrashCan، عملکرد آن را در یک آزمایش انتقال به مجموعه‌داده DeepTrash نیز بررسی کرده است. این رویکرد نشان می‌دهد که ارزیابی انتقال بین دامنه‌ها می‌تواند اطلاعاتی فراتر از عملکرد مدل در یک مجموعه‌داده منفرد فراهم کند.

با این حال، باید میان مقاومت در برابر تخریب‌های کنترل‌شده تصویر، تعمیم بین‌دامنه‌ای و سازگارسازی دامنه تمایز روشنی قائل شد. اعمال نویز، کاهش کنتراست، تغییر روشنایی یا سایر اختلالات کنترل‌شده به یک تصویر، برای سنجش میزان حساسیت مدل نسبت به تغییرات مشخص ورودی مفید است، اما به‌تنهایی معادل تعمیم به یک محیط واقعی جدید نیست. در مقابل، ارزیابی Cross-Domain زمانی معنا پیدا می‌کند که داده‌های مبدأ و مقصد از نظر توزیع یا شرایط تصویربرداری متفاوت باشند. همچنین، اگر از داده‌های دامنه مقصد برای آموزش یا تنظیم مجدد مدل استفاده شود، مسئله از «ارزیابی تعمیم» به سمت «سازگارسازی دامنه» تغییر می‌کند. تفکیک این مفاهیم برای طراحی یک ارزیابی معتبر و جلوگیری از برداشت نادرست از مفهوم Robustness ضروری است (Ganin et al., 2016; Zhou et al., 2023).

از منظر روش‌شناختی، بنابراین یک خلأ مهم در پژوهش‌های موجود، فقدان یک چارچوب ارزیابی چندبعدی است که داده، معماری، دقت، کارایی محاسباتی و پایداری در برابر تغییر شرایط را در یک مطالعه واحد و تحت کنترل آزمایشی مشترک بررسی کند. مرور نظام‌مند و مطالعات مروری اخیر نیز نشان داده‌اند که بخش قابل توجهی از ادبیات موجود یا بر بهبود یک معماری خاص تمرکز دارد، یا تنها یک مجموعه‌داده و یک شرایط ارزیابی را بررسی می‌کند؛ درحالی‌که مقایسه سیستماتیک میان خانواده‌های معماری مختلف و بررسی هم‌زمان جنبه‌های دقت و تعمیم همچنان کمتر مورد توجه قرار گرفته است (Moorton et al., 2024; Moorton et al., 2025).

بر این اساس، مسئله اصلی پژوهش حاضر صرفاً یافتن مدلی با بیشترین مقدار mAP نیست؛ بلکه تعیین این موضوع است که در یک چارچوب آزمایشی کنترل‌شده و بر پایه یک مجموعه‌داده چندمنبعیِ پالایش‌شده و دارای نظام طبقه‌بندی مشترک، تفاوت عملکرد و کارایی میان سه خانواده معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny چگونه است و هر یک از این معماری‌ها در مواجهه با تغییرات شرایط تصویری و اختلاف دامنه تا چه اندازه پایدار باقی می‌مانند.

در این پژوهش، برای کاهش اثر عوامل مداخله‌گر، سه مدل بر روی داده و تقسیم‌بندی یکسان، اندازه ورودی یکسان و سخت‌افزار محاسباتی یکسان ارزیابی می‌شوند. تعداد دوره‌های آموزشی و معیار اصلی انتخاب checkpoint نیز

در چارچوب مشترک تعریف شده‌اند؛ بااین‌حال، برخی تنظیمات اجرایی مانند اندازه Batch و بهینه‌ساز، با توجه به الزامات حافظه‌ای و تفاوت چارچوب‌های پیاده‌سازی، بین مدل‌ها متفاوت است و جزئیات آن‌ها به‌صورت شفاف در فصل روش‌شناسی گزارش می‌شود. این طراحی با ثابت نگه‌داشتن متغیرهای اصلی داده و ارزیابی، امکان می‌دهد تفاوت‌های مشاهده‌شده تا حد امکان به تفاوت معماری‌ها و تنظیمات مشخص مدل‌ها نسبت داده شوند، نه به تغییر هم‌زمان مجموعه‌آزمون یا معیار ارزیابی.

در سطح داده نیز، پژوهش حاضر بر این فرض استوار است که ادغام داده‌های چندمنبعی بدون همسان‌سازی معنایی و کنترل کیفیت، لزوماً یک مزیت محسوب نمی‌شود. بنابراین، ادغام داده‌ها در این پژوهش به معنای صرفاً کنار هم قراردادن تصاویر چند مجموعه‌داده نیست؛ بلکه فرایندی شامل یکپارچه‌سازی منابع، بررسی سازگاری برچسب‌ها، پالایش حاشیه‌نویسی‌ها، حذف یا مدیریت موارد ناسازگار و ایجاد یک فضای طبقه‌بندی مشترک است. این رویکرد می‌تواند بخشی از نویز ناشی از ناهمگونی داده‌ها را کاهش داده و زمینه مناسب‌تری برای مقایسه معماری‌ها فراهم کند.

نکته مهم دیگر، عدم تکیه بر یک معیار منفرد برای تعیین مدل برتر است. در یک سامانه تشخیص پسماند دریایی، افزایش دقت در صورتی ارزش کاربردی بیشتری دارد که با سرعت پردازش قابل قبول و هزینه محاسباتی متناسب همراه باشد. به همین دلیل، پژوهش حاضر عملکرد مدل‌ها را از طریق مجموعه‌ای از معیارهای مکمل شامل Precision،Recall ،mAP@50 و mAP@50:95 بررسی می‌کند و در کنار آن، معیارهای کارایی محاسباتی مانند FPS و Latency را نیز مورد توجه قرار می‌دهد. mAP@50:95 به‌عنوان معیار اصلی دقت کلی در نظر گرفته می‌شود، در حالی که Precision،Recall و mAP@50 اطلاعات مکملی درباره رفتار مدل در تشخیص و مکان‌یابی ارائه می‌کنند. این رویکرد از انتخاب مدلی صرفاً بر اساس یک معیار جلوگیری کرده و امکان تحلیل چندبعدی عملکرد را فراهم می‌سازد.

همچنین، برای تحلیل پایداری مدل‌ها، افت عملکرد نسبت به وضعیت پایه مورد توجه قرار می‌گیرد. در این پژوهش، برای معیارهایی که مقدار بیشتر آن‌ها مطلوب است، شاخص Degradation به‌صورت اختلاف عملکرد شرایط پایه و شرایط تغییریافته تعریف می‌شود:

که در آن M_clean عملکرد معیار در شرایط پایه و M_condition عملکرد همان معیار در شرایط تغییریافته است. مقدار مثبت بیانگر افت عملکرد و مقدار منفی بیانگر بهبود نسبت به شرایط پایه است. در آزمایش‌های H2و H3 همین تعریف اختلاف مطلق برای شاخص Degradation استفاده شده است. برای معیارهایی که مقدار کمتر آن‌ها مطلوب است، مانندLatency ، جهت تعریف شاخص باید به‌صورت جداگانه و متناسب با هدف benchmarkمشخص شود.

$$D_M = M_clean - M_condition$$

در نهایت، مسئله پژوهش حاضر را می‌توان در قالب یک زنجیره روش‌شناختی مشخص صورت‌بندی کرد: کیفیت و سازگاری داده‌ها بر قابلیت یادگیری اثر می‌گذارد؛ معماری مدل بر نحوه استخراج و ترکیب ویژگی‌ها و در نتیجه بر دقت و هزینه محاسباتی اثرگذار است؛ تغییر شرایط تصویری می‌تواند موجب افت عملکرد شود؛ و اختلاف دامنه می‌تواند قابلیت تعمیم مدل را محدود کند. ازاین‌رو، ارزیابی یک آشکارساز مناسب برای پسماندهای دریایی نیازمند بررسی هم‌زمان این ابعاد است.

بر مبنای این مسئله، پژوهش حاضر با تمرکز بر سه معماری متفاوت RT-DETR-L،YOLOv8n و RTMDet-Tiny، یک چارچوب مقایسه‌ای کنترل‌شده ایجاد می‌کند که در آن ابتدا اثر استفاده از داده‌های چندمنبعیِ پالایش‌شده بر فرایند تشخیص بررسی می‌شود، سپس عملکرد پایه سه معماری تحت شرایط آموزشی مشترک مقایسه می‌گردد، و در ادامه پایداری آن‌ها در برابر تغییرات کنترل‌شده و اختلاف دامنه مورد ارزیابی قرار می‌گیرد. هدف نهایی، صرفاً معرفی یک مدل با بیشترین دقت نیست؛ بلکه ارائه شواهد تجربی برای پاسخ به این پرسش است که کدام ویژگی از یک آشکارساز ــ دقت، سرعت، هزینه محاسباتی یا پایداری در برابر تغییر شرایط ــ در چه شرایطی مزیت بیشتری ایجاد می‌کند و چگونه می‌توان میان این ابعاد برای کاربرد تشخیص خودکار پسماندهای دریایی تصمیم‌گیری کرد.

از این منظر، شکاف پژوهشی مورد نظر این مطالعه در تقاطع چهار حوزه قرار می‌گیرد: (1) یکپارچه‌سازی و پالایش داده‌های چندمنبعی، (2) مقایسه کنترل‌شده معماری‌های متفاوت تشخیص شیء، (3) ارزیابی هم‌زمان دقت و کارایی محاسباتی، و (4) بررسی پایداری و قابلیت تعمیم مدل در شرایطی فراتر از داده‌های پایه. ترکیب این چهار محور در یک پروتکل آزمایشی واحد، چارچوبی فراهم می‌کند که می‌تواند ارزیابی مدل‌های تشخیص پسماند دریایی را از مقایسه صرفاً مبتنی بر mAP به سمت یک ارزیابی جامع‌تر، منصفانه‌تر و کاربردمحور هدایت کند.

1-3 اهمیت و ضرورت پژوهش

1-3-1 اهمیت زیست‌محیطی

پایش پسماندهای دریایی برای شناخت مقدار، نوع، پراکنش و روند تغییرات آن‌ها اهمیت دارد و داده‌های حاصل از پایش می‌توانند در تصمیم‌گیری‌های مربوط به پیشگیری، مدیریت و پاک‌سازی مورد استفاده قرار گیرند (National Oceanic and Atmospheric Administration Marine Debris Program, 2025). با افزایش حجم

تصاویر تولیدشده توسط سامانه‌های تصویربرداری، توسعه ابزارهای خودکار می‌تواند ظرفیت تحلیل داده را افزایش داده و بررسی دستی حجم گسترده‌ای از تصاویر را کاهش دهد.

هدف استفاده از یادگیری عمیق در این زمینه، جایگزینی کامل روش‌های محیط‌زیستی و مشاهده میدانی نیست؛ بلکه ایجاد یک ابزار محاسباتی برای پردازش مقیاس‌پذیر داده‌های تصویری و استخراج اطلاعات مکانی و طبقه‌ای از اشیای قابل مشاهده است.

1-3-2 اهمیت فنی

محیط‌های زیرآبی شرایط دشواری برای سیستم‌های بینایی ماشین ایجاد می‌کنند. افت کیفیت تصویر، تغییر رنگ، کاهش کنتراست، تاری، ذرات معلق و تغییر شرایط نور می‌توانند ویژگی‌های بصری اشیا را تغییر دهند و موجب کاهش قابلیت تعمیم مدل شوند (Er et al., 2023; Sun et al., 2026).

از این رو، ارزیابی یک آشکارساز صرفاً روی داده‌های پاک نمی‌تواند به‌تنهایی برای انتخاب مدل مناسب کافی باشد. مدل مطلوب باید علاوه بر عملکرد تشخیصی مناسب، در برابر بخشی از تغییرات تصویری و تغییر توزیع داده‌ها نیز رفتار قابل‌قبولی داشته باشد.

مقایسه RT-DETR-L،YOLOv8n و RTMDet-Tiny از این منظر اهمیت دارد که این مدل‌ها بر مبنای طراحی‌های معماری متفاوت، مسئله تعادل میان دقت و سرعت را دنبال می‌کنند. RT-DETR-L بر معماری Transformer و تشخیص end-to-end تکیه دارد، در حالی که YOLOv8n و RTMDet-Tiny از طراحی‌های متفاوت آشکارسازهای بلادرنگ مبتنی بر شبکه‌های کانولوشنی بهره می‌برند (Jocher et al., 2023; Lyu et al., 2022; Zhao et al., 2024).

1-3-3 اهمیت روش‌شناختی

اهمیت روش‌شناختی پژوهش در آن است که سه سطح متفاوت از عملکرد را از یکدیگر تفکیک می‌کند:

۱. عملکرد در شرایط پایه؛
۲. مقاومت در برابر اختلالات تصویری کنترل‌شده؛
۳. رفتار مدل تحت تغییر دامنه.

این تفکیک امکان می‌دهد مشخص شود که آیا یک مدل صرفاً در شرایط استاندارد عملکرد بالایی دارد یا اینکه این عملکرد در برابر تغییرات ورودی و تغییر توزیع داده‌ها نیز تا حد قابل‌قبولی حفظ می‌شود.

همچنین افزودن مرحله سازگارسازی محدود، ارزیابی را از یک مقایسه توصیفی فراتر می‌برد و امکان بررسی میزان قابلیت بازیابی عملکرد را فراهم می‌کند. به این ترتیب، پژوهش نه‌تنها می‌پرسد «کدام مدل بهتر است؟»، بلکه می‌پرسد «کدام مدل در برابر تغییر شرایط پایدارتر است و در صورت افت، تا چه اندازه قابلیت بازیابی دارد؟».

1-3-4 اهمیت کاربردی

در سامانه‌های نزدیک به بلادرنگ، انتخاب مدل تنها بر اساس دقت مناسب نیست. سرعت استنتاج، تأخیر، هزینه محاسباتی و محدودیت منابع سخت‌افزاری نیز می‌توانند در تصمیم‌گیری نقش داشته باشند. بنابراین، ارزیابی هم‌زمان دقت و کارایی محاسباتی می‌تواند تصویری واقع‌بینانه‌تر از قابلیت استفاده عملی مدل‌ها ارائه کند.

1-4 هدف کلی پژوهش

هدف کلی این پژوهش، **ارزیابی و مقایسه نظام‌مند مدل‌های RT-DETR-L،YOLOv8n و RTMDet-Tiny برای تشخیص اشیای مرتبط با پسماندهای دریایی، با تأکید بر عملکرد پایه، مقاومت در برابر اختلالات تصویری، رفتار تحت تغییر دامنه و امکان بازیابی عملکرد از طریق سازگارسازی محدود دامنه** است.

در این راستا، هدف پژوهش صرفاً تعیین مدلی با بیشترین مقدار mAP در شرایط پایه نیست؛ بلکه تلاش می‌شود مدلی شناسایی شود که بر اساس مجموعه‌ای از شواهد شامل دقت تشخیص، پایداری در شرایط نامطلوب، قابلیت انتقال بین‌دامنه‌ای و هزینه محاسباتی، انتخاب مناسب‌تری برای شرایط مورد مطالعه باشد.

1-5 اهداف اختصاصی پژوهش

۱. یکپارچه‌سازی داده‌های چندمنبعی و ایجاد یک چارچوب داده‌ای هماهنگ از نظر تعریف کلاس‌ها، قالب annotation و ساختار ارزیابی.

۲. کنترل و اعتبارسنجی کیفیت داده‌ها و annotationها با هدف کاهش اثر خطاهای داده‌ای بر مقایسه مدل‌ها.

۳. ایجاد یک پروتکل کنترل‌شده برای مقایسه RT-DETR-L،YOLOv8n و RTMDet-Tiny.

۴. مقایسه عملکرد پایه سه مدل بر اساس معیارهای استاندارد تشخیص شیء شامل Recall،Precision ، mAP@0.50 و mAP@0.50:0.95.

۵. بررسی مقاومت سه مدل در برابر اختلالات تصویری کنترل‌شده.

۶. کمی‌سازی میزان افت عملکرد هر مدل نسبت به وضعیت پایه در شرایط اختلال.

۷. بررسی عملکرد مدل‌ها در دامنه هدف و تعیین میزان افت ناشی از تغییر دامنه.

۸. مقایسه حساسیت معماری‌های مختلف نسبت به تغییر دامنه.

۹. بررسی پایداری رتبه‌بندی مدل‌ها در شرایط پایه، اختلال و تغییر دامنه.

۱۰. تعیین مدل منتخب برای مرحله سازگارسازی بر اساس یک قاعده از پیش تعیین‌شده.

۱۱. بررسی اثر سازگارسازی محدود دامنه بر عملکرد مدل منتخب در دامنه هدف.

۱۲. مقایسه عملکرد مدل منتخب پیش و پس از سازگارسازی.

۱۳. تعیین میزان بازیابی عملکرد مدل در دامنه هدف پس از سازگارسازی.

۱۴. مقایسه مدل‌ها از نظر دقت تشخیص و کارایی محاسباتی متناسب با الزامات کاربردهای نزدیک به بلادرنگ.

۱۵. ارائه یک چارچوب تجربی برای انتخاب مدل تشخیص پسماند دریایی با درنظرگرفتن هم‌زمان عملکرد پایه، مقاومت، انتقال بین‌دامنه‌ای و هزینه سازگارسازی.

1-6 سؤالات پژوهش

سؤال اصلی

آیا برتری عملکردی مدل‌های RT-DETR-L،YOLOv8n و RTMDet-Tiny در شرایط پایه در برابر اختلالات تصویری و تغییر دامنه حفظ می‌شود و آیا سازگارسازی محدود می‌تواند افت عملکرد مدل منتخب را در دامنه هدف کاهش دهد؟

سؤالات فرعی

سؤال 1:

آیا بین RT-DETR-L،YOLOv8n و RTMDet-Tiny از نظر عملکرد تشخیص شیء در شرایط پایه تفاوت وجود دارد؟

سؤال 2:

آیا میزان افت عملکرد سه مدل در برابر اختلالات تصویری کنترل‌شده با یکدیگر متفاوت است؟

سؤال 3:

آیا نوع و شدت اختلال تصویری اثر متفاوتی بر عملکرد سه معماری دارد؟

سؤال 4:

آیا عملکرد مدل‌های مورد مطالعه پس از انتقال از دامنه مبدأ به دامنه هدف کاهش می‌یابد؟

سؤال 5:

آیا میزان افت عملکرد ناشی از تغییر دامنه میان RT-DETR-L،YOLOv8n و RTMDet-Tiny متفاوت است؟

سؤال 6:

آیا مدلی که در شرایط پایه بهترین عملکرد را دارد، در شرایط اختلال و تغییر دامنه نیز رتبه نخست را حفظ می‌کند؟

سؤال 7:

آیا سازگارسازی محدود دامنه موجب بهبود عملکرد مدل منتخب در یک مجموعه آزمون مستقل از دامنه هدف می‌شود؟

سؤال 8:

آیا بهبود حاصل از سازگارسازی علاوه بر معناداری آماری، از نظر عملی نیز قابل‌توجه است؟

1-7 فرضیه‌های پژوهش

با توجه به ماهیت تجربی پژوهش، فرضیه‌ها بر اساس روابط قابل‌آزمون میان معماری مدل و شرایط ارزیابی تعریف می‌شوند.

فرضیه اول

H1: بین عملکرد پایه RT-DETR-L،YOLOv8n و RTMDet-Tiny در شرایط کنترل‌شده تفاوت معنادار وجود دارد.

فرضیه دوم

H2: میزان افت عملکرد ناشی از اختلالات تصویری کنترل‌شده بین RT-DETR-L،YOLOv8n و RTMDet-Tiny متفاوت است.

فرضیه سوم

H3: میزان افت عملکرد ناشی از انتقال از دامنه مبدأ به دامنه هدف در RT-DETR-L،YOLOv8n و RTMDet-Tiny متفاوت است.

فرضیه چهارم

H4: سازگارسازی محدود دامنه موجب افزایش معنادار عملکرد مدل منتخب در دامنه هدف نسبت به وضعیت بدون سازگارسازی می‌شود.

در این پژوهش، تغییر یا ثبات رتبه‌بندی مدل‌ها در شرایط مختلف به‌عنوان یک سؤال پژوهشی مستقل بررسی می‌شود و از تبدیل آن به فرضیه‌ای کلی و فاقد تعریف عملیاتی خودداری می‌شود.

1-8 متغیرهای پژوهش

1-8-1 متغیرهای مستقل

متغیرهای مستقل پژوهش عبارت‌اند از:

- معماری مدل: YOLOv8n، RT-DETR-L و RTMDet-Tiny؛
- وضعیت تصویری: شرایط پایه و شرایط دارای اختلال؛
- نوع اختلال تصویری؛
- شدت اختلال؛
- دامنه داده: مبدأ و هدف؛
- وضعیت سازگارسازی: بدون سازگارسازی و پس از سازگارسازی.

1-8-2 متغیرهای وابسته

متغیرهای اصلی عملکرد عبارت‌اند از:

- Precision؛
- Recall؛
- mAP@0.50؛
- mAP@0.50:0.95.

در کنار مقادیر مطلق، تغییر عملکرد نسبت به شرایط پایه نیز بررسی خواهد شد. برای یک معیار عملکردی MM، افت مطلق به‌صورت زیر تعریف می‌شود:

$$\Delta M = M_{clean} - M_{condition}$$

و افت نسبی عملکرد به‌صورت زیر محاسبه می‌شود:

$$D_M = (M_{clean} - M_{condition}) / M_{clean} \times 100$$

در این رابطه، M_{clean} مقدار معیار موردنظر در شرایط پایه و $M_{condition}$ مقدار همان معیار در شرایط مورد ارزیابی است .این شاخص امکان مقایسه میزان افت نسبی مدل‌ها را در شرایط مختلف فراهم می‌کند.

جزئیات محاسبه شاخص‌ها، طراحی آزمون‌ها و روش تحلیل آماری در فصل سوم ارائه خواهد شد.

1-8-3 متغیرهای کارایی محاسباتی

با توجه به ماهیت بلادرنگ مدل‌های مورد مطالعه، کارایی محاسباتی نیز در ارزیابی لحاظ می‌شود. این بخش شامل شاخص‌هایی مانند سرعت استنتاج، زمان تأخیر، تعداد پارامترها و هزینه محاسباتی خواهد بود.

هدف از این بخش، جلوگیری از محدود کردن مقایسه به دقت تشخیص است؛ زیرا در سامانه‌های نزدیک به بلادرنگ، عملکرد نهایی تابعی از توازن میان دقت و هزینه محاسباتی است.

1-8-4 متغیرهای کنترل‌شده

برای کاهش عوامل مخدوش‌کننده، مجموعه‌داده، تقسیم‌بندی داده‌ها، تعریف کلاس‌ها، اندازه ورودی، سیاست افزایش داده، تعداد دوره‌های آموزش، بهینه‌ساز، سخت‌افزار و پروتکل ارزیابی در طراحی اصلی آزمایش کنترل می‌شوند.

با توجه به تفاوت ساختاری و مصرف حافظه معماری‌ها، اندازه batch می‌تواند متناسب با هر مدل متفاوت باشد. این تفاوت به‌عنوان یک تفاوت اجرایی در فرایند آموزش در نظر گرفته شده و مقدار و نحوه تنظیم آن در فصل سوم گزارش خواهد شد.

1-9 چارچوب مفهومی پژوهش

چارچوب مفهومی پژوهش بر این فرض استوار است که عملکرد یک آشکارساز را نمی‌توان با یک معیار منفرد و در یک شرایط ثابت به‌طور کامل توصیف کرد. از این منظر، معماری مدل تنها یکی از عوامل مؤثر بر عملکرد است و رفتار مدل باید در ارتباط با شرایط داده و محیط ارزیابی شود.

در سطح نخست، رابطه میان معماری و عملکرد پایه بررسی می‌شود

$$\text{Architecture} \rightarrow \text{Baseline Performance}$$

در سطح دوم، اثر اختلالات تصویری بر هر معماری بررسی می‌شود:

$$\text{Architecture} \times \text{Corruption Type / Severity} \rightarrow \text{Robustness}$$

در سطح سوم، انتقال مدل از دامنه مبدأ به دامنه هدف ارزیابی می‌شود:

$$\text{Architecture} \times \text{Domain Shift} \rightarrow \text{Cross-Domain Performance}$$

در سطح چهارم، مدل منتخب وارد مرحله سازگارسازی محدود می‌شود:

$$\text{Selected Model} \times \text{Target-Domain Information} \times \text{Adaptation} \rightarrow \text{Performance}$$

بنابراین، منطق کلی پژوهش به‌صورت زیر قابل نمایش است:

یکپارچه‌سازی داده‌های چندمنبعی

↓

هماهنگ‌سازی taxonomy و کنترل کیفیت annotation

↓

آموزش کنترل‌شده سه معماری

↓

ارزیابی عملکرد پایه

↓

ارزیابی مقاومت در برابر اختلالات تصویری

↓

ارزیابی انتقال از دامنه مبدأ به دامنه هدف

↓

انتخاب مدل بر اساس قاعده از پیش تعیین‌شده

↓

سازگارسازی محدود دامنه

↓

ارزیابی مستقل عملکرد پس از سازگارسازی

این چارچوب یک مدل علّی قطعی از رفتار شبکه‌های عصبی ارائه نمی‌کند؛ بلکه منطق مفهومی پژوهش و ارتباط میان مراحل اصلی ارزیابی را مشخص می‌سازد.

1-10 نوآوری و سهم علمی پژوهش

نوآوری پژوهش حاضر به معنای معرفی یک معماری جدید تشخیص شیء نیست. سهم علمی مطالعه در سطح **طراحی تجربی، ارزیابی و روش‌شناسی مقایسه‌ای** تعریف می‌شود.

1-10-1 یکپارچه‌سازی داده‌های چندمنبعی

یکی از اجزای اساسی پژوهش، ایجاد یک چارچوب داده‌ای هماهنگ از مجموعه‌داده‌های چندمنبعی است. در این فرایند، هماهنگ‌سازی taxonomy، قالب annotation و کنترل کیفیت داده‌ها با هدف کاهش اثر عوامل داده‌ای بر مقایسه معماری‌ها مورد توجه قرار می‌گیرد.

این موضوع از آن جهت اهمیت دارد که تفاوت عملکرد میان مدل‌ها زمانی قابل تفسیرتر است که مدل‌ها مسئله‌ای یکسان را روی داده‌هایی با تعریف و ساختار یکسان حل کنند. مطالعات مربوط به بازسازی و متوازن‌سازی مجموعه‌داده‌های زیرآبی نیز نشان داده‌اند که ویژگی‌های خود مجموعه‌داده می‌تواند بر ارزیابی مدل‌ها اثرگذار باشد (Barrelet et al., 2022).

1-10-2 تفکیک عملکرد پایه، مقاومت و انتقال بین‌دامنه‌ای

سهم دوم پژوهش، تفکیک صریح سه سطح عملکرد است: عملکرد در شرایط پایه، مقاومت در برابر اختلالات کنترل‌شده و عملکرد تحت تغییر دامنه.

این تفکیک امکان می‌دهد مشخص شود آیا مدلی که در شرایط استاندارد عملکرد بالاتری دارد، در شرایط غیرایده‌آل نیز همان مزیت را حفظ می‌کند یا خیر.

1-10-3 کمی‌سازی افت عملکرد

پژوهش حاضر علاوه بر گزارش عملکرد مطلق، تغییر عملکرد نسبت به وضعیت پایه را نیز کمی‌سازی می‌کند. این رویکرد امکان مقایسه حساسیت مدل‌ها نسبت به شرایط نامطلوب را فراهم می‌سازد.

به‌عنوان مثال، دو مدل ممکن است در یک وضعیت خاص مقدار mAP مشابهی داشته باشند، اما یکی از آن‌ها ممکن است افت بسیار بیشتری نسبت به عملکرد اولیه خود تجربه کرده باشد. از این رو، مقدار مطلق عملکرد و میزان افت نسبی باید در کنار یکدیگر تفسیر شوند.

1-10-4 پیوند ارزیابی domain shift و adaptation

یکی دیگر از ویژگی‌های طراحی پژوهش، قرار دادن ارزیابی تغییر دامنه و سازگارسازی در یک زنجیره منطقی است. ابتدا میزان افت عملکرد در دامنه هدف مشخص می‌شود و سپس بررسی می‌شود که آیا یک راهبرد سازگارسازی محدود می‌تواند بخشی از این افت را جبران کند.

این طراحی امکان می‌دهد مسئله از سطح «آیا مدل تعمیم می‌یابد؟» به سطح کاربردی‌تر «در صورت عدم تعمیم کافی، آیا می‌توان با هزینه محدود عملکرد آن را بهبود داد؟» منتقل شود.

1-10-5 انتخاب مدل بر اساس شواهد چندبعدی

هدف پژوهش تولید یک رتبه‌بندی ساده بر اساس یک معیار واحد نیست. مدل‌ها از نظر عملکرد پایه، مقاومت در برابر اختلالات، رفتار بین‌دامنه‌ای و کارایی محاسباتی بررسی می‌شوند و انتخاب مدل برای مرحله سازگارسازی بر اساس یک قاعده از پیش تعیین‌شده انجام خواهد شد.

در نتیجه، سؤال نهایی پژوهش از «کدام مدل بیشترین mAP را دارد؟» به سؤال جامع‌تری تبدیل می‌شود:

کدام معماری، در مجموعه شرایط مورد مطالعه، ترکیب مناسب‌تری از دقت، پایداری، قابلیت انتقال و هزینه محاسباتی را ارائه می‌کند؟

1-11 محدودیت‌های پژوهش

با وجود تلاش برای طراحی یک ارزیابی کنترل‌شده، نتایج پژوهش حاضر باید با توجه به محدودیت‌های آن تفسیر شوند.

نخست، هیچ مجموعه‌داده تصویری نمی‌تواند تمام تنوع محیط‌های دریایی، شرایط نوری، عمق‌ها، دوربین‌ها و انواع پسماند را پوشش دهد. بنابراین، نتایج مطالعه نباید بدون شواهد مستقل به تمام محیط‌های دریایی تعمیم داده شوند.

دوم، اختلالات تصویری مورد استفاده در آزمایش تنها نماینده بخشی از تغییرات ممکن در داده‌های تصویری هستند. بنابراین، مقاومت مشاهده‌شده در برابر اختلالات کنترل‌شده نباید به‌عنوان اثبات robustness عمومی مدل در تمام شرایط واقعی تفسیر شود.

سوم، دامنه هدف مورد استفاده برای ارزیابی cross-domain تنها یک نمونه از تغییرات ممکن میان محیط مبدأ و محیط هدف است. از این رو، موفقیت یا شکست مدل در این دامنه به‌تنهایی اثبات‌کننده قابلیت تعمیم عمومی آن نیست.

چهارم، سازگارسازی دامنه در این پژوهش در محدوده یک راهبرد مشخص و محدود بررسی می‌شود. بنابراین، نتایج آن نباید به‌عنوان اثبات برتری عمومی تمام روش‌های domain adaptation تفسیر شود.

پنجم، محدودیت منابع محاسباتی می‌تواند تعداد اجراهای تکراری، دامنه تحلیل‌های تکمیلی و گستره مطالعات حذف مؤلفه را محدود کند. با این حال، محدودیت محاسباتی نباید به استفاده از مجموعه آزمون نهایی برای آموزش، انتخاب مدل یا تنظیم پارامترها منجر شود.

ششم، مدل‌های یادگیری عمیق ممکن است به دلیل ماهیت تصادفی برخی مراحل آموزش، بین اجراهای مختلف نتایج متفاوتی ایجاد کنند. بنابراین، در صورت امکان، تکرار آزمایش‌ها با seedهای مستقل و گزارش پراکندگی نتایج می‌تواند قابلیت اتکای مقایسه را افزایش دهد.

هفتم، عدم توازن میان کلاس‌ها می‌تواند بر یادگیری مدل و تفسیر معیارهای کلی اثرگذار باشد. از این رو، تحلیل نتایج نباید تنها به معیارهای تجمیعی محدود شود و در صورت امکان باید عملکرد در سطح کلاس نیز بررسی شود.

در نهایت، این پژوهش یک مطالعه تجربی مبتنی بر داده‌های تصویری موجود است و نتایج آن جایگزین اعتبارسنجی میدانی مستقیم در محیط‌های دریایی نخواهد بود. اعتبار بیرونی نتایج به میزان شباهت دامنه‌های ارزیابی‌شده با شرایط واقعی کاربرد وابسته است.

1-12 ساختار پایان‌نامه

این پایان‌نامه در پنج فصل تنظیم شده است.

فصل اول به کلیات پژوهش اختصاص دارد و زمینه مسئله، بیان مسئله، اهمیت و ضرورت، اهداف، سؤالات، فرضیه‌ها، متغیرها، چارچوب مفهومی، سهم علمی و محدودیت‌های پژوهش را تشریح می‌کند.

فصل دوم به مبانی نظری و پیشینه پژوهش اختصاص دارد. در این فصل، مباحث مرتبط با پسماندهای دریایی، تشخیص شیء، یادگیری عمیق، معماری‌های YOLO، RT-DETR-L و RTMDet-Tiny، مجموعه‌داده‌های زیرآبی، robustness، domain shift، domain adaptation و مطالعات پیشین بررسی و تحلیل خواهند شد.

فصل سوم روش‌شناسی پژوهش را ارائه می‌کند. جزئیات مربوط به داده‌ها، آماده‌سازی و اعتبارسنجی annotation، تقسیم‌بندی داده‌ها، معماری‌ها، تنظیمات آموزش، معیارهای ارزیابی، طراحی آزمون‌های robustness، ارزیابی cross-domain، سازگارسازی و روش تحلیل آماری در این فصل ارائه می‌شود.

فصل چهارم به ارائه و تحلیل نتایج اختصاص دارد. نتایج عملکرد پایه، مقاومت در برابر اختلالات، تغییر دامنه، سازگارسازی و کارایی محاسباتی مدل‌ها در این فصل گزارش و مقایسه می‌شوند.

فصل پنجم شامل بحث، نتیجه‌گیری و پیشنهادهای پژوهش است. یافته‌های اصلی با توجه به سؤالات پژوهش و مطالعات پیشین تفسیر شده و محدودیت‌ها و مسیرهای پیشنهادی برای تحقیقات آینده ارائه می‌شوند.

1-13 جمع‌بندی فصل

در این فصل، مسئله تشخیص خودکار پسماندهای دریایی در چارچوب گسترده‌تر پایش تصویری محیط‌های دریایی معرفی شد. بررسی ادبیات نشان می‌دهد که اگرچه یادگیری عمیق و آشکارسازهای بلادرنگ ظرفیت قابل‌توجهی برای خودکارسازی تحلیل تصاویر دارند، پیچیدگی محیط زیرآبی و تفاوت میان شرایط آموزشی و عملیاتی می‌تواند قابلیت تعمیم مدل‌ها را محدود کند.

بر همین اساس، مسئله پژوهش از یک مقایسه ساده میان سه معماری به یک چارچوب چندسطحی برای ارزیابی عملکرد گسترش یافت. در این چارچوب، عملکرد پایه، مقاومت در برابر اختلالات تصویری، رفتار تحت تغییر دامنه و امکان بازیابی عملکرد پس از سازگارسازی محدود به‌صورت زنجیره‌ای بررسی می‌شوند.

هدف اصلی پژوهش، تعیین یک برنده صرفاً بر اساس یک معیار منفرد نیست؛ بلکه شناسایی معماری‌ای است که در مجموعه شرایط مورد مطالعه، ترکیب مناسبی از دقت، پایداری، قابلیت انتقال و کارایی محاسباتی ارائه کند. مبانی نظری، مطالعات پیشین و شکاف‌های پژوهشی مرتبط با این مسئله در فصل دوم بررسی خواهند شد.

منابع لاتین فصل اول:

Barrelet, C., Chaumont, M., Subsol, G., Creuze, V., & Gouttefarde, M. (2022). From TrashCan to UNO: Deriving an underwater image dataset to get a more consistent and balanced version. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*.

Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020). End-to-end object detection with transformers. In *Computer Vision – ECCV 2020* (pp. 213–229). Springer. https://doi.org/10.1007/978-3-030-58452-8_13

Deep learning-based detection of submerged debris and plastics in underwater environments: A systematic review. (2026). *International Journal of Environmental Science and Technology*.

Er, M. J., Chen, J., Zhang, Y., & Gao, W. (2023). Research challenges, recent advances, and popular datasets in deep learning-based underwater marine object detection: A review. *Sensors*, *23*(4), 1990. https://doi.org/10.3390/s23041990

Fulton, M., Hong, J., Islam, M. J., & Sattar, J. (2019). Robotic detection of marine litter using deep visual detection models. In *2019 International Conference on Robotics and Automation (ICRA)* (pp. 5752–5758). IEEE. https://doi.org/10.1109/ICRA.2019.8793975

Fulton, M. S., Hong, J., & Sattar, J. (2020). *Trash-ICRA19: A bounding box labeled dataset of underwater trash*. Data Repository for the University of Minnesota. https://doi.org/10.13020/X0QN-Y082

Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M., & Lempitsky, V. (2016). Domain-adversarial training of neural networks. *Journal of Machine Learning Research*, *17*(59), 1–35

Hong, J., Fulton, M., & Sattar, J. (2020). TrashCan: A semantically-segmented dataset towards visual detection of marine debris. *arXiv*. https://arxiv.org/abs/2007.08097

Hendrycks, D., & Dietterich, T. (2019). Benchmarking neural network robustness to common corruptions and perturbations. In *International Conference on Learning Representations (ICLR)*.

Li, W., Li, F., Luo, Y., Wang, P., & Sun, J. (2020). Deep domain adaptive object detection: A survey. In *2020 IEEE Symposium Series on Computational Intelligence (SSCI)* (pp. 1808–1813). IEEE. https://doi.org/10.1109/SSCI47803.2020.9308604

Li, X., et al. (2026). Transformer-based detection of underwater plastic debris with cross-domain evaluation. *Frontiers in Marine Science*.

Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 2980–2988). IEEE. https://doi.org/10.1109/ICCV.2017.324

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *Computer Vision – ECCV 2014* (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

Lyu, C., Zhang, W., Huang, H., Zhou, Y., Wang, Y., Liu, Y., Zhang, S., & Chen, K. (2022). RTMDet-Tiny: An empirical study of designing real-time object detectors. *arXiv*. https://arxiv.org/abs/2212.07784

Moorton, M., et al. (2024). A systematic review and analysis of deep learning-based underwater object detection. *Neurocomputing, 527*, 204–232. https://doi.org/10.1016/j.neucom.2023.01.056

Moorton, M., et al. (2025). Up-to-date scoping review of object detection methods for macro-marine debris. *Marine Pollution Bulletin*.

National Oceanic and Atmospheric Administration. (2025). *What is marine debris?* NOAA Marine Debris Program.

National Oceanic and Atmospheric Administration. (2025). *Why is marine debris a problem?* NOAA Marine Debris Program.

National Oceanic and Atmospheric Administration. (2025). *Monitoring marine debris*. NOAA Marine Debris Program.

Sun, P., Ju, Z., Liu, S., Li, X., Chen, M., & Chen, G. (2026). A review of underwater object detection methods based on deep learning. *Proceedings of the Institution of Mechanical Engineers, Part M: Journal of Engineering for the Maritime Environment, 240*(3). https://doi.org/10.1177/14750902261423406

United Nations Environment Programme. (2021). *From pollution to solution: A global assessment of marine litter and plastic pollution*. United Nations Environment Programme.

Zhao, Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). DETRs beat YOLOs on real-time object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 16965–16974). IEEE. https://doi.org/10.1109/CVPR52733.2024.01605

Zhou, K., Liu, Z., Qiao, Y., Xiang, T., & Loy, C. C. (2023). Domain generalization: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 45*(4), 4396–4415. https://doi.org/10.1109/TPAMI.2022.3195549

Zou, Z., Chen, K., Shi, Z., Guo, Y., & Ye, J. (2023). Object detection in 20 years: A survey. *Proceedings of the IEEE, 111*(3), 257–276. https://doi.org/10.1109/JPROC.2023.3238524

Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLO (Version 8.0.0)* [Computer software]. Zenodo. https://doi.org/10.5281/zenodo.7867787

فصل دوم

مبانی نظری و پیشینه پژوهش

2-1 مبانی نظری پسماند دریایی و ضرورت پایش هوشمند

پسماند دریایی یکی از مسائل پیچیده زیست‌محیطی در مقیاس جهانی است که منشأ آن به ورود، رهاسازی یا انتقال مواد ساخته‌شده توسط انسان به محیط‌های دریایی و ساحلی بازمی‌گردد. این پسماندها می‌توانند شامل پلاستیک، منسوجات، فلزات، لاستیک، تجهیزات ماهیگیری، تور، طناب، قطعات تجهیزات دریایی و سایر اشیای انسانی باشند. برخلاف بسیاری از آلاینده‌های موضعی، پسماندهای دریایی می‌توانند تحت تأثیر جریان‌های آبی، باد، امواج و فعالیت‌های انسانی در مناطق وسیعی جابه‌جا شوند و در محیط‌های سطحی، ستون آب، بستر دریا و مناطق ساحلی تجمع یابند.

اهمیت پایش پسماند دریایی تنها به تعیین مقدار مواد موجود در یک منطقه محدود نمی‌شود. داده‌های پایش می‌توانند برای شناخت الگوهای پراکنش، شناسایی مناطق تجمع، بررسی تغییرات زمانی، ارزیابی اثربخشی برنامه‌های کاهش آلودگی و پشتیبانی از تصمیم‌گیری‌های مدیریتی مورد استفاده قرار گیرند. به همین دلیل، کیفیت، تکرارپذیری و مقیاس‌پذیری فرایند پایش نقش مهمی در قابلیت استفاده از داده‌های حاصل از آن دارند.

در روش‌های سنتی، شناسایی و ثبت پسماند معمولاً بر مشاهده مستقیم، نمونه‌برداری میدانی یا بررسی دستی تصاویر متکی است. اگرچه این روش‌ها همچنان اهمیت علمی و کاربردی دارند، افزایش حجم داده‌های تصویری باعث شده است که تحلیل دستی به یک گلوگاه عملیاتی تبدیل شود. گسترش استفاده از دوربین‌های زیرآبی، وسایل نقلیه هدایت‌پذیر از راه دور، وسایل نقلیه خودکار زیرآبی، سامانه‌های تصویربرداری ساحلی و پهپادها، امکان جمع‌آوری حجم قابل‌توجهی از تصاویر را فراهم کرده است. در چنین شرایطی، توسعه سامانه‌هایی که بتوانند اشیای مرتبط با پسماند را به‌صورت خودکار شناسایی و مکان‌یابی کنند، اهمیت روزافزونی پیدا کرده است.

با این حال، استفاده از تصاویر برای پایش پسماند دریایی صرفاً مسئله‌ای مربوط به افزایش سرعت پردازش نیست. عملکرد سامانه‌های مبتنی بر تصویر به کیفیت داده، شرایط تصویربرداری، تنوع محیط، اندازه و ظاهر اشیا و

قابلیت تعمیم الگوریتم وابسته است. بنابراین، توسعه سامانه‌های هوشمند پایش مستلزم درک هم‌زمان مسئله زیست‌محیطی، ویژگی‌های داده‌های تصویری و محدودیت‌های الگوریتم‌های بینایی ماشین است.

در این چارچوب، تشخیص خودکار اشیا می‌تواند به‌عنوان یکی از فناوری‌های کلیدی برای پردازش داده‌های تصویری دریایی مطرح شود. برخلاف طبقه‌بندی تصویر که معمولاً یک یا چند برچسب را به کل تصویر اختصاص می‌دهد، تشخیص شیء قادر است نوع و موقعیت تقریبی هر شیء موجود در تصویر را تعیین کند. این ویژگی برای کاربردهای پایش دریایی اهمیت زیادی دارد، زیرا یک تصویر ممکن است شامل چندین شیء، گونه‌های زیستی، پوشش گیاهی و انواع مختلف پسماند باشد.

2-2 بینایی ماشین و تشخیص شیء

2-2-1 مفهوم تشخیص شیء

تشخیص شیء یکی از مسائل بنیادی بینایی ماشین است که هدف آن تعیین کلاس اشیا و مکان آن‌ها در یک تصویر است. خروجی یک آشکارساز معمولاً شامل مجموعه‌ای از پیش‌بینی‌ها است که هر یک از آن‌ها شامل برچسب کلاس، مختصات ناحیه محدودکننده و یک مقدار اطمینان است.

در یک مسئله تشخیص شیء، مدل باید علاوه بر پاسخ به این پرسش که «چه شیئی در تصویر وجود دارد»، بتواند مشخص کند «شیء در کدام قسمت تصویر قرار گرفته است». این ویژگی، تشخیص شیء را از طبقه‌بندی تصویر متمایز می‌کند و باعث می‌شود این فناوری برای کاربردهایی مانند پایش محیطی، رباتیک، ناوبری خودکار و نظارت تصویری مناسب باشد.

پیشرفت تشخیص شیء در دو دهه اخیر از روش‌های مبتنی بر استخراج ویژگی‌های دستی به معماری‌های یادگیری عمیق منجر شده است. در روش‌های قدیمی‌تر، ویژگی‌هایی مانند لبه، بافت، گرادیان یا الگوهای هندسی به‌صورت دستی طراحی می‌شدند و سپس یک طبقه‌بند برای تصمیم‌گیری مورد استفاده قرار می‌گرفت. محدودیت اصلی این روش‌ها وابستگی شدید عملکرد به کیفیت ویژگی‌های طراحی‌شده بود.

با ظهور شبکه‌های عصبی عمیق و شبکه‌های کانولوشنی، فرایند استخراج ویژگی و یادگیری تصمیم‌گیری در یک چارچوب یکپارچه قرار گرفت. مدل‌های جدید قادر شدند نمایش‌های سلسله‌مراتبی از داده‌ها را به‌صورت خودکار یاد بگیرند. در این نمایش‌ها، لایه‌های ابتدایی معمولاً ویژگی‌های ساده‌تر و لایه‌های عمیق‌تر الگوهای پیچیده‌تر و معنایی‌تر را استخراج می‌کنند.

مرور جامع Zou و همکاران (2023) نشان می‌دهد که توسعه تشخیص شیء مدرن را می‌توان به‌صورت تحول از روش‌های مبتنی بر ویژگی‌های دستی به آشکارسازهای عمیق، شبکه‌های تک‌مرحله‌ای، روش‌های مبتنی بر Transformer و سامانه‌های end-to-end در نظر گرفت.

2-2-2 آشکارسازهای دومرحله‌ای و تک‌مرحله‌ای

یکی از دسته‌بندی‌های متداول در تشخیص شیء، تقسیم آشکارسازها به روش‌های دومرحله‌ای و تک‌مرحله‌ای است.

در آشکارسازهای دومرحله‌ای، ابتدا نواحی احتمالی شامل شیء تولید می‌شوند و سپس این نواحی از نظر کلاس و مکان دقیق بررسی می‌شوند. خانواده R-CNN از نمونه‌های شناخته‌شده این رویکرد هستند. مزیت اصلی این روش‌ها در بسیاری از کاربردها دقت بالا بوده است، اما مراحل متعدد پردازش می‌توانند هزینه محاسباتی و زمان استنتاج را افزایش دهند.

در مقابل، آشکارسازهای تک‌مرحله‌ای تلاش می‌کنند پیش‌بینی مکان و کلاس اشیا را در یک فرایند یکپارچه انجام دهند. خانواده YOLO و بسیاری از آشکارسازهای متراکم در این گروه قرار می‌گیرند. این رویکرد به دلیل ساختار ساده‌تر فرایند استنتاج و امکان دستیابی به سرعت بالا، در کاربردهای نزدیک به بلادرنگ اهمیت زیادی پیدا کرده است.

با این حال، تقسیم‌بندی صرف مدل‌ها به تک‌مرحله‌ای و دومرحله‌ای برای توصیف تمام معماری‌های جدید کافی نیست. ظهور Transformerها در بینایی ماشین و توسعه آشکارسازهای end-to-end، رویکردهای جدیدی را ایجاد کرده است که برخی از مراحل سنتی تشخیص شیء را بازطراحی یا حذف می‌کنند. RT-DETR-L نمونه‌ای از این تحول است.

بنابراین، مقایسه معماری‌های جدید تشخیص شیء تنها مقایسه بین چند مدل نرم‌افزاری نیست، بلکه مقایسه میان فلسفه‌های مختلف طراحی برای استخراج ویژگی، نمایش اشیا، تخصیص نمونه‌ها و تولید خروجی تشخیص است.

2-3 چالش‌های تشخیص شیء در محیط‌های دریایی و زیرآبی

2-3-1 ویژگی‌های خاص تصاویر زیرآبی

تشخیص شیء در تصاویر زیرآبی با چالش‌هایی مواجه است که در بسیاری از مجموعه‌داده‌های متعارف بینایی ماشین وجود ندارد یا شدت آن‌ها کمتر است. آب محیطی با ویژگی‌های نوری پیچیده است و انتشار نور در آن تحت تأثیر جذب و پراکندگی قرار می‌گیرد.

با افزایش فاصله میان دوربین و شیء، بخشی از اطلاعات نوری کاهش یافته و در نتیجه وضوح و کنتراست تصویر ممکن است کاهش یابد. همچنین طول‌موج‌های مختلف نور به‌صورت یکسان در آب منتقل نمی‌شوند. این مسئله می‌تواند باعث تغییر ظاهر رنگی اجسام شود.

پراکندگی نور توسط ذرات معلق نیز می‌تواند موجب کاهش وضوح و ایجاد نوعی مه یا کدری در تصویر شود. افزون بر این، حرکت دوربین، حرکت آب، حرکت اشیا یا شرایط تصویربرداری می‌تواند تاری ایجاد کند.

Er و همکاران (2023) مجموعه‌ای از چالش‌های اصلی تشخیص اشیای دریایی زیرآبی را شامل کاهش کیفیت تصویر، تغییرات نور، کوچک بودن اشیا، پیچیدگی پس‌زمینه، شباهت ظاهری برخی اشیا، تغییر مقیاس و محدودیت منابع محاسباتی معرفی کرده‌اند.

این عوامل باعث می‌شوند که عملکرد مدل تنها تابع معماری نباشد. در عمل، کیفیت و تنوع داده‌های آموزشی، میزان شباهت داده‌های آموزش و آزمون و نوع تغییرات محیطی نیز نقش تعیین‌کننده‌ای دارند.

2-3-2 کوچک بودن و تغییر مقیاس اشیا

یکی از چالش‌های مهم در تشخیص پسماند دریایی، تغییر قابل‌توجه اندازه اشیا در تصویر است. اندازه ظاهری یک شیء می‌تواند بر اساس فاصله دوربین، زاویه دید، فاصله کانونی و ابعاد واقعی شیء تغییر کند.

اشیای کوچک معمولاً اطلاعات پیکسلی محدودی در اختیار مدل قرار می‌دهند. در نتیجه، استخراج ویژگی‌های متمایزکننده دشوارتر می‌شود. این مسئله در محیط‌های زیرآبی با کاهش کیفیت تصویر ترکیب شده و تشخیص اشیای کوچک را پیچیده‌تر می‌کند.

از سوی دیگر، یک نوع پسماند ممکن است در فاصله‌های مختلف ظاهرهای بسیار متفاوتی داشته باشد. بنابراین، مدل باید بتواند الگوهای یک شیء را در مقیاس‌های مختلف تشخیص دهد.

2-3-3 پیچیدگی پس‌زمینه

محیط بستر دریا و محیط‌های ساحلی می‌توانند شامل سنگ، شن، گیاه، مرجان، موجودات زنده و ساختارهای طبیعی یا مصنوعی باشند. برخی از این عناصر ممکن است از نظر شکل، رنگ یا بافت به پسماند شباهت داشته باشند.

برای مثال، یک قطعه پلاستیک ممکن است از نظر رنگ یا شکل با بخشی از پوشش گیاهی یا عناصر طبیعی محیط شباهت داشته باشد. همچنین تور، طناب یا پارچه می‌توانند شکل‌های انعطاف‌پذیر و بسیار متغیری داشته باشند.

این مسئله باعث می‌شود که تشخیص پسماند تنها به شناسایی الگوهای ساده بصری محدود نباشد و مدل نیازمند یادگیری نمایش‌های مقاوم‌تر و عمومی‌تر باشد.

2-3-4 عدم توازن کلاس‌ها

در بسیاری از مجموعه‌داده‌های تشخیص شیء، تعداد نمونه‌های کلاس‌ها یکسان نیست. برخی انواع اشیا تعداد زیادی نمونه دارند، در حالی که برخی کلاس‌ها به‌ندرت مشاهده می‌شوند.

این مسئله در داده‌های پسماند دریایی نیز اهمیت دارد، زیرا فراوانی واقعی انواع مختلف پسماند در محیط یکسان نیست و علاوه بر آن، برخی اشیا به‌دلیل ویژگی‌های تصویربرداری دشوارتر شناسایی می‌شوند.

عدم توازن کلاس‌ها می‌تواند موجب شود که یک مدل در یادگیری کلاس‌های پرتکرار عملکرد بهتری داشته باشد، اما در کلاس‌های کم‌نمونه ضعیف‌تر عمل کند. بنابراین، تفسیر عملکرد کلی باید در کنار بررسی رفتار مدل در سطح کلاس انجام شود.

2-4 مجموعه‌داده‌های پسماند دریایی

2-4-1 نقش مجموعه‌داده در یادگیری عمیق

در یادگیری عمیق، مجموعه‌داده تنها یک ورودی جانبی برای مدل نیست، بلکه بخش مهمی از مسئله یادگیری را تعریف می‌کند. مدل الگوهای موجود در داده‌های آموزشی را یاد می‌گیرد و کیفیت تعمیم آن تا حد زیادی به میزان تنوع، کیفیت برچسب‌ها و نمایندگی داده‌ها وابسته است.

در نتیجه، مقایسه مدل‌ها زمانی معتبرتر خواهد بود که تفاوت در داده‌های آموزشی، تعریف کلاس‌ها یا ساختار آزمون موجب ایجاد سوگیری در نتیجه نشود.

در کاربردهای تخصصی مانند تشخیص پسماند دریایی، مسئله مجموعه‌داده اهمیت بیشتری پیدا می‌کند؛ زیرا داده‌ها معمولاً از محیط‌های محدود، دوربین‌های خاص یا شرایط تصویربرداری مشخص جمع‌آوری شده‌اند.

2-4-2 مجموعه‌داده Trash-ICRA19

Trash-ICRA19 یکی از مجموعه‌داده‌های شناخته‌شده در حوزه تشخیص پسماند زیرآبی است که برای پشتیبانی از پژوهش‌های مرتبط با رباتیک دریایی و تشخیص خودکار زباله طراحی شده است.

Fulton و همکاران (2019) استفاده از مدل‌های تشخیص عمیق برای شناسایی پسماند دریایی را در زمینه رباتیک مورد بررسی قرار دادند. این مجموعه‌داده دارای برچسب‌های ناحیه محدودکننده است و از این نظر برای مسئله object detection مناسب است.

اهمیت Trash-ICRA19 در این است که مسئله تشخیص پسماند را از یک مسئله صرفاً طبقه‌بندی‌شده به مسئله مکان‌یابی و شناسایی هم‌زمان اشیا نزدیک می‌کند.

2-4-3 مجموعه‌داده TrashCan

مجموعه‌داده TrashCan یکی دیگر از منابع مهم در پژوهش‌های مرتبط با تحلیل تصاویر زیرآبی و پسماند دریایی است. این مجموعه‌داده علاوه بر پسماند، شامل عناصر طبیعی و مصنوعی دیگری نیز است و امکان مطالعه تعامل میان اشیای زیستی و پسماندهای انسانی را فراهم می‌کند.

Hong و همکاران (2020) مجموعه‌داده TrashCan را با هدف توسعه پژوهش‌های مرتبط با تشخیص و درک بصری پسماند دریایی ارائه کردند. وجود تنوع در محیط‌ها و اشیای موجود در این داده‌ها باعث شده است که TrashCan به یکی از منابع مهم برای توسعه و ارزیابی روش‌های یادگیری عمیق در این حوزه تبدیل شود.

با وجود اهمیت این مجموعه‌داده، استفاده مستقیم از آن در ترکیب با سایر داده‌ها نیازمند توجه به تفاوت‌های برچسب‌گذاری و ساختار taxonomy است.

2-4-4 داده‌های سطحی و گسترش تنوع دامنه تصویری

بخش مهمی از مسئله تعمیم‌پذیری مدل‌ها به تنوع محیط تصویربرداری وابسته است. داده‌های زیرآبی و داده‌های سطحی می‌توانند از نظر پس‌زمینه، نور، زاویه دید، فاصله دوربین، رنگ، شرایط جوی و ظاهر اشیا تفاوت قابل‌توجهی داشته باشند.

به همین دلیل، استفاده از داده‌های چندمنبعی می‌تواند تنوع مشاهده‌شده توسط مدل را افزایش دهد. با این حال، افزایش تنوع به‌تنهایی تضمین‌کننده بهبود عملکرد نیست.

ترکیب داده‌ها در صورتی می‌تواند مفید باشد که ساختار مفهومی کلاس‌ها، کیفیت برچسب‌ها و ناسازگاری‌های احتمالی میان منابع مورد بررسی قرار گیرد.

2-5 یکپارچه‌سازی داده‌های چندمنبعی

یکی از ارکان اساسی پژوهش حاضر، ایجاد یک مجموعه‌داده یکپارچه از منابع تصویری ناهمگون است. در مسائل تشخیص شیء در محیط‌های دریایی، داده‌های تصویری ممکن است از نظر محیط تصویربرداری، کیفیت تصویر، شرایط نوری، عمق، کدورت، نوع حسگر، زاویه دید و ساختار برچسب‌گذاری تفاوت قابل توجهی داشته باشند. بنابراین، ترکیب چند منبع داده تنها با الحاق فایل‌های تصویری به یکدیگر نمی‌تواند به ایجاد یک مجموعه‌داده مناسب برای آموزش و ارزیابی مدل‌های یادگیری عمیق منجر شود.

در پژوهش حاضر، یکپارچه‌سازی داده به‌عنوان فرایندی چندمرحله‌ای در نظر گرفته شده است که طی آن منابع مختلف از نظر **ساختار داده، تعریف کلاس‌ها، نظام برچسب‌گذاری و کیفیت annotation** به یک چارچوب مشترک نزدیک می‌شوند. هدف این فرایند، ایجاد یک فضای داده‌ای یکسان است که بتواند بدون تغییر در تعریف مسئله، برای آموزش و ارزیابی سه معماری YOLOv8n، RT-DETR-L و RTMDet-Tiny مورد استفاده قرار گیرد.

اهمیت این موضوع از آنجا ناشی می‌شود که مجموعه‌داده‌های مختلف معمولاً برای اهداف یکسانی ایجاد نشده‌اند. ممکن است یک شیء در یک مجموعه‌داده به‌صورت یک کلاس مستقل تعریف شده باشد، در حالی که همان شیء در منبعی دیگر در یک گروه عمومی‌تر قرار گرفته باشد. همچنین ممکن است برخی منابع علاوه بر پسماند، عناصر زیستی، تجهیزات تصویربرداری یا سایر اجزای محیط را نیز برچسب‌گذاری کرده باشند. در چنین شرایطی، استفاده مستقیم از برچسب‌های اولیه می‌تواند موجب ایجاد کلاس‌های هم‌معنا، هم‌پوشانی معنایی یا حتی تعارض در تعریف کلاس‌ها شود.

ازاین‌رو، در پژوهش حاضر یکپارچه‌سازی داده به‌صورت زنجیره‌ای از مراحل **بررسی منابع، تحلیل ساختار برچسب‌ها، هماهنگ‌سازی Taxonomy، کنترل کیفیت annotation و ایجاد ساختار نهایی مشترک** در نظر گرفته شده است. این رویکرد باعث می‌شود تفاوت عملکرد مدل‌ها تا حد امکان ناشی از تفاوت معماری و رفتار الگوریتمی آن‌ها باشد، نه ناشی از استفاده از فضای برچسب یا ساختار داده متفاوت.

2-5-1 مفهوم و چارچوب یکپارچه‌سازی داده

داده‌های مورد استفاده در پژوهش حاضر از ترکیب سه منبع اصلی شامل **Trash-ICRA19، TrashCan-10-DatasetNinja و داده‌های تصویری سطحی مرتبط با NOAA** تشکیل شده‌اند. این منابع از نظر منشأ داده و شرایط تصویربرداری یکسان نیستند و هر یک بخشی از فضای بصری مسئله را پوشش می‌دهند.

مجموعه‌داده Trash-ICRA19 شامل تصاویر واقعی زیرآبی با حاشیه‌گذاری جعبه‌ای است. این مجموعه از داده‌های J-EDI استخراج شده و شامل 5,700 تصویر است که نمونه‌هایی از پسماند، موجودات زیستی و ROV را در

محیط‌های واقعی زیرآبی دربرمی‌گیرد. تنوع کیفیت تصویر، عمق، شرایط نور، وضعیت اشیا، پوشیدگی و رشد زیستی از ویژگی‌های مهم این منبع است.

مجموعه TrashCan نیز از تصاویر زیرآبی استخراج‌شده از آرشیو J-EDI تشکیل شده است و در نسخه معرفی‌شده توسط آزمایشگاه iRVLab شامل 7,212 تصویر حاشیه‌گذاری‌شده است. برخلاف Trash-ICRA19، annotation اصلی TrashCan بر مبنای **instance segmentation** ارائه شده است؛ یعنی ناحیه مربوط به هر نمونه به‌صورت ماسک مشخص شده است. این مجموعه علاوه بر پسماند، ROV و طیف متنوعی از گیاهان و جانوران زیرآبی را نیز شامل می‌شود.

سومین مؤلفه، داده‌های تصویری سطحی مرتبط با برنامه **Marine Debris Monitoring and Assessment Project (MDMAP)** وابسته به NOAA است. این برنامه با هدف ثبت و پایش مقدار و نوع پسماندهای دریایی در خطوط ساحلی توسعه یافته و از یک چارچوب استاندارد برای ثبت و دسته‌بندی پسماند استفاده می‌کند. NOAA در راهنمای رسمی خود، اقلام پسماند را بر اساس ماده و سپس نوع شیء دسته‌بندی می‌کند.

نکته مهم در مورد این مؤلفه آن است که داده‌های NOAA از نظر ماهیت با دو منبع زیرآبی یکسان نیستند. MDMAP اساساً یک چارچوب پایش و ثبت پسماند ساحلی است و نه یک benchmark تشخیص شیء زیرآبی. بنابراین، استفاده از داده‌های آن در پژوهش حاضر به‌عنوان **منبع مکمل با شرایط تصویری متفاوت** تعریف می‌شود، نه به‌عنوان مجموعه‌داده‌ای کاملاً هم‌ساخت با Trash-ICRA19 و TrashCan.

این تفاوت برای پژوهش حاضر اهمیت دارد، زیرا یکی از اهداف ادغام داده‌ها افزایش تنوع شرایط مشاهده است. به بیان دیگر، داده‌های زیرآبی بخش اصلی محیط مورد مطالعه را پوشش می‌دهند، در حالی که داده‌های سطحی می‌توانند دامنه شرایط تصویری و ظاهری اشیای هدف را گسترش دهند.

2-5-1-1 منطق استفاده از منابع چندگانه

استفاده از چند منبع داده در این پژوهش صرفاً با هدف افزایش تعداد تصاویر انجام نشده است. مهم‌تر از حجم داده، **تنوع توزیع تصویری** است. در محیط‌های دریایی، ظاهر یک شیء می‌تواند تحت تأثیر عواملی مانند شدت و جهت نور، کدورت آب، عمق، پس‌زمینه، زاویه مشاهده، پوشیدگی، تغییرشکل فیزیکی و رشد زیستی قرار گیرد.

برای مثال، یک قطعه پلاستیکی ممکن است در یک تصویر زیرآبی به دلیل کاهش کنتراست و پراکندگی نور، مرز مشخصی نداشته باشد، در حالی که نمونه مشابه در یک تصویر سطحی با نور طبیعی و پس‌زمینه متفاوت ظاهر شود. در نتیجه، قرار گرفتن مدل در معرض شرایط تصویری متنوع‌تر می‌تواند زمینه مناسبی برای مطالعه قابلیت تعمیم آن فراهم کند.

بااین‌حال، افزایش تنوع داده بدون کنترل کیفیت می‌تواند اثر معکوس داشته باشد. تفاوت میان منابع ممکن است به اختلاف در تعریف کلاس‌ها، کیفیت annotation، توزیع کلاس‌ها و ساختار داده منجر شود. ازاین‌رو، ادغام منابع باید با یک فرایند کنترل‌شده و مبتنی بر یک taxonomy مشترک انجام شود.

به همین دلیل، در پژوهش حاضر، مفهوم **data integration** به معنای «الحاق ساده تصاویر» نیست، بلکه به معنای ایجاد یک مجموعه‌داده هماهنگ‌شده از منابع ناهمگون است که پس از یکسان‌سازی فضای برچسب و کنترل کیفیت annotation، برای مسئله تشخیص شیء مورد استفاده قرار می‌گیرد.

2-5-2 هماهنگ‌سازی Taxonomy و منطق شکل‌گیری ۱۳ کلاس نهایی

هماهنگ‌سازی نظام طبقه‌بندی یا **Taxonomy** در پژوهش حاضر صرفاً به یکسان‌سازی نام کلاس‌ها محدود نمی‌شود، بلکه یکی از مراحل اساسی در ایجاد یک فضای برچسب‌گذاری مشترک برای مجموعه‌داده نهایی است. داده‌های مورد استفاده از ترکیب سه منبع **TrashCan-10-DatasetNinja،Trash-ICRA19 و داده‌های تصویری سطحی NOAA** تشکیل شده‌اند. این منابع از نظر منشأ داده، شرایط تصویربرداری، نوع اشیا، ساختار برچسب‌گذاری و سطح جزئیات طبقه‌بندی کاملاً یکسان نیستند. ازاین‌رو، استفاده مستقیم از برچسب‌های اولیه منابع مختلف می‌تواند به ایجاد کلاس‌های هم‌معنا، کلاس‌های دارای هم‌پوشانی معنایی یا برچسب‌هایی با تعریف متفاوت منجر شود.

در پژوهش حاضر، هماهنگ‌سازی Taxonomy با هدف ایجاد **یک فضای برچسب مشترک، سازگار و قابل استفاده برای آموزش و ارزیابی هر سه معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny** انجام شده است. بنابراین، پس از بررسی محتوای منابع، روابط میان برچسب‌ها و قابلیت تفکیک بصری نمونه‌ها، ساختار نهایی در قالب **۱۳ کلاس مستقل** تعریف شده است. این ۱۳ کلاس برای هر سه مدل یکسان هستند و هیچ‌یک از مدل‌ها با Taxonomy متفاوت آموزش داده نمی‌شوند.

منطق شکل‌گیری این ساختار بر سه اصل استوار است. نخست، تا حد امکان باید اطلاعات معنادار موجود در منابع اولیه حفظ شود و حذف کلاس‌ها تنها با هدف کاهش تعداد برچسب‌ها انجام نشود. دوم، در تصاویر دریایی تنها پسماند مشاهده نمی‌شود و عناصر زیستی و محیطی نیز در کنار اشیای هدف حضور دارند؛ بنابراین، وجود برخی کلاس‌های غیرپسماندی برای بازنمایی فضای بصری مسئله اهمیت دارد. سوم، برای مقایسه عادلانه مدل‌ها، تمام معماری‌ها باید دقیقاً با **فضای برچسب یکسان** آموزش و ارزیابی شوند؛ زیرا تغییر تعداد یا تعریف کلاس‌ها می‌تواند مستقیماً بر دشواری مسئله و مقادیر معیارهای ارزیابی اثر بگذارد.

از نظر محتوایی، ۱۳ کلاس نهایی در سه گروه اصلی قرار می‌گیرند: **۶ کلاس جانوری، ۱ کلاس گیاهی و ۶ کلاس مربوط به پسماندها و بقایای اشیای هدف**.

جدول 2-1. ساختار نهایی ۱۳ کلاس مورد استفاده در پژوهش

شرح محتوای کلاس	نام کلاس	ردیف	گروه محتوایی
خرچنگ‌ها و نمونه‌های متناظر با این رده جانوری	animal_crab	1	جانوران دریایی
مارماهی‌ها و جانوران دریایی کشیده و مارمانند	animal_eel	2	جانوران دریایی
سایر جانوران دریایی که در گروه‌های اختصاصی دیگر قرار نمی‌گیرند	animal_etc	3	جانوران دریایی
ماهی‌ها و نمونه‌های مربوط به گروه ماهیان	animal_fish	4	جانوران دریایی
صدف‌ها و ساختارهای پوسته‌ای دریایی	animal_shells	5	جانوران دریایی
ستاره‌های دریایی و نمونه‌های متناظر	animal_starfish	6	جانوران دریایی
گیاهان دریایی، جلبک‌ها و سایر عناصر گیاهی یا گیاه‌مانند	plant	7	عناصر گیاهی
شاخه‌ها، قطعات چوبی و نمونه‌های شاخه‌مانند مطابق تعریف کلاسی داده	trash_branch	8	پسماندها و بقایای اشیای هدف
پوشاک، پارچه و سایر نمونه‌های منسوجاتی	trash_clothing	9	پسماندها و بقایای اشیای هدف
تورها، ساختارهای مشبک و بقایای مشابه تجهیزات شبکه‌ای	trash_net	10	پسماندها و بقایای اشیای هدف
نمونه‌های پسماندی که نوع اختصاصی آن‌ها از اطلاعات بصری قابل تعیین نیست	trash_unknown_instance	11	پسماندها و بقایای اشیای هدف
بقایا و قطعات نامنظم یا تخریب‌شده فاقد طبقه اختصاصی	trash_wreckage	12	پسماندها و بقایای اشیای هدف
اشیای پلاستیکی و قطعات پسماند پلاستیکی	trash_plastic	13	پسماندها و بقایای اشیای هدف

مجموع: ۱۳ کلاس شامل ۶ کلاس جانوری، ۱ کلاس گیاهی و ۶ کلاس در گروه trash.

منطق حضور کلاس‌های جانوری

شش کلاس animal_crab، animal_eel، animal_etc، animal_fish، animal_shells و animal_starfish به دلیل حضور عناصر جانوری در منابع تصویری در Taxonomy نهایی حفظ شده‌اند. تصاویر زیرآبی موجود در منابع مورد استفاده صرفاً شامل پسماند نیستند و موجودات زنده نیز در بسیاری از صحنه‌ها حضور دارند. برای نمونه، TrashCan به‌طور رسمی شامل پسماند، ROV و طیفی از گیاهان و جانوران زیرآبی معرفی شده است.

حفظ این کلاس‌ها باعث می‌شود فضای تصویری مسئله به یک محیط مصنوعی شامل «پسماند در برابر پس‌زمینه خنثی» محدود نشود. این موضوع از دیدگاه تشخیص شیء اهمیت دارد، زیرا عناصر زیستی ممکن است بر اساس شکل، بافت، اندازه یا رنگ با برخی پسماندها شباهت داشته باشند.

در این میان، animal_etc نقش یک کلاس عمومی را ایفا می‌کند و نمونه‌های جانوری را که در گروه‌های اختصاصی مانند ماهی، خرچنگ، مارماهی یا ستاره دریایی قرار نمی‌گیرند، پوشش می‌دهد. این ساختار امکان حفظ تنوع جانوری را بدون افزایش غیرضروری تعداد کلاس‌های بسیار خاص فراهم می‌کند.

منطق حضور کلاس plant

کلاس plant به عناصر گیاهی و گیاه‌مانند موجود در تصاویر اختصاص دارد. وجود این کلاس از آن جهت اهمیت دارد که عناصر گیاهی بخشی از محیط طبیعی تصاویر دریایی هستند و می‌توانند از نظر رنگ، بافت و ساختار با برخی پسماندها شباهت داشته باشند.

به‌عنوان نمونه، ساختارهای رشته‌ای یا متراکم گیاهی ممکن است از نظر ظاهر با تور یا سایر اشیای انعطاف‌پذیر مشابهت داشته باشند. در نتیجه، حفظ این کلاس به مدل امکان می‌دهد بخشی از عناصر طبیعی محیط را از اشیای هدف تفکیک کند.

منطق حضور کلاس‌های گروه trash

شش کلاس trash_branch، trash_clothing، trash_net، trash_unknown_instance، trash_wreckage و trash_plastic بخش مربوط به پسماندها و بقایای اشیای هدف را تشکیل می‌دهند.

کلاس trash_plastic برای نمونه‌های پلاستیکی و قطعات پسماند پلاستیکی تعریف شده است. این گروه از نظر شکل، اندازه، میزان تغییرشکل و وضعیت فیزیکی تنوع زیادی دارد؛ بنابراین، حفظ آن به‌عنوان یک کلاس مستقل امکان تحلیل عملکرد مدل در برابر پسماندهای پلاستیکی را فراهم می‌کند.

کلاس trash_net به تورها و ساختارهای مشبک اختصاص دارد. ساختار پراکنده و شبکه‌ای این اشیا ممکن است باعث شود بخشی از شیء با پس‌زمینه ترکیب شود و تشخیص مرز آن دشوارتر شود.

کلاس trash_clothing نمونه‌های پوشاک و منسوجات را پوشش می‌دهد. انعطاف‌پذیری این اشیا می‌تواند موجب تغییر شکل هندسی قابل توجه در تصاویر مختلف شود و در نتیجه، یک نمونه مشابه ممکن است با الگوهای ظاهری متفاوتی مشاهده شود.

کلاس trash_branch برای نمونه‌هایی تعریف شده است که مطابق Taxonomy نهایی در این گروه قرار گرفته‌اند. از نظر تفسیر علمی، نباید صرفاً از نام این کلاس نتیجه گرفت که تمام نمونه‌های آن الزاماً «پسماند مصنوعی» هستند. بنابراین، در تحلیل نتایج، تعریف عملیاتی کلاس و ویژگی بصری نمونه‌های موجود در مجموعه‌داده ملاک قرار می‌گیرد.

کلاس trash_wreckage نمونه‌هایی از بقایا و قطعات نامنظم یا تخریب‌شده را دربرمی‌گیرد که نمی‌توان آن‌ها را با اطمینان در یکی از گروه‌های اختصاصی دیگر قرار داد.

در نهایت، trash_unknown_instance برای نمونه‌هایی در نظر گرفته شده است که در چارچوب داده به‌عنوان پسماند شناسایی شده‌اند، اما تعیین نوع اختصاصی آن‌ها بر اساس اطلاعات بصری موجود امکان‌پذیر نیست. چنین وضعیتی می‌تواند در اثر پوشیدگی، تخریب، اندازه کوچک، کیفیت پایین تصویر، مشاهده ناقص یا شکل غیرمعمول شیء ایجاد شود. وجود این کلاس از تحمیل برچسب تخصصی و غیرقابل‌اعتماد به نمونه‌های مبهم جلوگیری می‌کند.

منطق کلی انتخاب ۱۳ کلاس

عدد ۱۳ در Taxonomy نهایی یک انتخاب صرفاً قراردادی برای افزایش یا کاهش پیچیدگی مدل نیست، بلکه نتیجه فرایند هماهنگ‌سازی ساختار برچسب‌گذاری منابع و تعریف یک فضای برچسب مشترک است.

از این منظر، کلاس‌های غیرپسماندی مانند animal_* و plant به‌عنوان پسماند تعریف نشده‌اند، بلکه بخشی از محتوای تصویری محیط را بازنمایی می‌کنند که مدل باید بتواند از پسماندها تفکیک کند. در مقابل، گروه trash_* بخش مربوط به پسماندها و بقایای اشیای هدف را تشکیل می‌دهد.

همچنین، Taxonomy نهایی باید در تمام مراحل مقایسه ثابت باقی بماند. به این معنا که **YOLOv8n، RT-DETR-L و RTMDet-Tiny هر سه با همین ۱۳ کلاس آموزش و ارزیابی می‌شوند** و هیچ‌یک از مدل‌ها از تعداد کلاس، تعریف کلاس یا فضای برچسب متفاوت استفاده نمی‌کند.

این ثبات امکان مقایسه عملکرد مدل‌ها را در سطح کلی و همچنین در سطح کلاس فراهم می‌کند. در نتیجه، می‌توان بررسی کرد که آیا یک معماری در تشخیص پسماندهای پلاستیکی، ساختارهای مشبک، نمونه‌های نامشخص یا عناصر زیستی عملکرد متفاوتی نسبت به معماری‌های دیگر دارد.

بنابراین:

1 (Plant) + 6 (Trash) + (Animal) 6 = 13

این ساختار به‌عنوان **فضای برچسب مشترک نهایی پژوهش** در آموزش و ارزیابی سه مدل مورد مطالعه مورد استفاده قرار می‌گیرد.

2-5-3 کیفیت Annotation و کنترل سازگاری برچسب‌ها

پس از تعیین Taxonomy مشترک، مرحله بعدی اطمینان از کیفیت و سازگاری annotationها است. در مسائل تشخیص شیء، annotation صرفاً اطلاعات جانبی درباره تصاویر نیست، بلکه مستقیماً تعریف هدف یادگیری را تعیین می‌کند. هر نمونه آموزشی از نظر مدل شامل رابطه‌ای میان **تصویر، موقعیت مکانی شیء و برچسب کلاس** است؛ بنابراین، خطا در هر یک از این مؤلفه‌ها می‌تواند بر فرایند یادگیری و در نهایت بر ارزیابی مدل اثر بگذارد.

در ساده‌ترین حالت، annotation یک شیء را می‌توان به صورت زیر نمایش داد:

$$Ai=(Bi,Ci)A_i=(B_i,C_i)$$

که در آن BiB_i نشان‌دهنده موقعیت مکانی شیء و CiC_i نشان‌دهنده کلاس آن است. در تشخیص شیء مبتنی بر bounding box، موقعیت شیء معمولاً با مختصات جعبه محدودکننده نمایش داده می‌شود. بنابراین، خطا در مختصات جعبه یا خطا در شناسه کلاس می‌تواند به شکل مستقیم ساختار هدف یادگیری را تغییر دهد.

2-5-3-1 خطاهای مکانی

یکی از مهم‌ترین انواع خطای annotation، خطا در تعیین مرز شیء است. این خطا می‌تواند به شکل‌های مختلفی رخ دهد؛ از جمله:

- جعبه‌ای که بخشی از شیء را حذف کرده است؛
- جعبه‌ای که بخش قابل توجهی از پس‌زمینه را دربرمی‌گیرد؛
- جابه‌جایی مختصات جعبه؛
- مختصات خارج از محدوده تصویر؛
- جعبه با عرض یا ارتفاع نامعتبر؛
- وجود annotation برای شیئی که در تصویر قابل مشاهده نیست.

این خطاها اهمیت ویژه‌ای دارند، زیرا مدل تشخیص شیء باید هم‌زمان محل شیء و کلاس آن را یاد بگیرد. در نتیجه، یک bounding box نامعتبر می‌تواند سیگنال آموزشی نادرستی ایجاد کند.

2-5-3-2 خطاهای طبقه‌بندی

نوع دوم خطا به شناسه کلاس مربوط می‌شود. در یک مجموعه‌داده چندمنبعی، ممکن است یک شیء مشابه در منابع مختلف با شناسه‌های متفاوت ذخیره شده باشد. بنابراین، صرف یکسان بودن نام فایل یا ساختار annotation به معنی یکسان بودن معنای کلاس نیست.

برای مثال، اگر یک منبع گروهی از اشیا را تحت یک کلاس عمومی قرار دهد و منبع دیگری همان گروه را به چند کلاس تخصصی تقسیم کند، استفاده مستقیم از شناسه‌های اولیه می‌تواند موجب ایجاد برچسب‌های ناسازگار شود. به همین دلیل، شناسه‌های کلاس باید پس از هماهنگ‌سازی Taxonomy به شناسه‌های نهایی تبدیل شوند.

در پژوهش حاضر، شناسه‌های کلاس نهایی در بازه صفر تا دوازده قرار گرفته و ترتیب آن‌ها برای هر سه مدل ثابت نگه داشته شده است. بنابراین، شناسه کلاس به‌تنهایی وابسته به منبع اولیه نیست، بلکه به **Taxonomy نهایی پژوهش** وابسته است.

2-5-3-3 سازگاری قالب annotation

علاوه بر محتوای annotation، قالب ذخیره‌سازی آن نیز باید یکسان و قابل تفسیر باشد. در مجموعه‌داده نهایی پژوهش، annotationها برای استفاده در سامانه‌های تشخیص شیء به قالب استاندارد مورد نیاز مدل‌ها تبدیل شده‌اند.

این تبدیل باید بدون تغییر معنای برچسب یا موقعیت مکانی شیء انجام شود. به عبارت دیگر، تبدیل قالب annotation نباید موجب جابه‌جایی مختصات، تغییر مقیاس نادرست یا تغییر شناسه کلاس شود.

از این منظر، فرایند آماده‌سازی داده باید سه ویژگی اصلی داشته باشد:

$$\text{Image} \leftrightarrow \text{Bounding Box} \leftrightarrow \text{Class ID}$$

به‌گونه‌ای که ارتباط میان این سه مؤلفه در تمام مراحل حفظ شود.

2-5-3-4 کنترل نمونه‌های مبهم

در داده‌های دریایی، برخی اشیا ممکن است به دلیل کدورت، پوشیدگی، تخریب، اندازه کوچک یا کیفیت پایین تصویر به‌طور کامل قابل تشخیص نباشند. حذف خودکار این نمونه‌ها لزوماً راهکار مناسبی نیست، زیرا حذف گسترده نمونه‌های دشوار می‌تواند توزیع واقعی مسئله را بیش از حد ساده کند.

در پژوهش حاضر، برای نمونه‌هایی که ماهیت آن‌ها به‌عنوان پسماند قابل تشخیص است اما تعیین نوع دقیق آن‌ها امکان‌پذیر نیست، کلاس trash_unknown_instance به‌عنوان یک گروه عمومی در نظر گرفته شده است. این رویکرد مانع از آن می‌شود که برای نمونه‌های مبهم، برچسب‌های تخصصی و غیرقابل اتکا اعمال شود.

بااین‌حال، نمونه‌ای که اساساً قابل تشخیص نیست یا annotation آن از نظر مکانی فاقد اعتبار است، نباید صرفاً با هدف افزایش حجم داده حفظ شود. بنابراین، میان **ابهام ذاتی شیء** و **خطای annotation** باید تمایز قائل شد.

2-5-3-5 کنترل کیفیت و اثر آن بر مقایسه مدل‌ها

کیفیت annotation تنها بر عملکرد یک مدل منفرد اثر نمی‌گذارد، بلکه مستقیماً بر اعتبار مقایسه میان مدل‌ها نیز تأثیر دارد. اگر یک بخش از داده دارای annotationهای نادرست باشد، تمام مدل‌هایی که با آن داده آموزش می‌بینند در معرض یک منبع خطای مشترک قرار خواهند گرفت.

ازاین‌رو، کنترل کیفیت annotation در پژوهش حاضر به‌عنوان بخشی از فرایند آماده‌سازی داده در نظر گرفته می‌شود و نه یک مرحله اختیاری پس از آموزش مدل. هدف اصلی آن ایجاد یک مجموعه‌داده است که در آن تعریف کلاس‌ها، شناسه‌ها و موقعیت مکانی اشیا در حد امکان سازگار و قابل اعتماد باشد.

این موضوع از منظر مقایسه عادلانه اهمیت ویژه‌ای دارد؛ زیرا برای مقایسه RT-DETR-L،YOLOv8n و RTMDet-Tiny لازم است هر سه مدل با **دقیقاً همان تصاویر، همان تقسیم‌بندی داده، همان Taxonomy و همان annotationهای نهایی** مواجه شوند. در غیر این صورت، تفاوت مشاهده‌شده در معیارهای عملکرد ممکن است ناشی از تفاوت در داده آموزشی یا کیفیت annotation باشد و نه تفاوت واقعی میان معماری‌ها.

بنابراین، زنجیره آماده‌سازی داده در پژوهش حاضر را می‌توان به صورت زیر خلاصه کرد:

در نتیجه، یکپارچه‌سازی داده، هماهنگ‌سازی Taxonomy و کنترل کیفیت annotation سه مرحله مجزا اما به‌هم‌پیوسته هستند که در کنار یکدیگر امکان تشکیل یک مجموعه‌داده مشترک برای مقایسه سه معماری تشخیص شیء را فراهم می‌کنند.

Multi-source Data→Taxonomy Harmonization→Annotation Quality Control→Unified Dataset→Fair Model Comparison

2-6 یادگیری عمیق در تشخیص پسماند دریایی

با گسترش روش‌های یادگیری عمیق، تشخیص خودکار اشیا در تصاویر دریایی و زیرآبی به یکی از حوزه‌های مهم کاربرد بینایی ماشین در پایش محیط‌های آبی تبدیل شده است. برخلاف روش‌های کلاسیک مبتنی بر استخراج دستی ویژگی، شبکه‌های عصبی عمیق قادرند نمایش‌های چندسطحی از اطلاعات تصویری را مستقیماً از داده خام یاد بگیرند. این قابلیت، به‌ویژه در محیط‌هایی که ظاهر اشیا تحت تأثیر شرایط تصویربرداری قرار می‌گیرد، اهمیت دارد.

در حوزه پسماند دریایی، استفاده از یادگیری عمیق تا حد زیادی با توسعه مجموعه‌داده‌های تخصصی و تلاش برای خودکارسازی تحلیل تصاویر زیرآبی همراه بوده است. Fulton و همکاران (2019) با بررسی کاربرد مدل‌های تشخیص عمیق در سامانه‌های رباتیک، نشان دادند که روش‌های مبتنی بر یادگیری عمیق می‌توانند برای شناسایی خودکار پسماند در تصاویر زیرآبی مورد استفاده قرار گیرند. این مطالعات، زمینه را برای توسعه آشکارسازهای عمیق‌تر و مجموعه‌داده‌های تخصصی‌تر فراهم کردند.

یکی از تحولات مهم در این مسیر، ایجاد مجموعه‌داده‌هایی مانند **Trash-ICRA19** و **TrashCan** بود. مجموعه Trash-ICRA19 شامل تصاویر زیرآبی دارای Annotation جعبه محدودکننده برای پسماند و برخی موجودات و عناصر غیرپسماند است و تنوع شرایط تصویربرداری آن، مسئله تشخیص را به شرایط واقعی‌تر نزدیک می‌کند (Fulton et al., 2020). مجموعه TrashCan نیز با فراهم‌کردن Annotationهای دقیق‌تر و پوشش اشیای پسماند، ROV و عناصر زیستی زیرآبی، امکان بررسی گسترده‌تر روش‌های تشخیص و بخش‌بندی را فراهم کرده است (Hong et al., 2020).

با وجود این پیشرفت‌ها، عملکرد آشکارسازهای عمیق در تصاویر دریایی صرفاً به معماری شبکه وابسته نیست. ویژگی‌های تصویربرداری زیرآبی، از جمله کاهش کنتراست، تغییرات رنگی، پراکندگی و جذب نور، وجود ذرات معلق، انسداد جزئی، پوشیدگی زیستی و شباهت ظاهری میان برخی پسماندها و عناصر طبیعی، می‌توانند فرآیند تشخیص را پیچیده کنند. علاوه بر این، ناهمگونی میان منابع داده از نظر نوع دوربین، عمق تصویربرداری، شرایط نوری، پس‌زمینه و شیوه Annotation می‌تواند موجب ایجاد اختلاف میان توزیع داده‌های آموزشی و شرایط مورد انتظار در کاربردهای جدید شود.

از این منظر، توسعه آشکارسازهای جدید را نمی‌توان تنها با افزایش مقدار یک معیار عملکرد در یک مجموعه آزمون ثابت ارزیابی کرد. اهمیت عملی یک مدل زمانی بهتر مشخص می‌شود که عملکرد آن در برابر تغییرات شرایط تصویربرداری، تفاوت دامنه داده و محدودیت‌های محاسباتی نیز بررسی شود. مرورهای جدید در زمینه تشخیص اشیای دریایی و زیرآبی نیز بر اهمیت هم‌زمان دقت، سرعت، تعمیم‌پذیری و مقاومت مدل‌ها در برابر تغییرات محیطی تأکید کرده‌اند (Er et al., 2023; Moorton et al., 2025).

۲-۶-۱ تحول آشکارسازهای عمیق در مسئله پسماند دریایی

روند توسعه آشکارسازهای عمیق را می‌توان از نظر معماری به‌طور کلی به دو مسیر مهم تقسیم کرد. مسیر نخست بر توسعه آشکارسازهای مبتنی بر شبکه‌های کانولوشنی و بهینه‌سازی آن‌ها برای دستیابی به سرعت بالا و هزینه محاسباتی پایین متمرکز شده است. خانواده YOLO از مهم‌ترین نمونه‌های این رویکرد محسوب می‌شود. مسیر دوم با

ظهور معماری‌های مبتنی بر Transformer شکل گرفت که تلاش می‌کنند روابط مکانی و معنایی میان عناصر تصویر را با استفاده از سازوکارهای توجه مدل‌سازی کنند. DETR و نسل‌های سریع‌تر آن مانند RT-DETR-L در این گروه قرار می‌گیرند (Carion et al., 2020; Zhao et al., 2024).

در کنار این دو مسیر، تلاش‌هایی نیز برای طراحی آشکارسازهای CNN با تمرکز ویژه بر کاربردهای بلادرنگ انجام شده است. RTMDet-Tiny نمونه‌ای از این رویکرد است که هدف آن طراحی یک آشکارساز با توازن مناسب میان دقت، سرعت و پیچیدگی محاسباتی است (Lyu et al., 2022).

بنابراین، انتخاب سه معماری **RT-DETR-L،YOLOv8n و RTMDet-Tiny** در پژوهش حاضر صرفاً انتخاب سه مدل متداول نیست؛ بلکه امکان مقایسه سه رویکرد معماری متفاوت را در یک مسئله یکسان فراهم می‌کند. YOLOv8n نماینده نسل جدید آشکارسازهای تک‌مرحله‌ای مبتنی بر CNN، RT-DETR-L نماینده آشکارسازهای Real-Time مبتنی بر Transformer و RTMDet-Tiny نماینده طراحی بهینه‌شده آشکارسازهای CNN برای کاربردهای بلادرنگ است.

۲-۶-۲ ضرورت مقایسه معماری‌ها در یک چارچوب کنترل‌شده

مقایسه معماری‌های مختلف زمانی از اعتبار علمی کافی برخوردار است که اختلاف میان شرایط آزمایش تا حد امکان کنترل شود. در غیر این صورت، تفاوت مشاهده‌شده در عملکرد ممکن است ناشی از عواملی مانند کیفیت داده، Taxonomy، تقسیم‌بندی مجموعه داده، اندازه تصاویر یا تنظیمات آموزش باشد و نه الزاماً ناشی از تفاوت معماری.

از این رو، در پژوهش حاضر، سه معماری مورد بررسی بر روی یک مجموعه داده یکپارچه و دارای Taxonomy مشترک ارزیابی می‌شوند. همچنین تقسیم‌بندی داده‌ها میان مدل‌ها ثابت نگه داشته می‌شود و شرایط اصلی آزمایش، شامل اندازه تصویر، تعداد دوره‌های آموزش، Optimizer، راهبرد Augmentation، سخت‌افزار و سایر عوامل کنترل‌شده، تا حد امکان یکسان در نظر گرفته می‌شوند. تفاوت در Batch Size تنها در مواردی مجاز است که محدودیت حافظه و ساختار محاسباتی معماری چنین تفاوتی را ضروری کند. جزئیات دقیق این تنظیمات در فصل سوم ارائه خواهد شد.

این چارچوب موجب می‌شود مقایسه از حالت مقایسه ساده چند مدل خارج شده و به یک **ارزیابی کنترل‌شده معماری‌ها** تبدیل شود. در چنین شرایطی، علاوه بر Recall،Precision و mAP، شاخص‌هایی مانند سرعت استنتاج، Latency و رفتار مدل در شرایط تغییریافته نیز می‌توانند برای تحلیل جامع‌تر مورد استفاده قرار گیرند.

۲-۶-۳ گذار از تشخیص پایه به ارزیابی Robustness و تعمیم‌پذیری

در کاربردهای واقعی، یک مدل تشخیص پسماند دریایی ممکن است با تصاویری مواجه شود که از نظر کیفیت، شرایط نور، رنگ، پس‌زمینه یا محیط تصویربرداری با داده‌های آموزشی متفاوت هستند. بنابراین، ارزیابی صرفاً روی مجموعه آزمون هم‌توزیع با داده‌های آموزش، اطلاعات محدودی درباره قابلیت تعمیم مدل فراهم می‌کند.

بر این اساس، در مطالعات جدید، مفاهیمی مانند **Robustness**، **Domain Shift**، **Domain Generalization** و **Domain Adaptation** اهمیت بیشتری پیدا کرده‌اند. Robustness به میزان حفظ عملکرد مدل در برابر تغییرات یا اختلالات مشخص در داده اشاره دارد، در حالی که Domain Shift به تفاوت میان توزیع داده‌های مبدأ و مقصد مربوط می‌شود. Domain Adaptation نیز به روش‌هایی اشاره دارد که با استفاده از اطلاعات مربوط به دامنه مقصد، مدل را برای شرایط جدید سازگار می‌کنند.

این تمایز در پژوهش حاضر اهمیت روش‌شناختی دارد؛ زیرا عملکرد مدل در شرایط پایه، مقاومت آن در برابر تغییرات کنترل‌شده و رفتار آن در یک دامنه متفاوت نباید به‌عنوان یک مفهوم واحد تفسیر شوند. تفکیک این سناریوها امکان می‌دهد مشخص شود آیا یک مدل صرفاً در شرایط داده‌های آموزشی عملکرد مناسبی دارد یا اینکه می‌تواند تغییرات محیطی و تفاوت‌های دامنه را نیز تا حد قابل قبولی تحمل کند.

۲-۶-۴ جایگاه YOLOv8n، RT-DETR-L و RTMDet-Tiny در پژوهش حاضر

بر مبنای مباحث فوق، سه معماری انتخاب‌شده در این پژوهش سه نقطه متفاوت از فضای طراحی آشکارسازهای نوین را پوشش می‌دهند:

YOLOv8n↔CNN-based RT-DETR-L↔Transformer-based RTMDet-Tiny↔CNN-based

هدف از این انتخاب، تعیین یک مدل «بهترین» بدون توجه به شرایط کاربرد نیست؛ بلکه بررسی این موضوع است که هر رویکرد معماری در مواجهه با مسئله تشخیص پسماند دریایی چه رفتار و چه مبادله‌ای میان دقت، سرعت، هزینه محاسباتی و تعمیم‌پذیری ایجاد می‌کند.

بر همین اساس، در بخش‌های بعدی فصل، ابتدا معماری YOLOv8n، سپس RT-DETR-L و در ادامه RTMDet-Tiny به‌صورت مستقل بررسی می‌شوند. پس از تشریح مبانی هر معماری، مقایسه نظری آن‌ها انجام خواهد شد تا تفاوت‌های ساختاری میان سه رویکرد روشن شود. در نهایت، این مبانی نظری زمینه لازم را برای طراحی آزمایش‌های فصل سوم و تفسیر نتایج فصل چهارم فراهم می‌کنند.

۲-۶-۵ جمع‌بندی

یادگیری عمیق نقش مهمی در گذار از تحلیل دستی تصاویر دریایی به سمت تشخیص خودکار پسماند ایفا کرده است. توسعه مجموعه‌داده‌های تخصصی مانند Trash-ICRA19 و TrashCan نیز امکان ارزیابی سیستماتیک‌تر آشکارسازهای عمیق را فراهم کرده است. با این حال، چالش‌های ناشی از شرایط تصویربرداری زیرآبی، ناهمگونی منابع داده، تغییر دامنه و محدودیت تعمیم همچنان پابرجا هستند.

در چنین شرایطی، مقایسه چند معماری تحت یک پروتکل کنترل‌شده می‌تواند تصویر دقیق‌تری از توانایی و محدودیت‌های هر رویکرد ارائه دهد. بر همین اساس، پژوهش حاضر سه معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny را در یک چارچوب داده‌ای و آزمایشی مشترک بررسی می‌کند. بخش بعدی به بررسی ساختار و مبانی معماری YOLOv8n اختصاص دارد.

۲-۷ معماری YOLO و YOLOv8n

خانواده YOLO یکی از شناخته‌شده‌ترین رویکردهای تشخیص شیء تک‌مرحله‌ای است که هدف اصلی آن انجام هم‌زمان مکان‌یابی و طبقه‌بندی اشیا در یک فرایند یکپارچه است. برخلاف آشکارسازهای دومرحله‌ای که معمولاً ابتدا نواحی کاندید را استخراج و سپس آن‌ها را طبقه‌بندی می‌کنند، معماری YOLO پیش‌بینی‌های تشخیص را مستقیماً از نگاشت‌های ویژگی حاصل از تصویر ورودی تولید می‌کند. این ویژگی، در کنار طراحی‌های مختلف برای استخراج ویژگی، ادغام اطلاعات چندمقیاسی و کاهش هزینه محاسباتی، موجب شده است که خانواده YOLO به یکی از رویکردهای مهم برای کاربردهای تشخیص بلادرنگ تبدیل شود.

در مسئله تشخیص پسماند دریایی، سرعت استنتاج در کنار دقت اهمیت ویژه‌ای دارد؛ زیرا بخشی از کاربردهای بالقوه این سامانه‌ها به پایش خودکار، تصویربرداری رباتیک زیرآبی، وسایل نقلیه خودران و سامانه‌های پایش ساحلی مربوط می‌شود. بااین‌حال، تصاویر دریایی معمولاً با چالش‌هایی نظیر تغییرات شدید روشنایی، کدورت آب، پس‌زمینه‌های پیچیده، هم‌پوشانی اشیا، تغییر مقیاس و شکل پسماندها و شباهت ظاهری برخی پسماندها با عناصر طبیعی مواجه‌اند. ازاین‌رو، انتخاب یک معماری صرفاً بر اساس دقت خام کافی نیست و لازم است ویژگی‌های ساختاری آشکارساز و رفتار آن در شرایط مختلف نیز مورد توجه قرار گیرد.

۲-۷-۱ تکامل خانواده YOLO

تکامل خانواده YOLO را می‌توان به‌عنوان روندی تدریجی در جهت افزایش دقت، بهبود استخراج ویژگی، کاهش هزینه محاسباتی و ساده‌سازی فرایند آموزش و استنتاج در نظر گرفت. در نسل‌های اولیه، مسئله اصلی ایجاد یک

آشکارساز تک‌مرحله‌ای با سرعت بالا بود. در ادامه، ساختارهای مبتنی بر شبکه‌های کانولوشنی عمیق، سازوکارهای استخراج ویژگی چندمقیاسی، معماری‌های CSP، مسیرهای ادغام بالا به پایین و پایین به بالا و در نهایت روش‌های بدون Anchor به این خانواده افزوده شدند.

در نسخه‌های اولیه YOLO، پیش‌بینی جعبه‌های محدودکننده تا حد زیادی بر پایه Anchor Boxهای از پیش تعریف‌شده انجام می‌شد. این رویکرد اگرچه امکان مدل‌سازی اشیای دارای نسبت‌های ابعادی متفاوت را فراهم می‌کرد، اما وابستگی به طراحی و تنظیم Anchorها را نیز به همراه داشت. در ادامه، معماری‌های جدیدتر با حرکت به سمت آشکارسازی Anchor-Free تلاش کردند وابستگی به این پارامترهای از پیش تعیین‌شده را کاهش دهند.

در YOLOv8n این روند به مرحله مهمی رسید. این معماری از بلوک C2f در Backbone، ساختار SPPF برای افزایش میدان دید مؤثر، سازوکار FPN–PAN برای ادغام ویژگی‌های چندمقیاسی و یک Head تفکیک‌شده و Anchor-Free استفاده می‌کند. همچنین، مکان‌یابی جعبه‌ها با استفاده از نمایش توزیعی مختصات و Distribution Focal Loss انجام می‌شود. این تغییرات، YOLOv8n را به یک آشکارساز تک‌مرحله‌ای با ساختار نسبتاً ساده، سرعت مناسب و قابلیت استفاده در طیف گسترده‌ای از مسائل تشخیص شیء تبدیل کرده است.

بنابراین، تکامل YOLO را نباید صرفاً به افزایش شماره نسخه‌ها محدود کرد؛ بلکه این روند نشان‌دهنده تغییر تدریجی در نحوه استخراج ویژگی، ادغام اطلاعات، تخصیص نمونه‌های مثبت، نمایش مختصات جعبه و طراحی Head تشخیص است. در پژوهش حاضر، YOLOv8n به‌عنوان نماینده معماری‌های مبتنی بر CNN در برابر RT-DETR-L به‌عنوان یک رویکرد مبتنی بر Transformer و RTMDet-Tiny به‌عنوان یک آشکارساز CNN با تمرکز ویژه بر تشخیص بلادرنگ مقایسه می‌شود.

۲-۷-۲ ساختار کلی YOLOv8n

ساختار کلی YOLOv8n را می‌توان در سه بخش اصلی شامل **Backbone**، **Neck** و **Detection Head** خلاصه کرد. Backbone وظیفه استخراج ویژگی از تصویر ورودی را بر عهده دارد؛ Neck ویژگی‌های استخراج‌شده در مقیاس‌های مختلف را با یکدیگر ترکیب می‌کند؛ و Detection Head از ویژگی‌های ادغام‌شده برای پیش‌بینی موقعیت جعبه‌ها و کلاس اشیا استفاده می‌کند.

به‌صورت مفهومی، فرایند تشخیص در YOLOv8n را می‌توان به شکل زیر نمایش داد:

Input Image→Backbone→Multi-scale Features→Neck→Detection Head→Bounding Boxes + Class Scores

Backbone معمولاً ویژگی‌هایی را در چند وضوح مکانی استخراج می‌کند. این ویژگی‌ها در ادامه به Neck منتقل می‌شوند تا اطلاعات معنایی عمیق‌تر با اطلاعات مکانی دقیق‌تر ترکیب شوند. در نهایت، Head تشخیص از این نمایش چندمقیاسی برای شناسایی اشیا در اندازه‌های مختلف استفاده می‌کند.

این ساختار برای مسئله پسماند دریایی اهمیت زیادی دارد؛ زیرا پسماندها در تصاویر واقعی اندازه یکسانی ندارند. برای مثال، یک قطعه پلاستیک ممکن است در تصویر به‌صورت یک شیء کوچک و دور دیده شود، در حالی که یک تور یا قطعه بزرگ‌تر ممکن است بخش قابل توجهی از تصویر را اشغال کند. بنابراین، وجود نمایش چندمقیاسی برای حفظ هم‌زمان اطلاعات مکانی و معنایی ضروری است.

۳-۷-۲ Backbone و ماژول C2f

Backbone بخش استخراج ویژگی YOLOv8n است و وظیفه دارد تصویر خام را به نمایش‌های ویژگی سلسله‌مراتبی تبدیل کند. در مراحل ابتدایی شبکه، ویژگی‌های مکانی و الگوهای کم‌سطح مانند لبه‌ها، بافت‌ها و تغییرات موضعی استخراج می‌شوند. با افزایش عمق شبکه، ویژگی‌ها انتزاعی‌تر شده و اطلاعات معنایی بیشتری را دربر می‌گیرند.

یکی از عناصر شاخص YOLOv8n، جایگزینی ساختار C3 نسل‌های پیشین با **C2f** است. C2f را می‌توان عضوی از خانواده ساختارهای Cross-Stage Partial دانست که هدف آن حفظ مسیرهای مؤثر انتقال گرادیان و استفاده مجدد از ویژگی‌های میانی است.

در یک نمایش ساده، ورودی ماژول C2f ابتدا توسط یک لایه کانولوشنی به کانال‌های مناسب تبدیل و سپس به چند مسیر تقسیم می‌شود. بخشی از ویژگی‌ها از طریق مجموعه‌ای از Bottleneckها پردازش می‌شوند و خروجی‌های میانی این Bottleneckها نیز در مرحله ادغام مورد استفاده قرار می‌گیرند. بنابراین، برخلاف ساختارهایی که صرفاً آخرین خروجی یک زنجیره Bottleneck را به مرحله ادغام منتقل می‌کنند، C2f اطلاعات بیشتری از مسیرهای میانی شبکه در اختیار مرحله Fusion قرار می‌دهد.

به‌صورت مفهومی:

که در آن BiB_i خروجی Bottleneckهای متوالی است.

XSplit{X1,X2,B1,B2,…,Bn}ConcatenationXcatFusionXfusion

این طراحی از دو جهت برای تشخیص پسماند دریایی اهمیت دارد. نخست، پسماندهای دریایی ممکن است دارای ساختارهای بافتی پیچیده و مرزهای نامنظم باشند و بنابراین غنی بودن نمایش ویژگی می‌تواند به تفکیک آن‌ها از

پس‌زمینه کمک کند. دوم، استفاده از ویژگی‌های میانی می‌تواند به حفظ اطلاعاتی کمک کند که در شبکه‌های عمیق‌تر ممکن است در اثر Downsampling تضعیف شوند.

از منظر معماری، C2f یکی از مهم‌ترین تفاوت‌های YOLOv8n با نسل‌های پیشین است و نقش قابل توجهی در ایجاد تعادل میان ظرفیت نمایش ویژگی و هزینه محاسباتی دارد.

۴-۷-۲ ماژول SPPF

یکی دیگر از اجزای مهم معماری YOLOv8n، ماژول **Spatial Pyramid Pooling–Fast (SPPF)** است که در بخش عمیق Backbone قرار می‌گیرد. هدف اصلی این ماژول افزایش میدان دید مؤثر شبکه و فراهم‌کردن امکان استفاده از اطلاعات فضایی در مقیاس‌های مختلف است.

در تصاویر دریایی، اشیای مورد تشخیص ممکن است در پس‌زمینه‌ای بسیار متغیر قرار داشته باشند. برای مثال، تشخیص یک قطعه پلاستیک کوچک ممکن است به اطلاعات محلی نیاز داشته باشد، در حالی که تشخیص یک تور یا جسم بزرگ ممکن است به اطلاعات گسترده‌تری از محیط اطراف وابسته باشد. افزایش میدان دید شبکه می‌تواند در چنین شرایطی مفید باشد.

SPPF با استفاده از عملیات Max Pooling متوالی و ادغام خروجی‌های حاصل، اطلاعاتی با میدان دید متفاوت تولید می‌کند. در یک نمایش ساده، می‌توان ساختار آن را به صورت زیر نشان داد:

$$X \rightarrow \{X, P(X), P2(X), P3(X)\} \rightarrow \text{Concat} \rightarrow \text{Fusion}$$

که PP نشان‌دهنده عملیات Pooling است.

مزیت اصلی این طراحی نسبت به اجرای مستقیم چند Pooling با اندازه‌های بزرگ‌تر، کاهش هزینه محاسباتی ناشی از استفاده مجدد از عملیات Pooling متوالی است. در نتیجه، SPPF می‌تواند بدون ایجاد افزایش شدید در پیچیدگی محاسباتی، اطلاعات فضایی در مقیاس‌های مختلف را در اختیار شبکه قرار دهد.

۵-۷-۲ Neck و ساختار FPN–PAN

پس از استخراج ویژگی در Backbone، لازم است اطلاعات مربوط به مقیاس‌های مختلف با یکدیگر ترکیب شوند. این وظیفه در YOLOv8n بر عهده Neck قرار دارد. Neck از ایده‌های **Feature Pyramid Network (FPN)** و **Path Aggregation Network (PAN)** برای ترکیب ویژگی‌های سطح بالا و پایین استفاده می‌کند.

FPN عمدتاً یک مسیر بالا به پایین ایجاد می‌کند که در آن ویژگی‌های معنایی سطح بالا به سمت وضوح‌های مکانی بالاتر منتقل می‌شوند. این فرایند باعث می‌شود ویژگی‌های دارای اطلاعات معنایی قوی‌تر در اختیار لایه‌هایی قرار گیرند که وضوح مکانی بیشتری دارند.

در مقابل، مسیر PAN یک مسیر پایین به بالا ایجاد می‌کند تا اطلاعات مکانی دقیق‌تر از لایه‌های کم‌عمق‌تر به سطوح عمیق‌تر منتقل شود. ترکیب این دو مسیر باعث ایجاد یک نمایش چندمقیاسی غنی‌تر می‌شود.

به‌صورت مفهومی:

Backbone FeaturesFPN: Top-downIntermediate FeaturesPAN: Bottom-upMulti-scale Features

این ویژگی برای تشخیص پسماندهای دریایی اهمیت خاصی دارد. اجسامی مانند قطعات کوچک پلاستیک، طناب‌های باریک یا بخش‌هایی از تور ممکن است در یک تصویر تنها چند پیکسل یا ناحیه‌ای کوچک را تشکیل دهند. در مقابل، اجسامی مانند قطعات بزرگ‌تر پسماند یا تجمعات مشخص می‌توانند در مقیاس بزرگ ظاهر شوند. استفاده از ویژگی‌های چندمقیاسی امکان برخورد هم‌زمان با این دو وضعیت را فراهم می‌کند.

۶-۷-۲ Detection Head؛ ساختار Anchor-Free و تفکیک‌شده

یکی از تغییرات مهم YOLOv8n نسبت به معماری‌های قدیمی‌تر خانواده YOLO، استفاده از یک **Detection Head بدون Anchor** است. در روش‌های Anchor-Based، مدل برای هر موقعیت مکانی نسبت به مجموعه‌ای از جعبه‌های مرجع با اندازه و نسبت ابعاد از پیش تعیین‌شده پیش‌بینی انجام می‌دهد. این رویکرد به تنظیم Anchorها وابسته است و در صورت تفاوت زیاد توزیع اندازه و نسبت ابعاد اشیا با Anchorهای انتخاب‌شده می‌تواند محدودیت‌هایی ایجاد کند.

در معماری Anchor-Free، مدل مستقیماً نسبت به نقاط یا مکان‌های مرجع موجود در نگاشت ویژگی پیش‌بینی انجام می‌دهد و نیازی به تعریف مجموعه‌ای از Anchor Boxهای ثابت ندارد. این موضوع موجب ساده‌تر شدن بخشی از فرایند طراحی و کاهش وابستگی به توزیع هندسی از پیش تعیین‌شده اشیا می‌شود.

Head YOLOv8n همچنین به‌صورت **Decoupled** طراحی شده است؛ به این معنا که مسیر پردازش مربوط به طبقه‌بندی از مسیر مربوط به رگرسیون جعبه تفکیک می‌شود. این تفکیک از این دیدگاه اهمیت دارد که دو وظیفه classification و localization اهداف کاملاً یکسانی ندارند. Classification به تشخیص تعلق یک نمونه به یک کلاس توجه دارد، در حالی که localization به تخمین دقیق موقعیت و ابعاد جعبه محدودکننده مربوط است.

بنابراین، می‌توان خروجی Head را به‌صورت مفهومی چنین نمایش داد: Multi-scale Features→Decoupled Detection Head→{Classification BranchBox Regression Branch

نکته مهم آن است که این ساختار را نباید با معماری‌های قدیمی‌تر YOLO که دارای شاخه مستقل objectness بودند یکسان دانست. در YOLOv8n، طراحی Head بر پیش‌بینی کلاس و مکان جعبه متمرکز است و سازوکار تخصیص نمونه‌ها و تابع زیان نیز متناسب با همین طراحی انجام می‌شود.

۷-۷-۲ تخصیص نمونه‌ها با Task-Aligned Assigner

یکی از مسائل اساسی در آموزش آشکارسازهای شیء، تعیین این موضوع است که کدام نقاط پیش‌بینی باید به یک شیء واقعی اختصاص داده شوند. این مسئله تحت عنوان **Sample Assignment** شناخته می‌شود.

YOLOv8n از رویکرد **Task-Aligned Assignment** استفاده می‌کند که ریشه آن در روش Task Alignment Learning مطرح‌شده توسط Feng و همکاران (2021) قرار دارد. ایده اصلی این روش، کاهش عدم‌هم‌ترازی میان کیفیت طبقه‌بندی و کیفیت مکان‌یابی است.

$$t = s^{\alpha} \times IoU^{\beta}$$

که در آن:

- s امتیاز طبقه‌بندی نمونه،
- IoU میزان هم‌پوشانی جعبه پیش‌بینی و جعبه واقعی،
- α و β پارامترهای کنترل‌کننده سهم هر دو مؤلفه هستند.

بنابراین، نمونه‌ای که از نظر طبقه‌بندی مناسب باشد اما مکان‌یابی ضعیفی داشته باشد، الزاماً نمونه مثبت ایده‌آلی محسوب نمی‌شود. برعکس، نمونه‌ای که مکان‌یابی دقیق داشته ولی امتیاز طبقه‌بندی مناسبی ندارد نیز ممکن است گزینه مطلوبی نباشد.

این موضوع در تشخیص پسماند دریایی اهمیت دارد؛ زیرا برخی اشیا از نظر ظاهری شباهت زیادی به عناصر طبیعی محیط دارند. برای مثال، تفکیک برخی انواع پسماند از گیاهان، جانوران یا عناصر طبیعی پس‌زمینه می‌تواند دشوار باشد. در چنین شرایطی، هماهنگی میان کیفیت طبقه‌بندی و مکان‌یابی می‌تواند بر کیفیت نمونه‌های آموزشی مؤثر باشد.

۲-۷-۸ توابع زیان YOLOv8n

یادگیری آشکارساز YOLOv8n از طریق کمینه‌سازی ترکیبی از مؤلفه‌های مختلف تابع زیان انجام می‌شود. این مؤلفه‌ها را می‌توان در دو بخش اصلی مربوط به طبقه‌بندی و مکان‌یابی در نظر گرفت.

به‌صورت مفهومی:

L_total = L_cls + L_box

که در آن $LclsL_{\{cls\}}$ زیان طبقه‌بندی و $LboxL_{\{box\}}$ زیان مربوط به مکان‌یابی جعبه است.

۲-۷-۸-۱ زیان طبقه‌بندی

برای بخش طبقه‌بندی، YOLOv8n از **Binary Cross-Entropy with Logits Loss (BCEWithLogitsLoss)** استفاده می‌کند. در این چارچوب، خروجی خام شبکه پیش از تبدیل به احتمال، مستقیماً وارد تابع زیان می‌شود.

فرم کلی BCE را می‌توان به صورت زیر نمایش داد:

L_BCE = −[y log(p) + (1 − y) log(1 − p)]

که در آن yy برچسب واقعی و pp احتمال پیش‌بینی‌شده برای کلاس موردنظر است.

این سازوکار امکان یادگیری احتمال تعلق نمونه به کلاس‌های مختلف را فراهم می‌کند و در کنار سازوکار تخصیص نمونه‌ها، بخش طبقه‌بندی آشکارساز را شکل می‌دهد.

۲-۷-۸-۲ زیان مکان‌یابی و CIoU

برای ارزیابی کیفیت جعبه پیش‌بینی‌شده، تنها بررسی میزان هم‌پوشانی کافی نیست. دو جعبه ممکن است IoU مشابهی داشته باشند، اما از نظر فاصله مرکز یا نسبت ابعاد متفاوت باشند. ازاین‌رو، خانواده IoU Loss به‌گونه‌ای توسعه یافته است که علاوه بر میزان هم‌پوشانی، ویژگی‌های هندسی جعبه‌ها را نیز در نظر بگیرد.

در **Complete IoU (CIoU)** سه مؤلفه اصلی شامل هم‌پوشانی، فاصله مرکز دو جعبه و تفاوت نسبت ابعاد مورد توجه قرار می‌گیرد. فرم کلی آن را می‌توان به صورت زیر نمایش داد:

$$LCIoU = 1 - IoU + c2\rho2(b, bgt) + \alpha v$$

که در آن: ρ2(b,bgt) فاصله اقلیدسی مربع‌شده بین مراکز جعبه پیش‌بینی و جعبه واقعی است؛

- cc قطر مربع کوچک‌ترین ناحیه محصورکننده دو جعبه است؛
- vv مؤلفه مربوط به تفاوت نسبت ابعاد است؛
- α وزن این مؤلفه را تعیین می‌کند.

استفاده از چنین تابعی برای پسماندهای دریایی می‌تواند اهمیت داشته باشد؛ زیرا بسیاری از اشیای این حوزه شکل‌های کشیده یا نامنظم دارند؛ برای مثال تور، طناب و برخی قطعات پلاستیکی ممکن است نسبت طول به عرض بسیار متفاوتی داشته باشند.

Distribution Focal Loss ۳-۸-۷-۲

یکی دیگر از ویژگی‌های مهم YOLOv8n استفاده از **Distribution Focal Loss (DFL)** در رگرسیون جعبه است. ایده اصلی DFL آن است که مختصات مرزهای جعبه به‌جای پیش‌بینی مستقیم یک مقدار منفرد، به‌صورت یک توزیع گسسته روی چند مقدار مجاور مدل شوند.

اگر xx یک مختصات واقعی و yiy_i احتمال تعلق آن مختصات به bin مربوط به مقدار ii باشد، مقدار نهایی می‌تواند از امید ریاضی این توزیع به دست آید:

$$\hat{x} = \Sigma_i \, i \, y_i$$

این نمایش توزیعی به مدل اجازه می‌دهد عدم‌قطعیت و تغییرات ظریف در موقعیت مرزهای جعبه را بهتر مدل کند.

در مسئله تشخیص پسماند دریایی، این موضوع به‌ویژه زمانی اهمیت پیدا می‌کند که مرز شیء به دلیل کدورت، بازتاب نور، پوشش زیستی، هم‌پوشانی یا پس‌زمینه مشابه به‌طور دقیق مشخص نباشد.

تشخیص چندمقیاسی ۹-۷-۲

تشخیص چندمقیاسی یکی از ویژگی‌های کلیدی آشکارسازهای مدرن است. در YOLOv8n، ویژگی‌های حاصل از Backbone و Neck در وضوح‌های مختلف برای انجام پیش‌بینی مورد استفاده قرار می‌گیرند. این ساختار به مدل اجازه می‌دهد اشیای کوچک، متوسط و بزرگ را در مقیاس‌های متفاوت پردازش کند.

به‌صورت مفهومی:

$$P3, P4, P5 \rightarrow \text{Detection Head}$$

که این نگاشت‌ها دارای رزولوشن‌ها و میدان‌های دید متفاوت هستند.

در تصاویر دریایی، اهمیت این سازوکار دوچندان است. برای نمونه، یک قطعه پلاستیک کوچک در فاصله زیاد ممکن است تنها بخش کوچکی از تصویر را اشغال کند، درحالی‌که یک تور یا قطعه بزرگ پسماند ممکن است در مقیاس بسیار بزرگ ظاهر شود. استفاده از چند مقیاس امکان ایجاد تعادل میان جزئیات مکانی و اطلاعات معنایی را فراهم می‌کند.

با این حال، تشخیص اشیای بسیار کوچک همچنان یکی از چالش‌های اساسی در تصاویر دریایی است؛ زیرا Downsampling متوالی می‌تواند اطلاعات مکانی مربوط به اجسام کوچک را تضعیف کند. بنابراین، وجود معماری چندمقیاسی اگرچه ضروری است، به‌تنهایی تضمین‌کننده عملکرد مطلوب در همه شرایط نیست.

۲-۷-۱۰ پس‌پردازش و Non-Maximum Suppression

پس از تولید پیش‌بینی‌های اولیه، معمولاً تعداد زیادی جعبه با هم‌پوشانی بالا برای یک شیء تولید می‌شود. برای حذف پیش‌بینی‌های تکراری از **Non-Maximum Suppression (NMS)** استفاده می‌شود.

در ساده‌ترین شکل، NMS جعبه‌ای را که بیشترین امتیاز را دارد انتخاب کرده و جعبه‌های دیگری را که IoU آن‌ها با جعبه منتخب از یک آستانه مشخص بیشتر است، حذف یا سرکوب می‌کند.

به‌صورت مفهومی:

Raw PredictionsConfidence ThresholdingFiltered PredictionsNMSFinal Detections

NMS در کاربردهای دریایی اهمیت ویژه‌ای دارد، زیرا بافت‌های پیچیده، انعکاس نور و ساختارهای مشابه ممکن است باعث تولید چند پیش‌بینی نزدیک برای یک شیء شوند. در چنین شرایطی، عملکرد پس‌پردازش می‌تواند بر Precision و همچنین زمان نهایی استنتاج اثرگذار باشد.

ازاین‌رو، در مقایسه سرعت مدل‌ها باید مشخص شود که زمان گزارش‌شده مربوط به کدام بخش از زنجیره پردازش است؛ زیرا تفاوت میان زمان خام شبکه و زمان کل سامانه شامل پیش‌پردازش، استنتاج و پس‌پردازش می‌تواند قابل توجه باشد.

۲-۷-۱۱ مزایا و محدودیت‌های YOLOv8n در تشخیص پسماند دریایی

YOLOv8n از چند ویژگی برخوردار است که آن را برای مسئله حاضر به گزینه مناسبی تبدیل می‌کند. نخست، ساختار تک‌مرحله‌ای آن امکان انجام تشخیص با هزینه محاسباتی نسبتاً پایین را فراهم می‌کند. دوم، استفاده از Backbone و Neck چندمقیاسی برای برخورد با اشیای دارای اندازه‌های متفاوت مناسب است. سوم، طراحی Anchor-Free نیاز به تعریف Anchorهای اختصاصی برای توزیع هندسی داده‌ها را کاهش می‌دهد. چهارم، استفاده از C2f، Task-Aligned Assignment و DFL مجموعه‌ای از تغییرات معماری و آموزشی را فراهم می‌کند که برای بهبود استخراج ویژگی، تخصیص نمونه و مکان‌یابی طراحی شده‌اند.

با وجود این مزایا، YOLOv8n محدودیت‌هایی نیز دارد. عملکرد آن همچنان به کیفیت داده‌های آموزشی، تنوع دامنه تصویری و کیفیت Annotation وابسته است. همچنین، در محیط‌های زیرآبی، عواملی مانند کدورت،

تغییرات رنگ، کاهش کنتراست، هم‌پوشانی اشیا و شباهت پسماندها با عناصر طبیعی می‌توانند موجب افت عملکرد شوند.

یکی دیگر از محدودیت‌های مهم، مسئله تعمیم‌پذیری میان دامنه‌هاست. مدلی که روی تصاویر یک منبع داده یا شرایط تصویربرداری خاص عملکرد مطلوبی دارد، الزاماً در تصاویر حاصل از دوربین، محیط یا شرایط نوری متفاوت همان عملکرد را حفظ نمی‌کند. به همین دلیل، در پژوهش حاضر ارزیابی مدل صرفاً به یک مقدار mAP محدود نمی‌شود و موضوع پایداری عملکرد در شرایط تغییریافته نیز در چارچوب ارزیابی مورد توجه قرار می‌گیرد.

۱۲-۷-۲ جایگاه YOLOv8n در پژوهش حاضر

در پژوهش حاضر، YOLOv8n به‌عنوان یکی از سه معماری اصلی برای تشخیص پسماند دریایی انتخاب شده است. جایگاه این مدل در طراحی پژوهش از آن جهت اهمیت دارد که امکان مقایسه یک آشکارساز CNN تک‌مرحله‌ای با دو رویکرد متفاوت، یعنی RT-DETR-L و RTMDet-Tiny، را فراهم می‌کند.

چارچوب مقایسه‌ای پژوهش به‌صورت مفهومی چنین تعریف می‌شود:

CNN-based YOLOv8n ⟷ Transformer-based RT-DETR-L ⟷ CNN-based RTMDet-Tiny

علامت دوطرفه در این نمایش به معنای تبدیل یا ارتباط معماری میان مدل‌ها نیست، بلکه بیانگر **مقایسه متقابل سه رویکرد معماری** در یک چارچوب ارزیابی کنترل‌شده است.

برای جلوگیری از اثرگذاری تفاوت‌های داده‌ای بر نتایج، هر سه مدل در پژوهش حاضر بر اساس یک مجموعه داده یکپارچه و یک Taxonomy مشترک ارزیابی خواهند شد. همچنین اندازه ورودی تصویر، تعداد دوره‌های آموزش، بهینه‌ساز، راهبرد کلی افزایش داده، سخت‌افزار و تقسیم‌بندی داده‌ها به‌صورت کنترل‌شده در نظر گرفته می‌شوند. تفاوت در اندازه Batch تنها در صورتی اعمال می‌شود که محدودیت‌های حافظه و ساختار معماری مدل‌ها آن را ضروری کند؛ زیرا برابر بودن Batch الزاماً به معنای برابر بودن شرایط محاسباتی نیست.

جزئیات دقیق این تنظیمات، شامل اندازه تصویر، تعداد Epochها، Batch Size، نرخ یادگیری، روش زمان‌بندی نرخ یادگیری، وضعیت وزن‌های پیش‌آموزش‌دیده و سایر پارامترهای آموزش در فصل روش‌شناسی پژوهش ارائه خواهد شد.

هدف از قرار دادن YOLOv8n در این چارچوب، صرفاً تعیین اینکه «کدام مدل بیشترین mAP را دارد» نیست؛ بلکه ارزیابی هم‌زمان دقت تشخیص، توانایی مکان‌یابی، سرعت استنتاج، هزینه محاسباتی و میزان پایداری عملکرد در برابر تغییر شرایط است. به این ترتیب، نتیجه پژوهش می‌تواند تصویری جامع‌تر از نقاط قوت و محدودیت‌های معماری‌های مختلف برای مسئله تشخیص پسماند دریایی ارائه کند.

۱۳-۷-۲ جمع‌بندی

YOLOv8n یک آشکارساز تک‌مرحله‌ای مبتنی بر شبکه‌های کانولوشنی است که با ترکیب Backbone مبتنی بر C2f، ماژول Neck،SPPF چندمقیاسی مبتنی بر FPN–PAN و Detection Head بدون Anchor و تفکیک‌شده، چارچوبی نسبتاً کارآمد برای تشخیص اشیا ارائه می‌کند. استفاده از Task-Aligned Assignment، CIoU و Distribution Focal Loss نیز نشان‌دهنده توجه این معماری به هماهنگی میان طبقه‌بندی، مکان‌یابی و کیفیت نمونه‌های آموزشی است.

از دیدگاه مسئله حاضر، قابلیت پردازش چندمقیاسی YOLOv8n برای تشخیص پسماندهایی با اندازه‌های متفاوت اهمیت دارد، درحالی‌که ساختار Anchor-Free و طراحی تک‌مرحله‌ای آن می‌تواند برای کاربردهای نیازمند سرعت بالا مفید باشد. در مقابل، حساسیت به تغییرات دامنه تصویری و چالش تشخیص اشیای کوچک و کم‌کنتراست همچنان از موضوعات مهم در کاربرد آن برای تصاویر دریایی محسوب می‌شود.

بر این اساس، YOLOv8n در پژوهش حاضر نه به‌عنوان یک مدل منفرد، بلکه به‌عنوان نماینده یک رویکرد معماری CNN در یک مطالعه مقایسه‌ای کنترل‌شده در نظر گرفته می‌شود. این جایگاه امکان مقایسه آن با RT-DETR-L و RTMDet-Tiny را فراهم می‌کند و زمینه لازم برای بررسی رابطه میان نوع معماری، دقت، سرعت و پایداری مدل در تشخیص پسماندهای دریایی را ایجاد می‌نماید.

منابع مورد استفاده در این بخش Jocher et al. (2023); Feng et al. (2021); Li et al. (2020); Zheng et al. (2020).

۸-۲ معماری RT-DETR-L

معماری‌های مبتنی بر Transformer در سال‌های اخیر به یکی از مسیرهای مهم توسعه سامانه‌های تشخیص شیء تبدیل شده‌اند. نقطه عطف این مسیر، معرفی خانواده DETR بود که مسئله تشخیص شیء را با استفاده از معماری Transformer و در قالب یک فرایند End-to-End صورت‌بندی کرد. در این رویکرد، برخلاف آشکارسازهای متداول که معمولاً به مجموعه‌ای از قواعد و مراحل پس‌پردازشی مانند Non-Maximum Suppression وابسته هستند، تشخیص اشیا به‌صورت مستقیم‌تر و با استفاده از مجموعه‌ای از Object Queryها انجام می‌شود (Carion et al., 2020).

با وجود مزیت‌های مفهومی DETR، نسخه‌های اولیه آن از نظر هزینه محاسباتی و سرعت استنتاج برای کاربردهای بلادرنگ محدودیت‌هایی داشتند. RT-DETR-L با هدف رفع این مسئله توسعه یافت و تلاش کرد معماری

Transformer را با یک طراحی کارآمدتر برای استخراج و ادغام ویژگی‌های چندمقیاسی ترکیب کند. در مقاله اصلی، RT-DETR-L به‌عنوان یک آشکارساز End-to-End بلادرنگ معرفی شده است که با طراحی یک Encoder ترکیبی کارآمد و سازوکار انتخاب Query، هزینه پردازشی را کاهش می‌دهد و در عین حال مزیت حذف NMS را حفظ می‌کند (Zhao et al., 2024).

از دیدگاه پژوهش حاضر، RT-DETR-L اهمیت ویژه‌ای دارد؛ زیرا در کنار YOLOv8n و RTMDet-Tiny امکان مقایسه سه رویکرد معماری متفاوت را فراهم می‌کند:

CNN-basedYOLOv8nvs.Transformer-basedRT-DETR-Lvs.CNN-basedRTMDet-Tiny

در این نمایش، RT-DETR-L نماینده رویکردهای مبتنی بر Transformer در چارچوب مقایسه‌ای پژوهش است.

۲-۸-۱ گذار از DETR به RT-DETR-L

معماری DETR توسط Carion و همکاران (2020) با هدف تبدیل تشخیص شیء به یک مسئله پیش‌بینی مجموعه‌ای معرفی شد. ایده اصلی این بود که مدل بتواند مجموعه‌ای از اشیای موجود در تصویر را مستقیماً پیش‌بینی کند و وابستگی به فرایندهای سنتی مانند Anchor Design و NMS را کاهش دهد.

ساختار کلی DETR را می‌توان به‌صورت زیر نمایش داد:

Image→CNN Backbone→Transformer Encoder→Transformer Decoder→Object Queries→Detections

با وجود این طراحی ساده و End-to-End، استفاده مستقیم از Transformer برای پردازش ویژگی‌های تصویری با وضوح بالا می‌تواند هزینه محاسباتی قابل توجهی ایجاد کند. به همین دلیل، استفاده از DETRهای اولیه در کاربردهای بلادرنگ دشوار بود.

RT-DETR-L با بازطراحی بخش استخراج و پردازش ویژگی تلاش می‌کند این مشکل را کاهش دهد. ایده اصلی آن، تفکیک تعاملات درون‌مقیاسی از ادغام بین‌مقیاسی در Encoder است تا محاسبات غیرضروری کاهش یابد. علاوه بر این، انتخاب Queryهای باکیفیت برای Decoder موجب می‌شود بخش Transformer از مجموعه‌ای مناسب‌تر از کاندیداهای اولیه استفاده کند (Zhao et al., 2024).

بنابراین، مسیر مفهومی تحول را می‌توان به صورت زیر خلاصه کرد: DETR→Efficient Transformer-based DETectors→RT-DETR-L

هدف این تحول، حفظ ویژگی End-to-End بودن در کنار رسیدن به سرعت مناسب برای کاربردهای بلادرنگ است.

۲-۸-۲ ساختار کلی RT-DETR-L

ساختار کلی RT-DETR-L را می‌توان در چند بخش اصلی شامل Backbone، Hybrid Encoder ، Query Selection و Transformer Decoder تقسیم‌بندی کرد.

نمایش ساده فرایند پردازش به شکل زیر است:

Input Image→Backbone→Multi-scale Features→Hybrid Encoder→Object Query Selection→Transformer Decoder→Final Predictions

Backbone وظیفه استخراج ویژگی‌های تصویری را بر عهده دارد. ویژگی‌های حاصل از چند سطح شبکه سپس وارد Hybrid Encoder می‌شوند. این Encoder به‌جای اعمال یک Transformer Encoder سنگین بر تمام ویژگی‌های چندمقیاسی، تعاملات درون هر مقیاس و ادغام بین مقیاس‌ها را به‌شکل تفکیک‌شده پردازش می‌کند.

پس از آن، مجموعه‌ای از ویژگی‌ها برای ایجاد Object Queryهای اولیه مورد استفاده قرار می‌گیرند. Queryهای انتخاب‌شده وارد Decoder می‌شوند و Decoder در چند مرحله به اصلاح مکان و کلاس اشیا می‌پردازد.

در نتیجه، می‌توان جریان اصلی معماری را چنین خلاصه کرد: Input Image→Feature Extraction→Hybrid Encoder→Query Selection/Initialization→Transformer Decoder→Iterative Refinement→Final Detections

این ساختار، RT-DETR-L را از آشکارسازهای متداولی مانند YOLOv8n متمایز می‌کند.

۲-۸-۳ استخراج ویژگی و نمایش چندمقیاسی

مانند بسیاری از آشکارسازهای مدرن، RT-DETR-L نیز برای تشخیص اشیای دارای اندازه‌های متفاوت به نمایش ویژگی چندمقیاسی نیاز دارد. Backbone ویژگی‌هایی را از سطوح مختلف استخراج می‌کند که هرکدام دارای وضوح مکانی و سطح معنایی متفاوت هستند.

ویژگی‌های سطح پایین‌تر معمولاً اطلاعات مکانی دقیق‌تری دارند، در حالی که ویژگی‌های عمیق‌تر دارای اطلاعات معنایی غنی‌تری هستند. بنابراین، استفاده هم‌زمان از این ویژگی‌ها برای تشخیص اشیای کوچک و بزرگ اهمیت دارد.

در مسئله پسماند دریایی، این موضوع اهمیت ویژه‌ای دارد. برای مثال، قطعات کوچک پلاستیک یا اجزای باریک تور ممکن است تنها بخش کوچکی از تصویر را اشغال کنند، در حالی که یک قطعه بزرگ پسماند یا یک مجموعه متراکم از اشیا ممکن است در مقیاس بسیار بزرگ‌تر ظاهر شود.

بنابراین، RT-DETR-L نیز همانند YOLOv8n باید بتواند اطلاعات چندمقیاسی را به‌گونه‌ای مؤثر ترکیب کند؛ اما روش انجام این کار در این دو معماری یکسان نیست.

Hybrid Encoder ۴-۸-۲

یکی از مهم‌ترین اجزای RT-DETR-L، **Hybrid Encoder** است. طراحی این Encoder با هدف کاهش هزینه محاسباتی Transformer و در عین حال حفظ توانایی مدل در برقراری ارتباط میان ویژگی‌های مختلف انجام شده است.

در معماری Transformer، محاسبه Self-Attention در نگاشت‌های ویژگی با تعداد زیاد توکن می‌تواند هزینه محاسباتی بالایی داشته باشد. اگر وضوح مکانی ویژگی افزایش یابد، تعداد توکن‌ها نیز افزایش پیدا می‌کند و در نتیجه هزینه تعامل میان آن‌ها بیشتر می‌شود.

RT-DETR-L برای کاهش این مشکل، فرایند پردازش ویژگی را به دو نوع تعامل اصلی تفکیک می‌کند:

۱. **تعامل درون‌مقیاسی (Intra-scale Interaction)**

۲. **ادغام بین‌مقیاسی (Cross-scale Fusion)**

در بخش اول، روابط موجود در یک مقیاس مشخص مورد پردازش قرار می‌گیرند. در بخش دوم، اطلاعات سطوح مختلف با یکدیگر ترکیب می‌شوند.

به‌صورت مفهومی:

Multi-scale FeaturesIntra-scale TransformerEnhanced FeaturesCross-scale Feature FusionEncoded Features

این تفکیک، یکی از عوامل اصلی طراحی RT-DETR-L برای رسیدن به سرعت بالاتر نسبت به استفاده مستقیم از Encoderهای Transformer سنگین است. مقاله اصلی RT-DETR-L صراحتاً Hybrid Encoder را برای پردازش سریع ویژگی‌های چندمقیاسی و جداسازی این دو نوع تعامل معرفی می‌کند.

۵-۸-۲ تعامل درون‌مقیاسی

در تعامل درون‌مقیاسی، هدف مدل یادگیری روابط موجود میان بخش‌های مختلف ویژگی در یک سطح مشخص است. این قابلیت به Transformer اجازه می‌دهد وابستگی‌هایی را که ممکن است در یک پنجره محلی یا در یک عملیات کانولوشنی ساده به‌راحتی قابل مدل‌سازی نباشند، مورد توجه قرار دهد.

این ویژگی می‌تواند در محیط‌های دریایی مفید باشد؛ زیرا ظاهر یک پسماند ممکن است تنها از اطلاعات محلی قابل تشخیص نباشد. برای نمونه، تشخیص یک جسم ممکن است به رابطه آن با بخش‌های اطراف، ساختار پس‌زمینه و الگوی کلی تصویر وابسته باشد.

با این حال، Self-Attention در وضوح‌های بالا هزینه محاسباتی قابل توجهی دارد. ازاین‌رو، RT-DETR-L از یک طراحی انتخابی برای استفاده مؤثرتر از Transformer بهره می‌گیرد و تلاش می‌کند پردازش پرهزینه را به بخش‌هایی محدود کند که بیشترین ارزش را برای نمایش معنایی دارند.

۶-۸-۲ ادغام بین‌مقیاسی

ویژگی‌های حاصل از سطوح مختلف Backbone باید در نهایت با یکدیگر ترکیب شوند. این فرایند در RT-DETR-L به‌گونه‌ای طراحی شده است که اطلاعات مکانی و معنایی سطوح مختلف در اختیار Decoder قرار گیرد.

می‌توان این فرایند را به‌صورت زیر نمایش داد:

$$F_1, F_2, F_3 \rightarrow \text{Cross-scale Fusion} \rightarrow F_encoded$$

در این رابطه، F1,F2,F3F_1,F_2,F_3 نمایش‌های ویژگی در مقیاس‌های مختلف هستند.

ادغام بین‌مقیاسی به مدل اجازه می‌دهد ویژگی‌های کم‌وضوح اما معنایی را با ویژگی‌های دارای وضوح مکانی بیشتر ترکیب کند. این موضوع برای تشخیص اشیای کوچک اهمیت زیادی دارد.

در داده‌های پسماند دریایی، چنین قابلیتی می‌تواند برای شناسایی اشیایی که از نظر اندازه کوچک هستند اما در زمینه پیچیده‌ای قرار گرفته‌اند مفید باشد.

۷-۸-۲ Object Query و انتخاب Query

یکی از تفاوت‌های بنیادی RT-DETR-L با آشکارسازهای CNN متداول، استفاده از **Object Query** است. Query را می‌توان به‌عنوان یک نمایش آموختنی یا استخراج‌شده در نظر گرفت که وظیفه آن تمرکز بر یک شیء بالقوه در تصویر و تولید پیش‌بینی متناظر است.

در DETRهای اولیه، Queryها به‌صورت قابل‌آموزش وارد Decoder می‌شوند. RT-DETR-L از یک راهبرد **Query Selection** استفاده می‌کند تا Queryهای اولیه با کیفیت بالاتری انتخاب شوند.

این مسئله از آن جهت اهمیت دارد که اگر Queryهای اولیه اطلاعات ضعیفی درباره مکان یا وجود اشیا داشته باشند، Decoder مجبور خواهد بود مراحل بیشتری را صرف اصلاح آن‌ها کند.

RT-DETR-L از **Uncertainty-Minimal Query Selection** برای انتخاب Queryهای مناسب استفاده می‌کند. ایده اصلی این است که Queryهایی که اطلاعات مکانی و معنایی قابل اعتمادتری دارند، به‌عنوان ورودی اولیه Decoder انتخاب شوند (Zhao et al., 2024).

به‌صورت مفهومی:

Encoder Features→Candidate Queries→Query Selection→High-quality Queries

این طراحی یکی از عناصر مهم در دستیابی RT-DETR-L به تعادل میان دقت و سرعت محسوب می‌شود.

Transformer Decoder ۸-۸-۲

پس از انتخاب Queryها، آن‌ها وارد Transformer Decoder می‌شوند. Decoder وظیفه دارد اطلاعات مربوط به هر Query را با ویژگی‌های تصویر ترکیب کرده و پیش‌بینی نهایی را تولید کند.

در هر مرحله از Query،Decoder ها می‌توانند اطلاعات مربوط به کلاس و مکان شیء را اصلاح کنند. این فرایند را می‌توان به‌صورت یک روند تکرارشونده در نظر گرفت:

$$Q_0 \rightarrow Q_1 \rightarrow Q_2 \rightarrow \cdots \rightarrow Q_n$$

که در آن Query Q0Q_0 اولیه و QnQ_n نمایش اصلاح‌شده پس از چند لایه Decoder است.

هر Query در نهایت می‌تواند به یک پیش‌بینی شامل کلاس و جعبه محدودکننده متناظر شود.

$$Q_i \rightarrow (\hat{c}_i, \hat{b}_i)$$

که c^i\hatc_i کلاس پیش‌بینی‌شده و b^i\hatb_i جعبه پیش‌بینی‌شده است.

این ساختار یکی از تفاوت‌های بنیادی RT-DETR-L با YOLOv8n محسوب می‌شود. در YOLOv8n، پیش‌بینی‌ها مستقیماً از نگاشت‌های ویژگی چندمقیاسی تولید و سپس با NMS پالایش می‌شوند، در حالی که RT-DETR-L از Query و Decoder برای تولید مجموعه نهایی تشخیص‌ها استفاده می‌کند.

End-to-End Detection ۹-۸-۲ و حذف NMS

یکی از مهم‌ترین ویژگی‌های RT-DETR-L، ماهیت **End-to-End** آن است. در آشکارسازهای متداول مانند YOLO، شبکه تعداد زیادی پیش‌بینی تولید می‌کند و پس از آن NMS برای حذف پیش‌بینی‌های تکراری اجرا می‌شود.

در RT-DETR-L، معماری به‌گونه‌ای طراحی شده است که مجموعه‌ای محدود از Queryها مستقیماً برای تولید تشخیص‌ها مورد استفاده قرار گیرند. بنابراین، نیاز به NMS به‌عنوان مرحله استاندارد پس‌پردازش حذف می‌شود.

فرایند دو رویکرد را می‌توان به شکل زیر مقایسه کرد: YOLOv8n:Multi-scale Features→Detection Head→Dense Predictions→NMS→Final Detections

در مقابل RT-DETR-L: Backbone/Hybrid Encoder→Multi-scale Features→Transformer Decoder + Object Queries→Final: Detections

مطابق مقاله اصلی RT-DETR-L، یکی از انگیزه‌های اصلی طراحی آن، حذف اثر منفی NMS بر سرعت و دقت سامانه‌های بلادرنگ بوده است.

این تفاوت برای پژوهش حاضر بسیار مهم است؛ زیرا هنگام مقایسه Latency و FPS، نباید صرفاً زمان عبور داده از شبکه عصبی در نظر گرفته شود. تعریف دقیق معیار سرعت باید مشخص کند که آیا زمان پیش‌پردازش و پس‌پردازش نیز در اندازه‌گیری لحاظ شده است یا خیر.

۲-۸-۱۰ تطبیق Queryها با اشیای واقعی

آموزش مدل‌های DETR-based به یک مسئله مهم دیگر نیز وابسته است: تعیین اینکه هر Query باید با کدام شیء واقعی متناظر شود.

در این خانواده از مدل‌ها، مسئله Assignment معمولاً به‌صورت تطبیق مجموعه‌ای میان پیش‌بینی‌ها و Ground Truthها صورت‌بندی می‌شود. در نتیجه، برخلاف روش‌های متراکم که تعداد زیادی Anchor یا موقعیت مکانی را به‌صورت مستقل بررسی می‌کنند، هر Query در نهایت به یک پیش‌بینی مشخص مربوط می‌شود.

این ساختار می‌تواند باعث کاهش پیش‌بینی‌های تکراری شود و در عین حال فرآیند تشخیص را به یک مسئله مجموعه‌ای نزدیک کند.

در داده‌های دریایی، چنین رویکردی می‌تواند در صحنه‌های متراکم که چند شیء در مجاورت یکدیگر قرار دارند اهمیت داشته باشد. بااین‌حال، عملکرد نهایی همچنان به کیفیت Annotation و تفکیک دقیق اشیای نزدیک به یکدیگر وابسته است.

۲-۸-۱۱ Auxiliary Loss و نظارت در طول Decoder

در معماری‌های DETR-based، نظارت آموزشی می‌تواند در چند مرحله Decoder اعمال شود تا شبکه علاوه بر خروجی نهایی، در مراحل میانی نیز بازخورد دریافت کند. این سازوکار به مدل کمک می‌کند فرآیند اصلاح Queryها را به‌صورت تدریجی یاد بگیرد.

به‌صورت مفهومی:

$$\cdots \rightarrow Q_0 \rightarrow D_1 \rightarrow D_2 \rightarrow D_3$$

و در هر مرحله می‌توان پیش‌بینی‌هایی تولید کرد که برای ایجاد سیگنال آموزشی مورد استفاده قرار گیرند.

این نوع نظارت مرحله‌ای می‌تواند به بهبود فرایند یادگیری و تسهیل همگرایی مدل کمک کند؛ هرچند مقدار و نحوه استفاده از Lossهای کمکی به پیاده‌سازی و پیکربندی دقیق مدل وابسته است.

بنابراین، در توصیف علمی RT-DETR-L باید میان **ساختار معماری اصلی** و **تنظیمات آموزشی یک پیاده‌سازی خاص** تمایز قائل شد. این تفکیک در پژوهش حاضر اهمیت دارد، زیرا هدف مقایسه معماری‌هاست و جزئیات تنظیمات آموزش باید به‌صورت شفاف در فصل سوم گزارش شوند.

۱۲-۸-۲ مقیاس‌پذیری RT-DETR-L

RT-DETR-L در چند اندازه معماری ارائه شده است و امکان استفاده از Backboneها و پیکربندی‌های مختلف را فراهم می‌کند. این ویژگی اجازه می‌دهد مدل متناسب با محدودیت‌های سخت‌افزاری و نیازهای کاربردی انتخاب شود.

در پژوهش اصلی، نسخه‌های مختلف RT-DETR-L از جمله مدل‌های مبتنی بر R18، R50 و R101 و نسخه‌های مقیاس‌پذیرتر بررسی شده‌اند. همچنین، نویسندگان نشان داده‌اند که تعداد لایه‌های Decoder را می‌توان برای تنظیم سرعت و دقت تغییر داد، بدون آنکه نیاز به آموزش مجدد کل مدل وجود داشته باشد (Zhao et al., 2024).

این ویژگی برای سامانه‌هایی با منابع محاسباتی محدود اهمیت دارد؛ زیرا امکان ایجاد تعادل میان دقت و سرعت را فراهم می‌کند.

در پژوهش حاضر نیز انتخاب نسخه مشخص RT-DETR-L باید بر اساس محدودیت حافظه GPU، هزینه محاسباتی و ضرورت مقایسه منصفانه انجام شود. بااین‌حال، انتخاب یک نسخه سبک‌تر نباید با کاهش اندازه تصویر ورودی جبران شود؛ زیرا اندازه ورودی یکی از عوامل مؤثر بر عملکرد تشخیص اشیای کوچک است و تغییر آن می‌تواند قابلیت مقایسه میان مدل‌ها را تحت تأثیر قرار دهد.

۱۳-۸-۲ RT-DETRv2 و توسعه معماری

پس از معرفی RT-DETR-L، نسخه بهبودیافته‌ای با عنوان **RT-DETRv2** ارائه شد. این نسخه با هدف افزایش انعطاف‌پذیری و عملکرد RT-DETR-L، تغییراتی در استخراج ویژگی چندمقیاسی، روش نمونه‌برداری و راهبرد آموزش ایجاد کرد.

یکی از تغییرات مهم RT-DETRv2 استفاده از تعداد متفاوت نقاط نمونه‌برداری در مقیاس‌های مختلف Deformable Attention است. همچنین یک اپراتور نمونه‌برداری گسسته به‌صورت اختیاری معرفی شده است تا برخی محدودیت‌های مربوط به استقرار عملیاتی کاهش یابد. علاوه بر این، راهبردهای آموزشی مانند Dynamic Data Augmentation و Scale-Adaptive Hyperparameters نیز مورد استفاده قرار گرفته‌اند.

با وجود این توسعه‌ها، در پژوهش حاضر باید دقیقاً مشخص شود که کدام نسل و کدام پیاده‌سازی از RT-DETR-L مورد استفاده قرار گرفته است. زیرا RT-DETR-L و RT-DETRv2 را نمی‌توان صرفاً با یک نام عمومی در گزارش نتایج جایگزین یکدیگر کرد.

این موضوع به‌خصوص در مقایسه علمی اهمیت دارد؛ زیرا تفاوت در معماری، وزن‌های پیش‌آموزش‌دیده یا راهبرد آموزش می‌تواند بر عملکرد نهایی اثر بگذارد.

۲-۸-۱۴ مزایا و محدودیت‌های RT-DETR-L در تشخیص پسماند دریایی

RT-DETR-L چند ویژگی دارد که آن را برای مسئله تشخیص پسماند دریایی به گزینه‌ای مهم تبدیل می‌کند. نخست، استفاده از Transformer امکان مدل‌سازی روابط گسترده میان بخش‌های مختلف تصویر را فراهم می‌کند. این قابلیت می‌تواند در محیط‌هایی با پس‌زمینه پیچیده مفید باشد. دوم، ماهیت End-to-End مدل موجب حذف وابستگی به NMS می‌شود. سوم، استفاده از ویژگی‌های چندمقیاسی امکان پردازش اشیای دارای اندازه‌های متفاوت را فراهم می‌کند. چهارم، طراحی Query-based می‌تواند به کاهش پیش‌بینی‌های تکراری کمک کند.

بااین‌حال، RT-DETR-L محدودیت‌هایی نیز دارد. معماری Transformer معمولاً نسبت به برخی آشکارسازهای CNN به منابع محاسباتی بیشتری نیاز دارد، به‌خصوص زمانی که ویژگی‌های با وضوح بالا پردازش می‌شوند. علاوه بر این، آموزش مدل‌های DETR-based ممکن است نسبت به برخی آشکارسازهای سنتی حساسیت بیشتری به طراحی Training Pipeline داشته باشد.

در مسئله پسماند دریایی، این محدودیت‌ها زمانی اهمیت بیشتری پیدا می‌کنند که تصاویر شامل اشیای کوچک، کنتراست پایین یا تعداد زیادی شیء نزدیک به یکدیگر باشند. در چنین شرایطی، توانایی معماری در حفظ اطلاعات مکانی و انتخاب Queryهای مناسب نقش مهمی در عملکرد نهایی دارد.

از سوی دیگر، RT-DETR-L می‌تواند در صحنه‌هایی که روابط زمینه‌ای و ساختار کلی تصویر اهمیت دارند، مزیت بالقوه‌ای داشته باشد. بنابراین، ارزیابی تجربی آن در کنار مدل‌های CNN می‌تواند اطلاعات ارزشمندی درباره مناسب‌ترین نوع معماری برای این حوزه فراهم کند.

۲-۸-۱۵ جایگاه RT-DETR-L در پژوهش حاضر

در پژوهش حاضر، RT-DETR-L به‌عنوان نماینده رویکردهای Transformer-based در مقایسه با دو معماری CNN-based مورد استفاده قرار می‌گیرد. هدف از این انتخاب، بررسی این پرسش است که آیا استفاده از معماری Transformer می‌تواند در تشخیص پسماند دریایی نسبت به آشکارسازهای CNN مزیت قابل اندازه‌گیری ایجاد کند یا خیر.

چارچوب مفهومی مقایسه به شکل زیر تعریف می‌شود YOLOv8CNN-basedRT-DETR-LTransformer-basedRTMDet-TinyCNN-based:

در این مقایسه، هدف صرفاً تعیین بالاترین mAP نیست. عملکرد هر مدل از منظر مجموعه‌ای از شاخص‌ها شامل Precision،Recall، mAP@0.50، mAP@0.50:0.95 ، سرعت استنتاج، Latency و پایداری در شرایط تغییریافته مورد بررسی قرار می‌گیرد.

به‌ویژه، حذف NMS در RT-DETR-L باید هنگام تفسیر معیارهای سرعت مورد توجه قرار گیرد. اگر FPS سه مدل مقایسه شود، باید مشخص شود که معیار گزارش‌شده مربوط به زمان کل Inference Pipeline است یا فقط زمان Forward Pass شبکه. در غیر این صورت، مقایسه سرعت ممکن است به نفع یا ضرر یک معماری خاص سوگیری پیدا کند.

از طرف دیگر، برای حفظ اعتبار مقایسه، تغییر اندازه تصویر، تفاوت در داده آموزشی، تغییر Taxonomy یا استفاده از مجموعه آزمون متفاوت نباید به‌عنوان بخشی از تفاوت معماری تلقی شود. بنابراین، RT-DETR-L در این پژوهش در همان چارچوب داده‌ای و ارزیابی مورد استفاده برای YOLOv8n و RTMDet-Tiny قرار می‌گیرد.

۲-۸-۱۶ مقایسه مفهومی YOLOv8n و RT-DETR-L

تفاوت اصلی دو معماری را می‌توان در سطح جریان پردازش خلاصه کرد:

جدول 2-2. مقایسه مفهومی ویژگی‌های YOLOv8n وRT-DETR-L

ویژگی	YOLOv8n	RT-DETR-L
خانواده معماری	CNN-based	Transformer-based
نوع آشکارساز	One-stage	End-to-End
تولید پیش‌بینی	Dense prediction	Query-based prediction
Anchor	Anchor-Free	Query-based

حذف شده در طراحی End-to-End	مورد استفاده	NMS
Backbone + Hybrid Encoder	Backbone + Neck	پردازش ویژگی
Transformer Decoder	Detection Head	سازوکار اصلی تشخیص
Multi-scale features + Hybrid Encoder	FPN–PAN	ویژگی چندمقیاسی
Decoder-based refinement	Head-based prediction	اصلاح پیش‌بینی
دقت و سرعت End-to-End	تعادل سرعت و دقت	هدف طراحی

این جدول نشان می‌دهد که تفاوت YOLOv8n و RT-DETR-L صرفاً در نام مدل یا نوع Backbone خلاصه نمی‌شود، بلکه این دو مدل از دو منطق متفاوت برای تولید تشخیص استفاده می‌کنند.

در YOLOv8n، پیش‌بینی‌ها از نگاشت‌های ویژگی چندمقیاسی استخراج شده و سپس با یک مرحله پس‌پردازشی پالایش می‌شوند؛ در RT-DETR-L، مجموعه Queryها در Decoder پردازش شده و تشخیص‌ها به‌صورت مستقیم‌تر تولید می‌شوند.

از این منظر، مقایسه این دو معماری می‌تواند برای بررسی اثر نوع معماری بر عملکرد تشخیص پسماند دریایی ارزشمند باشد.

۲-۸-۱۷ جمع‌بندی

RT-DETR-L یک آشکارساز شیء مبتنی بر Transformer است که با هدف ایجاد یک چارچوب End-to-End و در عین حال مناسب برای کاربردهای بلادرنگ توسعه یافته است. این معماری با استفاده از Hybrid Encoder، پردازش کارآمد ویژگی‌های چندمقیاسی را دنبال می‌کند و با استفاده از Query Selection و Transformer Decoder، پیش‌بینی اشیا را بدون نیاز به NMS انجام می‌دهد.

مهم‌ترین تمایز RT-DETR-L نسبت به آشکارسازهای CNN مانند YOLOv8n در نحوه تولید و پالایش پیش‌بینی‌هاست. YOLOv8n بر استخراج و ادغام ویژگی‌های کانولوشنی و تولید متراکم پیش‌بینی‌ها تکیه دارد، در حالی که RT-DETR-L مسئله تشخیص را در قالب پیش‌بینی مجموعه‌ای مبتنی بر Query صورت‌بندی می‌کند.

از منظر تشخیص پسماند دریایی، RT-DETR-L ظرفیت بالقوه‌ای برای مدل‌سازی روابط گسترده تصویری و کاهش پیش‌بینی‌های تکراری دارد؛ اما در مقابل، هزینه محاسباتی و حساسیت آن به طراحی مناسب Pipeline آموزشی می‌تواند از عوامل محدودکننده باشد.

در نتیجه، قرار دادن RT-DETR-L در کنار YOLOv8n و RTMDet-Tiny امکان بررسی تجربی این مسئله را فراهم می‌کند که آیا تفاوت بنیادین میان معماری‌های CNN و Transformer در شرایط یکسان داده‌ای، به تفاوت معناداری در دقت، سرعت و پایداری تشخیص پسماندهای دریایی منجر می‌شود یا خیر.

در این چارچوب، جزئیات نسخه دقیق مدل، وزن‌های پیش‌آموزش‌دیده، اندازه ورودی، تنظیمات آموزش، Batch Size، تعداد دوره‌های آموزش و سایر پارامترهای اجرایی در فصل سوم گزارش خواهند شد تا بخش نظری حاضر از جزئیات روش‌شناختی تفکیک شود.

۹-۲ معماری RTMDet-Tiny

۹-۲-۱ جایگاه RTMDet-Tiny در آشکارسازهای بلادرنگ

RTMDet-Tiny یکی از خانواده‌های آشکارسازهای تک‌مرحله‌ای است که با هدف دستیابی به تعادل مناسب میان **دقت تشخیص، پیچیدگی محاسباتی و سرعت استنتاج** طراحی شده است. این معماری حاصل یک مطالعه تجربی نظام‌مند درباره اجزای مؤثر در طراحی آشکارسازهای بلادرنگ است و تلاش می‌کند بدون اتکا به پیچیدگی‌های غیرضروری، ظرفیت استخراج ویژگی و کیفیت پیش‌بینی را افزایش دهد. در طراحی RTMDet-Tiny، انتخاب Backbone، Neck، Head ، راهبرد تخصیص برچسب و روش‌های آموزش به‌صورت یک مجموعه هماهنگ مورد بررسی قرار گرفته‌اند (Lyu et al., 2022).

یکی از ویژگی‌های مهم RTMDet-Tiny، ارائه خانواده‌ای از مدل‌ها با اندازه‌های متفاوت است که امکان ایجاد توازن میان منابع محاسباتی و عملکرد تشخیص را فراهم می‌کند. این خانواده شامل گونه‌هایی از مدل‌های کوچک و کم‌هزینه تا مدل‌های بزرگ‌تر است و از این نظر برای کاربردهای بلادرنگ با محدودیت منابع سخت‌افزاری انعطاف‌پذیری مناسبی دارد (Lyu et al., 2022).

از دیدگاه معماری، ساختار کلی RTMDet-Tiny را می‌توان به‌صورت زیر نمایش داد:

Input Image→CSPNeXt→Multi-scale Features→CSPNeXt-PAFPN→RTMDet-Tiny Head→{Bounding Boxes,Class Scores}

در این ساختار، Backbone مسئول استخراج نمایش‌های سلسله‌مراتبی از تصویر، Neck مسئول ادغام اطلاعات در مقیاس‌های مختلف و Head مسئول تولید پیش‌بینی‌های طبقه‌بندی و مکان‌یابی است.

۲-۹-۲ فلسفه طراحی و معماری کلی RTMDet-Tiny

طراحی RTMDet-Tiny بر این ایده استوار است که افزایش دقت یک آشکارساز بلادرنگ الزاماً نباید از طریق افزایش شدید عمق یا پیچیدگی مدل انجام شود. در مقاله اصلی RTMDet-Tiny، نویسندگان مجموعه‌ای از مؤلفه‌های معماری و راهبردهای آموزشی را به‌صورت تجربی ارزیابی کرده و سپس ترکیبی از آن‌ها را برای دستیابی به یک آشکارساز کارآمد انتخاب کرده‌اند (Lyu et al., 2022).

در این چارچوب، معماری نهایی از سه بخش اصلی تشکیل می‌شود:

```
RTMDet-Tiny = CSPNeXt Backbone + CSPNeXt-PAFPN Neck + RTMDet-Tiny Detection Head
```

Backbone مبتنی بر CSPNeXt برای استخراج ویژگی طراحی شده است، CSPNeXtPAFPN اطلاعات میان مقیاس‌های مختلف را ترکیب می‌کند و سر تشخیص، پیش‌بینی‌های نهایی را تولید می‌کند. در کنار این ساختار، **Dynamic Soft Label Assigner** نقش مهمی در تعیین نمونه‌های مثبت و منفی در فرآیند آموزش دارد.

بنابراین، نوآوری RTMDet-Tiny را نباید صرفاً به یک Backbone یا Head خاص محدود کرد؛ بلکه عملکرد آن حاصل تعامل میان طراحی معماری، راهبرد تخصیص برچسب و روش‌های آموزشی است.

۳-۹-۲ Backbone مبتنی بر CSPNeXt

Backbone در RTMDet-Tiny از معماری **CSPNeXt** استفاده می‌کند. این ساختار از خانواده معماری‌های Cross Stage Partial الهام گرفته شده و با هدف افزایش بهره‌وری استخراج ویژگی و در عین حال کنترل هزینه محاسباتی طراحی شده است. در پیاده‌سازی MMYOLO،CSPNeXt به‌عنوان Backbone اختصاصی RTMDet-Tiny تعریف شده و امکان مقیاس‌بندی عمق و عرض شبکه را فراهم می‌کند.

یکی از اجزای مهم CSPNeXt، **CSPNeXt Block** است. این بلوک با استفاده از کانولوشن‌های Depthwise با هسته نسبتاً بزرگ، دامنه دریافت فضایی را افزایش می‌دهد، در حالی که هزینه محاسباتی آن نسبت به استفاده مستقیم از کانولوشن‌های متراکم با هسته بزرگ کنترل می‌شود. مقاله RTMDet-Tiny استفاده از بلوک‌هایی با کانولوشن Depthwise با هسته بزرگ را یکی از اجزای مؤثر در طراحی آشکارساز معرفی می‌کند (Lyu et al., 2022).

در پیاده‌سازی CSPNeXt، ساختار Backbone شامل یک **Stem** و چند Stage متوالی است. در مراحل ابتدایی، ویژگی‌های فضایی با وضوح بالاتر استخراج می‌شوند و با افزایش عمق شبکه، وضوح فضایی کاهش یافته و تعداد

کانال‌ها افزایش پیدا می‌کند. این سلسله‌مراتب امکان استخراج ویژگی‌هایی با سطوح مختلف معنایی و فضایی را فراهم می‌سازد.

به‌صورت مفهومی می‌توان فرآیند استخراج ویژگی را چنین نمایش داد:

$$I \rightarrow \text{Backbone} \rightarrow \{F_1, F_2, F_3, F_4\}$$

که در آن II تصویر ورودی و FiF_i نمایش ویژگی در سطوح مختلف شبکه است.

در مسئله تشخیص پسماند دریایی، چنین ساختاری اهمیت ویژه‌ای دارد؛ زیرا اشیای موردنظر ممکن است از نظر اندازه، شکل، بافت و میزان قابل‌مشاهده‌بودن تفاوت زیادی داشته باشند.

۲-۹-۴ Neck مبتنی بر CSPNeXtPAFPN

پس از استخراج ویژگی‌های چندسطحی توسط Backbone، این ویژگی‌ها وارد Neck می‌شوند. RTMDet-Tiny از ساختار **CSPNeXtPAFPN** استفاده می‌کند که ترکیبی از بلوک‌های CSPNeXt و سازوکار Path Aggregation برای انتقال اطلاعات میان سطوح مختلف ویژگی است.

هدف اصلی این بخش، ایجاد نمایش‌هایی است که در آن اطلاعات مکانی سطوح با وضوح بالا و اطلاعات معنایی سطوح عمیق‌تر به شکل مؤثری ترکیب شوند.

به‌صورت مفهومی:

$$I \rightarrow \text{CSPNeXt} \rightarrow \{F_3, F_4, F_5\} \rightarrow \text{CSPNeXt-PAFPN} \rightarrow \{P_3, P_4, P_5\} \rightarrow \text{RTMDet-Tiny Head} \rightarrow \text{Detections}$$

در این رابطه، FiF_i خروجی‌های Backbone و PiP_i ویژگی‌های ادغام‌شده‌ای هستند که برای مرحله تشخیص مورد استفاده قرار می‌گیرند.

در نتیجه، اطلاعات اشیای کوچک که وابستگی بیشتری به جزئیات فضایی دارند، از ویژگی‌های با وضوح بالاتر بهره می‌برند؛ در حالی که ویژگی‌های عمیق‌تر اطلاعات معنایی مناسب‌تری برای تشخیص اشیای بزرگ‌تر فراهم می‌کنند.

۲-۹-۵ Detection Head و ساختار تفکیک‌شده

پس از تولید ویژگی‌های چندمقیاسی، این ویژگی‌ها به سر تشخیص RTMDet-Tiny منتقل می‌شوند. Head وظیفه دارد دو نوع خروجی اصلی را تولید کند:

Detection Head → { Classification → Class Scores ; Bounding-Box Regression → Bounding Boxes }

در پیاده‌سازی RTMDet-Tiny، شاخه طبقه‌بندی و شاخه مکان‌یابی به‌صورت مجزا برای پیش‌بینی کلاس و مختصات جعبه عمل می‌کنند. این تفکیک به مدل اجازه می‌دهد دو وظیفه اصلی تشخیص شیء را با نمایش‌ها و اهداف بهینه‌تر دنبال کند. مستندات MMYOLO نیز در سطح پیاده‌سازی، خروجی‌های جداگانه cls_scores و bbox_preds را برای سطوح مختلف ویژگی نشان می‌دهند.

یکی از اجزای مرتبط با طراحی Head در RTMDet-Tiny، **SepBNHead** است. در این طراحی، بخشی از پارامترهای کانولوشنی میان سطوح مختلف به اشتراک گذاشته می‌شوند، در حالی که آمار Batch Normalization برای سطوح مختلف جدا نگه داشته می‌شود. این راهکار در مطالعه طراحی RTMDet-Tiny به‌عنوان یکی از مؤلفه‌های مؤثر در ایجاد تعادل میان اشتراک پارامترها و تفاوت توزیع ویژگی‌ها در مقیاس‌های مختلف بررسی شده است.

۶-۹-۲ Dynamic Soft Label Assigner

یکی از تفاوت‌های مهم RTMDet-Tiny با بسیاری از آشکارسازهای کلاسیک، راهبرد **Dynamic Soft Label Assigner** است.

در آموزش آشکارسازهای شیء، باید مشخص شود که کدام پیش‌بینی‌ها به هر Ground Truth اختصاص داده شوند. این فرآیند با عنوان **Label Assignment** شناخته می‌شود و مستقیماً بر کیفیت آموزش مدل تأثیر می‌گذارد.

در روش‌های ساده‌تر، نمونه‌ها ممکن است با استفاده از قواعد ثابت فضایی یا معیارهای از پیش تعیین‌شده انتخاب شوند. RTMDet-Tiny از یک راهبرد پویا استفاده می‌کند که کیفیت پیش‌بینی، میزان هم‌پوشانی و اطلاعات طبقه‌بندی را در فرآیند تطبیق لحاظ می‌کند. در این روش، برچسب نرم می‌تواند کیفیت مکانی پیش‌بینی را نیز در تعیین هدف طبقه‌بندی منعکس کند.

به‌صورت مفهومی می‌توان فرآیند را چنین نمایش داد:

Predictions+Ground TruthDynamic Soft Label Assignment

Sample Scores / Matching Quality→{Positive Samples,Negative Samples}

در نتیجه، نمونه مثبت الزاماً تنها بر اساس یک معیار ثابت انتخاب نمی‌شود؛ بلکه کیفیت پیش‌بینی در فرآیند تطبیق وارد می‌شود.

این موضوع برای داده‌های پسماند دریایی اهمیت دارد؛ زیرا در تصاویر زیرآبی یا سطحی، مرز اشیا ممکن است مبهم باشد و کیفیت مکانی پیش‌بینی‌ها در نمونه‌های مختلف تفاوت قابل‌توجهی داشته باشد.

از سوی دیگر، این راهبرد از نظر محاسباتی می‌تواند هزینه حافظه بیشتری ایجاد کند؛ مستندات MMYOLO نیز افزایش مصرف حافظه RTMDet-Tiny را تا حدی به محاسبه ماتریس هزینه در Dynamic Soft Label Assigner نسبت می‌دهند.

۲-۹-۷ توابع زیان در RTMDet-Tiny

```
L_total = L_cls + L_bbox
```

که در آن $\{\{cls\}\}LclsL$ زیان طبقه‌بندی و $\{\{bbox\}\}LbboxL$ زیان مکان‌یابی جعبه است.

در پیاده‌سازی RTMDet-Tiny، وزن نمونه‌ها و معیارهای حاصل از فرآیند تخصیص برچسب در محاسبه زیان‌ها نیز مورد استفاده قرار می‌گیرند؛ به این ترتیب، کیفیت تطبیق نمونه با Ground Truth می‌تواند در میزان اثرگذاری آن نمونه بر فرآیند یادگیری منعکس شود.

از دیدگاه مفهومی:

Label Assignment→Sample Quality Estimation→Loss Weighting→Loss Computation→Model Update

بنابراین، در RTMDet-Tiny فرآیند تخصیص نمونه و محاسبه زیان را نمی‌توان کاملاً مستقل از یکدیگر در نظر گرفت.

۲-۹-۸ راهبردهای بهینه‌سازی و Bag-of-Freebies

یکی از جنبه‌های مهم RTMDet-Tiny این است که بهبود عملکرد تنها از طریق تغییر معماری حاصل نمی‌شود. مقاله اصلی مجموعه‌ای از راهبردهای آموزشی را نیز بررسی می‌کند که می‌توانند بدون افزایش شدید پیچیدگی استنتاج، عملکرد مدل را بهبود دهند (Lyu et al., 2022).

این رویکرد که در ادبیات آشکارسازها با مفهوم **Bag-of-Freebies** شناخته می‌شود، شامل استفاده هدفمند از تکنیک‌هایی در فرآیند آموزش است که هزینه اصلی آن‌ها در زمان آموزش پرداخت می‌شود، نه الزاماً در زمان استنتاج.

در طراحی RTMDet-Tiny، مؤلفه‌هایی مانند بهینه‌سازی مناسب، راهبردهای افزایش داده و پیش‌آموزش Backbone در کنار طراحی معماری مورد بررسی قرار گرفته‌اند. آزمایش‌های ارائه‌شده در مستندات MMYOLO نیز نشان می‌دهد که ترکیب تدریجی این مؤلفه‌ها می‌تواند بهبود عملکرد را بدون افزایش متناظر در هزینه استنتاج ایجاد کند.

این اصل از نظر پژوهشی مهم است؛ زیرا در مقایسه مدل‌ها باید میان **بهبود ناشی از معماری** و **بهبود ناشی از راهبرد آموزش** تمایز مفهومی برقرار شود.

۲-۹-۹ مزایا و محدودیت‌های RTMDet-Tiny در تشخیص پسماند دریایی

RTMDet-Tiny از چند جهت برای مسئله تشخیص پسماند دریایی مناسب است. نخست، طراحی آن با هدف دستیابی به عملکرد بلادرنگ انجام شده است. دوم، استفاده از استخراج ویژگی چندمقیاسی امکان پردازش اشیایی با اندازه‌های متفاوت را فراهم می‌کند. سوم، CSPNeXt و CSPNeXtPAFPN با هدف ایجاد توازن میان ظرفیت نمایش ویژگی و هزینه محاسباتی طراحی شده‌اند (Lyu et al., 2022).

این ویژگی‌ها در تشخیص پسماند دریایی اهمیت دارند؛ زیرا یک تصویر ممکن است هم‌زمان شامل اشیای بسیار کوچک در فاصله دور و اشیای بزرگ‌تر در پیش‌زمینه باشد.

با این حال، RTMDet-Tiny محدودیت‌هایی نیز دارد. فرآیند Dynamic Soft Label Assignment می‌تواند نسبت به برخی روش‌های ساده‌تر هزینه حافظه بیشتری داشته باشد، به‌خصوص زمانی که تعداد جعبه‌های برچسب‌گذاری‌شده در یک Batch زیاد باشد.

همچنین، عملکرد آشکارساز همچنان به کیفیت داده، سازگاری Annotation و میزان شباهت توزیع داده‌های آموزش و آزمون وابسته است. بنابراین، استفاده از معماری قدرتمند به‌تنهایی تضمین‌کننده تعمیم مناسب در شرایط تصویربرداری متفاوت نیست.

۲-۹-۱۰ جایگاه RTMDet-Tiny در پژوهش حاضر

در پژوهش حاضر، RTMDet-Tiny به‌عنوان سومین معماری اصلی در کنار YOLOv8n و RT-DETR-L مورد ارزیابی قرار می‌گیرد. انتخاب این سه مدل امکان مقایسه سه رویکرد متفاوت در طراحی آشکارسازهای مدرن را فراهم می‌کند.

به‌صورت مفهومی: YOLOv8vs.RT-DETR-Lvs.RTMDet-Tiny

در این مقایسه، YOLOv8n نماینده یک آشکارساز تک‌مرحله‌ای مبتنی بر CNN با طراحی Anchor-Free، RT-DETR-L نماینده آشکارسازهای بلادرنگ مبتنی بر Transformer و پیش‌بینی End-to-End، و RTMDet-Tiny نماینده یک آشکارساز CNNمحور با طراحی بهینه‌شده برای کاربردهای بلادرنگ است.

هدف از قرار دادن RTMDet-Tiny در این چارچوب، تعیین این موضوع است که آیا طراحی معماری و راهبردهای آموزشی آن می‌تواند در داده‌های یکپارچه پسماند دریایی، نسبت به دو معماری دیگر مزیت قابل‌توجهی از نظر دقت، سرعت و پایداری ایجاد کند یا خیر.

تمامی مدل‌ها در پژوهش حاضر تحت یک پروتکل کنترل‌شده ارزیابی می‌شوند تا تفاوت مشاهده‌شده تا حد امکان به معماری مدل نسبت داده شود، نه به تفاوت در داده یا شرایط آزمایش.

۲-۹-۱۱ مقایسه مفهومی YOLOv8n،RT-DETR-L و RTMDet-Tiny

جدول 2–3. مقایسه معماری و ویژگی‌هایYOLOv8n ، RT-DETR-L وRTMDet-Tiny

ویژگی	YOLOv8n	RT-DETR-L	RTMDet-Tiny
رویکرد اصلی	CNN	Transformer + CNN	CNN
نوع آشکارساز	One-Stage	End-to-End	One-Stage
Head	Anchor-Free و تفکیک‌شده	Transformer Decoder	تفکیک‌شده
تخصیص نمونه	Task-Aligned Assigner	Matching مبتنی بر Query	Dynamic Soft Label Assigner
NMS در معماری اصلی	دارد	ندارد	دارد
استخراج ویژگی چندمقیاسی	دارد	دارد	دارد
تمرکز طراحی	سرعت و سادگی مؤثر	حذف وابستگی به NMS و End-to-End بودن	توازن دقت، سرعت و کارایی محاسباتی
Backbone/Encoder شاخص	C2f-based CNN	Hybrid Encoder	CSPNeXt
Neck شاخص	FPN–PAN	Hybrid Encoder	CSPNeXtPAFPN

این مقایسه نشان می‌دهد که انتخاب سه معماری مذکور صرفاً مقایسه سه مدل با نام‌های متفاوت نیست؛ بلکه مقایسه‌ای میان **سه مسیر طراحی متفاوت برای دستیابی به تشخیص بلادرنگ** است.

۲-۹-۱۲ جمع‌بندی

RTMDet-Tiny یک آشکارساز بلادرنگ است که طراحی آن حاصل بررسی تجربی و هماهنگ چندین مؤلفه معماری و آموزشی است. ساختار اصلی آن بر پایه CSPNeXt در Backbone، CSPNeXtPAFPN در Neck و یک سر تشخیص تفکیک‌شده شکل گرفته است. در کنار این اجزا، Dynamic Soft Label Assigner نقش مهمی در تعیین نمونه‌های آموزشی و انعکاس کیفیت پیش‌بینی‌ها در فرآیند تطبیق دارد (Lyu et al., 2022).

از منظر پژوهش حاضر، اهمیت RTMDet-Tiny در آن است که امکان ارزیابی یک معماری CNNمحور با طراحی متفاوت از YOLOv8n را در کنار RT-DETR-L فراهم می‌کند. در نتیجه، مقایسه نهایی می‌تواند مشخص کند که در مسئله تشخیص پسماند دریایی و تحت یک پروتکل آزمایشی یکسان، کدام رویکرد از نظر دقت تشخیص، سرعت استنتاج و پایداری عملکرد، مناسب‌تر است.

۲-۱۰ معیارهای ارزیابی عملکرد آشکارسازهای شیء

ارزیابی عملکرد آشکارسازهای شیء صرفاً با یک معیار منفرد نمی‌تواند تصویری کامل از کیفیت یک مدل ارائه کند؛ زیرا یک آشکارساز باید هم‌زمان در شناسایی صحیح اشیاء، تعیین موقعیت مکانی آن‌ها، کاهش پیش‌بینی‌های نادرست، پوشش دادن نمونه‌های واقعی و در کاربردهای بلادرنگ، حفظ سرعت مناسب استنتاج عملکرد قابل قبولی داشته باشد. این مسئله در تشخیص پسماندهای دریایی اهمیت بیشتری پیدا می‌کند، زیرا ویژگی‌هایی مانند اندازه کوچک برخی اشیاء، هم‌پوشانی پسماندها، شباهت ظاهری میان پسماند و عناصر طبیعی، تغییرات روشنایی، کدورت آب، بازتاب نور، تغییر زاویه دید و تفاوت میان شرایط تصویربرداری می‌توانند به‌صورت هم‌زمان بر مکان‌یابی و طبقه‌بندی اثر بگذارند.

در ارزیابی آشکارسازهای شیء، معیارهایی مانند Precision، Recall ، Intersection over Union (IoU)، Average Precision (AP) و mean Average Precision (mAP) برای سنجش کیفیت تشخیص و مکان‌یابی به‌کار می‌روند. در استانداردهای رایج ارزیابی، به‌ویژه پروتکل COCO، AP در چندین آستانه IoU محاسبه می‌شود تا ارزیابی تنها به تشخیص تقریبی شیء محدود نشود و دقت مکانی جعبه‌های پیش‌بینی‌شده نیز مورد سنجش قرار گیرد (Lin et al., 2014).

از سوی دیگر، در کاربردهای عملی، به‌ویژه سامانه‌های پایش و تشخیص بلادرنگ، معیارهای سرعتی مانند Frames Per Second (FPS) و Latency نیز اهمیت دارند. همچنین، هنگامی که هدف ارزیابی

قابلیت استفاده مدل در شرایط متفاوت از داده‌های آموزشی باشد، بررسی افت عملکرد تحت تغییرات توزیع داده یا **Domain Shift** ضروری خواهد بود. در نتیجه، در پژوهش حاضر ارزیابی عملکرد مدل‌ها در یک چارچوب چندمعیاره تعریف می‌شود که ابعاد مختلف دقت تشخیص، دقت مکانی، سرعت استنتاج و پایداری عملکرد تحت تغییر شرایط را پوشش می‌دهد.

۲-۱۰-۱ ماتریس درهم‌ریختگی و مفاهیم FP،TP و FN

در ساده‌ترین سطح، ارزیابی یک سامانه تشخیص شیء بر مبنای مقایسه پیش‌بینی‌های مدل با اشیای مرجع یا **Ground Truth** انجام می‌شود. در این فرایند، هر پیش‌بینی باید از دو جنبه مورد بررسی قرار گیرد: نخست، آیا کلاس پیش‌بینی‌شده با کلاس واقعی مطابقت دارد و دوم، آیا موقعیت مکانی جعبه پیش‌بینی‌شده به اندازه کافی با جعبه مرجع هم‌پوشانی دارد یا خیر.

سه مفهوم اصلی در این ارزیابی عبارت‌اند از:

True Positive (TP): زمانی رخ می‌دهد که مدل یک شیء موجود را با کلاس صحیح و مکان‌یابی قابل قبول شناسایی کند.

False Positive (FP): زمانی رخ می‌دهد که مدل شیئی را پیش‌بینی کند که در **Ground Truth** متناظر معتبر نداشته باشد، یا کلاس پیش‌بینی‌شده نادرست باشد، یا پیش‌بینی مکانی آن برای تطبیق با نمونه واقعی کافی نباشد.

False Negative (FN): زمانی رخ می‌دهد که یک شیء واقعی در **Ground Truth** وجود داشته باشد، اما مدل نتواند آن را به‌درستی شناسایی کند.

به‌صورت مفهومی می‌توان رابطه میان این سه حالت را چنین نمایش داد:

Prediction → { TP: تشخیص صحیح | FP: تشخیص نادرست | FN: شیء از دست‌رفته }

در طبقه‌بندی دودویی کلاسیک، مفهوم **True Negative (TN)** نیز در کنار **FP،TP** و **FN** تعریف می‌شود. بااین‌حال، در تشخیص شیء، استفاده مستقیم از **TN** به همان معنای طبقه‌بندی کلاسیک مناسب نیست؛ زیرا فضای تصویر شامل تعداد بسیار زیادی مکان بالقوه برای «عدم وجود شیء» است و تعریف واحد و معناداری از همه مکان‌های منفی وجود ندارد. به همین دلیل، معیارهای استاندارد تشخیص شیء مانند **Precision،Recall، AP** و **mAP** عمدتاً بر **FP،TP، FN** ، رتبه‌بندی پیش‌بینی‌ها و میزان هم‌پوشانی جعبه‌ها تمرکز می‌کنند و **TN** را به‌صورت مستقیم وارد محاسبه نمی‌کنند.

بنابراین، در پژوهش حاضر نیز ارزیابی آشکارسازها بر مبنای معیارهای متداول **Object Detection** انجام می‌شود و از تفسیر مستقیم **TN** به‌عنوان یک مؤلفه مستقل ماتریس درهم‌ریختگی اجتناب می‌شود. این رویکرد از نظر روش‌شناختی با پروتکل‌های استاندارد ارزیابی آشکارسازهای شیء سازگارتر است.

برای تعیین اینکه یک پیش‌بینی از نوع **TP** محسوب شود یا خیر، علاوه بر تطابق کلاس، معمولاً یک آستانه برای **IoU** میان جعبه پیش‌بینی‌شده و جعبه واقعی در نظر گرفته می‌شود. بنابراین:

$$TP \Leftrightarrow ClassMatch \wedge IoU \geq \tau\{TP\{ClassMatch\}IoU\}$$

τ = آستانه IoU

۲-۱۰-۲ معیار Precision

معیار **Precision** بیانگر نسبت پیش‌بینی‌های مثبت صحیح به کل پیش‌بینی‌های مثبت مدل است. این معیار نشان می‌دهد از میان تمام اشیایی که مدل به‌عنوان یک نمونه معتبر شناسایی کرده است، چه نسبتی واقعاً صحیح بوده‌اند.

Precision به‌صورت زیر تعریف می‌شود:

$$Precision = TPTP + FP\{Precision = \{TP\}\{TP + FP\}\}$$

هرچه مقدار **Precision** بیشتر باشد، تعداد پیش‌بینی‌های نادرست یا **False Positive** کمتر است.

در مسئله تشخیص پسماند دریایی، **Precision** بالا اهمیت ویژه‌ای دارد؛ زیرا ممکن است عناصر طبیعی مانند سنگ، گیاه، حباب، انعکاس نور یا ساختارهای زیستی با پسماند اشتباه گرفته شوند. چنین خطاهایی موجب افزایش **FP** شده و در نتیجه **Precision** را کاهش می‌دهند.

برای مثال، اگر یک مدل از میان ۱۰۰ پیش‌بینی خود، ۸۵ پیش‌بینی صحیح و ۱۵ پیش‌بینی نادرست داشته باشد، خواهیم داشت:

Precision = TP / (TP + FP) = 85 / (85 + 15) = 0.85

بنابراین **Precision** برابر با ۸۵ درصد خواهد بود.

بااین‌حال، **Precision** به‌تنهایی کافی نیست. مدلی ممکن است با تولید تعداد محدودی پیش‌بینی بسیار مطمئن، **Precision** بالایی به دست آورد، اما تعداد زیادی از اشیای واقعی را تشخیص ندهد. برای اندازه‌گیری این جنبه، **Recall** مورد استفاده قرار می‌گیرد.

۲-۱۰-۳ معیار Recall

معیار Recall یا حساسیت بیانگر توانایی مدل در شناسایی نمونه‌های واقعی است. این معیار نسبت اشیای واقعی که به‌درستی شناسایی شده‌اند به کل اشیای موجود در Ground Truth را نشان می‌دهد.

رابطه Recall به‌صورت زیر است:

$$Recall = TPTP + FN\{Recall = \{TP\}\{TP + FN\}\}$$

در این رابطه، FN نشان‌دهنده نمونه‌های واقعی است که مدل نتوانسته است آن‌ها را به‌درستی تشخیص دهد.

هرچه Recall بیشتر باشد، تعداد اشیای واقعی ازدست‌رفته کمتر خواهد بود. این موضوع در سامانه‌های پایش پسماند دریایی اهمیت قابل توجهی دارد؛ زیرا از دست دادن یک پسماند واقعی، به‌ویژه پسماندهای کوچک یا کم‌وضوح، می‌تواند قابلیت عملی سامانه را کاهش دهد.

برای مثال، اگر در یک مجموعه ارزیابی ۱۰۰ شیء واقعی وجود داشته باشد و مدل بتواند ۸۵ مورد را به‌درستی شناسایی کند، درحالی‌که ۱۵ مورد را از دست بدهد، خواهیم داشت:

$$Recall = 8585 + 15 = 0.85Recall = \{85\}\{85 + 15\} = 0.85$$

Recall = TP / (TP + FN) = 85 / (85 + 15) = 0.85

رابطه میان Precision و Recall از مهم‌ترین ملاحظات ارزیابی آشکارسازهای شیء است. افزایش سخت‌گیری مدل در پذیرش پیش‌بینی‌ها می‌تواند تعداد False Positiveها را کاهش داده و Precision را افزایش دهد، اما هم‌زمان ممکن است برخی اشیای واقعی حذف شده و Recall کاهش پیدا کند. ازاین‌رو، ارزیابی هم‌زمان این دو معیار ضروری است.

۲-۱۰-۴ معیار Intersection over Union (IoU)

در تشخیص شیء، صحیح بودن کلاس به‌تنهایی کافی نیست و موقعیت مکانی شیء نیز باید با دقت مناسبی تعیین شود. معیار Intersection over Union (IoU) یکی از متداول‌ترین معیارها برای اندازه‌گیری میزان هم‌پوشانی میان جعبه پیش‌بینی‌شده و جعبه مرجع است.

اگر B_p جعبه پیش‌بینی‌شده و B_gt جعبه Ground Truth باشد، IoU به‌صورت زیر تعریف می‌شود:

$$IoU = |Bp \cap Bgt||Bp \cup Bgt|\{IoU = \{\vee B_pB_{\{} >\} \vee\}\{\vee B_pB_{\{} >\} \vee\}\}$$

که در آن:

- **BpB_p: جعبه مرزی پیش‌بینی‌شده؛**
- **BgtB_{gt}: جعبه مرزی واقعی؛**

- **$B_p \cap B_{gt}$**: ناحیه اشتراک دو جعبه؛
- **$B_p \cup B_{gt}$**: ناحیه اجتماع دو جعبه.

مقدار **IoU** در بازه صفر تا یک قرار می‌گیرد:

$$0 \leq IoU \leq 1$$

مقدار صفر نشان‌دهنده عدم هم‌پوشانی و مقدار یک بیانگر تطابق کامل دو جعبه است.

برای مثال، اگر سطح اشتراک دو جعبه برابر ۶۰ واحد و سطح اجتماع آن‌ها برابر ۱۰۰ واحد باشد:

$$IoU = |B_p \cap B_{gt}| / |B_p \cup B_{gt}| = 60 / 100 = 0.60$$

بنابراین میزان هم‌پوشانی برابر با ۰/۶ یا ۶۰ درصد است.

در ارزیابی آشکارساز، معمولاً **IoU** به‌عنوان یک آستانه برای تعیین صحیح یا نادرست بودن مکان‌یابی مورد استفاده قرار می‌گیرد. به‌عنوان نمونه، در آستانه:

$$IoU \geq 0.50$$

پیش‌بینی‌ای که هم‌زمان کلاس صحیح داشته باشد و **IoU** آن با **Ground Truth** حداقل ۰/۵ باشد، می‌تواند به‌عنوان یک تشخیص صحیح در نظر گرفته شود.

اهمیت **IoU** در پژوهش حاضر از آن جهت است که پسماندهای دریایی ممکن است شکل‌های نامنظم، اندازه‌های کوچک، مرزهای مبهم و هم‌پوشانی بالایی داشته باشند. بنابراین، صرف تشخیص وجود یک شیء کافی نیست و کیفیت مکان‌یابی آن نیز باید ارزیابی شود.

۲-۱۰-۵ منحنی Precision–Recall

از آنجا که خروجی آشکارسازهای شیء معمولاً شامل یک **Confidence Score** برای هر پیش‌بینی است، می‌توان با تغییر آستانه پذیرش پیش‌بینی‌ها، مقادیر مختلف **Precision** و **Recall** را به دست آورد.

اگر آستانه **Confidence** افزایش یابد، مدل فقط پیش‌بینی‌های مطمئن‌تر را حفظ می‌کند. این امر معمولاً باعث کاهش **False Positive** و افزایش **Precision** می‌شود، اما ممکن است برخی پیش‌بینی‌های صحیح با **Confidence** پایین نیز حذف شده و **Recall** کاهش یابد.

برعکس، کاهش آستانه **Confidence** معمولاً موجب افزایش **Recall** می‌شود، اما می‌تواند تعداد پیش‌بینی‌های اشتباه را نیز افزایش دهد.

نتیجه این فرایند، مجموعه‌ای از نقاط Precision–Recall است که می‌توان آن‌ها را به‌صورت منحنی نمایش داد:

$$\text{PR Curve} = \{(\text{Recall}_i, \text{Precision}_i)\}, i = 1, \ldots, n$$

محور افقی منحنی PR معمولاً Recall و محور عمودی Precision است.

یک آشکارساز مطلوب باید بتواند در محدوده وسیعی از Recall، Precision بالایی حفظ کند. بنابراین، منحنی‌ای که در قسمت بالاتری از فضای Precision–Recall قرار گیرد، در حالت کلی عملکرد بهتری دارد.

این ویژگی باعث می‌شود منحنی PR نسبت به گزارش یک Precision یا Recall منفرد، تصویر جامع‌تری از رفتار آشکارساز ارائه کند.

۲-۱۰-۶ معیار Average Precision (AP)

معیار Average Precision (AP) برای خلاصه‌سازی عملکرد مدل در سراسر منحنی Precision–Recall استفاده می‌شود. به‌صورت مفهومی، AP را می‌توان مساحت زیر منحنی Precision–Recall در نظر گرفت:

$$AP = \int_0^1 P(R)dR \{AP = \quad {}_{\{}0\}^{\{}1\}P(R)dR\}$$

که در آن P(R)P(R) تابع Precision برحسب Recall است.

در پیاده‌سازی‌های واقعی، این انتگرال به‌صورت گسسته و با استفاده از نقاط مختلف منحنی Precision–Recall محاسبه می‌شود. در پروتکل‌های مدرن مبتنی بر COCO، منحنی Precision–Recall با نمونه‌برداری متراکم از Recall ارزیابی می‌شود و AP در آستانه‌های مختلف IoU محاسبه می‌گردد (Lin et al., 2014).

به‌صورت کلی، AP یک کلاس cc در آستانه IoU برابر τ\tau را می‌توان به شکل زیر نمایش داد:

$$AP_c(\tau) = \int_0^1 P_c(R; \tau)\, dR$$

در این رابطه، زیروند cc به کلاس موردنظر و τ\tau به آستانه IoU اشاره دارد.

AP بنابراین دو جنبه را به‌طور هم‌زمان در نظر می‌گیرد:

۱. توانایی مدل در حفظ Precision؛

۲. توانایی مدل در افزایش Recall.

ازاین‌رو، **AP** نسبت به استفاده از **Precision** یا **Recall** در یک آستانه **Confidence** مشخص، معیار جامع‌تری برای ارزیابی آشکارساز است.

۲-۱۰-۷ معیار mAP@0.50

برای چندکلاسه بودن مسئله، عملکرد مدل باید برای هر کلاس به‌صورت جداگانه محاسبه شده و سپس میانگین‌گیری شود. اگر تعداد کلاس‌ها برابر **CC** باشد، **mAP** در یک آستانه مشخص از **IoU** به‌صورت زیر تعریف می‌شود:

$$\mathrm{mAP}(\tau) = (1 / C)\ \Sigma_c{=}1\text{^}C\ \mathrm{AP}_c(\tau)$$
$$\tau = 0.50$$

$$mAP@0.50 = 1C\sum c = 1CAPc(0.50)\{mAP@0.50 = \{1\}\{C\}\quad \{c = 1\}^{\{C\}}AP_c(0.50)\}$$

این معیار نشان می‌دهد که مدل در شرایطی که حداقل ۵۰ درصد هم‌پوشانی میان جعبه پیش‌بینی و **Ground Truth** برای پذیرش مکان‌یابی کافی باشد، به‌طور میانگین چه عملکردی در تمام کلاس‌ها دارد.

mAP@0.50 نسبت به خطای مکان‌یابی حساسیت کمتری نسبت به معیارهای مبتنی بر آستانه‌های بالاتر **IoU** دارد. به همین دلیل، ممکن است مدلی **mAP@0.50** بالایی داشته باشد، اما در آستانه‌های بالاتر **IoU** عملکرد ضعیف‌تری نشان دهد.

در مسئله حاضر، این تفاوت اهمیت دارد؛ زیرا ممکن است مدل بتواند وجود یک قطعه پسماند را به‌درستی تشخیص دهد، اما جعبه پیش‌بینی‌شده آن به‌اندازه کافی دقیق نباشد.

۲-۱۰-۸ معیار mAP@0.50:0.95

یکی از مهم‌ترین معیارهای استاندارد ارزیابی آشکارسازهای شیء، **mAP@0.50:0.95** یا **COCO-style mAP** است. در این معیار، **AP** در ده آستانه **IoU** از ۰/۵۰ تا ۰/۹۵ با گام ۰/۰۵ محاسبه شده و سپس میانگین آن‌ها گرفته می‌شود. این روش برخلاف ارزیابی صرفاً در **IoU=0.50**، کیفیت مکان‌یابی را در سطوح مختلف سخت‌گیری ارزیابی می‌کند (**Lin et al., 2014**).

مجموعه آستانه‌ها عبارت است از:

$$T = \{0.50, 0.55, 0.60, 0.65, 0.70, 0.75, 0.80, 0.85, 0.90, 0.95\}$$

در نتیجه:

$$mAP@0.50{:}\,0.95 = 110\sum\tau \in TmAP(\tau)\{mAP@0.50{:}\,0.95 = \{1\}\{10\}\quad {}_{\{}T\}mAP()\}$$

یا به‌صورت بازتر:

$$mAP@0.50{:}\,0.95$$
$$= 110[mAP50 + mAP55 + mAP60 + \cdots + mAP95]\{mAP@0.50{:}\,0.95$$
$$= \{1\}\{10\}\left[mAP_{\{}50\} + mAP_{\{}55\} + mAP_{\{}60\} + +mAP_{\{}95\}\right]\}$$

این معیار نسبت به mAP@0.50 سخت‌گیرانه‌تر است؛ زیرا در آستانه‌های بالاتر، جعبه پیش‌بینی باید از نظر مکانی تطابق بیشتری با Ground Truth داشته باشد.

به همین دلیل، فاصله میان:

mAP@0.50mAP@0.50

و

mAP@0.50:0.95mAP@0.50:0.95

می‌تواند اطلاعات مفیدی درباره کیفیت مکان‌یابی مدل ارائه کند. اگر مقدار mAP@0.50 بالا ولی mAP@0.50:0.95 به‌طور محسوسی پایین‌تر باشد، می‌توان استنباط کرد که مدل در تشخیص کلی اشیاء موفق است، اما دقت مکان‌یابی جعبه‌ها در شرایط سخت‌تر محدودیت دارد.

پروتکل COCO دقیقاً با هدف ارائه ارزیابی ظریف‌تر از کیفیت تشخیص و مکان‌یابی، میان چندین آستانه IoU میانگین‌گیری می‌کند (Lin et al., 2014).

ازاین‌رو، در پژوهش حاضر mAP@0.50:0.95 باید معیار اصلی برای مقایسه کلی کیفیت تشخیص مدل‌ها در نظر گرفته شود و mAP@0.50 در کنار آن برای تفسیر آسان‌تر عملکرد در آستانه استاندارد ۰/۵ گزارش شود.

۲-۱۰-۹ مقایسه mAP@0.50 و mAP@0.50:0.95

اگرچه هر دو معیار بر پایه AP ساخته شده‌اند، حساسیت آن‌ها به کیفیت مکان‌یابی یکسان نیست.

جدول 2-4. مقایسه معیارهای mAP@0.50 وmAP@0.50:0.95

معیار	تعریف	حساسیت به مکان‌یابی دقیق	کاربرد تفسیری
mAP@0.50	میانگین AP در IoU=0.50	متوسط	توانایی کلی تشخیص
mAP@0.50:0.95	میانگین AP در IoUهای	بالا	کیفیت جامع تشخیص و

مکان‌یابی		0.50 تا 0.95	

در نتیجه، استفاده هم‌زمان از این دو معیار امکان تفکیک دو جنبه متفاوت از عملکرد را فراهم می‌کند. **mAP@0.50** بیشتر پاسخ می‌دهد که آیا مدل توانسته است اشیاء را به‌طور کلی شناسایی کند یا خیر؛ درحالی‌که **mAP@0.50:0.95** علاوه بر شناسایی، کیفیت مکان‌یابی جعبه را نیز در سطوح مختلف سخت‌گیری ارزیابی می‌کند.

۲-۱۰-۱۰ ارزیابی عملکرد در سطح کلاس

میانگین کلی **mAP** ممکن است برخی ضعف‌های کلاس‌محور را پنهان کند. به همین دلیل، در مسائل چندکلاسه، بررسی **AP** هر کلاس نیز اهمیت دارد.

اگر مجموعه کلاس‌ها به‌صورت زیر تعریف شود:

$$C = \{c_1, c_2, \ldots, c_{13}\}$$

آنگاه برای هر کلاس می‌توان مقدار:

APciAP_{c_i}

را محاسبه کرد.

در پژوهش حاضر، این موضوع به‌طور خاص اهمیت دارد؛ زیرا کلاس‌های مختلف پسماند دریایی از نظر اندازه، شکل، بافت، میزان مشاهده‌پذیری و فراوانی نمونه‌ها یکسان نیستند. برای مثال، ممکن است یک کلاس با تعداد نمونه زیاد، سهم قابل توجهی در **mAP** کلی داشته باشد، درحالی‌که مدل در یک کلاس کم‌نمونه عملکرد ضعیفی ارائه دهد.

بنابراین، گزارش موارد زیر می‌تواند تصویر دقیق‌تری از رفتار مدل ارائه کند:

$$APanimal_{crab}, APanimal_{eel}, \ldots, APtrash_{plastic}\{AP_{\{}animalcrab\}, AP_{\{}animaleel\}, , AP_{\{}trashplastic\}\}$$

همچنین می‌توان برای هر کلاس، **Recall**،**Precision** و **AP** را به‌صورت جداگانه تحلیل کرد.

این تحلیل برای تشخیص عدم توازن عملکرد میان کلاس‌ها اهمیت دارد؛ زیرا یک مدل تنها زمانی می‌تواند به‌عنوان آشکارساز مناسب پسماند دریایی ارزیابی شود که عملکرد آن صرفاً ناشی از کلاس‌های پرتعداد نباشد.

۲-۱۰-۱۱ معیارهای سرعت: FPS

دقت بالا برای یک آشکارساز کافی نیست، به‌ویژه زمانی که مدل برای سامانه‌های پایش بلادرنگ، ربات‌های زیرآبی، پهپادها یا سامانه‌های تصویربرداری مستمر در نظر گرفته شود.

یکی از رایج‌ترین معیارهای سرعت، **Frames Per Second (FPS)** است. **FPS** تعداد فریم‌هایی را نشان می‌دهد که مدل در یک ثانیه پردازش می‌کند.

اگر مدل **NN** فریم را در مدت **TT** ثانیه پردازش کند:

$$FPS = N / T$$

برای مثال، اگر یک مدل ۱۰۰۰ تصویر را در ۵۰ ثانیه پردازش کند:

$$FPS = 1000 / 50 = 20\ FPS$$

بنابراین نرخ پردازش برابر با ۲۰ فریم بر ثانیه خواهد بود.

هرچه **FPS** بیشتر باشد، سرعت پردازش بالاتر است.

بااین‌حال، مقایسه **FPS** میان مدل‌ها تنها زمانی معتبر است که شرایط اندازه‌گیری یکسان باشد. عواملی مانند:

- سخت‌افزار،
- اندازه تصویر،
- دقت عددی،
- **Batch Size**،
- روش زمان‌گیری،
- زمان پیش‌پردازش،
- زمان پس‌پردازش،
- انتقال داده میان **CPU** و **GPU**،
- و **Warm-up** اولیه **GPU**

می‌توانند بر مقدار **FPS** اثر بگذارند.

بنابراین، در مقایسه علمی مدل‌های **YOLOv8n**، **RT-DETR-L** و **RTMDet-Tiny**، اندازه‌گیری **FPS** باید تحت شرایط سخت‌افزاری و ورودی یکسان انجام شود.

۲-۱۰-۱۲ معیار Latency

Latency یا زمان تأخیر، مدت‌زمان لازم برای پردازش یک ورودی و تولید خروجی را نشان می‌دهد. اگر T_total زمان لازم برای پردازش NN نمونه باشد، میانگین زمان پردازش هر نمونه از رابطه زیر به دست می‌آید:

```
Latency = T_total / N
```

اگر زمان برحسب ثانیه باشد، برای تبدیل به میلی‌ثانیه خواهیم داشت:

$$Latencyms = TtotalN \times 1000\{Latency_{\{}ms\} = \{T_{\{}\{total\}\}\}\{N\}1000\}$$

برای مثال، اگر ۱۰۰۰ تصویر در ۲۰ ثانیه پردازش شوند:

```
Latency = 20 / 1000 = 0.02 s
```

و در نتیجه:

```
Latency = 20 ms
```

در شرایط ایده‌آل و زمانی که کل زمان پردازش یک فریم در FPS لحاظ شده باشد، می‌توان رابطه تقریبی زیر را در نظر گرفت:

```
FPS ≈ 1000 / Latency_ms
```

بااین‌حال، این رابطه تنها در صورتی معتبر است که تعریف Latency و FPS دقیقاً یکسان باشد. اگر مثلاً FPS فقط زمان Forward Pass را در نظر بگیرد، اما Latency شامل Pre-processing و Post-processing نیز باشد، مقادیر حاصل را نمی‌توان مستقیماً معکوس یکدیگر در نظر گرفت.

ازاین‌رو، در گزارش نتایج باید دقیقاً مشخص شود که زمان‌گیری مربوط به کدام بخش از Pipeline است.

۲-۱۰-۱۳ اهمیت یکسان‌سازی شرایط اندازه‌گیری سرعت

سرعت استنتاج یک مدل به‌تنهایی یک ویژگی مطلق معماری نیست و به شرایط اجرا وابسته است. بنابراین، مقایسه سه معماری مختلف زمانی علمی خواهد بود که عوامل اصلی آزمایش ثابت نگه داشته شوند.

به‌صورت مفهومی:

```
Performance_speed = f(Architecture, Hardware, Input Size, Precision, Batch, Pipeline)
```

در نتیجه، اگر یک مدل با اندازه تصویر کوچک‌تر یا دقت عددی متفاوت ارزیابی شود، مقایسه مستقیم FPS آن با مدل دیگری که تحت شرایط متفاوت اجرا شده است می‌تواند منجر به نتیجه‌گیری نادرست شود.

در پژوهش حاضر، بنابراین سرعت باید در چارچوب یک پروتکل کنترل‌شده گزارش شود و شرایط اجرای سه مدل تا حد امکان یکسان نگه داشته شود.

۲-۱۰-۱۴ مفهوم Robustness در آشکارسازهای شیء

Robustness یا استحکام عملکرد به توانایی مدل برای حفظ سطح قابل قبول عملکرد در مواجهه با تغییرات و اختلالاتی اشاره دارد که الزاماً در داده‌های آموزشی به همان شکل مشاهده نشده‌اند.

در مسئله تشخیص پسماند دریایی، عوامل متعددی می‌توانند موجب کاهش عملکرد شوند؛ از جمله:

- **تغییر شرایط روشنایی؛**
- **تغییر زاویه تصویربرداری؛**
- **تغییر عمق یا شرایط آب؛**
- **کدورت و کاهش وضوح؛**
- **بازتاب و شکست نور؛**
- **تاری حرکتی؛**
- **تغییر پس‌زمینه؛**
- **تغییر اندازه ظاهری اشیاء؛**
- **هم‌پوشانی چند پسماند؛**
- **تفاوت نوع دوربین و حسگر؛**
- **و تفاوت میان محیط‌های تصویربرداری.**

بنابراین، عملکرد بالا روی داده آزمون هم‌توزیع با داده آموزش لزوماً به معنای Robust بودن مدل نیست.

در ادبیات یادگیری ماشین، یکی از چالش‌های اساسی زمانی رخ می‌دهد که توزیع داده‌های آزمون با داده‌های آموزش متفاوت باشد. این وضعیت تحت عنوان **Domain Shift** شناخته می‌شود و می‌تواند باعث افت قابل توجه عملکرد مدل شود (**Zhou et al., 2023**).

۲-۱۰-۱۵ مفهوم Domain Shift

فرض می‌شود داده‌های آموزشی از یک توزیع مبدأ به‌صورت زیر نمونه‌برداری شوند:

$$P_s(X, Y) \sim (X_s, Y_s)$$

و داده‌های ارزیابی هدف از توزیع دیگری تولید شوند:

$$P_t(X, Y) \sim (X_t, Y_t)$$

اگر:

$$P_s(X, Y) \neq P_t(X, Y)$$

باشد، می‌توان گفت میان حوزه مبدأ و هدف نوعی **Domain Shift** وجود دارد.

این تفاوت ممکن است از چند منشأ ناشی شود:

۱. تغییر شرایط محیطی؛

۲. تغییر حسگر یا دوربین؛

۳. تغییر زاویه دید؛

۴. تغییر کیفیت تصویر؛

۵. تغییر پس‌زمینه؛

۶. تغییر توزیع اندازه اشیاء؛

۷. تغییر توزیع کلاس‌ها؛

۸. یا ترکیبی از عوامل فوق.

در کاربردهای دریایی، چنین مسئله‌ای کاملاً محتمل است؛ زیرا تصاویر ثبت‌شده توسط دوربین‌های زیرآبی، تصاویر **ROV**، تصاویر سطح آب یا تصاویر ثبت‌شده در شرایط نوری متفاوت الزاماً توزیع بصری یکسانی ندارند.

پژوهش‌های حوزه **Domain Generalization** نیز نشان می‌دهند که مدل‌هایی که روی یک توزیع داده آموزش دیده‌اند، ممکن است در مواجهه با داده‌های خارج از توزیع افت عملکرد داشته باشند (**Zhou et al., 2023**).

۲-۱۰-۱۶ تفاوت **Robustness**، **Domain Shift** و **Domain Generalization**

این سه مفهوم نباید به‌صورت مترادف استفاده شوند.

Robustness یک ویژگی عملکردی است و به میزان حفظ عملکرد مدل در برابر تغییرات و اختلالات اشاره می‌کند.

Domain Shift وضعیت یا پدیده‌ای است که در آن توزیع داده آموزش و ارزیابی با یکدیگر متفاوت می‌شود.

Domain Generalization مسئله‌ای است که در آن مدل با استفاده از داده‌های حوزه مبدأ آموزش داده می‌شود و هدف، عملکرد مناسب روی حوزه‌های ناشناخته یا خارج از توزیع بدون استفاده مستقیم از داده هدف در فرایند آموزش است (**Zhou et al., 2023**).

بنابراین رابطه مفهومی را می‌توان به شکل زیر بیان کرد:

$$DomainShift \rightarrow PotentialPerformanceDegradation$$
$$\rightarrow RobustnessEvaluation\{DomainPotentialRobustness\}$$

و در سطح وسیع‌تر:

Source Domain → Training → Unseen Target Domain → Generalization

در پژوهش حاضر، هدف اصلی توسعه یک روش **Domain Adaptation** جدید نیست؛ بلکه مقایسه میزان حفظ عملکرد مدل‌ها در شرایط متفاوت و بررسی افت عملکرد آن‌هاست. بنابراین، اصطلاح **Robustness under Domain Shift** برای توصیف این بخش مناسب‌تر از ادعای انجام **Domain Adaptation** است.

این تفکیک از نظر علمی اهمیت دارد، زیرا **Domain Adaptation** معمولاً مستلزم استفاده از اطلاعات حوزه هدف در فرایند آموزش یا سازگارسازی مدل است، درحالی‌که ارزیابی **Robustness** می‌تواند صرفاً عملکرد مدل آموزش‌دیده را روی شرایط متفاوت بررسی کند. ادبیات جدید تشخیص بین‌حوزه‌ای نیز

Domain Shift را یکی از عوامل اصلی افت عملکرد آشکارسازهای آموزش‌دیده در یک حوزه و استفاده‌شده در حوزه دیگر معرفی می‌کند.

۲-۱۰-۱۷ ارزیابی افت عملکرد تحت شرایط تغییریافته

برای سنجش Robustness، تنها گزارش عملکرد مدل در شرایط پایه کافی نیست. باید عملکرد مدل در شرایط پایه و شرایط تغییریافته با یکدیگر مقایسه شوند.

فرض شود:

$$McleanM_{\{\{clean\}\}}$$

عملکرد مدل در شرایط پایه و:

$$MconditionM_{\{\{condition\}\}}$$

عملکرد همان مدل در یک شرایط تغییریافته باشد.

برای معیارهایی که مقدار بیشتر نشان‌دهنده عملکرد بهتر است، مانند Recall،Precision و mAP، افت نسبی عملکرد به‌صورت زیر تعریف می‌شود:

$$\Delta rel(\%) = Mclean - MconditionMclean \times 100\{ \quad _{\{\{rel\}\}}()$$
$$= ac\{M_{\{\{clean\}\}} - M_{\{\{condition\}\}}\}\{M_{\{\{clean\}\}}\}100\}$$

اگر مثلاً مقدار mAP مدل در شرایط پایه برابر ۰/۶۰ و در شرایط تغییریافته برابر ۰/۴۸ باشد:

$$\Delta rel = 0.60 - 0.480.60 \times 100 \quad _{\{\{rel\}\}} = \{0.60 - 0.48\}\{0.60\}100$$

بنابراین:

$$\Delta rel = 20\% \quad _{\{\{rel\}\}} = 20$$

یعنی مدل در شرایط تغییریافته نسبت به حالت پایه، ۲۰ درصد افت نسبی داشته است.

برای معیارهایی که مقدار کمتر نشان‌دهنده عملکرد بهتر است، مانند Latency، تعریف افت باید متناسب با جهت مطلوب معیار تنظیم شود. در این حالت:

$$\Delta_rel(\%) = [(M_clean - M_condition) / M_clean] \times 100$$

این تعریف باعث می‌شود افزایش Latency به‌عنوان بدتر شدن عملکرد تلقی شود.

۲-۱۰-۱۸ شاخص حفظ عملکرد

برای تفسیر ساده‌تر Robustness می‌توان از شاخص Performance Retention یا درصد حفظ عملکرد نیز استفاده کرد.

برای معیارهایی که مقدار بیشتر بهتر است:

$$Retention(\%) = MconditionMclean \times 100\{Retention() = \{M_{\{}\{condition\}\}\}\{M_{\{}\{clean\}\}\}100\}$$

همچنین رابطه میان Retention و افت نسبی چنین است:

$$Retention(\%) = 100 - \Delta rel(\%)\{Retention() = 100 - \ _{\{}\{rel\}\}()\}$$

برای مثال، اگر مدل در شرایط پایه mAP برابر ۰/۶۰ و در شرایط تغییریافته ۰/۴۸ داشته باشد:

Retention(%) = (M_condition / M_clean) × 100 = (0.48 / 0.60) × 100 = 80%

در نتیجه می‌توان گفت مدل ۸۰ درصد از عملکرد پایه خود را حفظ کرده و افت نسبی آن ۲۰ درصد بوده است.

این شاخص برای مقایسه سه معماری مفید است، زیرا ممکن است یک مدل در شرایط پایه بهترین mAP را داشته باشد، اما تحت Domain Shift افت بیشتری نشان دهد؛ درحالی‌که مدل دیگری ممکن است mAP پایه کمی پایین‌تر اما پایداری بیشتری داشته باشد.

۲-۱۰-۱۹ مقایسه منصفانه مدل‌ها با استفاده از چند معیار

هدف اصلی پژوهش حاضر صرفاً یافتن مدلی با بیشترین mAP نیست، بلکه مقایسه جامع سه معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny از جنبه‌های مختلف است.

بنابراین، عملکرد هر مدل را می‌توان به‌صورت یک بردار چندبعدی در نظر گرفت:

$$P = [Precision, Recall, mAP@0.50, mAP@0.50{:}\ 0.95, FPS, Latency, Robustness]\{bf\{P\} = [Precision, Recall, mAP@0.50, mAP@0.50{:}\ 0.95, FPS, Latency, Robustness]\}$$

در این چارچوب، هیچ معیار منفردی قادر نیست تمام ابعاد عملکرد مدل را توصیف کند.

برای مثال:

- **Precision بالا → خطای مثبت کاذب کمتر؛**
- **Recall بالا → اشیای واقعی کمتری از دست می‌روند؛**

- **mAP@0.50 بالا ← عملکرد مناسب در آستانه استاندارد IoU؛**
- **mAP@0.50:0.95 بالا ← مکان‌یابی دقیق‌تر در آستانه‌های سخت‌گیرانه؛**
- **FPS بالا ← توانایی پردازش سریع‌تر؛**
- **Latency پایین ← پاسخ سریع‌تر برای هر تصویر؛**
- **افت عملکرد کمتر ← Robustness بالاتر در شرایط متفاوت.**

بنابراین، ممکن است یک مدل از نظر دقت بهترین باشد، اما از نظر سرعت ضعیف‌تر عمل کند؛ یا مدلی سرعت بیشتری داشته باشد اما تحت Domain Shift افت عملکرد بیشتری نشان دهد.

۲-۱۰-۲۰ مسئله Trade-off میان دقت و سرعت

یکی از مهم‌ترین مسائل در طراحی آشکارسازهای بلادرنگ، وجود Trade-off میان دقت و سرعت است.

به‌صورت مفهومی:

$$Accuracy \leftrightarrow Efficiency\{AccuracyEfficiency\}$$

مدل‌های پیچیده‌تر معمولاً ظرفیت بیشتری برای استخراج ویژگی‌های غنی دارند، اما افزایش پیچیدگی محاسباتی می‌تواند زمان استنتاج و مصرف منابع را افزایش دهد. در مقابل، مدل‌های سبک‌تر ممکن است سرعت بالاتری داشته باشند، اما در برخی شرایط از نظر دقت یا مکان‌یابی ضعیف‌تر باشند.

ازاین‌رو، مقایسه مدل‌ها باید به‌جای تمرکز بر یک معیار، بر مبنای مجموعه‌ای از شاخص‌های مکمل انجام شود.

در پژوهش حاضر، این موضوع اهمیت ویژه‌ای دارد؛ زیرا هدف، مقایسه سه خانواده معماری با فلسفه طراحی متفاوت است:

$$YOLOv8 \leftrightarrow RT-DETR-L$$
$$\leftrightarrow RTMDet-Tiny\{YOLOv8RT-DETR-LRTMDet-Tiny\}$$

در اینجا علامت دوطرفه صرفاً بیانگر مقایسه تجربی سه معماری است و به معنای ارتباط ساختاری یا تبدیل یک معماری به معماری دیگر نیست.

۲-۱۰-۲۱ اهمیت mAP به‌عنوان معیار اصلی دقت

در مقایسه آشکارسازهای چندکلاسه، استفاده از mAP به دلیل ترکیب عملکرد کلاس‌های مختلف و وابستگی آن به Precision–Recall و IoU، معیار مناسبی برای ارزیابی کلی محسوب می‌شود.

بااین‌حال، در این پژوهش mAP@0.50:0.95 اهمیت بیشتری دارد؛ زیرا معیار مذکور علاوه بر توانایی شناسایی، دقت مکان‌یابی را در طیفی از آستانه‌های IoU ارزیابی می‌کند.

به‌صورت مفهومی:

mAP@0.50 → Detection Quality

در مقابل:

$$mAP@0.50:0.95 \rightarrow Detection + LocalizationQuality\{mAP@0.50:0.95 Detection + Localization\}$$

ازاین‌رو، در تحلیل نهایی نتایج، اختلاف مدل‌ها در mAP@0.50:0.95 باید در کنار mAP@0.50، Precision و Recall تفسیر شود و هیچ‌یک به‌تنهایی مبنای قطعی برای برتری یک معماری قرار نگیرد.

۲-۱۰-۲۲ اهمیت تحلیل اختلاف mAP@0.50 و mAP@0.50:0.95

اختلاف میان این دو معیار می‌تواند یک شاخص تفسیری برای کیفیت مکان‌یابی ارائه کند.

به‌صورت ساده:

$$Dlocalization = mAP@0.50 - mAP@0.50:0.95\{D_{\{}localization\} = mAP@0.50 - mAP@0.50:0.95\}$$

اگر این فاصله بزرگ باشد، ممکن است مدل در تشخیص کلی اشیاء مناسب باشد، اما با افزایش سخت‌گیری مکانی، عملکرد آن کاهش یابد.

اگر این فاصله کوچک‌تر باشد، می‌توان نتیجه گرفت که عملکرد مدل در آستانه‌های بالاتر IoU نیز پایدارتر است.

البته این کمیت یک معیار استاندارد مستقل COCO نیست و صرفاً باید به‌عنوان یک شاخص تحلیلی مکمل تفسیر شود، نه به‌عنوان جایگزین mAP@0.50:0.95.

۲-۱۰-۲۳ ارتباط معیارها با انواع خطا

هر معیار بخشی از رفتار آشکارساز را منعکس می‌کند:

$$\downarrow \text{FP} \uparrow \Rightarrow \text{Precision}$$

این روابط نشان می‌دهند که چرا استفاده هم‌زمان از معیارهای مختلف ضروری است.

مدلی که Precision بالایی دارد اما Recall پایینی دارد، احتمالاً محافظه‌کار است و بسیاری از اشیاء را از دست می‌دهد. در مقابل، مدلی با Recall بالا و Precision پایین ممکن است تعداد زیادی پیش‌بینی اشتباه تولید کند. همچنین، مدلی با mAP@0.50 بالا اما mAP@0.50:0.95 پایین ممکن است اشیاء را شناسایی کند اما مکان‌یابی آن‌ها به‌اندازه کافی دقیق نباشد.

۲-۱۰-۲۴ ارزیابی Robustness در چارچوب پژوهش حاضر

در پژوهش حاضر، Robustness صرفاً به‌معنای «بالا بودن mAP» تعریف نمی‌شود؛ بلکه به توانایی مدل در حفظ عملکرد هنگام مواجهه با شرایط تصویری یا توزیعی متفاوت اشاره دارد.

اگر عملکرد مدل kk در شرایط پایه و تغییریافته به‌ترتیب با:

$$Mk, cleanM_{\{}k, \{clean\}\}$$

و

$$Mk, conditionM_{\{}k, \{condition\}\}$$

$$\Delta_k,\text{rel}(\%) = [(M_k,\text{clean} - M_k,\text{condition}) / M_k,\text{clean}] \times 100$$

معیار مناسبی برای مقایسه افت نسبی عملکرد مدل‌ها خواهد بود.

در نتیجه، اگر: ΔYOLOv8rel<ΔRT−DETRrel

باشد، می‌توان گفت YOLOv8n افت نسبی کمتری داشته و در آن شرایط خاص عملکرد پایدارتر بوده است؛ حتی اگر mAP پایه آن الزاماً بالاتر نباشد.

این نکته برای پژوهش حاضر اهمیت دارد، زیرا مقایسه معماری‌ها نباید فقط به «چه مدلی بیشترین دقت پایه را دارد؟» محدود شود، بلکه باید به این سؤال نیز پاسخ دهد که «کدام مدل در برابر تغییر شرایط عملکرد خود را بهتر حفظ می‌کند؟».

۲-۱۰-۲۵ ارزیابی چندمعیاره به‌عنوان چارچوب نهایی

با توجه به ماهیت مسئله، چارچوب ارزیابی پژوهش حاضر را می‌توان به چهار محور اصلی تقسیم کرد:

الف) دقت تشخیص

Precision, Recall

این معیارها کیفیت تشخیص از منظر خطاهای مثبت کاذب و منفی کاذب را بررسی می‌کنند.

ب) دقت کلی و مکانی

$mAP@0.50, mAP@0.50:0.95, IoU\{mAP@0.50, mAP@0.50:0.95, IoU\}$

این مجموعه کیفیت تشخیص و مکان‌یابی را ارزیابی می‌کند.

ج) کارایی محاسباتی

Efficiency → {FPS, Latency}

این معیارها قابلیت استفاده از مدل در کاربردهای بلادرنگ را بررسی می‌کنند.

د) پایداری و تعمیم‌پذیری

Performance Drop, Retention, Robustness

این بخش میزان حفظ عملکرد در شرایط متفاوت را بررسی می‌کند.

Model → { Accuracy → {Precision, Recall, mAP@0.50}; Localization → {IoU, mAP@0.50:0.95}; Efficiency → {FPS, Latency}; Robustness → {Relative Drop, Retention} }

این چارچوب اجازه می‌دهد سه معماری مورد مطالعه نه‌تنها بر اساس دقت خام، بلکه بر اساس مجموعه‌ای از ویژگی‌های مؤثر در کاربرد واقعی مقایسه شوند.

۲-۱۰-۲۶ معیارهای اصلی مورد استفاده در پژوهش حاضر

با توجه به اهداف پژوهش، معیارهای اصلی ارزیابی مدل‌های **RT-DETR-L**،**YOLOv8n** و **RTMDet-Tiny** شامل موارد زیر خواهند بود:

جدول 2-5. معیارهای اصلی ارزیابی و هدف از به‌کارگیری آن‌ها

هدف از ارزیابی	معیار	گروه
سنجش میزان صحت پیش‌بینی‌های مثبت	Precision	دقت
سنجش توانایی شناسایی اشیای واقعی	Recall	دقت
سنجش میزان هم‌پوشانی جعبه پیش‌بینی و مرجع	IoU	مکان‌یابی
ارزیابی عملکرد چندکلاسه در IoU=0.50	mAP@0.50	دقت جامع
ارزیابی جامع تشخیص و مکان‌یابی در چند آستانه IoU	mAP@0.50:0.95	دقت جامع
سنجش نرخ پردازش تصاویر	FPS	سرعت
سنجش زمان پاسخ برای هر ورودی	Latency	سرعت
سنجش افت عملکرد نسبت به حالت پایه	Relative Performance Drop	پایداری
سنجش درصد عملکرد حفظ‌شده	Performance Retention	پایداری

در میان این معیارها، mAP@0.50:0.95 به‌عنوان معیار اصلی کیفیت کلی تشخیص و مکان‌یابی در نظر گرفته می‌شود؛ درحالی‌که mAP@0.50، Precision و Recall برای تفسیر جزئی‌تر عملکرد، و FPS و Latency برای ارزیابی کارایی محاسباتی مورد استفاده قرار می‌گیرند.

همچنین، معیارهای افت نسبی و حفظ عملکرد برای تحلیل Robustness و بررسی رفتار مدل‌ها تحت شرایط متفاوت به‌کار گرفته خواهند شد.

۲-۱۰-۲۷ ملاحظات مربوط به مقایسه منصفانه مدل‌ها

برای اینکه اختلاف مشاهده‌شده میان سه مدل به تفاوت واقعی معماری‌ها نسبت داده شود، شرایط ارزیابی باید کنترل شوند. در یک مقایسه علمی، تفاوت در داده، تقسیم‌بندی، اندازه تصویر، سخت‌افزار یا سایر شرایط اصلی می‌تواند موجب ایجاد یک عامل مخدوش‌کننده شود.

Observed Difference = Architecture Effect + Experimental Factors

هدف طراحی آزمایش کنترل‌شده آن است که سهم عوامل جانبی کاهش یابد:

Observed Difference ≈ Architecture Effect

بر این اساس، در پژوهش حاضر مقایسه مدل‌ها بر مبنای یک داده‌مجموعه و یک تقسیم‌بندی مشترک، اندازه تصویر یکسان، سخت‌افزار یکسان و چارچوب ارزیابی مشترک انجام می‌شود. تفاوت در Batch Size در صورت نیاز ناشی از محدودیت حافظه و تفاوت ساختاری معماری‌هاست و نباید با تغییر داده یا معیار ارزیابی همراه شود.

این اصل برای تفسیر نتایج بسیار مهم است؛ زیرا هدف پژوهش، مقایسه عملکرد سه خانواده آشکارساز تحت یک پروتکل کنترل‌شده است، نه مقایسه سه مجموعه آزمایش با شرایط متفاوت.

۲-۱۰-۲۸ جمع‌بندی معیارهای ارزیابی

در مجموع، ارزیابی یک آشکارساز شیء را نمی‌توان با یک عدد منفرد به‌طور کامل توصیف کرد. Precision و Recall اطلاعاتی درباره نوع خطاهای تشخیص ارائه می‌کنند، IoU کیفیت مکان‌یابی را اندازه می‌گیرد، AP منحنی Precision–Recall را به یک شاخص خلاصه تبدیل می‌کند و mAP امکان مقایسه عملکرد چندکلاسه را فراهم می‌سازد. در پروتکل COCO، میانگین‌گیری AP در آستانه‌های IoU از ۰/۵۰ تا ۰/۹۵ موجب می‌شود کیفیت مکان‌یابی با سخت‌گیری بیشتری ارزیابی شود (Lin et al., 2014).

از سوی دیگر، FPS و Latency جنبه محاسباتی و قابلیت استفاده عملی مدل را مشخص می‌کنند، درحالی‌که تحلیل افت نسبی عملکرد و Performance Retention امکان بررسی Robustness مدل‌ها در مواجهه با شرایط متفاوت را فراهم می‌سازد. اهمیت این بخش به‌ویژه در شرایط Domain Shift بیشتر است، زیرا تفاوت میان توزیع داده آموزش و داده مورد استفاده در کاربرد واقعی می‌تواند باعث کاهش عملکرد آشکارساز شود.

بر این اساس، چارچوب ارزیابی پژوهش حاضر به‌صورت زیر تعریف می‌شود:

Comprehensive Evaluation = {Accuracy, Localization, Efficiency, Robustness}

یا به‌صورت جزئی‌تر:

Evaluation Metrics = {P, R, mAP@0.50, mAP@0.50:0.95, FPS, Latency, Relative Drop, Retention}

چنین چارچوبی امکان می‌دهد مقایسه RT-DETR-L،YOLOv8n و RTMDet-Tiny از یک مقایسه صرفاً مبتنی بر دقت فراتر رفته و به یک ارزیابی چندبعدی از دقت تشخیص، کیفیت مکان‌یابی، کارایی محاسباتی و پایداری عملکرد تبدیل شود. این رویکرد با ماهیت کاربردی تشخیص پسماندهای دریایی سازگارتر است، زیرا در یک

سامانه واقعی، بهترین مدل الزاماً مدلی نیست که تنها بالاترین mAP را به دست آورد؛ بلکه مدلی است که با در نظر گرفتن دقت، سرعت و پایداری، بهترین توازن را برای شرایط مورد مطالعه ایجاد کند.

۲-۱۱ مطالعات و پژوهش‌های پیشین در تشخیص پسماند دریایی

پژوهش در زمینه تشخیص خودکار پسماندهای دریایی طی سال‌های اخیر از روش‌های مبتنی بر پردازش تصویر و طبقه‌بندی سنتی به سمت مدل‌های عمیق تشخیص شیء، شبکه‌های بلادرنگ و در سال‌های اخیر معماری‌های مبتنی بر Transformer حرکت کرده است. این تحول را نمی‌توان صرفاً نتیجه افزایش پیچیدگی مدل‌ها دانست؛ بلکه توسعه داده‌مجموعه‌های تخصصی، افزایش توان محاسباتی، ظهور آشکارسازهای تک‌مرحله‌ای و نیاز به پردازش بلادرنگ در سامانه‌های رباتیک نیز نقش مهمی در این روند داشته‌اند.

با وجود پیشرفت‌های قابل توجه، محیط دریایی همچنان یکی از حوزه‌های دشوار برای تشخیص بصری محسوب می‌شود. کاهش کنتراست، پراکندگی نور، کدورت آب، تغییر شرایط روشنایی، پس‌زمینه‌های پیچیده، کوچک بودن برخی اشیاء، هم‌پوشانی پسماندها با عناصر طبیعی و تفاوت شرایط تصویربرداری می‌توانند موجب کاهش هم‌زمان دقت و تعمیم‌پذیری مدل شوند. مرور Er et al. (2023) چهار چالش اصلی را در تشخیص بصری زیرآبی برجسته می‌کند: تخریب کیفیت تصویر، تشخیص اشیای کوچک، ضعف تعمیم‌پذیری و الزامات تشخیص بلادرنگ.

از سوی دیگر، مرور نظام‌مندتر Moorton et al. (2025) نشان می‌دهد که اگرچه در پنج سال اخیر استفاده از یادگیری عمیق در تشخیص پسماندهای دریایی رشد قابل توجهی داشته است، هنوز یک چارچوب Benchmarkشده و یکپارچه برای ارزیابی و مقایسه روش‌های بینایی ماشین در محیط‌های دریایی وجود ندارد. این یافته از منظر پژوهش حاضر اهمیت ویژه‌ای دارد، زیرا یکی از اهداف اصلی مطالعه حاضر، ایجاد یک مقایسه کنترل‌شده میان سه خانواده معماری متفاوت است.

۲-۱۱-۱ مطالعات اولیه مبتنی بر یادگیری عمیق و تشخیص پسماند دریایی

یکی از مطالعات مهم و تأثیرگذار در این حوزه، پژوهش Fulton et al. (2019) با عنوان *Robotic Detection of Marine Litter Using Deep Visual Detection Models* است. این مطالعه از نخستین

تلاش‌های مهم برای استفاده از مدل‌های تشخیص عمیق در محیط واقعی زیرآبی به شمار می‌رود و مسئله تشخیص پسماند دریایی را از منظر کاربرد در سامانه‌های رباتیک خودکار بررسی کرد.

در این پژوهش، داده‌های واقعی پسماند دریایی برای آموزش و ارزیابی مدل‌های تشخیص شیء مورد استفاده قرار گرفتند و عملکرد مدل‌ها علاوه بر دقت، از نظر قابلیت اجرا روی سکوهای محاسباتی با توان متفاوت نیز بررسی شد. بنابراین، این مطالعه از همان ابتدا دو مؤلفه مهم را در کنار یکدیگر قرار داد: دقت تشخیص و کارایی محاسباتی. این رویکرد برای سامانه‌های رباتیک دریایی اهمیت دارد، زیرا مدل تشخیص در یک محیط عملیاتی الزاماً به یک رایانه رومیزی قدرتمند دسترسی ندارد.

داده‌های مورد استفاده در این خط پژوهشی بعداً در قالب مجموعه **Trash-ICRA19** در دسترس جامعه پژوهشی قرار گرفت. این مجموعه شامل حدود ۵۷۰۰ تصویر دارای برچسب **Bounding Box** است و تصاویر آن از داده‌های **J-EDI** استخراج شده‌اند. تنوع کیفیت تصاویر، عمق، دوربین، شرایط نور، وضوح آب، میزان پوشیدگی و وضعیت ظاهری پسماندها، این داده‌مجموعه را به یکی از منابع مهم برای مطالعه تشخیص پسماند در محیط واقعی تبدیل کرده است.

اهمیت این مطالعات فقط در ارائه یک مدل مشخص خلاصه نمی‌شود؛ بلکه اهمیت بنیادی آن‌ها در ایجاد یک مسیر پژوهشی قابل بازتولید برای تشخیص پسماند دریایی است. پیش از شکل‌گیری این داده‌مجموعه‌ها، مقایسه روش‌های تشخیص در محیط دریایی به دلیل نبود داده‌های عمومی و دارای **Annotation** استاندارد دشوار بود.

۲-۱۱-۲ شکل‌گیری داده‌مجموعه TrashCan

گام مهم بعدی در توسعه این حوزه، معرفی **TrashCan** توسط **Hong et al. (2020)** بود. **TrashCan** با هدف فراهم کردن داده مناسب برای توسعه آشکارسازهای مقاوم و دقیق پسماند دریایی طراحی شد و علاوه بر **Bounding Box**، دارای **Annotation**های مبتنی بر **Instance Segmentation** نیز است. این مجموعه از تصاویر زیرآبی استخراج‌شده از منابع مختلف تشکیل شده و دو پیکربندی اصلی **TrashCan-Instance** و **TrashCan-Material** را ارائه می‌کند.

TrashCan-Instance در مقایسه با داده‌های اولیه، تنوع بیشتری از اشیای موجود در محیط زیرآبی را در خود جای داده است. در این تصاویر علاوه بر پسماند، عناصر زیستی و اشیای مرتبط با عملیات

تصویربرداری نیز مشاهده می‌شوند. همین ویژگی باعث می‌شود مسئله تشخیص پسماند صرفاً به تشخیص اشیای پلاستیکی محدود نباشد، بلکه به مسئله تفکیک پسماند از محیط و موجودات دریایی نیز تبدیل شود.

یکی از ویژگی‌های مهم TrashCan آن است که داده‌ها از ویدئوهای زیرآبی مربوط به ROVها استخراج شده‌اند. در نتیجه، تغییرات شرایط تصویربرداری، نور، عمق و پس‌زمینه در داده‌ها وجود دارد. این ویژگی اگرچه آموزش مدل را دشوارتر می‌کند، اما از نظر توسعه آشکارسازهای قابل استفاده در محیط واقعی ارزشمند است. داده‌مجموعه رسمی TrashCan در حال حاضر ۷۲۱۲ تصویر Annotated را شامل می‌شود و تصاویر آن از مجموعه J-EDI متعلق به JAMSTEC منشأ گرفته‌اند.

از دیدگاه پژوهشی، TrashCan را می‌توان نقطه‌ای دانست که در آن مسئله تشخیص پسماند دریایی از یک مسئله نسبتاً محدود تشخیص چند نوع زباله به یک مسئله چندکلاسه، چندشیئی و محیط‌محور نزدیک‌تر شد.

۲-۱۱-۳ مطالعات مبتنی بر آشکارسازهای تک‌مرحله‌ای

با افزایش استفاده از آشکارسازهای تک‌مرحله‌ای، خانواده YOLO به یکی از مسیرهای اصلی تحقیقات تشخیص پسماند دریایی تبدیل شد. مزیت اصلی این خانواده در ترکیب مناسب سرعت و دقت و قابلیت استفاده در سامانه‌های بلادرنگ است.

مطالعات مبتنی بر YOLO در داده‌های دریایی عمدتاً با هدف افزایش حساسیت به اشیای کوچک، بهبود استخراج ویژگی، تقویت Feature Fusion و کاهش هزینه محاسباتی انجام شده‌اند. مرور Moorton et al. (2025) نیز نشان می‌دهد که خانواده YOLO در مطالعات اخیر تشخیص پسماند دریایی سهم قابل توجهی داشته و مدل‌هایی مانند YOLOv5 و YOLOv8n به‌طور مشخص در این حوزه مورد استفاده قرار گرفته‌اند.

یکی از نمونه‌های مشخص، پژوهش Zhou et al. با عنوان YOLOTrashCan: A Deep Learning Marine Debris Detection Network است که بر استفاده از ساختار YOLO برای داده‌های TrashCan تمرکز دارد. این مطالعه نشان می‌دهد که طراحی اختصاصی Feature Extraction و Feature Fusion می‌تواند برای مقابله با چالش‌هایی مانند اندازه کوچک و Occlusion در پسماندهای دریایی مفید باشد. مرورهای اخیر گزارش می‌کنند که این مدل در نسخه‌های مختلف TrashCan

بهبودهایی در دقت تشخیص ایجاد کرده است، هرچند همچنان فاصله میان عملکرد آزمایشگاهی و شرایط واقعی باقی می‌ماند.

این دسته از مطالعات یک نکته مهم را آشکار می‌کنند: در مسئله پسماند دریایی، صرف استفاده از یک آشکارساز عمومی کافی نیست و ویژگی‌های خاص داده‌های دریایی می‌توانند نیازمند تغییر در Backbone، Neck، Attention، Loss یا راهبردهای آموزش باشند.

بااین‌حال، یک محدودیت مهم در این رویکرد وجود دارد. بسیاری از مطالعات به جای مقایسه چند معماری عمومی در یک چارچوب ثابت، یک مدل پایه را انتخاب کرده و سپس چندین تغییر معماری روی همان مدل اعمال می‌کنند. در چنین شرایطی، افزایش عملکرد مشاهده‌شده لزوماً نشان نمی‌دهد که خانواده معماری جدید ذاتاً بهتر است؛ زیرا بخشی از بهبود ممکن است ناشی از Moduleهای اضافه‌شده یا تغییرات اختصاصی آموزش باشد.

۲-۱۱-۴ مطالعات مبتنی بر YOLOv5 و معماری‌های اصلاح‌شده

نسل YOLOv5 نیز در مطالعات تشخیص پسماند دریایی مورد توجه قرار گرفته است. یکی از رویکردهای رایج در این دسته از مطالعات، جایگزین کردن Backbone با شبکه‌های سبک‌تر مانند MobileNet و افزودن سازوکارهای Attention برای افزایش قابلیت استخراج ویژگی‌های مرتبط با پسماند بوده است.

این رویکردها معمولاً با دو هدف دنبال شده‌اند:

۱. کاهش هزینه محاسباتی؛

۲. افزایش حساسیت مدل به ویژگی‌های متمایزکننده پسماند.

مرور Moorton et al. (2025) گزارش می‌کند که برخی مطالعات مبتنی بر YOLOv5 با اصلاح Backbone و افزودن Attention توانسته‌اند روی TrashCan عملکرد بهتری نسبت به نسخه پایه نشان دهند و هم‌زمان بر کاربرد بلادرنگ تأکید داشته‌اند.

بااین‌حال، یک مشکل روش‌شناختی در بسیاری از این مطالعات آن است که معیارهای مقایسه همیشه تحت یک پروتکل کاملاً یکسان گزارش نمی‌شوند. تفاوت در اندازه تصویر، سخت‌افزار،

Augmentation، تعداد **Epoch**، نسخه داده و حتی تعریف معیار می‌تواند مقایسه مستقیم نتایج را دشوار کند.

از این منظر، افزایش mAP یک مدل اصلاح‌شده به‌تنهایی برای نتیجه‌گیری درباره برتری معماری کافی نیست. برای مقایسه معماری‌ها باید تا حد امکان متغیرهای آزمایش کنترل شوند.

۲-۱۱-۵ مطالعات مبتنی بر EfficientDet و توجه به کارایی محاسباتی

Zocco et al. (2023) مسئله را از زاویه دیگری دنبال کردند و بر کارایی آشکارساز برای سامانه‌های بینایی **AUV** تمرکز کردند. آن‌ها نسخه‌های **EfficientDet** را برای تشخیص پسماند دریایی بهینه کرده و هم‌زمان افزایش **AP** را بدون افزایش متناظر در **GPU Latency** گزارش کردند. همچنین، آن‌ها یک مجموعه داده اختصاصی برای تشخیص کیسه‌ها و بطری‌های پلاستیکی در آب ایجاد و مدل را با استفاده از این داده و دو داده‌مجموعه عمومی دیگر آموزش دادند.

اهمیت این مطالعه در آن است که نشان می‌دهد معیار «بهترین دقت» لزوماً تنها معیار مناسب برای انتخاب مدل نیست. در یک سامانه رباتیک، افزایش دقت در صورتی که با افزایش شدید زمان استنتاج همراه باشد، ممکن است از نظر کاربردی مطلوب نباشد.

بنابراین، مفهوم **Accuracy–Efficiency Trade-off** در مطالعات تشخیص پسماند دریایی اهمیت زیادی پیدا می‌کند.

در این چارچوب می‌توان عملکرد یک مدل را به‌صورت:

```
Performance = f(Accuracy, Efficiency)
```

در نظر گرفت.

به‌عبارت دیگر، مدلی که **AP** بالاتری دارد، الزاماً بهترین گزینه برای استقرار روی سامانه رباتیک نیست؛ بلکه باید مشخص شود این افزایش دقت با چه هزینه محاسباتی حاصل شده است.

این دیدگاه با چارچوب پژوهش حاضر نیز سازگار است؛ زیرا در این پژوهش علاوه بر **mAP**، معیارهای **FPS** و **Latency** نیز برای مقایسه مدل‌ها در نظر گرفته شده‌اند.

۲-۱۱-۶ مطالعات مبتنی بر YOLOv8n

با معرفی YOLOv8n، توجه بخشی از پژوهش‌های جدید به این معماری معطوف شده است. ساختار Anchor-Free، Head تفکیک‌شده، C2f، FPN–PAN و راهبردهای جدید Assignment باعث شده‌اند YOLOv8n به گزینه‌ای رایج برای تشخیص سریع اشیاء تبدیل شود.

در حوزه پسماند دریایی نیز مطالعات مستقیمی بر مبنای YOLOv8n انجام شده‌اند. برای مثال، Jiang et al. (2024) نسخه‌ای اصلاح‌شده از YOLOv8n را برای تشخیص و طبقه‌بندی پسماند دریایی پیشنهاد کردند. این روش با افزودن اجزایی مانند C2f-SCConv، CloFormer و WIoU تلاش کرد استخراج ویژگی، کاهش افزونگی و Regression جعبه‌ها را بهبود دهد. آزمایش‌ها روی TrashCan-Instance و TrashCan-Material انجام شد و نویسندگان افزایش mAP@0.5 و F1 را نسبت به YOLOv8n پایه گزارش کردند.

این دسته از مطالعات نشان می‌دهد که YOLOv8n می‌تواند یک Baseline مناسب برای مسئله پسماند دریایی باشد. بااین‌حال، باید میان دو نوع پژوهش تفاوت قائل شد:

دسته اول: مطالعاتی که YOLOv8n را به‌عنوان مدل پایه انتخاب کرده و آن را با Moduleهای جدید توسعه می‌دهند.

دسته دوم: مطالعاتی که YOLOv8n را به‌عنوان یک معماری استاندارد و بدون تغییر اساسی با سایر خانواده‌های آشکارساز مقایسه می‌کنند.

دسته اول بیشتر به بهینه‌سازی یک معماری خاص می‌پردازد، درحالی‌که دسته دوم برای پاسخ به سؤال «کدام فلسفه معماری برای این مسئله مناسب‌تر است؟» ارزش بیشتری دارد.

پژوهش حاضر در گروه دوم قرار می‌گیرد؛ زیرا هدف آن طراحی یک Module جدید برای YOLOv8n نیست، بلکه مقایسه YOLOv8n با دو خانواده معماری متفاوت، یعنی RT-DETR-L و RTMDet-Tiny، تحت یک پروتکل کنترل‌شده است.

۲-۱۱-۷ مطالعات مربوط به YOLOv8n-Seg و تفکیک نمونه‌ای

علاوه بر Object Detection، مسئله Instance Segmentation نیز در تشخیص پسماند دریایی مورد توجه قرار گرفته است. دلیل این موضوع آن است که پسماندها در بسیاری از تصاویر شکل‌های نامنظم دارند و Bounding Box الزاماً تمام جزئیات مکانی شیء را نمایش نمی‌دهد.

برای مثال، یک مطالعه منتشرشده در IEEE Access در سال ۲۰۲۴، نسخه بهبودیافته YOLOv8n-Seg را برای Segmentation پسماند زیرآبی بررسی کرده است. این پژوهش از داده TrashCan استفاده کرده و هدف آن دستیابی هم‌زمان به تفکیک دقیق‌تر نمونه‌ها و عملکرد نزدیک به بلادرنگ بوده است.

اگرچه Instance Segmentation از نظر مکانی اطلاعات بیشتری از Object Detection ارائه می‌کند، استفاده از آن الزاماً برای هر کاربرد بهترین انتخاب نیست. Segmentation معمولاً هزینه Annotation و محاسباتی بیشتری دارد و اگر هدف سامانه صرفاً شناسایی و مکان‌یابی سریع پسماند باشد، Object Detection می‌تواند انتخاب مناسب‌تری باشد.

از این رو، پژوهش حاضر بر Object Detection تمرکز دارد و مسئله Segmentation را به‌عنوان یک مسیر پژوهشی مکمل در نظر می‌گیرد.

۲-۱۱-۸ مطالعات مبتنی بر MLDet و آشکارسازهای اختصاصی پسماند

یکی دیگر از مسیرهای پژوهشی، طراحی آشکارسازهای اختصاصی برای پسماند دریایی است. Ma et al. (2023) در پژوهشی با عنوان MLDet: Towards Efficient and Accurate Deep Learning Method for Marine Litter Detection یک آشکارساز اختصاصی برای تشخیص پسماند دریایی پیشنهاد کردند.

در این مطالعه، راهکارهایی مانند Data Augmentation، بهینه‌سازی Loss، Deformable Convolution، Transfer Learning و ATSS برای بهبود استخراج ویژگی و Assignment نمونه‌های مثبت و منفی مورد استفاده قرار گرفتند. هدف اصلی، دستیابی هم‌زمان به دقت مناسب و کارایی محاسباتی بود.

این پژوهش نمونه‌ای از یک روند مهم در ادبیات است: به جای استفاده مستقیم از یک Detector عمومی، اجزای مختلف معماری برای ویژگی‌های خاص مسئله پسماند تنظیم می‌شوند.

بااین‌حال، این رویکرد نیز یک محدودیت اساسی دارد. هنگامی که یک مدل با مجموعه‌ای از تغییرات معماری و Hyperparameterهای اختصاصی ساخته می‌شود، تعیین اینکه بهبود مشاهده‌شده دقیقاً ناشی از کدام مؤلفه بوده است دشوارتر می‌شود. علاوه بر این، مقایسه چنین مدل‌هایی با معماری‌های پایه در شرایط متفاوت می‌تواند منجر به نتیجه‌گیری ناعادلانه شود.

بنابراین، پژوهش حاضر به جای معرفی یک Detector اختصاصی جدید، بر مقایسه معماری‌های شناخته‌شده در شرایط یکسان تمرکز دارد.

۲-۱۱-۹ مطالعات جدید مبتنی بر معماری‌های Transformer

ظهور Transformerها در تشخیص شیء، مسیر جدیدی را در Computer Vision ایجاد کرد. معماری DETR و مدل‌های بعدی آن مسئله تشخیص را به‌صورت Set Prediction فرموله کردند و وابستگی به برخی اجزای سنتی آشکارسازها مانند NMS را کاهش دادند.

در محیط‌های دریایی، Transformerها از این جهت مورد توجه قرار گرفته‌اند که می‌توانند روابط مکانی و وابستگی‌های گسترده میان اجزای تصویر را مدل کنند. این ویژگی در محیط‌هایی که اشیاء کوچک، پس‌زمینه پیچیده و Occlusion وجود دارد، بالقوه ارزشمند است.

RT-DETR-L در این مسیر اهمیت ویژه‌ای دارد. این معماری با استفاده از Hybrid Encoder، Query Selection و Transformer Decoder تلاش می‌کند ویژگی‌های DETR را با الزامات Real-Time Object Detection ترکیب کند.

مطالعات جدیدتر نیز استفاده از RT-DETR-L را در محیط‌های زیرآبی و دریایی دنبال کرده‌اند. برای مثال، یک پژوهش منتشرشده در Marine Pollution Bulletin در سال ۲۰۲۶ یک نسخه سبک‌شده از RT-DETR-L را برای تشخیص پسماند زیرآبی پیشنهاد کرده است که با جایگزینی اجزای معماری و فشرده‌سازی مدل، هدف آن کاهش پیچیدگی و حفظ دقت تشخیص بوده است.

همچنین، در سال ۲۰۲۶ پژوهش دیگری یک چارچوب Real-Time مبتنی بر RT-DETR-L را برای تشخیص اشیای زیرآبی بررسی کرده و به‌طور مشخص مسئله توازن میان دقت و Latency را مورد توجه قرار داده است.

این مطالعات نشان می‌دهند که خانواده RT-DETR-L در حال ورود جدی‌تر به کاربردهای دریایی است. بااین‌حال، بخش قابل توجهی از این پژوهش‌ها بر بهبود خود RT-DETR-L متمرکز هستند و کمتر به مقایسه کنترل‌شده RT-DETR-L با آشکارسازهای CNN مدرن مانند YOLOv8n و RTMDet-Tiny در یک داده‌مجموعه مشترک می‌پردازند.

۲-۱۱-۱۰ جایگاه RTMDet-Tiny در مطالعات تشخیص بلادرنگ

RTMDet-Tiny یکی از خانواده‌های آشکارسازهای بلادرنگ است که با تمرکز بر طراحی سیستماتیک معماری و بررسی تجربی اجزای مختلف Detector توسعه یافته است. این خانواده بر ترکیب Backbone کارآمد، Feature Pyramid مناسب و Head تفکیک‌شده تأکید دارد.

با وجود اهمیت RTMDet-Tiny در ادبیات عمومی Real-Time Object Detection، استفاده از آن در مطالعات اختصاصی تشخیص پسماند دریایی نسبت به YOLO کمتر گزارش شده است. این موضوع یک فرصت پژوهشی ایجاد می‌کند، زیرا RTMDet-Tiny از نظر فلسفه طراحی با YOLOv8n شباهت‌هایی دارد، اما دقیقاً همان معماری نیست و می‌تواند به‌عنوان یک نماینده مستقل از آشکارسازهای CNN بلادرنگ مورد ارزیابی قرار گیرد.

از این منظر، مقایسه:

YOLOv8n در برابر RTMDet-Tiny

می‌تواند نشان دهد که آیا تفاوت در طراحی Backbone، Neck، Assignment و Head در یک مسئله تخصصی مانند پسماند دریایی به تفاوت معناداری در عملکرد منجر می‌شود یا خیر.

این مسئله زمانی ارزش بیشتری پیدا می‌کند که RTMDet-Tiny در کنار یک معماری Transformer مانند RT-DETR-L قرار گیرد.

در نتیجه:

YOLOv8n ↔ RT-DETR-L ↔ RTMDet-Tiny

سه دیدگاه معماری متفاوت یا نیمه‌متفاوت برای تشخیص بلادرنگ را در یک چارچوب مقایسه‌ای قرار می‌دهند.

۲-۱۱-۱۱ مطالعات مربوط به داده‌های TrashCan و مسئله تنوع داده

TrashCan به دلیل گستردگی و تنوع Annotation به یکی از منابع اصلی مطالعات تشخیص پسماند دریایی تبدیل شده است. مرور Moorton et al. (2025) نشان می‌دهد TrashCan 1.0 از پرتکرارترین داده‌مجموعه‌های مورد استفاده در مطالعات Object Recognition این حوزه بوده است. این مرور همچنین اشاره می‌کند که بخشی از مطالعات موجود از داده‌های JAMSTEC، TrashCan و Trash-ICRA19 استفاده کرده‌اند.

بااین‌حال، استفاده گسترده از یک منبع داده لزوماً به معنای تنوع واقعی کافی نیست. TrashCan و Trash-ICRA19 هر دو ریشه مهمی در داده‌های J-EDI دارند. در نتیجه، اگر چند مطالعه مختلف روی همین داده‌ها آموزش و آزمون انجام دهند، نتایج آن‌ها ممکن است از نظر آماری و بصری بیش از حد به یک Domain خاص وابسته باشد.

این مسئله یک نکته مهم درباره Generalization ایجاد می‌کند:

$$LargeDataset \neq LargeDomainDiversity\{\{LargeDataset\}\{LargeDomainDiversity\}\}$$

یعنی افزایش تعداد تصاویر الزاماً به معنای پوشش طیف وسیع‌تری از شرایط محیطی نیست.

در نتیجه، توسعه داده‌مجموعه‌های چندمنبعی می‌تواند یک مسیر مهم برای کاهش وابستگی مدل به یک منبع تصویری خاص باشد.

۲-۱۱-۱۲ مطالعات مربوط به ادغام داده‌های چندمنبعی

یکی از روندهای قابل توجه در مطالعات جدید، حرکت از استفاده از یک داده‌مجموعه منفرد به سمت استفاده از چند منبع داده است.

Zocco et al. (2023)، برای نمونه، علاوه بر داده اختصاصی خود، از دو داده‌مجموعه عمومی برای آموزش مدل‌های EfficientDet استفاده کردند. این رویکرد نشان می‌دهد که استفاده از چند منبع می‌تواند دامنه تنوع تصویری داده آموزشی را افزایش دهد.

بااین‌حال، ادغام داده‌های چندمنبعی یک مسئله ساده **Concatenation** نیست. تفاوت در **Taxonomy**، نوع **Annotation**، تعریف کلاس‌ها، کیفیت تصاویر، توزیع کلاس‌ها و شرایط تصویربرداری می‌تواند موجب ایجاد ناسازگاری شود.

بنابراین:

$$\text{Multi-source Integration} \neq \text{Simple Concatenation}$$

$$D_1, D_2, \ldots, D_n \rightarrow \text{Taxonomy Harmonization} \rightarrow \text{Annotation Validation} \rightarrow \text{Quality Control} \rightarrow D_unified$$

این موضوع در پژوهش حاضر اهمیت بنیادی دارد؛ زیرا هدف از ادغام منابع مختلف، صرفاً افزایش تعداد تصاویر نیست، بلکه ایجاد یک مجموعه داده یکپارچه با **Taxonomy** مشترک برای مقایسه منصفانه مدل‌هاست.

۲-۱۱-۱۳ مسئله هماهنگ‌سازی **Taxonomy** در مطالعات پیشین

یکی از محدودیت‌های مهم در ادغام داده‌های دریایی، تفاوت در تعریف کلاس‌هاست.

برای نمونه، **TrashCan-Instance** و **TrashCan-Material** از دو منطق متفاوت برای تعریف کلاس‌ها استفاده می‌کنند. در یکی، اشیاء بر اساس **Instance** و نوع شیء تفکیک می‌شوند، درحالی‌که دیگری بیشتر بر مبنای جنس یا **Material** دسته‌بندی می‌کند. **TrashCan** رسمی نیز این دو نسخه را به‌صورت جداگانه معرفی کرده است.

این تفاوت نشان می‌دهد که حتی زمانی که دو داده‌مجموعه هر دو درباره «پسماند دریایی» هستند، لزوماً مستقیماً قابل ادغام نیستند.

در نتیجه، ایجاد یک **Taxonomy** مشترک نیازمند تصمیم‌گیری درباره موارد زیر است:

- کدام کلاس‌ها از نظر معنایی معادل‌اند؛
- کدام کلاس‌ها باید ادغام شوند؛
- کدام کلاس‌ها باید حذف شوند؛
- کدام کلاس‌ها باید به یک کلاس عمومی‌تر نگاشت شوند؛
- و چگونه باید موارد **Ambiguous** مدیریت شوند.

این مرحله یکی از تفاوت‌های اصلی میان «افزایش داده» و «ادغام داده» است.

۲-۱۱-۱۴ محدودیت‌های مشترک مطالعات پیشین

بررسی ادبیات نشان می‌دهد که مطالعات موجود، علی‌رغم دستاوردهای قابل توجه، با مجموعه‌ای از محدودیت‌های مشترک مواجه‌اند.

۱. وابستگی زیاد به یک داده‌مجموعه

بخش قابل توجهی از مطالعات بر TrashCan، Trash-ICRA19 یا منابع مشتق‌شده از J-EDI متمرکز هستند. این مسئله می‌تواند باعث وابستگی عملکرد مدل به ویژگی‌های یک Domain خاص شود.

۲. تفاوت در Taxonomy

مطالعات مختلف از تعداد و تعریف کلاس‌های متفاوت استفاده می‌کنند. بنابراین مقایسه mAP بین دو مطالعه الزاماً به معنای مقایسه مستقیم دو مدل نیست.

۳. تفاوت در پروتکل ارزیابی

تفاوت در IoU Threshold، تعریف mAP، داده آزمون، Image Size و سایر شرایط ارزیابی می‌تواند مقایسه عددی را دشوار کند.

۴. تمرکز بر بهبود یک معماری

بسیاری از پژوهش‌ها یک مدل پایه را انتخاب کرده و سپس با افزودن Attention، Feature Fusion، Loss یا Backbone جدید عملکرد آن را افزایش می‌دهند. این رویکرد برای طراحی مدل جدید مفید است، اما برای مقایسه فلسفه‌های معماری مناسب نیست.

۵. توجه ناکافی به Robustness

درصد زیادی از مطالعات عملکرد مدل را روی Test Set مشابه داده آموزشی گزارش می‌کنند، اما بررسی افت عملکرد تحت تغییر Domain یا شرایط تصویری متفاوت به اندازه معیارهای Accuracy مورد توجه قرار نگرفته است.

۶. گزارش محدود معیارهای کارایی

برخی مطالعات بر mAP تمرکز دارند، درحالی‌که برای کاربردهای بلادرنگ، FPS، Latency و هزینه محاسباتی نیز اهمیت دارند.

۷. نبود چارچوب مقایسه‌ای استاندارد

مرور Moorton et al ۲۰۲۵. یکی از صریح‌ترین شواهد این خلأ است و نتیجه می‌گیرد که در این حوزه هنوز یک چارچوب Benchmarkشده برای ارزیابی و مقایسه روش‌های بینایی ماشین وجود ندارد.

۲-۱۱-۱۵ مقایسه انتقادی مطالعات پیشین

جدول ۲-۶. خلاصه‌ای از مسیر اصلی مطالعات

پژوهش / مسیر	داده یا منبع	رویکرد	تمرکز اصلی	نقطه قوت	محدودیت اصلی
Fulton et al. (2019)	داده‌های واقعی زیرآبی Trash- / ICRA19	آشکارسازهای عمیق	تشخیص پسماند و کاربرد رباتیک	پایه‌گذاری تشخیص عمیق پسماند دریایی	تعداد محدود کلاس‌ها و وابستگی به Domain زیرآبی
Hong et al. (2020)	TrashCan	Faster R-CNN / Mask R-CNN	Detection و Segmentation	داده چندکلاسه و Annotation غنی	پیچیدگی و وابستگی به داده‌های J- EDI
مطالعات YOLO	TrashCan و داده‌های مشابه	YOLOv5 و مدل‌های اصلاح‌شده	سرعت و دقت	مناسب برای کاربرد بلادرنگ	تفاوت زیاد در اصلاحات و پروتکل آزمایش
Zhou et .al	TrashCan	YOLOTrashCan	Feature Extraction/Fusion	توجه به اشیای کوچک و Occlusion	تمرکز بر یک خانواده معماری
Ma et al. (2023)	داده‌های دریایی	MLDet	کارایی و دقت	ترکیب Augmentation Transfer ، Learning و Assignment	آشکارساز اختصاصی و دشواری

مقایسه مستقیم					
تمرکز بر EfficientDet	توجه هم‌زمان به AP و Latency	Efficiency و Real-Time	EfficientDet	داده اختصاصی + داده‌های عمومی	Zocco et al. (2023)
مدل اختصاصی و تغییرات متعدد	بهبود عملکرد نسبت به YOLOv8n پایه	بهبود Feature Extraction و Loss	YOLOv8n اصلاح‌شده	TrashCan	Jiang et al. (2024)
بیشتر بر بهبود RT-DETR-L متمرکز	استفاده از End-to-End Detection	Real-Time و Transformer	RT-DETR-L و نسخه‌های اصلاح‌شده	داده‌های دریایی/زیرآبی	مطالعات جدید RT-DETR-L
مرور است و آزمایش جدید ارائه نمی‌کند	شناسایی نبود Benchmark استاندارد	تحلیل وضعیت حوزه	Scoping Review	مرور مطالعات	Moorton et al. (2025)
محدود به داده و شرایط تعریف‌شده پژوهش	مقایسه سه خانواده در پروتکل مشترک	مقایسه کنترل‌شده + Robustness	YOLOv8n / RT-DETR-L / RTMDet-Tiny	داده چندمنبعی یکپارچه	پژوهش حاضر

این جدول نشان می‌دهد که ادبیات موجود از نظر توسعه مدل غنی است، اما از نظر مقایسه کنترل‌شده معماری‌ها هنوز جای کار وجود دارد.

۲-۱۱-۱۶ تحلیل شکاف اول: نبود مقایسه کنترل‌شده بین خانواده‌های معماری

یکی از مهم‌ترین شکاف‌های شناسایی‌شده، نبود مقایسه مستقیم و کنترل‌شده میان خانواده‌های معماری متفاوت است.

بسیاری از مطالعات موجود یکی از دو مسیر زیر را دنبال کرده‌اند:

```
Baseline Detector + Proposed Module → Modified Baseline
Existing Detector + Proposed Module → Improved Detector
```

اما سؤال متفاوتی که پژوهش حاضر مطرح می‌کند این است: **Accuracy+Localization+Efficiency+Robustness**برای پاسخ به چنین سؤالی، لازم است سه معماری تحت شرایط تا حد امکان مشترک ارزیابی شوند.

در پژوهش حاضر، این سه معماری عبارت‌اند از:

YOLOv8n, RT-DETR-L, RTMDet-Tiny

انتخاب این سه مدل امکان مقایسه سه رویکرد مهم را فراهم می‌کند:

- **YOLOv8n** به‌عنوان آشکارساز **CNN** بلادرنگ با طراحی مدرن؛
- **RT-DETR-L** به‌عنوان آشکارساز مبتنی بر **Transformer** و **End-to-End**؛
- **RTMDet-Tiny** به‌عنوان آشکارساز **CNN** بلادرنگ با طراحی مهندسی‌شده برای کارایی.

۲-۱۱-۱۷ تحلیل شکاف دوم: نبود یک داده‌مجموعه یکپارچه با **Taxonomy** مشترک

مطالعات موجود اغلب بر یک داده‌مجموعه مشخص یا یک نسخه مشخص از **TrashCan** تمرکز دارند. از طرف دیگر، داده‌مجموعه‌های مختلف دارای تعریف کلاس و ساختار **Annotation** متفاوت هستند.

این موضوع مانع مهمی برای توسعه یک **Benchmark** مشترک است.

در پژوهش حاضر، این مسئله با تعریف یک **Taxonomy** مشترک و ادغام داده‌های چندمنبعی مورد توجه قرار می‌گیرد:

$$D_1 + D_2 + D_3 \rightarrow \text{Integration} \rightarrow \text{Harmonization} \rightarrow \text{Validation} \rightarrow \text{Quality Control} \rightarrow D_{unified}$$

است.

نتیجه نهایی یک داده‌مجموعه با **Taxonomy** مشترک ۱۳ کلاسه است که امکان آموزش و ارزیابی سه معماری را روی یک فضای برچسب مشترک فراهم می‌کند.

۲-۱۱-۱۸ تحلیل شکاف سوم: تفاوت میان عملکرد پایه و Robustness

یکی از محدودیت‌های مطالعات موجود این است که عملکرد مدل اغلب با یک مجموعه معیار روی یک Test Set گزارش می‌شود. چنین ارزیابی‌ای برای اندازه‌گیری Accuracy ضروری است، اما برای پاسخ به این سؤال کافی نیست:

آیا مدل در شرایط متفاوت نیز عملکرد خود را حفظ می‌کند؟

این مسئله در محیط دریایی اهمیت ویژه‌ای دارد، زیرا توزیع تصاویر ممکن است با تغییر دوربین، عمق، کیفیت آب، زاویه دید یا شرایط سطحی تغییر کند.

ازاین‌رو، پژوهش حاضر علاوه بر عملکرد پایه، افت عملکرد نسبت به شرایط پایه را نیز بررسی می‌کند.

برای معیارهای بیشتر-بهتر، مانند mAP:

$$\Delta_rel = (M_clean - M_condition) / M_clean \times 100$$

تفسیر:

این شاخص اجازه می‌دهد مدل‌ها بر اساس میزان حفظ عملکرد نیز مقایسه شوند.

بنابراین ممکن است:

mAPA>mAPBmAP_A>mAP_B

اما:

ΔA > ΔB

باشد.

در چنین حالتی، مدل A از نظر عملکرد پایه بهتر است، اما مدل B در برابر تغییر شرایط مقاوم‌تر است.

این تمایز یکی از محورهای اصلی تحلیل پژوهش حاضر خواهد بود.

۲-۱۱-۱۹ تحلیل شکاف چهارم: عدم توجه کافی به هم‌زمانی Accuracy و Efficiency

در بسیاری از مطالعات، افزایش mAP به‌عنوان نتیجه اصلی گزارش می‌شود؛ درحالی‌که در کاربردهای عملی، هزینه محاسباتی و سرعت استنتاج نیز اهمیت دارند.

پژوهش Zocco et al. (2023) نمونه‌ای روشن از اهمیت این مسئله است که در آن AP و GPU Latency به‌صورت هم‌زمان مورد توجه قرار گرفته‌اند.

بنابراین، در پژوهش حاضر نیز عملکرد مدل‌ها فقط به‌صورت:

max(mAP)

تعریف نمی‌شود، بلکه به‌صورت چندهدفه بررسی خواهد شد:

Model Performance ≠ Accuracy alone; includes Accuracy, Efficiency and Robustness

در این چارچوب، FPS و Latency در کنار mAP و سایر معیارهای دقت گزارش می‌شوند.

۲-۱۱-۲۰ تحلیل شکاف پنجم: ضرورت کنترل متغیرهای آزمایش

یکی از مسائل مهم هنگام مقایسه نتایج مطالعات مختلف این است که شرایط آزمایش آن‌ها یکسان نیست.

فرض کنیم دو مدل AA و BB به‌ترتیب عملکرد:

MAM_A

و:

MBM_B

را ارائه کنند.

اگر مدل A با Image Size متفاوت، Augmentation متفاوت، داده متفاوت یا سخت‌افزار متفاوت آزمایش شده باشد، آنگاه:

MA−MBM_A-M_B

لزوماً نشان‌دهنده تفاوت واقعی معماری نیست.

بنابراین، برای مقایسه علمی باید تا حد امکان عوامل اصلی کنترل شوند:

$$Dataset = Constant\{Dataset = Constant\}Split = Constant\{Split = Constant\}ImageConstant\{Image = Constant\}Hardwa\Re = Constant\{Hardware = Constant\}$$

و:

$$\mathbf{E}valuationProtocol = Constant\{Evaluation = Constant\}$$

در پژوهش حاضر، این اصل مبنای طراحی آزمایش مقایسه‌ای سه مدل خواهد بود.

۲-۱۱-۲۱ جایگاه پژوهش حاضر در ادبیات

Research Position = Multi-source Data Integration + Controlled Architecture Comparison + Real-Time Efficiency + Robustness under Domain Shift

در این چارچوب، پژوهش حاضر قصد ندارد صرفاً یک نسخه اصلاح‌شده از YOLOv8n یا RT-DETR-L یا RTMDet-Tiny ارائه کند. نوآوری اصلی در طراحی یک چارچوب مقایسه‌ای کنترل‌شده قرار دارد.

این چارچوب از چند مرحله تشکیل می‌شود:

Multi-source Data → Taxonomy Harmonization → Annotation Validation → Unified 13-Class Dataset → Common Experimental Protocol → {YOLOv8n, RT-DETR-L, RTMDet-Tiny} → {Accuracy, Localization, Efficiency, Robustness} → Comparative Analysis

در نتیجه، مسئله پژوهش از «ساخت یک مدل جدید» به سمت «شناخت تجربی رفتار سه خانواده معماری در یک مسئله تخصصی» تغییر می‌کند.

۲-۱۱-۲۲ تفاوت پژوهش حاضر با مطالعات بهبوددهنده مدل

تمایز مهم دیگر آن است که بسیاری از مطالعات موجود، یک معماری را انتخاب کرده و با افزودن اجزای جدید به دنبال افزایش عملکرد آن هستند.

به‌صورت مفهومی:

Baseline Model⟶Module Addition⟶Improved Model

در مقابل، پژوهش حاضر از منطق زیر پیروی می‌کند:

Unified Dataset⟶ { YOLOv8 / RT-DETR-L / RTMDet-Tiny } ⟶Common Evaluation

در نتیجه، سؤال اصلی دیگر این نیست که «چه Module جدیدی می‌تواند mAP یک مدل را افزایش دهد؟»، بلکه این است که:

در شرایط داده‌ای و آزمایشی کنترل‌شده، کدام یک از سه معماری مورد مطالعه بهترین توازن میان دقت، سرعت و پایداری را برای تشخیص پسماند دریایی فراهم می‌کند؟

این تفاوت، جایگاه پژوهش حاضر را از بسیاری از مطالعات صرفاً معماری‌محور متمایز می‌کند.

۲-۱۱-۲۳ جدول نهایی شکاف پژوهشی

جدول ۲-۷. جمع‌بندی شکاف‌های پژوهشی و رویکرد پژوهش حاضر

رویکرد پژوهش حاضر	وضعیت غالب در مطالعات پیشین	شکاف شناسایی‌شده
ادغام چند منبع داده	استفاده گسترده از TrashCan/J-EDI	وابستگی به یک منبع داده
Taxonomy مشترک ۱۳ کلاسه	تعداد و تعریف کلاس‌های متفاوت	تفاوت Taxonomy
استانداردسازی و Validation	Segmentation،Bounding Box و ساختارهای متفاوت	تفاوت Annotation
مقایسه RT-DETR-L،YOLOv8n و RTMDet-Tiny	عمدتاً بهبود یک مدل	مقایسه معماری
پروتکل مشترک	پروتکل‌های متفاوت	کنترل شرایط
mAP@0.50، Recall،Precision و mAP@0.50:0.95	تمرکز بر mAP	دقت
FPS و Latency	گزارش نامنظم یا محدود	سرعت
تحلیل افت نسبی عملکرد	کمتر مورد توجه	Robustness
ارزیابی شرایط متفاوت	اغلب محدود	Domain Shift
تحلیل چندمعیاره	تمرکز بر یک معیار	نتیجه‌گیری

۲-۱۱-۲۴ جمع‌بندی مطالعات پیشین

بررسی مطالعات پیشین نشان می‌دهد که تشخیص خودکار پسماند دریایی از یک مسئله اولیه مبتنی بر آشکارسازهای CNN به حوزه‌ای چندبعدی تبدیل شده است که در آن کیفیت داده، طراحی معماری، سرعت، دقت مکان‌یابی و تعمیم‌پذیری همگی نقش تعیین‌کننده دارند.

مطالعات Fulton et al. (2019) و توسعه داده‌مجموعه Trash-ICRA19 نقش مهمی در ایجاد زیرساخت داده‌ای برای تشخیص پسماند واقعی زیرآبی داشتند.

TrashCan نیز با ارائه داده‌های گسترده‌تر و Annotationهای Instance-level مسیر پژوهش را به سمت مسائل چندکلاسه و پیچیده‌تر هدایت کرد.

پس از آن، خانواده‌های YOLO،EfficientDet و آشکارسازهای اختصاصی مانند MLDet تلاش کردند مسئله سرعت و دقت را از طریق اصلاح Backbone،Feature Fusion ،Attention ،Loss و Assignment بهبود دهند.

مطالعات جدیدتر مبتنی بر YOLOv8n نیز نشان داده‌اند که معماری‌های مدرن‌تر می‌توانند با تغییرات مناسب در Feature Extraction و Regression بهبود عملکرد ایجاد کنند.

در سال‌های اخیر، ورود Transformer-based Detectorها و به‌ویژه RT-DETR-L نیز مسیر دیگری را برای دستیابی به تشخیص End-to-End و بلادرنگ فراهم کرده است و مطالعات جدید دریایی به‌تدریج این خانواده را وارد حوزه تشخیص زیرآبی کرده‌اند.

با وجود این پیشرفت‌ها، دو مسئله همچنان برجسته باقی می‌ماند. نخست، تفاوت زیاد در داده، Annotation،Taxonomy و پروتکل ارزیابی که مقایسه مستقیم مدل‌ها را دشوار می‌کند. دوم، تمرکز بسیاری از مطالعات بر بهبود یک معماری خاص به جای مقایسه کنترل‌شده چند خانواده معماری است. مرور ۲۰۲۵ نیز نبود یک چارچوب Benchmarkشده برای مقایسه روش‌های بینایی ماشین در محیط‌های دریایی را به‌عنوان یکی از شکاف‌های مهم حوزه شناسایی کرده است.

ازاین‌رو، پژوهش حاضر با ایجاد یک داده‌مجموعه یکپارچه از منابع چندگانه، هماهنگ‌سازی Taxonomy و Annotation، و مقایسه سه معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny تحت یک پروتکل آزمایشی مشترک، تلاش می‌کند بخشی از این شکاف را پوشش دهد.

Overall Performance = {Accuracy, Localization, Efficiency, Robustness}

بنابراین، خروجی مورد انتظار پژوهش صرفاً تعیین «بهترین مدل از نظر mAP» نیست، بلکه شناسایی رابطه میان معماری، دقت، سرعت و پایداری عملکرد در مسئله تشخیص پسماند دریایی است. چنین رویکردی می‌تواند مبنای مناسب‌تری برای انتخاب آشکارساز در کاربردهای آینده مبتنی بر سامانه‌های پایش و رباتیک دریایی فراهم کند.

2-12 جمع‌بندی فصل دوم و استخراج چارچوب نظری پژوهش

فصل حاضر با هدف تبیین مبانی نظری، مفاهیم فنی و وضعیت مطالعات پیشین مرتبط با تشخیص خودکار پسماندهای دریایی با استفاده از روش‌های بینایی ماشین و یادگیری عمیق تدوین شد. بررسی انجام‌شده نشان داد که مسئله تشخیص پسماند دریایی را نمی‌توان صرفاً به انتخاب یک معماری آشکارساز و مقایسه مقدار یک شاخص دقت محدود کرد؛ بلکه عملکرد نهایی سامانه تابعی از ویژگی‌های داده، کیفیت و سازگاری حاشیه‌نویسی‌ها، ساختار طبقه‌بندی، معماری آشکارساز، معیارهای ارزیابی و شرایط تصویربرداری است.

از منظر داده، ماهیت پیچیده محیط دریایی موجب می‌شود تصاویر مورد استفاده برای آموزش آشکارسازها از نظر روشنایی، کدری آب، پس‌زمینه، مقیاس اشیا، میزان هم‌پوشانی، زاویه دید، فاصله دوربین تا هدف و میزان تخریب یا پوشیدگی اشیا دارای تنوع قابل‌توجهی باشند. این عوامل می‌توانند موجب تغییر توزیع داده و در نتیجه کاهش قابلیت تعمیم مدل‌های آموزش‌دیده در شرایط کنترل‌شده شوند. در مطالعات مروری نیز افت کیفیت تصویر، وجود اهداف کوچک، ضعف تعمیم‌پذیری و الزامات تشخیص بلادرنگ از جمله چالش‌های اصلی آشکارسازی بصری در محیط‌های زیرآبی گزارش شده‌اند (Er et al., 2023).

از سوی دیگر، بررسی داده‌مجموعه‌های تخصصی نشان می‌دهد که داده‌های مربوط به پسماند دریایی از نظر نوع محیط، شیوه تصویربرداری، سطح حاشیه‌نویسی و نظام طبقه‌بندی یکسان نیستند. داده‌مجموعه‌هایی مانند Trash-ICRA19 و TrashCan نقش مهمی در توسعه روش‌های یادگیری عمیق برای تشخیص و قطعه‌بندی پسماند دریایی داشته‌اند؛ با این حال، تفاوت در Taxonomy، نوع Annotation و شرایط تصویربرداری می‌تواند انتقال مستقیم داده‌ها از یک منبع به منبع دیگر را با

محدودیت مواجه کند. ازاین‌رو، یکپارچه‌سازی داده‌ها پیش از آموزش مدل، نیازمند هماهنگ‌سازی نظام کلاس‌ها، بررسی سازگاری حاشیه‌نویسی‌ها و کنترل کیفیت داده‌ها است.

2-12-1 جمع‌بندی مبانی داده و یکپارچه‌سازی اطلاعات

بررسی مباحث مربوط به داده‌های چندمنبعی نشان داد که افزایش حجم داده به‌تنهایی تضمین‌کننده بهبود عملکرد آشکارساز نیست. در صورتی که داده‌های حاصل از منابع مختلف دارای تعریف‌های متفاوت از کلاس‌ها، حاشیه‌نویسی‌های ناسازگار یا کیفیت متغیر باشند، ادغام مستقیم آن‌ها می‌تواند موجب افزایش نویز برچسبی و ایجاد ابهام در فرآیند یادگیری شود.

بنابراین، در پژوهش حاضر، مفهوم «ادغام داده‌ها» در معنای یکپارچه‌سازی چندمنبعی داده‌های تصویری تعریف می‌شود؛ به این معنا که داده‌های حاصل از منابع مختلف پس از بررسی ساختار برچسب‌ها، هماهنگ‌سازی **Taxonomy**، اعتبارسنجی **Annotation** و کنترل کیفیت در یک چارچوب مشترک مورد استفاده قرار می‌گیرند. این تعریف از ادغام داده‌ها با مفهوم **Data Fusion** در سطح ویژگی یا حسگر متفاوت است و نباید این دو مفهوم در تفسیر پژوهش یکسان تلقی شوند.

به‌صورت مفهومی، فرآیند ایجاد داده‌مجموعه یکپارچه را می‌توان چنین نمایش داد:

$$D_1, D_2, \ldots, D_n \rightarrow \text{Taxonomy Harmonization} \rightarrow \text{Annotation Validation} \rightarrow \text{Quality Control} \rightarrow D_unified$$

در این رابطه، **D_1** تا **D_n** نشان‌دهنده منابع مختلف داده و **D_unified** نشان‌دهنده مجموعه‌داده نهایی پس از فرآیند یکپارچه‌سازی و کنترل کیفیت است. بنابراین، رابطه فوق به معنای **Concatenation** ساده داده‌ها نیست؛ بلکه بیانگر یک فرآیند کنترل‌شده برای تبدیل چند منبع ناهمگون به یک مجموعه‌داده با ساختار مشترک است.

بر اساس ساختار نهایی داده‌مجموعه پژوهش، یک **Taxonomy** مشترک شامل ۱۳ کلاس ایجاد شده است:

۱. **animal_crab**
۲. **animal_eel**
۳. **animal_etc**
۴. **animal_fish**
۵. **animal_shells**

۶. animal_starfish
۷. plant
۸. trash_branch
۹. trash_clothing
۱۰. trash_net
۱۱. trash_unknown_instance
۱۲. trash_wreckage
۱۳. trash_plastic

این ساختار امکان می‌دهد که هر سه معماری مورد مطالعه، یعنی YOLOv8n، RT-DETR-L و RTMDet-Tiny، مسئله یکسانی را با مجموعه کلاس‌های یکسان حل کنند. بنابراین، اختلاف مشاهده‌شده در عملکرد مدل‌ها را می‌توان با اطمینان بیشتری به تفاوت‌های معماری، قابلیت استخراج ویژگی، راهبرد تشخیص و کارایی محاسباتی آن‌ها نسبت داد، نه به تفاوت در تعریف مسئله یا ساختار کلی داده.

از دیدگاه نظری، رابطه میان داده‌های چندمنبعی و داده‌مجموعه نهایی به صورت زیر قابل خلاصه‌سازی است:

```
D_multi-source → D_unified^(13-class)
```

در این چارچوب، داده‌مجموعه یکپارچه نقش ورودی مشترک برای مرحله مقایسه معماری‌ها را ایفا می‌کند.

2-12-2 جمع‌بندی مبانی معماری آشکارسازها

بررسی معماری‌های مورد استفاده در این پژوهش نشان داد که سه مدل انتخاب‌شده صرفاً سه نسخه متفاوت از یک خانواده معماری نیستند، بلکه سه رویکرد متفاوت برای حل مسئله آشکارسازی شیء را نمایندگی می‌کنند.

YOLOv8n نماینده نسل جدید آشکارسازهای تک‌مرحله‌ای مبتنی بر شبکه‌های کانولوشنی است که با استفاده از استخراج ویژگی چندمقیاسی، ساختار C2f، SPPF، Neck مبتنی بر FPN/PAN و Head تفکیک‌شده و Anchor-Free، بر دستیابی هم‌زمان به دقت و سرعت تمرکز دارد.

در مقابل، RT-DETR-L رویکردی مبتنی بر Transformer و آشکارسازی End-to-End را ارائه می‌کند. استفاده از Hybrid Encoder، Object Query، Query Selection و Transformer

Decoder موجب می‌شود این معماری از نظر سازوکار پردازش با آشکارسازهای سنتی تک‌مرحله‌ای تفاوت داشته باشد. از ویژگی‌های مهم این خانواده، طراحی End-to-End و کاهش وابستگی به فرآیندهای پس‌پردازش متداول در آشکارسازهای سنتی است.

RTMDet-Tiny نیز یک آشکارساز بلادرنگ مبتنی بر CNN است که با استفاده از CSPNeXt، CSPNeXtPAFPN، Head تفکیک‌شده و Dynamic Soft Label Assigner، تلاش می‌کند توازن مناسبی میان دقت و هزینه محاسباتی ایجاد کند.

در نتیجه، انتخاب این سه معماری امکان یک مقایسه سه‌جانبه میان رویکردهای زیر را فراهم می‌کند:

YOLOv8n ↔ RT-DETR-L ↔ RTMDet-Tiny

علامت دوطرفه در این نمایش به معنای ارتباط یا تبدیل معماری‌ها به یکدیگر نیست؛ بلکه نشان‌دهنده قرار گرفتن آن‌ها در یک چارچوب مقایسه‌ای مشترک است.

اهمیت چنین مقایسه‌ای زمانی بیشتر آشکار می‌شود که هدف پژوهش تنها دستیابی به بیشترین mAP نباشد، بلکه دقت، مکان‌یابی، سرعت، تأخیر و پایداری عملکرد نیز به صورت هم‌زمان مورد بررسی قرار گیرد.

2-12-3 جمع‌بندی معیارهای ارزیابی

بررسی معیارهای ارزیابی نشان داد که هیچ معیار منفردی نمی‌تواند عملکرد یک آشکارساز را به صورت کامل توصیف کند. Precision و Recall دو جنبه مکمل از عملکرد تشخیص را نشان می‌دهند؛ به‌طوری‌که Precision نسبت پیش‌بینی‌های مثبت صحیح به کل پیش‌بینی‌های مثبت و Recall نسبت نمونه‌های مثبت شناسایی‌شده صحیح به کل نمونه‌های مثبت واقعی را بیان می‌کند.

معیار IoU نیز مبنای سنجش میزان هم‌پوشانی میان جعبه پیش‌بینی‌شده و جعبه واقعی است:

$$|IoU = |B_p \cap B_gt| / |B_p \cup B_gt$$

که در آن B_p جعبه پیش‌بینی‌شده و B_gt جعبه واقعی است.

در ادامه، AP و mAP امکان خلاصه‌سازی عملکرد مدل را در سطوح مختلف IoU فراهم می‌کنند. در این پژوهش، mAP@0.50 و mAP@0.50:0.95 به عنوان معیارهای اصلی ارزیابی دقت و مکان‌یابی در نظر گرفته می‌شوند.

معیار mAP@0.50 عملکرد مدل را در آستانه IoU برابر با 0.50 خلاصه می‌کند، در حالی که mAP@0.50:0.95 عملکرد مدل را در مجموعه‌ای از آستانه‌های IoU از 0.50 تا 0.95 با گام 0.05 ارزیابی می‌کند. بنابراین، معیار دوم نسبت به معیار نخست سخت‌گیرانه‌تر است و برای ارزیابی هم‌زمان تشخیص صحیح و کیفیت مکان‌یابی مناسب‌تر است.

به طور کلی، می‌توان ارتباط مفهومی میان دقت تشخیص و مکان‌یابی را چنین نمایش داد:

$$\text{Detection Accuracy} \rightarrow \{\text{Precision, Recall, mAP}\}$$

$$\text{Localization Quality} \rightarrow \{\text{IoU, mAP@0.50:0.95}\}$$

با این حال، در یک سامانه عملی، دقت بالا به‌تنهایی کافی نیست. بنابراین، معیارهای سرعت پردازش و تأخیر نیز باید در کنار معیارهای دقت و مکان‌یابی بررسی شوند. FPS تعداد تصاویر پردازش‌شده در واحد زمان را نشان می‌دهد و Latency مدت زمان لازم برای پردازش یک تصویر یا نمونه را بیان می‌کند.

از این منظر، ارزیابی مدل‌ها در پژوهش حاضر بر چهار محور مکمل استوار خواهد بود:

$$\text{Model Evaluation} = \{\text{Accuracy, Localization, Efficiency, Robustness}\}$$

که در آن Accuracy شامل معیارهایی نظیر Precision،Recall و Localization،mAP شامل معیارهایی مانند IoU و mAP در آستانه‌های مختلف، Efficiency شامل FPS و Latency و Robustness شامل میزان حفظ عملکرد مدل در شرایط تغییر یافته است.

2-12-4 جمع‌بندی مفهوم Robustness و Domain Shift

یکی از نتایج مهم بررسی ادبیات این است که عملکرد بالای مدل روی داده‌های آزمون هم‌توزیع با داده‌های آموزش لزوماً به معنای عملکرد مطلوب در شرایط واقعی نیست. تفاوت میان توزیع داده‌های آموزش و شرایط جدید می‌تواند موجب Domain Shift شود.

اگر داده‌های مبدأ و مقصد به‌ترتیب با توزیع‌های زیر نمایش داده شوند:

$sim P_s(X,Y)\ (X_s,Y_s)$

و

$sim P_t(X,Y)\ (X_t,Y_t)$

در شرایط **Domain Shift** معمولاً داریم:

$$P_s(X,Y) \neq P_t(X,Y)$$

در محیط دریایی، این تفاوت می‌تواند ناشی از تغییر در کیفیت آب، روشنایی، زاویه تصویربرداری، پس‌زمینه، نوع دوربین، شرایط سطح یا زیرآب و تفاوت میان منابع تصویری باشد.

ازاین‌رو، **Robustness** در پژوهش حاضر صرفاً به معنای «دقت بالا» تعریف نمی‌شود؛ بلکه منظور توانایی مدل در حفظ بخش قابل‌قبولی از عملکرد پایه هنگام مواجهه با شرایط تصویری متفاوت است.

برای سنجش میزان افت نسبی عملکرد، رابطه زیر استفاده می‌شود:

$$\Delta_rel(\%) = [(M_clean - M_condition) / M_clean] \times 100$$

که در آن **M_clean** عملکرد مدل در شرایط پایه و **M_condition** عملکرد همان مدل در شرایط تغییریافته است.

در این تعریف، مقدار بزرگ‌تر **Δ_rel** نشان‌دهنده افت بیشتر عملکرد است و بنابراین، در صورت ثابت بودن سایر شرایط، مقدار کمتر **Δ_rel** بیانگر **Robustness** بالاتر مدل خواهد بود.

همچنین، میزان حفظ عملکرد مدل را می‌توان به صورت زیر محاسبه کرد:

$$Retention(\%) = (M_condition / M_clean) \times 100$$

در نتیجه، هرچه مقدار **Retention** بیشتر باشد، مدل بخش بیشتری از عملکرد پایه خود را در شرایط تغییریافته حفظ کرده است.

به عنوان مثال، دو مدل ممکن است در شرایط پایه **mAP** مشابهی داشته باشند، اما هنگام مواجهه با تغییرات محیطی افت عملکرد متفاوتی نشان دهند. در چنین شرایطی، مدلی که درصد بیشتری از عملکرد پایه خود را حفظ می‌کند، از دیدگاه **Robustness** عملکرد مطلوب‌تری خواهد داشت.

2-12-5 استخراج چارچوب نظری پژوهش

بر مبنای مباحث مطرح‌شده در این فصل، چارچوب نظری پژوهش حاضر بر این فرض اساسی استوار است که عملکرد نهایی یک سامانه تشخیص پسماند دریایی حاصل تعامل میان چهار گروه اصلی از عوامل است:

الف) ویژگی‌های داده و کیفیت داده‌مجموعه

شامل تنوع داده‌ها، شرایط تصویربرداری، پوشش کلاس‌ها، کیفیت **Annotation** و سازگاری **Taxonomy**.

ب) معماری آشکارساز

شامل سازوکار استخراج ویژگی، ساختار **Feature Pyramid**، روش تولید **Prediction**، روش تخصیص نمونه‌های مثبت و منفی و سازوکار نهایی آشکارسازی.

ج) ابعاد عملکرد

شامل **Accuracy**، **Localization**، **Efficiency** و **Robustness**.

د) شرایط ارزیابی

شامل شرایط پایه و شرایط تغییریافته که برای سنجش میزان تعمیم‌پذیری و پایداری مدل مورد استفاده قرار می‌گیرند.

بر این اساس، چارچوب مفهومی پژوهش را می‌توان به صورت زیر نمایش داد:

```
D_multi-source → Taxonomy Harmonization → Annotation Validation → Quality Control → D_unified^(13-class)
```

سپس:

```
D_unified^(13-class) → Common Experimental Protocol → {YOLOv8n, RT-DETR-L, RTMDet-Tiny}
```

و در مرحله ارزیابی:

Accuracy, Localization, Efficiency, } → {YOLOv8n, RT-DETR-L, RTMDet-Tiny}

{Robustness

و در نهایت:

Evaluation → Comparative Analysis

این ساختار نشان می‌دهد که یکپارچه‌سازی داده‌ها پیش‌نیاز ایجاد یک محیط مقایسه‌ای مشترک است و انتخاب معماری، متغیر اصلی مقایسه‌ای پژوهش محسوب می‌شود.

2-12-6 منطق مقایسه منصفانه مدل‌ها

یکی از مهم‌ترین نتایج استخراج‌شده از ادبیات، ضرورت کنترل متغیرهای آزمایشگاهی در مقایسه آشکارسازها است. اگر مدل‌ها روی داده‌های متفاوت، اندازه تصویر متفاوت، تعداد Epoch متفاوت، راهبردهای Augmentation متفاوت یا شرایط سخت‌افزاری متفاوت آموزش داده شوند، اختلاف عملکرد مشاهده‌شده الزاماً ناشی از معماری مدل نخواهد بود.

ازاین‌رو، منطق نظری پژوهش حاضر بر ایجاد یک پروتکل مقایسه کنترل‌شده استوار است. در این پروتکل، سه معماری از یک داده‌مجموعه نهایی و یک Taxonomy مشترک استفاده می‌کنند و عوامل اصلی مؤثر بر آموزش تا حد امکان ثابت نگه داشته می‌شوند.

اصل مقایسه کنترل‌شده را می‌توان به صورت زیر نمایش داد:

Common Dataset + Common Taxonomy + Common Image Size + Common Training Protocol + Common Hardware → Controlled Comparison

این رابطه به معنای آن نیست که تمام تنظیمات فنی هر معماری باید بدون توجه به ماهیت آن‌ها کاملاً یکسان باشند. برخی پارامترها ممکن است به دلیل تفاوت ذاتی معماری‌ها نیازمند تنظیم متناسب باشند. برای مثال، Batch Size ممکن است با توجه به محدودیت حافظه و ویژگی‌های محاسباتی هر مدل متفاوت باشد.

در چنین شرایطی، اصل حاکم بر مقایسه، یکسان‌سازی شرایط مؤثر بر مسئله و ثبت شفاف هرگونه تفاوت ضروری در تنظیمات است. جزئیات دقیق این تنظیمات باید در فصل سوم ارائه شود تا امکان بازتولید آزمایش‌ها فراهم باشد.

2-12-7 رابطه میان Accuracy، Localization، Efficiency و Robustness

چارچوب نظری پژوهش حاضر صرفاً به دنبال شناسایی «بهترین مدل» بر اساس بیشترین mAP نیست. در سامانه‌های تشخیص پسماند دریایی، به‌ویژه در کاربردهای رباتیک و سامانه‌های دارای منابع محاسباتی محدود، افزایش دقت ممکن است با افزایش هزینه محاسباتی همراه باشد.

بنابراین، یک مدل با mAP بالاتر الزاماً بهترین انتخاب عملی نیست؛ اگر این افزایش دقت با کاهش شدید FPS یا افزایش Latency همراه باشد. از سوی دیگر، مدل سریع‌تر نیز الزاماً برتر نیست، اگر تعداد زیادی از اهداف را از دست بدهد یا مکان‌یابی نامناسبی داشته باشد.

همچنین، مدلی که در شرایط پایه عملکرد بالایی دارد، در صورتی که هنگام تغییر شرایط تصویری افت شدیدی داشته باشد، الزاماً گزینه مناسب‌تری برای کاربردهای واقعی نیست.

از این منظر، کیفیت کلی یک آشکارساز را می‌توان به صورت مفهومی تابعی از چهار بعد اصلی در نظر گرفت:

$$\text{Model Quality} = f(\text{Accuracy}, \text{Localization}, \text{Efficiency}, \text{Robustness})$$

این رابطه یک تابع ریاضی عملیاتی برای محاسبه امتیاز نهایی مدل نیست، بلکه بیان مفهومی این موضوع است که کیفیت کلی یک آشکارساز از چند بعد مکمل تشکیل می‌شود.

در نتیجه، تحلیل نهایی باید بتواند به پرسش‌هایی از این دست پاسخ دهد:

- کدام معماری بیشترین دقت تشخیص را ارائه می‌کند؟
- کدام معماری بهترین دقت مکان‌یابی را دارد؟
- کدام معماری سرعت پردازش بالاتری دارد؟
- آیا افزایش دقت با هزینه محاسباتی قابل‌توجه همراه است؟
- کدام معماری عملکرد پایه خود را در شرایط تغییریافته بهتر حفظ می‌کند؟
- آیا یک معماری خاص در تمام معیارها برتری دارد یا عملکرد مدل‌ها دارای Trade-off است؟

این رویکرد، مقایسه معماری‌ها را از یک رتبه‌بندی تک‌معیاره به یک ارزیابی چندبعدی تبدیل می‌کند.

2-12-8 مدل مفهومی نهایی پژوهش

با ترکیب نتایج حاصل از مبانی نظری، مطالعات پیشین و شکاف‌های شناسایی‌شده، مدل مفهومی نهایی پژوهش را می‌توان در مسیر زیر خلاصه کرد:

$$D_1, D_2, \ldots, D_n \rightarrow \text{Taxonomy Harmonization} \rightarrow \text{Annotation Validation} \rightarrow \text{Quality Control} \rightarrow D_unified\text{^}(13\text{-class})$$

سپس:

$$D_unified\text{^}(13\text{-class}) \rightarrow \text{Common Experimental Protocol} \rightarrow \{\text{YOLOv8n, RT-DETR-L, RTMDet-Tiny}\}$$

و در ادامه:

$$\text{Accuracy, Localization, Efficiency, } \} \rightarrow \{\text{YOLOv8n, RT-DETR-L, RTMDet-Tiny}\} \{\text{Robustness}$$

و در نهایت:

$$\text{Comparative Analysis} \rightarrow \{\text{Accuracy, Localization, Efficiency, Robustness}\}$$

بنابراین، مسیر کلی پژوهش به صورت زیر قابل بیان است:

$$\text{Multi-source Data} \rightarrow \text{Unified 13-Class Dataset} \rightarrow \text{Common Experimental Protocol} \rightarrow \text{YOLOv8n / RT-DETR-L / RTMDet-Tiny} \rightarrow \text{Multi-dimensional Evaluation} \rightarrow \text{Comparative Analysis}$$

این چارچوب، ارتباط منطقی میان مراحل آماده‌سازی داده، انتخاب معماری، طراحی آزمایش و ارزیابی نتایج را نشان می‌دهد.

2-12-9 ارتباط چارچوب نظری با شکاف پژوهشی

مطالعات بررسی‌شده در بخش‌های پیشین نشان دادند که بخش قابل‌توجهی از پژوهش‌های موجود بر بهبود یک معماری خاص، طراحی یک آشکارساز اصلاح‌شده یا افزایش عملکرد روی یک داده‌مجموعه مشخص تمرکز دارند. در مقابل، مقایسه مستقیم چند خانواده معماری متفاوت تحت یک پروتکل آزمایشی

کنترل‌شده، همراه با بررسی هم‌زمان دقت، کارایی و **Robustness**، می‌تواند دیدگاه متفاوتی برای ارزیابی عملی مدل‌ها فراهم کند.

از این منظر، جایگاه پژوهش حاضر را می‌توان در نقطه تلاقی چهار محور اصلی تعریف کرد:

Research\ Position

```
Research Position = {Multi-source Data Integration; Controlled Architecture Comparison; Real-Time Efficiency; Robustness under Domain Shift}
```

محور نخست بر ایجاد یک مجموعه‌داده یکپارچه از منابع مختلف و هماهنگ‌سازی ساختار کلاس‌ها و **Annotation**ها تمرکز دارد. محور دوم بر مقایسه کنترل‌شده **RT-DETR-L**،**YOLOv8n** و **RTMDet-Tiny** استوار است. محور سوم، قابلیت استفاده عملی مدل‌ها را از نظر سرعت پردازش و تأخیر بررسی می‌کند و محور چهارم به سنجش میزان حفظ عملکرد مدل‌ها در شرایط متفاوت از وضعیت پایه اختصاص دارد.

بر این اساس، پژوهش حاضر تلاش می‌کند فاصله میان «بهبود عملکرد یک مدل در یک شرایط مشخص» و «شناخت مقایسه‌ای رفتار معماری‌های متفاوت در یک محیط آزمایشی کنترل‌شده» را کاهش دهد.

2-12-10 جمع‌بندی نهایی فصل دوم

مرور مبانی نظری و مطالعات پیشین نشان داد که تشخیص خودکار پسماند دریایی یک مسئله چندوجهی است که در آن کیفیت داده، ساختار طبقه‌بندی، معماری آشکارساز، معیارهای ارزیابی و شرایط تصویربرداری به صورت هم‌زمان بر عملکرد سامانه اثر می‌گذارند.

از منظر داده، یکپارچه‌سازی منابع مختلف بدون هماهنگ‌سازی **Taxonomy** و کنترل کیفیت **Annotation** می‌تواند موجب ایجاد ناسازگاری در فرآیند آموزش شود. از منظر معماری، **YOLOv8n**، **RT-DETR-L** و **RTMDet-Tiny** سه رویکرد متفاوت برای دستیابی به تشخیص سریع و دقیق ارائه می‌کنند و بنابراین مقایسه آن‌ها می‌تواند اطلاعات ارزشمندی درباره **Trade-off** میان دقت، سرعت و هزینه محاسباتی فراهم کند.

از منظر ارزیابی نیز مشخص شد که استفاده از یک معیار منفرد برای تعیین برتری مدل‌ها کافی نیست. Precision، Recall، mAP@0.50 و mAP@0.50:0.95 باید در کنار معیارهای مکان‌یابی و Efficiency مانند IoU، FPS و Latency تفسیر شوند. افزون بر این، بررسی افت عملکرد در شرایط تغییریافته می‌تواند اطلاعاتی درباره Robustness و میزان تعمیم‌پذیری مدل‌ها فراهم کند.

بر این اساس، چارچوب نظری پژوهش حاضر بر زنجیره زیر استوار است:

Multi-source Data → Taxonomy Harmonization → Annotation Validation → Quality Control → Unified 13-Class Dataset → Common Experimental Protocol → {YOLOv8n, RT-DETR-L, RTMDet-Tiny} → {Accuracy, Localization, Efficiency, Robustness} → Comparative Analysis

این چارچوب نشان می‌دهد که نوآوری پژوهش حاضر صرفاً در استفاده از یک معماری جدید یا اعمال یک تغییر جزئی در ساختار شبکه خلاصه نمی‌شود؛ بلکه در ایجاد یک چارچوب منظم برای یکپارچه‌سازی داده، هماهنگ‌سازی Taxonomy، مقایسه کنترل‌شده معماری‌های متفاوت و ارزیابی هم‌زمان دقت، مکان‌یابی، کارایی و Robustness قرار دارد.

در نتیجه، فصل دوم مبنای نظری لازم را برای طراحی آزمایش‌های فصل سوم فراهم می‌کند. در فصل سوم، بر اساس این چارچوب، فرآیند آماده‌سازی نهایی داده‌ها، ساختار داده‌مجموعه، تقسیم‌بندی آموزش، اعتبارسنجی و آزمون، تنظیمات کنترل‌شده آموزش، مشخصات سخت‌افزاری و نرم‌افزاری، پروتکل ارزیابی، شرایط آزمون Robustness و روش تحلیل مقایسه‌ای نتایج به صورت دقیق تشریح خواهد شد.

2-13 تغییر دامنه

2-13-1 مفهوم Domain Shift

یکی از فرض‌های ضمنی بسیاری از مدل‌های یادگیری ماشین این است که داده‌های آموزش و آزمون از توزیع‌های مشابهی تولید شده‌اند.

در کاربردهای واقعی، این فرض همیشه برقرار نیست.

Domain shift زمانی رخ می‌دهد که توزیع داده‌های مورد استفاده برای آموزش با توزیع داده‌های محیط هدف تفاوت داشته باشد.

این تفاوت ممکن است ناشی از تغییر:

- نوع دوربین؛
- محیط تصویربرداری؛
- نور؛
- زاویه دید؛
- فاصله دوربین؛
- کیفیت تصویر؛
- پس‌زمینه؛
- شرایط محیطی؛
- یا ترکیب این عوامل باشد.

در نتیجه، مدلی که در داده‌های دامنه مبدأ عملکرد خوبی دارد، ممکن است در دامنه هدف افت عملکرد نشان دهد.

Domain Adaptation 2-13-2

Domain adaptation به مجموعه‌ای از روش‌ها اشاره دارد که هدف آن‌ها کاهش اثر اختلاف میان دامنه مبدأ و هدف است.

در این رویکرد، اطلاعاتی از دامنه هدف به‌نوعی در فرایند سازگاری مورد استفاده قرار می‌گیرد.

Ganin و همکاران (2016) یکی از چارچوب‌های تأثیرگذار یادگیری بازنمایی مستقل از دامنه را معرفی کردند که در توسعه پژوهش‌های domain adaptation نقش مهمی داشته است.

در مسئله تشخیص شیء، domain adaptation می‌تواند پیچیده‌تر از طبقه‌بندی باشد، زیرا تفاوت دامنه نه‌تنها بر ویژگی‌های ظاهری، بلکه بر مکان، اندازه و نمایش اشیا نیز اثر می‌گذارد.

Domain Generalization 2-13-3

Domain generalization با domain adaptation تفاوت دارد.

در domain adaptation، اطلاعاتی از دامنه هدف برای کاهش فاصله میان دامنه‌ها مورد استفاده قرار می‌گیرد.

در مقابل، در domain generalization هدف آن است که مدل بدون مشاهده مستقیم داده‌های دامنه هدف در مرحله آموزش، توانایی بیشتری برای تعمیم به توزیع‌های جدید داشته باشد.

Zhou و همکاران (2023) نشان می‌دهند که domain generalization به یکی از حوزه‌های مهم یادگیری ماشین تبدیل شده است، زیرا در بسیاری از کاربردهای واقعی امکان دسترسی کامل به داده‌های دامنه هدف پیش از استقرار مدل وجود ندارد.

2-14 رابطه Robustness و Domain Shift

Robustness و domain shift مفاهیمی مرتبط اما یکسان نیستند.

Robustness معمولاً به بررسی رفتار مدل در برابر تغییرات کنترل‌شده ورودی اشاره دارد.

Domain shift به تفاوت میان توزیع‌های واقعی داده در دامنه‌های مختلف مربوط می‌شود.

ممکن است یک مدل در برابر یک نوع اختلال مصنوعی مقاوم باشد، اما در دامنه‌ای با دوربین یا پس‌زمینه متفاوت افت شدیدی داشته باشد.

همچنین ممکن است مدلی در برابر تغییر دامنه عملکرد قابل‌قبولی داشته باشد، اما نسبت به یک اختلال خاص مانند تاری حساس باشد.

بنابراین، ارزیابی این دو مفهوم باید به‌صورت تفکیک‌شده انجام شود.

این تفکیک یکی از پایه‌های نظری پژوهش حاضر را تشکیل می‌دهد.

2-15 سازگارسازی محدود دامنه

پس از مشاهده افت عملکرد در دامنه هدف، یکی از پرسش‌های مهم این است که آیا می‌توان بخشی از این افت را با استفاده از اطلاعات محدود دامنه هدف جبران کرد.

سازگارسازی محدود دامنه می‌تواند به‌عنوان یک فرایند عملی برای بررسی این موضوع در نظر گرفته شود که مدل تا چه حد قابلیت تطبیق با شرایط جدید را دارد.

هدف چنین مرحله‌ای در پژوهش حاضر ارائه یک روش جدید domain adaptation نیست.

بلکه هدف، بررسی تجربی میزان بازیابی عملکرد مدل منتخب پس از اعمال یک راهبرد سازگارسازی محدود است.

بنابراین، رابطه میان مراحل پژوهش به این صورت قابل درک است:

عملکرد پایه ← بررسی مقاومت ← ارزیابی تغییر دامنه ← انتخاب مدل ← سازگارسازی محدود ← ارزیابی بازیابی عملکرد

این ساختار باعث می‌شود مرحله سازگارسازی به‌عنوان یک اقدام مستقل و جدا از مسئله اصلی تلقی نشود، بلکه بخشی از یک زنجیره ارزیابی تصمیم‌محور باشد.

2-16 کارایی محاسباتی و کاربردهای نزدیک به بلادرنگ

در کاربردهای عملی تشخیص شیء، دقت تنها معیار تصمیم‌گیری نیست.

یک مدل با عملکرد بسیار بالا ممکن است به منابع محاسباتی زیادی نیاز داشته باشد و استفاده از آن در سامانه‌های محدود را دشوار کند.

بنابراین، در کنار معیارهای دقت، شاخص‌هایی مانند سرعت استنتاج، زمان تأخیر، تعداد پارامترها و هزینه محاسباتی اهمیت دارند.

این موضوع به‌ویژه در سامانه‌های رباتیک دریایی، وسایل خودکار، سامانه‌های مبتنی بر پردازش لبه و کاربردهای نزدیک به بلادرنگ اهمیت بیشتری پیدا می‌کند.

مقایسه RT-DETR-L،YOLOv8n و RTMDet-Tiny از این منظر نیز دارای اهمیت است، زیرا این مدل‌ها راهبردهای متفاوتی برای ایجاد توازن میان دقت و هزینه محاسباتی دنبال می‌کنند.

با این حال، مقایسه سرعت باید تحت شرایط کنترل‌شده انجام شود، زیرا نوع سخت‌افزار، اندازه ورودی، پیاده‌سازی نرم‌افزاری و محیط اجرا می‌توانند بر نتایج تأثیر بگذارند.

2-17 پیشینه پژوهش

2-17-1 پژوهش‌های مرتبط با مجموعه‌داده‌های پسماند دریایی

یکی از پایه‌های توسعه روش‌های یادگیری عمیق در این حوزه، ایجاد مجموعه‌داده‌های تخصصی است.

Fulton و همکاران (2019) مسئله تشخیص پسماند دریایی را در زمینه رباتیک دریایی مورد بررسی قرار دادند و نشان دادند که مدل‌های تشخیص عمیق می‌توانند برای شناسایی اشیای پسماند در تصاویر زیرآبی مورد استفاده قرار گیرند.

Hong و همکاران (2020) با ارائه TrashCan، یک منبع داده مهم برای توسعه پژوهش‌های مرتبط با تشخیص و درک صحنه‌های دریایی فراهم کردند.

Barrelet و همکاران (2022) نیز به مسئله سازگاری و توازن داده‌ها توجه کرده‌اند. این دسته از پژوهش‌ها نشان می‌دهد که کیفیت و ساختار مجموعه‌داده می‌تواند به اندازه انتخاب معماری مدل در نتایج نهایی اهمیت داشته باشد.

2-17-2 پژوهش‌های مرتبط با تشخیص شیء زیرآبی

مرور Er و همکاران (2023) نشان می‌دهد که تشخیص اشیا در محیط زیرآبی با چالش‌های متعددی مواجه است.

از جمله این چالش‌ها می‌توان به:

- کاهش کیفیت تصویر؛
- تغییر رنگ؛
- پراکندگی نور؛
- اشیای کوچک؛
- پیچیدگی پس‌زمینه؛
- تغییر مقیاس؛
- و محدودیت تعمیم اشاره کرد.

این چالش‌ها نشان می‌دهد که افزایش عملکرد یک مدل در یک مجموعه‌داده مشخص به‌تنهایی نمی‌تواند معادل افزایش قابلیت اعتماد آن در محیط‌های مختلف باشد.

2-17-3 پژوهش‌های مرتبط با Transformer در تشخیص شیء

Carion و همکاران (2020) با معرفی DETR، استفاده از Transformer را در تشخیص end-to-end گسترش دادند.

پس از آن، پژوهش‌های مختلف تلاش کردند محدودیت‌های DETR اولیه را کاهش دهند.

RT-DETR-L توسط Zhao و همکاران (2024) با تمرکز بر دستیابی به تشخیص بلادرنگ توسعه یافت.

اهمیت این جریان پژوهشی در آن است که نشان می‌دهد معماری‌های مبتنی بر Transformer می‌توانند در کنار آشکارسازهای متداول CNNمحور به‌عنوان گزینه‌های جدی برای تشخیص شیء مطرح شوند.

2-17-4 پژوهش‌های مرتبط با آشکارسازهای بلادرنگ

آشکارسازهای بلادرنگ بخش مهمی از ادبیات تشخیص شیء را تشکیل می‌دهند.

خانواده YOLO یکی از مهم‌ترین جریان‌های توسعه در این زمینه است.

RTMDet-Tiny نیز نمونه‌ای از پژوهش‌هایی است که بر طراحی تجربی اجزای آشکارساز و دستیابی به توازن میان دقت و کارایی تمرکز دارند (Lyu et al., 2022).

وجود این معماری‌ها نشان می‌دهد که مسئله اصلی در آشکارسازهای مدرن تنها افزایش ظرفیت شبکه نیست، بلکه طراحی ساختاری است که بتواند میان دقت، سرعت و هزینه محاسباتی توازن برقرار کند.

2-17-5 پژوهش‌های مرتبط با مقاومت مدل‌ها

Hendrycks و Dietterich (2019) اهمیت ارزیابی مقاومت مدل‌های یادگیری عمیق را در برابر اختلالات رایج نشان دادند.

اگرچه مطالعه آن‌ها بر طبقه‌بندی تصویر تمرکز داشت، مفهوم اصلی آن در پژوهش‌های تشخیص شیء نیز اهمیت دارد.

مدلی که تنها در داده‌های مشابه آموزش ارزیابی می‌شود، ممکن است در شرایط واقعی رفتار متفاوتی نشان دهد.

بنابراین، ارزیابی مقاومت می‌تواند اطلاعات مکملی نسبت به معیارهای عملکرد پایه ارائه کند.

2-17-6 پژوهش‌های مرتبط با انتقال بین‌دامنه‌ای

پژوهش‌های domain adaptation نشان داده‌اند که اختلاف توزیع میان داده‌های مبدأ و هدف می‌تواند به افت عملکرد مدل‌های یادگیری عمیق منجر شود.

Ganin و همکاران (2016) از پژوهش‌های مهم در زمینه یادگیری بازنمایی مقاوم‌تر نسبت به تفاوت دامنه محسوب می‌شوند.

Zhou و همکاران (2023) نیز domain generalization را به‌عنوان حوزه‌ای مهم برای افزایش قابلیت تعمیم مدل‌ها به دامنه‌های مشاهده‌نشده بررسی کرده‌اند.

در حوزه تشخیص پسماند دریایی، اهمیت این مسئله بیشتر می‌شود؛ زیرا داده‌های تصویری ممکن است از محیط‌ها، تجهیزات و شرایط تصویربرداری متفاوت جمع‌آوری شوند.

2-18 جمع‌بندی پیشینه و خلأ پژوهشی

مرور مبانی نظری و پیشینه پژوهش نشان می‌دهد که در سال‌های اخیر پیشرفت قابل‌توجهی در سه حوزه اصلی رخ داده است:

نخست، توسعه مجموعه‌داده‌های تخصصی برای پسماند و اشیای دریایی؛

دوم، توسعه معماری‌های پیشرفته تشخیص شیء؛

سوم، گسترش پژوهش‌ها در زمینه مقاومت مدل‌ها و تعمیم بین‌دامنه‌ای.

با وجود این پیشرفت‌ها، چند مسئله همچنان اهمیت دارد.

بخش قابل‌توجهی از مطالعات تشخیص پسماند دریایی بر گزارش عملکرد مدل در یک مجموعه آزمون مشخص متمرکز هستند.

در چنین ارزیابی‌هایی، ممکن است مشخص شود کدام مدل در شرایط آزمون مورد نظر عملکرد بالاتری دارد، اما این نتیجه لزوماً اطلاعات کافی درباره رفتار مدل در برابر اختلالات یا انتقال به دامنه‌ای متفاوت فراهم نمی‌کند.

از سوی دیگر، تفاوت میان مجموعه‌داده‌ها و taxonomy آن‌ها می‌تواند مقایسه مستقیم مدل‌ها را دشوار کند.

همچنین، ادبیات موجود در حوزه robustness و domain shift عمدتاً به‌صورت حوزه‌های مستقل توسعه یافته‌اند، در حالی که در کاربردهای عملی می‌توان این دو مفهوم را به‌عنوان دو بعد متفاوت از قابلیت اعتماد مدل بررسی کرد.

بر این اساس، خلأ اصلی مورد توجه پژوهش حاضر در سه سطح قابل بیان است.

سطح اول: خلأ داده‌ای و مقایسه‌ای

نیاز به یک چارچوب داده‌ای هماهنگ برای مقایسه مدل‌های مختلف وجود دارد؛ چارچوبی که در آن ناهمگونی منابع داده و تعریف کلاس‌ها تا حد امکان کنترل شود.

سطح دوم: خلأ ارزیابی

مقایسه مدل‌ها نباید تنها به عملکرد پایه محدود شود و لازم است مقاومت آن‌ها در برابر اختلالات تصویری به‌صورت مستقل بررسی شود.

سطح سوم: خلأ تعمیم‌پذیری

رفتار مدل‌ها در دامنه‌ای متفاوت باید جدا از عملکرد پایه و مقاومت در برابر اختلالات کنترل‌شده بررسی شود.

بر همین اساس، پژوهش حاضر سه معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny را در یک چارچوب مقایسه‌ای چندبعدی بررسی می‌کند.

هدف این مقایسه صرفاً تعیین مدل دارای بیشترین مقدار mAP نیست.

بلکه هدف، بررسی این مسئله است که تفاوت معماری‌ها چگونه در ابعاد مختلف عملکرد شامل دقت پایه، مقاومت در برابر اختلال، حساسیت به تغییر دامنه و قابلیت بازیابی عملکرد پس از سازگارسازی منعکس می‌شود.

2-19 جایگاه پژوهش حاضر در میان مطالعات پیشین

با توجه به مبانی نظری و مطالعات پیشین، جایگاه پژوهش حاضر را می‌توان به‌صورت زیر تعریف کرد.

این پژوهش:

- یک معماری جدید تشخیص شیء ارائه نمی‌کند؛
- ادعای ارائه روش جدید برای data fusion ندارد؛
- ادعای ارائه الگوریتم جدید domain adaptation ندارد.

در مقابل، سهم پژوهش در طراحی و اجرای یک چارچوب تجربی قرار دارد که چند بعد عملکرد را به‌صورت تفکیک‌شده بررسی می‌کند.

این ابعاد عبارت‌اند از:

۱. عملکرد پایه در شرایط استاندارد؛
۲. مقاومت در برابر اختلالات تصویری کنترل‌شده؛
۳. افت عملکرد ناشی از تغییر دامنه؛
۴. امکان بازیابی عملکرد مدل منتخب از طریق سازگارسازی محدود؛
۵. کارایی محاسباتی در کنار معیارهای دقت.

بنابراین، پژوهش حاضر تلاش می‌کند از یک پرسش ساده با عنوان «کدام مدل دقیق‌تر است؟» فراتر رود و پرسش جامع‌تری را مطرح کند:

کدام معماری در مجموعه شرایط مورد بررسی، شامل عملکرد پایه، شرایط دارای اختلال و انتقال بین‌دامنه‌ای، رفتار قابل‌اعتمادتر و متوازن‌تری ارائه می‌دهد؟

2-20 جمع‌بندی فصل

در این فصل، مبانی نظری و مطالعات پیشین مرتبط با تشخیص پسماند دریایی، تشخیص شیء مبتنی بر یادگیری عمیق، چالش‌های تصاویر زیرآبی، مجموعه‌داده‌های تخصصی، یکپارچه‌سازی داده‌های چندمنبعی، معماری‌های RT-DETR-L،YOLOv8n و RTMDet-Tiny، معیارهای ارزیابی عملکرد، مقاومت در برابر اختلالات تصویری، تغییر دامنه و سازگارسازی دامنه بررسی شد.

بررسی مطالعات نشان داد که توسعه مدل‌های تشخیص شیء در سال‌های اخیر پیشرفت قابل‌توجهی داشته است، اما عملکرد بالا در یک مجموعه آزمون استاندارد به‌تنهایی نمی‌تواند قابلیت اعتماد مدل در شرایط متفاوت را تضمین کند.

محیط‌های دریایی و زیرآبی به دلیل تغییرات کیفیت تصویر، پیچیدگی پس‌زمینه، تغییر مقیاس اشیا و تفاوت شرایط تصویربرداری، زمینه‌ای مناسب برای بررسی چندبعدی عملکرد مدل‌ها فراهم می‌کنند.

همچنین مشخص شد که مقاومت در برابر اختلالات تصویری و قابلیت تعمیم بین‌دامنه‌ای باید به‌عنوان دو مفهوم مرتبط اما متمایز در نظر گرفته شوند. مقاومت به حفظ عملکرد در برابر تغییرات کنترل‌شده ورودی مربوط است، در حالی که تغییر دامنه به اختلاف توزیع میان محیط آموزش و محیط هدف اشاره دارد.

بر این اساس، پژوهش حاضر با مقایسه سه معماری RT-DETR-L،YOLOv8n و RTMDet-Tiny، عملکرد آن‌ها را در چارچوبی چندبعدی بررسی می‌کند. این چارچوب شامل عملکرد پایه، مقاومت، رفتار بین‌دامنه‌ای و امکان بازیابی عملکرد پس از سازگارسازی محدود است.

مبانی نظری و پیشینه پژوهش ارائه‌شده در این فصل، زمینه لازم برای طراحی روش پژوهش و پروتکل تجربی را فراهم می‌کند. در فصل سوم، روش‌شناسی پژوهش، ساختار داده‌ها، فرایند آماده‌سازی و یکپارچه‌سازی داده، پروتکل مقایسه مدل‌ها، طراحی ارزیابی‌ها و روش تحلیل نتایج تشریح خواهد شد.

منابع فصل دوم

Barrelet, C., Chaumont, M., Subsol, G., Creuze, V., & Gouttefarde, M. (2022). From TrashCan to UNO: Deriving an underwater image dataset to get a more consistent

and balanced version. In *Proceedings of the 26th International Conference on Pattern Recognition (ICPR 2022)*.

Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020). End-to-end object detection with Transformers. In *Computer Vision – ECCV 2020* (pp. 213–229). Springer.

Er, M. J., Chen, J., Zhang, Y., & Gao, W. (2023). Research challenges, recent advances, and popular datasets in deep learning-based underwater marine object detection: A review. *Sensors*, *23*(4), 1990.

Fulton, M., Hong, J., Islam, M. J., & Sattar, J. (2019). Robotic detection of marine litter using deep visual detection models. In *2019 International Conference on Robotics and Automation (ICRA)* (pp. 5752–5758). IEEE. https://doi.org/10.1109/ICRA.2019.8793975

Fulton, M. S., Hong, J., & Sattar, J. (2020). *Trash-ICRA19: A bounding box labeled dataset of underwater trash* [Data set]. Data Repository for the University of Minnesota. https://doi.org/10.13020/x0qn-y082

Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., March, M., & Lempitsky, V. (2016). Domain-adversarial training of neural networks. *Journal of Machine Learning Research*, *17*(59), 1–35.

Hendrycks, D., & Dietterich, T. (2019). Benchmarking neural network robustness to common corruptions and perturbations. In *International Conference on Learning Representations (ICLR)*.

Hong, J., Fulton, M., & Sattar, J. (2020). TrashCan: A semantically-segmented dataset towards visual detection of marine debris. *arXiv*. https://arxiv.org/abs/2007.08097

Jocher, G., Chaurasia, A., & Qiu, J. (2023). *YOLO by Ultralytics* (Version 8.0.0) [Computer software]. Zenodo. https://doi.org/10.5281/zenodo.7867787

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *Computer Vision – ECCV 2014* (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

Lyu, C., Zhang, W., Huang, H., Zhou, Y., Wang, Y., Liu, Y., Zhang, S., & Chen, K. (2022). RTMDet-Tiny: An empirical study of designing real-time object detectors. *arXiv*. https://arxiv.org/abs/2212.07784

National Oceanic and Atmospheric Administration Marine Debris Program. (2024). *Why is marine debris a problem?* National Oceanic and Atmospheric Administration.

National Oceanic and Atmospheric Administration Marine Debris Program. (2025). *Monitoring*. National Oceanic and Atmospheric Administration.

National Oceanic and Atmospheric Administration Marine Debris Program. (2025). *What is marine debris?* National Oceanic and Atmospheric Administration.

United Nations Environment Programme. (2021). *From pollution to solution: A global assessment of marine litter and plastic pollution*. United Nations Environment Programme.

Zhao, Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). DETRs beat YOLOs on real-time object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 16965–16974). IEEE. https://doi.org/10.1109/CVPR52733.2024.01605

Zhou, K., Liu, Z., Qiao, Y., Xiang, T., & Loy, C. C. (2023). Domain generalization: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *45*(4), 4396–4415. https://doi.org/10.1109/TPAMI.2022.3195549

Zou, Z., Chen, K., Shi, Z., Guo, Y., & Ye, J. (2023). Object detection in 20 years: A survey. *Proceedings of the IEEE*, *111*(3), 257–276. https://doi.org/10.1109/JPROC.2023.3238524

فصل سوم

روش‌شناسی پژوهش و طراحی آزمایش‌ها

3-1 مقدمه

این فصل روش‌شناسی پژوهش، ساختار و آماده‌سازی مجموعه‌داده، طراحی مقایسه سه آشکارساز، ساختار معماری مدل‌های مورد مطالعه، تنظیمات آموزش، محیط سخت‌افزاری و نرم‌افزاری، معیار انتخاب بهترین checkpoint و پروتکل ارزیابی را تشریح می‌کند. هدف اصلی پژوهش، مقایسه تجربی RT-DETR-L،YOLOv8n و RTMDet-Tiny در مسئله تشخیص چندکلاسه اشیای مرتبط با پسماندهای دریایی است.

طراحی آزمایش بر این اصل استوار است که متغیرهای اصلی مسئله و ارزیابی تا حد امکان ثابت باقی بمانند، در حالی که تنظیمات درون‌مدلی متناسب با ویژگی معماری و چارچوب نرم‌افزاری هر مدل حفظ و شفاف گزارش شوند. بنابراین، استفاده از dataset،taxonomy ،split و اندازه ورودی مشترک در کنار hyperparameterهای architecture-specific مبنای مقایسه قرار گرفته است.

3-2 طرح کلی پژوهش

چارچوب پژوهش از یک زنجیره مرحله‌ای تشکیل شده است: یکپارچه‌سازی و کنترل کیفیت داده‌ها، تثبیت taxonomy، ایجاد splitهای ثابت، آماده‌سازی قالب‌های سازگار با frameworkها، آموزش سه مدل، پایش validation، انتخاب checkpoint منتخب بر پایه mAP@0.50:0.95، ارزیابی مستقل Test، و در مراحل تکمیلی، تحلیل robustness، تغییر دامنه و سازگارسازی محدود.

منطق کلی را می‌توان چنین نمایش داد: داده‌های چندمنبعی ← کنترل کیفیت و taxonomy مشترک ← Train/Validation/Test ثابت ← آموزش مدل‌ها ← Validation و انتخاب Test ← checkpoint مستقل ← تحلیل دقت، پایداری، انتقال دامنه و هزینه محاسباتی.

3-3 مجموعه‌داده پژوهش

3-3-1 نسخه نهایی داده

نسخه نهایی مورد استفاده در آزمایش‌ها با نام trashcan_trash_icra19_AUGMENTED_MINOR_ONLY_V6_2_REPAIRED_VALIDATED تعریف شده است. ساختار اصلی شامل پوشه‌های images/train، images/val و images/test و پوشه‌های labels/train، labels/val و labels/test است. همچنین پوشه coco_annotations برای annotation سازگار با قالب COCO نگهداری شده است.

جدول 3-1. ساختار مجموعه‌داده و کارکرد اجزای آن

کارکرد	ساختار
تصاویر آموزش	images/train
تصاویر اعتبارسنجی	images/val
تصاویر آزمون	images/test
برچسب YOLO آموزش	labels/train
برچسب YOLO اعتبارسنجی	labels/val
برچسب YOLO آزمون	labels/test
annotation سازگار با COCO	coco_annotations
نسخه‌های پشتیبان annotation	labels_backup*
ردیابی اصلاحات برچسب	LABEL_REPAIR_AUDIT_
گزارش اصلاحات	LABEL_REPAIR_REPORT_
ممیزی و کنترل کیفیت نسخه نهایی	V6_2_AUDIT_

3-3-2 کنترل نسخه‌های داده و annotation

برای حفظ قابلیت ردیابی، چند نسخه پشتیبان از annotationها شامل labels_backup، labels_backup_before_split، labels_backup_compact و labels_backup_final نگهداری شده است.

همچنین پوشه‌های _LABEL_REPAIR_AUDIT و _LABEL_REPAIR_REPORT برای ثبت فرایند اصلاح و اعتبارسنجی مورد استفاده قرار گرفته‌اند.

در ساختار audit، موارد اصلاح یا نگاشت کلاسی از جمله animal_crab_TO_trash_plastic، animal_eel_TO_animal_etc و trash_unknown_instance_TO_trash_wreckage ثبت شده‌اند. این موارد باید در گزارش روش‌شناسی به‌عنوان تغییرات واقعی taxonomy/annotation مستند شوند و نسخه نهایی داده پس از تثبیت این تغییرات مبنای آموزش هر سه مدل باشد.

3-3-3 کنترل بصری و ممیزی داده

پوشه V6_2_AUDIT_ دارای زیرساخت‌هایی مانند CORRECTED_VISUAL_QA،ACTUAL_IMAGE_VISUAL_FORENSIC ، ROBUST_ACTUAL_FORENSIC،FINAL_VISUAL_QA و VISUAL_FORENSIC است و در آن نمونه‌های clipped،augmented و removed نیز ثبت شده‌اند. این ساختار، وجود یک مسیر ممیزی و کنترل بصری را نشان می‌دهد؛ اما حذف قطعی تمام near-duplicateها را صرفاً از روی نام پوشه نمی‌توان نتیجه گرفت و چنین ادعایی باید با گزارش کمی deduplication پشتیبانی شود.

3-4 فضای طبقه‌بندی

3-4-1 کلاس‌های نهایی

جدول 3-2. شناسه و کلاس‌های نهایی

کلاس	شناسه
animal_crab	0
animal_eel	1
animal_etc	2
animal_fish	3
animal_shells	4
animal_starfish	5
plant	6
trash_branch	7

8	trash_clothing
9	trash_net
10	trash_unknown_instance
11	trash_wreckage
12	trash_plastic

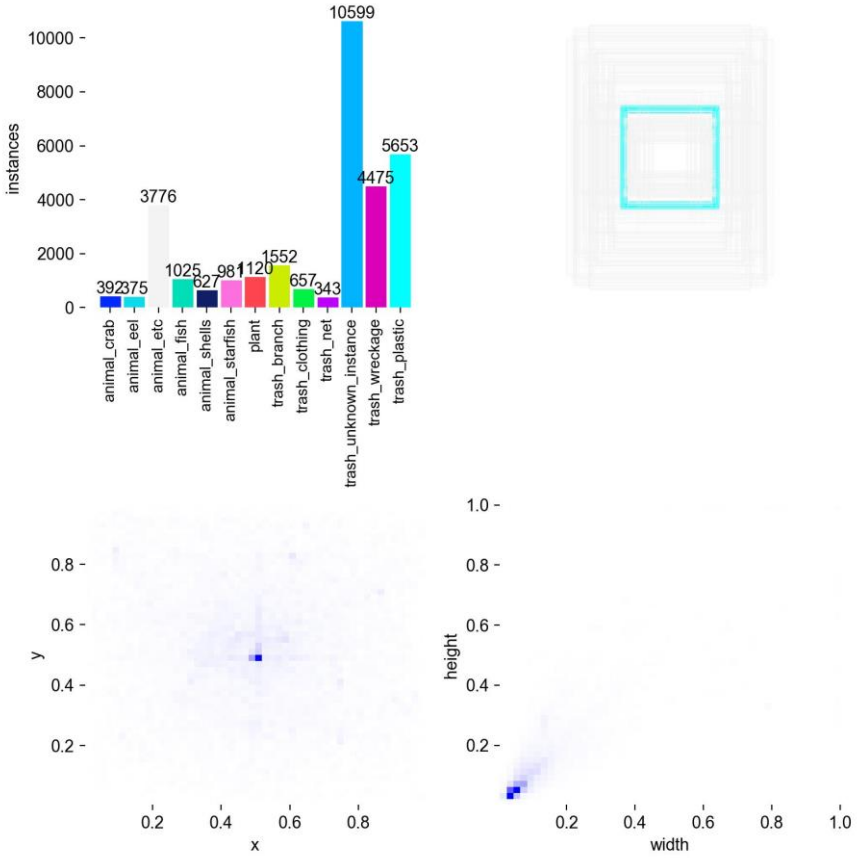
$C = 13$

تمام مدل‌ها دقیقاً با همین 13 کلاس آموزش داده شدند. ثابت‌بودن taxonomy از این جهت مهم است که تغییر تعداد یا معنای کلاس‌ها می‌تواند دشواری مسئله، توزیع خطا و معیارهای عملکرد را تغییر دهد.

علاوه بر نگاشت شناسه به نام کلاس، آمار توصیفی تعداد نمونه‌های هر کلاس (instances) در مجموعه Train یکپارچه و مشترک میان هر سه مدل (YOLOv8n، RT-DETR-L و RTMDet-Tiny) به شرح جدول زیر استخراج شده است. این آمار از تحلیل خودکار فایل‌های برچسب YOLO مجموعه Train به دست آمده است.

جدول تکمیلی. تعداد نمونه‌های هر کلاس در مجموعه Train مشترک (C = 13، جمع کل 31575 نمونه)

کلاس	تعداد نمونه (Train)
animal_crab	392
animal_eel	375
animal_etc	3776
animal_fish	1025
animal_shells	627
animal_starfish	981
plant	1120
trash_branch	1552
trash_clothing	657
trash_net	343
trash_unknown_instance	10599
trash_wreckage	4475
trash_plastic	5653
جمع کل	**31575**



نمودار تکمیلی. توزیع تعداد نمونه به تفکیک کلاس، جعبه‌های محدودکننده تجمیعی، و توزیع مکان/اندازه box boundingها در مجموعه Train مشترک

3-4-2 گروه‌بندی تحلیلی کلاس‌ها

برای تفسیر نتایج می‌توان کلاس‌ها را در گروه‌های جانوران دریایی، عناصر زیستی و پسماند/اشیای انسان‌ساخت مشاهده کرد. این گروه‌بندی صرفاً تحلیلی است و جایگزین ارزیابی 13 کلاسه نمی‌شود.

3-5 آماده‌سازی و کنترل کیفیت داده

کنترل کیفیت شامل بررسی سازگاری شناسه کلاس، ارتباط تصویر و annotation، معتبر بودن مختصات bounding box، و ثبت تغییرات در فایل‌های audit است. اصلاح annotation پیش از آموزش نهایی باید تثبیت شده باشد و هیچ اصلاح دستی مبتنی بر خروجی test پس از آغاز ارزیابی نهایی انجام نشود.

3-5-1 استقلال splitها و جلوگیری از leakage

Validation،Train و Test به‌صورت مستقل در ساختار داده نگهداری می‌شوند. با این حال، در داده‌های تصویری، استقلال کامل تنها با جداسازی نام فایل تضمین نمی‌شود؛ زیرا فریم‌های متوالی یا تصاویر نزدیک به هم می‌توانند اطلاعات مشابهی داشته باشند. از این رو، در صورت وجود توالی تصویربرداری مشترک، منشأ و وابستگی نمونه‌ها باید بررسی شود.

3-6 طراحی مقایسه کنترل‌شده

جدول 3-3. قواعد طراحی مقایسه کنترل‌شده

قاعده پژوهش	مولفه
یک نسخه نهایی مشترک	Dataset
13 کلاس مشترک	Taxonomy
Train/Validation/Test ثابت	Split
640×640	Input size
42 برای هر سه مدل	Seed
150	Maximum epochs
Validation mAP@0.50:0.95	Primary checkpoint metric
Validation mAP@0.50	Secondary metric
فقط ارزیابی نهایی	Test usage

تنظیمات داخلی مانند optimizer، learning rate، batch size، AMP و augmentation میان مدل‌ها الزاماً یکسان نیستند. این تفاوت‌ها architecture-specific هستند و باید همراه با نتایج گزارش شوند. بنابراین، واحد مقایسه در این پژوهش «پیکربندی اجرایی مشخص هر مدل در شرایط داده‌ای مشترک» است، نه مقایسه مدل‌هایی با ظرفیت یا recipe آموزشی کاملاً برابر.

3-7 اندازه ورودی و preprocessing

اندازه ورودی برای هر سه مدل 640×640 تعریف شد. این کنترل باعث می‌شود اثر مستقیم تغییر رزولوشن ورودی بر تشخیص اشیای کوچک و هزینه محاسباتی کاهش یابد. جزئیات resize یا padding داخلی می‌تواند میان frameworkها متفاوت باشد و در گزارش پیاده‌سازی باید شفاف باشد.

3-8 ساختار معماری YOLOv8n

3-8-1 نمای کلی

YOLOv8n نسخه Nano از خانواده YOLOv8n است. در پیاده‌سازی Ultralytics، اسکلت معماری را می‌توان در سه جزء اصلی Backbone،Neck و Detection Head خلاصه کرد. Backbone ویژگی‌های تصویری را در چند مقیاس استخراج می‌کند؛ Neck ویژگی‌های چندمقیاسی را ادغام می‌کند؛ و Head خروجی‌های تشخیص شامل مکان و کلاس را تولید می‌کند. در YOLOv8n،head از نوع anchor-free و decoupled است و برای رگرسیون جعبه و طبقه‌بندی شاخه‌های جداگانه دارد. این ساختار در مستندات رسمی معماری Ultralytics تشریح شده است. (Jocher et al., ۲۰۲۳)

3-8-2 Backbone

Backbone در YOLOv8n از بلوک‌های C2f برای استخراج و انتقال ویژگی استفاده می‌کند و اطلاعات را در چند سطح فضایی به سمت بخش بالادست شبکه منتقل می‌کند. در این معماری، downsampling تدریجی باعث می‌شود ویژگی‌های سطح بالا برای درک معنایی و ویژگی‌های با وضوح بالاتر برای اطلاعات مکانی در اختیار Neck قرار گیرند.

3-8-3 Neck

Neck وظیفه ادغام ویژگی‌های چندمقیاسی را بر عهده دارد و ساختار آن در خانواده YOLO از مسیرهای FPN/PAN برای انتقال اطلاعات معنایی و مکانی میان سطوح مختلف استفاده می‌کند. این بخش برای مسئله حاضر اهمیت دارد زیرا پسماندها می‌توانند از نظر اندازه ظاهری بسیار متفاوت باشند.

3-8-4 Detection Head

Head YOLOv8n از نوع anchor-free و decoupled است و پیش‌بینی‌های bounding box و classification را از روی ویژگی‌های چندمقیاسی تولید می‌کند. در این رویکرد، وابستگی به anchorهای از پیش تعریف‌شده حذف می‌شود. مشخصات این head در پیکربندی‌های رسمی Ultralytics مستند شده است. (Jocher et al., ۲۰۲۳)

3-8-5 جریان کلی پردازش

Image → Backbone → Multi-scale Features → FPN/PAN-style Neck → Anchor-free Detect Head → Boxes + Classes

در پژوهش حاضر، YOLOv8n به دلیل مقیاس سبک آن به‌عنوان یک configuration کم‌هزینه محاسباتی مورد مطالعه قرار گرفته است. بنابراین، نتایج آن باید همراه با محدودیت ظرفیت مدل و trade-off میان دقت و هزینه تحلیل شوند.

3-9 تنظیمات YOLOv8n

جدول 3-4. تنظیمات اصلی آموزشYOLOv8n

پارامتر	مقدار
Model	YOLOv8n
Classes	13
Max epochs	150
Batch size	16
Image size	640
Patience	20
Initial LR	0.001
Optimizer	Auto
Weight decay	0.0005
Momentum	0.937
Warmup	epoch 3
Seed	42
Deterministic	True
AMP	False
Workers	4
Save period	1

3-9-1 افزایش داده YOLOv8n

جدول 3-5. تنظیمات افزایش دادهYOLOv8n

مولفه	مقدار
Mosaic	فعال
MixUp	غیرفعال
Horizontal Flip	0.5
HSV-H	0.015
HSV-S	0.7
HSV-V	0.4
Translation	0.1
Scale	0.5
Close Mosaic	epoch 10 پایانی

در این mosaic،configuration در بخش پایانی آموزش غیرفعال می‌شود تا در آخرین مراحل آموزش سهم ترکیب‌های مصنوعی کاهش یابد. این سیاست باید دقیقاً همان‌گونه که در log یا configuration اجرا ثبت شده است گزارش شود.

3-10 ساختار معماری RT-DETR-L

3-10-1 جایگاه معماری

RT-DETR-L یک آشکارساز مبتنی بر Transformer و end-to-end است که با هدف رسیدن به تشخیص بلادرنگ طراحی شده است. مقاله اصلی RT-DETR-L از یک hybrid encoder کارآمد برای پردازش ویژگی‌های چندمقیاسی و سازوکار انتخاب query برای تولید queryهای باکیفیت برای decoder استفاده می‌کند و بر کاهش وابستگی به NMS تأکید دارد. [Zhao et al., 2024]

3-10-2 Backbone و hybrid encoder

ویژگی‌های استخراج‌شده در مقیاس‌های مختلف وارد encoder می‌شوند. در RT-DETR-L، طراحی hybrid encoder برای تفکیک پردازش درون‌مقیاس و ادغام بین‌مقیاس طراحی شده است تا هزینه attention

کاهش یابد و سرعت افزایش پیدا کند. این بخش یکی از تفاوت‌های بنیادی آن با آشکارسازهای متراکم CNNمحور است. [Zhao et al., 2024]

Query selection 3-10-3

پس از پردازش ویژگی‌ها، مکانیزم query selection برای انتخاب queryهای اولیه با کیفیت مناسب به کار می‌رود. این queryها ورودی decoder را تشکیل می‌دهند و در نهایت به پیش‌بینی مجموعه‌ای از اشیای موجود در تصویر منجر می‌شوند. [Zhao et al., 2024]

Transformer decoder 3-10-4 و خروجی

Transformer decoder queryها را با ویژگی‌های تصویری ترکیب می‌کند و مجموعه‌ای از پیش‌بینی‌ها را تولید می‌کند. رویکرد set prediction باعث می‌شود مدل به سمت پیش‌بینی end-to-end حرکت کند و نیاز به برخی مراحل سنتی detectorهای متراکم کاهش یابد.

Image → Backbone Features → Hybrid Encoder → Query Selection → Transformer Decoder → Object Predictions

3-11 تنظیمات RT-DETR-L

جدول 3-6. تنظیمات اصلی آموزشRT-DETR-L

پارامتر	مقدار
Model	RT-DETR-L
Weights	rtdetr-l.pt
Classes	13
Max epochs	150
Batch size	6
Image size	640
Patience	20
Optimizer	AdamW
Initial LR	0.0001
Weight decay	0.0005
Scheduler	Cosine LR

lrf	0.01
Warmup	epoch 2
Seed	42
AMP	True
Cache	Disk
Workers	2
Device	GPU 0
Pretrained	True
Save period	1

3-11-1 AMP و حافظه

به دلیل نیاز حافظه‌ای بالاتر، batch size برابر 6 تنظیم شد. AMP فعال بود تا هزینه حافظه و محاسبات کاهش یابد. در گزارش reproducibility، این تفاوت با YOLOv8n باید به‌طور شفاف ثبت شود.

3-11-2 Resume

در صورت استفاده از resume، آن را باید از انتخاب best checkpoint تفکیک کرد: resume برای ادامه یک اجرای قطع‌شده است، در حالی که best checkpoint وزن نهایی انتخاب‌شده از میان وضعیت‌های آموزشی بر اساس validation است.

3-12 ساختار معماری RTMDet-Tiny

3-12-1 نمای کلی

RTMDet-Tiny یک آشکارساز بلادرنگ از اکوسیستم OpenMMLab است که در configuration مورد استفاده از CSPNeXt به‌عنوان backbone، CSPNeXtPAFPN به‌عنوان neck و RTMDet-TinySepBNHead به‌عنوان detection head بهره می‌برد. تنظیمات ثبت‌شده شامل Widen Factor، P5 برابر 0.375 و Deepen Factor برابر 0.167 است.

Backbone: CSPNeXt 3-12-2

CSPNeXt backbone وظیفه استخراج ویژگی‌های سلسله‌مراتبی را بر عهده دارد. استفاده از scaling در عرض و عمق باعث ایجاد نسخه Tiny با ظرفیت کمتر و هزینه پایین‌تر نسبت به نسخه‌های بزرگ‌تر می‌شود.

Neck: CSPNeXtPAFPN 3-12-3

CSPNeXtPAFPN ویژگی‌های چندمقیاسی را برای انتقال اطلاعات معنایی و مکانی میان سطوح مختلف ادغام می‌کند. این بخش در تشخیص اشیایی با مقیاس متفاوت، از جمله اشیای کوچک، نقش مهمی دارد.

Detection Head 3-12-4

RTMDet-TinySepBNHead خروجی‌های تشخیص را از ویژگی‌های چندمقیاسی تولید می‌کند. ساختار head و نحوه post-processing در MMDetection با تنظیمات configuration قابل کنترل است.

Image → CSPNeXt Backbone → CSPNeXtPAFPN → RTMDet-TinySepBNHead → Detection Outputs

3-13 تنظیمات RTMDet-Tiny

جدول 3-7. تنظیمات اصلی آموزش RTMDet-Tiny

پارامتر	مقدار
Model	RTMDet-Tiny
Classes	13
Max epochs	150
Actual batch	4
Gradient accumulation	4
Effective batch	16
Image size	640×640
Optimizer	AdamW
Learning rate	0.0001
Weight decay	0.0005
Gradient clip	35
Seed	42

AMP	True
Validation interval	epoch 1

3-13-1 تجمع گرادیان

$$B_{effective} = 4 \times 4 = 16$$

batch مؤثر 16 به این معناست که گرادیان چهار mini-batch با اندازه 4 پیش از update تجمع می‌یابد. این حالت از نظر memory و رفتار normalization با batch واقعی 16 یکسان نیست و باید به همین شکل در تفسیر نتایج گزارش شود.

Scheduler 3-13-2

warmup خطی در 500 iteration و سپس CosineAnnealingLR با Tmax برابر 150 و eta_min برابر 1e-6 ثبت شده است. چون warmup این مدل بر حسب iteration و برخی تنظیمات مدل‌های دیگر بر حسب epoch گزارش شده‌اند، این مقادیر را نباید از نظر عددی به‌صورت مستقیم معادل‌سازی کرد.

3-13-3 افزایش داده و inference

pipeline ثبت‌شده شامل Cached Mosaic، Random Resize، Random Crop، YOLOX HSV Random Augmentation، Random Horizontal Flip، Padding و Cached MixUp است. برای Random Resize، ratio_range=(0.5,2.0) گزارش شده است. تنظیمات post-processing شامل NMS با IoU=0.65، score threshold=0.001 و max_per_img=300 است.

3-14 جدول مقایسه معماری و تنظیمات اصلی

جدول 3-8. مقایسه معماری و تنظیمات اصلی سه مدل

ویژگی	YOLOv8n	RT-DETR-L	RTMDet-Tiny
Family	YOLO	DETR/Transformer	RTMDet-Tiny/CNN
Scale	Nano	Large	Tiny
Backbone	C2f-based YOLOv8n backbone	Backbone + hybrid encoder	CSPNeXt
Feature fusion	FPN/PAN-style neck	Hybrid encoder /	CSPNeXtPAFPN

		multi-scale processing	
Head	Anchor-free decoupled Detect	Transformer decoder / set prediction	RTMDet-TinySepBNHead
Framework	Ultralytics	Ultralytics	MMDetection
Input	640×640	640×640	640×640
Batch	16	6	4
Effective batch	16	6	16
LR	0.001	0.0001	0.0001
Seed	42	42	42
AMP	False	True	True
Primary checkpoint metric	val mAP50-95	val mAP50-95	val mAP50-95

به دلیل تفاوت مقیاس مدل‌ها، جدول فوق نباید به‌عنوان مقایسه parameter-matched تفسیر شود. نتیجه‌گیری‌ها باید به configurationهای مشخص مورد مطالعه نسبت داده شوند.

3-15 انتخاب بهترین checkpoint

برای هر سه مدل، معیار اصلی انتخاب بهترین checkpoint،mAP@0.50:0.95 روی مجموعه Validation است. mAP@0.50 به‌عنوان معیار ثانویه برای گزارش و تحلیل مورد استفاده قرار می‌گیرد.

$$e^* = \text{argmax}_e \left[\text{mAP_val@0.50:0.95}(e) \right]$$

بنابراین checkpoint منتخب، وضعیت مدلی است که در میان epochها بیشترین mAP@0.50:0.95 را روی Validation کسب کرده است. Test در این انتخاب دخالت ندارد و تنها پس از نهایی‌شدن مدل برای ارزیابی مستقل استفاده می‌شود.

برای مدل‌های مبتنی بر Ultralytics (YOLOv8n و RT-DETR-L)، checkpoint نهایی منتخب هر مدل با نام فایل best.pt در پوشه اجرای همان مدل (weights/best.pt) ذخیره شده است؛ این فایل، وزن مرتبط با epoch منتخب بر اساس بیشترین mAP@0.50:0.95 روی Validation را در بر می‌گیرد و مجزا از last.pt (آخرین epoch آموزش، صرف‌نظر از عملکرد) نگهداری می‌شود.

برای RTMDet-Tiny که با چارچوب MMDetection آموزش دیده است، ساختار نام‌گذاری checkpoint متفاوت است: CheckpointHook این چارچوب به‌صورت پیش‌فرض بهترین وزن را بر اساس معیار پایش‌شده (در این پژوهش، mAP@0.50:0.95 روی Validation) با الگوی نام best_<معیار>_epoch_<N>.pth ذخیره می‌کند، نه best.pt. بر اساس رکوردهای آموزش گزارش‌شده در فصل چهارم، checkpoint منتخب RTMDet-Tiny مربوط به epoch 146 است.

3-16 معیارهای ارزیابی

3-16-1 Precision و Recall

$$\text{Precision} = TP / (TP + FP)$$

$$\text{Recall} = TP / (TP + FN)$$

$$F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

برای تعیین TP در تطبیق پیش‌بینی‌ها با برچسب واقعی (Truth Ground) در تمام ارزیابی‌های این پژوهش (H1 و H2)، آستانه IoU برابر با 0.50 در نظر گرفته شده است؛ یعنی یک پیش‌بینی تنها زمانی TP محسوب می‌شود که هم‌کلاس با یک GT بی‌جفت باشد و IoU میان آن دو حداقل 0.50 باشد. پیش از تطبیق، پیش‌بینی‌هایی با امتیاز اطمینان (confidence) کمتر از آستانه 0.25 حذف می‌شوند. تطبیق به‌صورت کلاس‌آگاه (class-aware) و یک‌به‌یک انجام می‌شود؛ هر پیش‌بینی و هر GT حداکثر یک‌بار جفت می‌شوند و در صورت وجود چند نامزد تطبیق، جفتی با بیشترین IoU در اولویت قرار می‌گیرد. Precision، Recall و F1 در سطح هر تصویر بر همین مبنا محاسبه شده‌اند.

3-16-2 IoU

$$\text{IoU} = \text{Area}(B_{pred} \cap B_{gt}) / \text{Area}(B_{pred} \cup B_{gt})$$

3-16-3 AP و mAP

$$C = 13، mAP = (1 / C) \Sigma AP_c$$

3-16-4 mAP@0.50 و mAP@0.50:0.95

mAP@0.50 عملکرد را در آستانه IoU برابر 0.50 خلاصه می‌کند. mAP@0.50:0.95 میانگین عملکرد در آستانه‌های 0.50، 0.55،...، 0.95 است و به دلیل سخت‌گیری بیشتر در localization معیار اصلی انتخاب checkpoint در این پژوهش است.

3-17 روش آزمون فرضیه‌های پژوهش

آزمون فرضیه‌های پژوهش به‌صورت مرحله‌ای و با استفاده از یک پروتکل مشترک ارزیابی طراحی شد. در این پروتکل، سه مدل RT-DETR-L،YOLOv8n و RTMDet-Tiny با taxonomy نهایی 13 کلاسه و splitهای ثابت Validation،Train و Test بررسی می‌شوند. مدل‌ها پس از آموزش و انتخاب checkpoint بر اساس mAP@0.50:0.95 در مجموعه Validation، در شرایط تعریف‌شده برای هر فرضیه ارزیابی می‌شوند. مجموعه Test در هیچ مرحله‌ای برای انتخاب مدل، تنظیم ابرپارامتر یا انتخاب checkpoint وارد فرآیند تصمیم‌گیری نمی‌شود.

منطق آزمون فرضیه‌ها بر تفکیک چهار سؤال تجربی استوار است: H1 برای مقایسه عملکرد پایه، H2 برای سنجش پایداری در برابر اغتشاشات تصویری کنترل‌شده، H3 برای اندازه‌گیری افت عملکرد در شرایط تغییر دامنه، و H4 برای بررسی اثر سازگارسازی محدود مدل منتخب با دامنه هدف. بنابراین، هر فرضیه واحد مقایسه، شرایط ورودی، شاخص اصلی و روش تحلیل مشخصی دارد.

3-17-1 آزمون فرضیه اول (H1): مقایسه عملکرد پایه

در H1، هر سه مدل بدون اعمال corruption مصنوعی یا adaptation و با checkpoint منتخب خود روی یک مجموعه آزمون مشترک ارزیابی می‌شوند. برای هر مدل، Precision،Recall، F1-score، mAP@0.50 و mAP@0.50:0.95 استخراج شده و مقایسه اصلی بر مبنای عملکرد حاصل از داده‌های یکسان انجام می‌گیرد.

برای تحلیل زوجی در سطح تصویر، مقدار F1-score حاصل از دو مدل برای همان تصویر با یکدیگر مقایسه می‌شود. از آنجا که تصاویر مورد ارزیابی برای مدل‌های مختلف مشترک‌اند و نرمال بودن اختلاف‌ها فرض نمی‌شود، مقایسه‌های زوجی با آزمون Wilcoxon signed-rank انجام می‌گیرد. در صورت انجام چند مقایسه هم‌زمان، اصلاح خطای ناشی از تعدد آزمون‌ها اعمال می‌شود.

3-17-2 آزمون فرضیه دوم (H2): ارزیابی پایداری در برابر اغتشاشات کنترل‌شده

در H2، هر تصویر پایه با نسخه‌های دارای تغییرات تصویری از پیش تعریف‌شده مقایسه می‌شود و ground truth در همه شرایط ثابت باقی می‌ماند. برای هر مدل، عملکرد در حالت پاک و حالت اغتشاش‌یافته در سطح تصویر محاسبه می‌شود.

میزان افت عملکرد با رابطه $\Delta M = M_clean - M_condition$ محاسبه می‌شود؛ در نتیجه مقدار کوچک‌تر ΔM نشان‌دهنده حفظ بهتر عملکرد تحت آن شرط است. برای گزارش درصدی نیز می‌توان از رابطه $Drop(\%) = [(M_clean - M_condition) / M_clean] \times 100$ استفاده کرد. نوع corruption، شدت، روش تولید و seed باید پیش از ارزیابی نهایی ثابت و ثبت شده باشند.

3-17-3 آزمون فرضیه سوم (H3): ارزیابی تغییر دامنه

در H3، عملکرد مدل‌های آموزش‌دیده در دامنه مبدأ در برابر مجموعه شرایط تغییر دامنه ارزیابی می‌شود. شرایط مورد استفاده شامل تغییرات کنترل‌شده در رنگ، روشنایی و گاما، تغییرات هندسی مانند چرخش، مقیاس و shear و همچنین سناریوی تغییر دامنه تصویربرداری ساحلی/UAV است. این شرایط به‌عنوان سناریوهای مشخص انتقال از توزیع مبدأ به توزیع هدف در نظر گرفته می‌شوند.

برای هر تصویر و هر شرط، عملکرد مدل در دامنه مبدأ و شرط هدف مقایسه می‌شود و افت دامنه به‌صورت $\Delta M_domain = M_source - M_target$ محاسبه می‌گردد. تحلیل هم در سطح کلی مجموعه شرایط و هم در سطح هر شرط انجام می‌شود تا مشخص شود برتری یک معماری فقط ناشی از یک سناریوی خاص نیست.

3-17-4 قاعده انتخاب مدل برای مرحله H4

مدل واردشونده به مرحله H4 پیش از مشاهده نتیجه آزمون نهایی دامنه هدف انتخاب می‌شود. قاعده انتخاب بر اساس شواهد حاصل از مراحل قبلی، یعنی عملکرد پایه و پایداری در شرایط تغییر یافته، تعریف می‌شود. برای جلوگیری از انتخاب مبتنی بر Test، داده‌های آزمون هدف در این تصمیم‌گیری استفاده نمی‌شوند.

برای خلاصه‌سازی رتبه‌بندی مراحل H1 تا H3 می‌توان از مجموع رتبه‌ها به‌صورت $R_total = R_H1 + R_H2 + R_H3$ استفاده کرد؛ در این تعریف، رتبه کمتر بیانگر جایگاه بهتر است. در کنار مجموع رتبه‌ها، تعداد رتبه‌های اول و میانگین رتبه نیز به‌عنوان شواهد کمکی بررسی می‌شوند. این قاعده به معنای برتری مطلق یک مدل در همه ابعاد نیست، بلکه مبنای ازپیش‌تعریف‌شده انتخاب برای H4 است.

3-17-5 آزمون فرضیه چهارم (H4): سازگارسازی محدود دامنه

پس از انتخاب مدل، یک مرحله سازگارسازی محدود با داده هدفِ ازپیش‌تعریف‌شده اجرا می‌شود. مقدار و نوع داده مورد استفاده برای adaptation، وضعیت برچسب‌ها، تعداد دوره‌های آموزشی و سایر تنظیمات باید پیش از اجرای آزمون تثبیت و مستندسازی شوند. مدل پایه و مدل سازگارشده با سایر شرایط ارزیابی یکسان روی مجموعه آزمون هدف مقایسه می‌شوند.

برای هر تصویر، تغییر عملکرد از رابطه $\Delta F1_i = F1_adapted,i - F1_base,i$ محاسبه می‌شود. مقدار مثبت نشان‌دهنده بهبود و مقدار منفی نشان‌دهنده افت عملکرد پس از سازگارسازی است. مقایسه زوجی قبل و بعد از adaptation با آزمون Wilcoxon signed-rank انجام می‌شود و در کنار مقدار p، اندازه اثر و در صورت اجرای bootstrap، فاصله اطمینان 95 درصد گزارش خواهد شد.

3-17-6 روش تحلیل آماری و تصمیم‌گیری درباره فرضیه‌ها

سطح معناداری آماری $\alpha = 0.05$ در نظر گرفته می‌شود. چون داده‌های مقایسه‌ای برای مدل‌های مختلف روی تصاویر یکسان به‌دست می‌آیند، واحد اصلی تحلیل زوج‌های متناظر در سطح تصویر است. در گزارش نتایج، علاوه بر معناداری آماری، اندازه اثر و در صورت امکان فاصله اطمینان گزارش می‌شود تا نتیجه‌گیری فقط به مقدار p وابسته نباشد.

تصمیم درباره تأیید یا رد هر فرضیه در فصل چهارم و بر اساس خروجی‌های آزمون آماری، اندازه اثر و معیارهای عملکرد انجام خواهد شد. فصل سوم تنها منطق آزمون، متغیرها، شرایط اجرا و قواعد تصمیم‌گیری را مشخص می‌کند و از درج نتیجه عددی یا تفسیر نهایی یافته‌ها در این فصل خودداری می‌شود.

3-18 تحلیل عملکرد کلاس‌به‌کلاس

برای جلوگیری از پنهان‌شدن رفتار کلاس‌های کم‌نمونه در میانگین کلی، AP هر کلاس، تعداد instanceها، و در صورت امکان precision و recall کلاس‌به‌کلاس گزارش می‌شوند. این تحلیل باید هنگام تفسیر عدم توازن کلاس‌ها و خطاهای confusion به کار رود.

3-19 ارزیابی robustness

در ارزیابی robustness، مدل منتخب هر معماری در شرایط پایه و سپس تحت تغییرات تصویری کنترل‌شده آزمون می‌شود. ساختار تحلیل می‌تواند به‌صورت Architecture × Corruption × Severity تعریف شود. در این

مرحله ground truth باید ثابت باقی بماند مگر آنکه یک transform هندسی به‌صورت ضروری مختصات annotation را نیز تغییر دهد.

$$\Delta M = M_clean - M_condition$$

$$Drop(\%) = [(M_clean - M_condition) / M_clean] \times 100$$

برای گزارش نهایی، نوع corruption، شدت، نحوه تولید، و seed باید دقیقاً مطابق اجرای واقعی مستند شود. corruption مصنوعی نباید معادل مستقیم با تمام تخریب‌های واقعی محیط دریایی تلقی شود؛ بلکه proxy برای شرایط انتخاب‌شده است.

3-20 ارزیابی تغییر دامنه

در ارزیابی cross-domain، داده مبدأ و هدف از یکدیگر تفکیک می‌شوند. مدل بدون adaptation روی دامنه هدف آزمون می‌شود تا مقدار افت ناشی از انتقال اندازه‌گیری شود. عملکرد مبدأ و هدف باید با همان checkpoint منتخب پایه مقایسه شوند.

$$\Delta M_domain = M_source - M_target$$

$$Drop_domain(\%) = [(M_source - M_target) / M_source] \times 100$$

در این مرحله، Test هدف نباید برای تنظیم checkpoint،model یا hyperparameter استفاده شود. همچنین cross-domain evaluation از domain adaptation متمایز است، زیرا در حالت اول اطلاعات هدف وارد به‌روزرسانی مدل نمی‌شود.

3-21 سازگارسازی محدود دامنه

پس از تعیین baseline بدون adaptation، در صورت اجرای مرحله سازگارسازی، مدل منتخب با استفاده از مقدار محدود و ازپیش‌تعریف‌شده‌ای از اطلاعات دامنه هدف تطبیق داده می‌شود. برای حفظ اعتبار آزمون، target adaptation data،target validation data در صورت وجود، و target test data باید نقش‌های جداگانه داشته باشند.

$$\Delta M_adapt = M_after - M_before$$

در صورت استفاده از شاخص recovery، می‌توان مقدار بازیابی افت را نسبت به فاصله بین عملکرد منبع و عملکرد مقصد پیش از adaptation محاسبه کرد. روش دقیق adaptation، مقدار داده هدف و وضعیت برچسب‌ها باید بر اساس اجرای واقعی پژوهش گزارش شوند.

3-22 انتخاب مدل برای adaptation

مدل واردشونده به adaptation نباید بر اساس عملکرد Test هدف انتخاب شود. قاعده انتخاب باید قبل از مشاهده نتیجه Test نهایی باشد؛ برای مثال بر مبنای validation و معیار اصلی checkpoint. این اصل از model-selection bias و test leakage جلوگیری می‌کند.

3-23 کارایی محاسباتی

در کنار دقت، شاخص‌های محاسباتی مانند تعداد پارامترها، اندازه مدل، GFLOPs، latency، FPS و مصرف حافظه GPU در صورت اندازه‌گیری معتبر گزارش می‌شوند. latency و FPS باید با شرایط benchmark مشخص، شامل سخت‌افزار، image size، batch، precision، warm-up و تعداد تکرارها گزارش شوند.

3-24 محیط سخت‌افزاری

آموزش مدل‌ها روی NVIDIA GeForce RTX 3060 Laptop GPU انجام شده است. محدودیت حافظه GPU موجب تفاوت batch size شد: YOLOv8n با 16، RT-DETR-L با 6 و RTMDet-Tiny با batch واقعی 4 اجرا شدند. برای RTMDet-Tiny از gradient accumulation برابر 4 استفاده شد.

3-25 محیط نرم‌افزاری Ultralytics

جدول 3-9. نسخه‌های محیط نرم‌افزاری Ultralytics وPyTorch

مولفه	مقدار ثبت‌شده
Python	3.13.2
Ultralytics	8.4.37
PyTorch	2.13.0+cu126 (طبق ثبت موجود)
TorchVision	0.28.0+cu126
OpenCV-Python	4.13.0.92
CUDA Build	12.6

نسخه‌های نرم‌افزار باید پیش از تحویل نهایی با خروجی مستقیم محیط اجرای واقعی تطبیق داده شوند، زیرا ثبت نادرست نسخه می‌تواند reproducibility را مختل کند.

3-26 محیط نرم‌افزاری MMDetection

جدول 3–10. نسخه‌های محیط نرم‌افزاری MMDetection وMMEngine

مولفه	نسخه
Python	3.11.9
PyTorch	cu121+2.1.0
TorchVision	cu121+0.16.0
MMEngine	0.10.7
MMCV	2.1.0
MMDetection	3.3.0
CUDA Build	12.1

RTMDet-Tiny در محیط مستقل MMDetection اجرا شد. تفاوت دو محیط نرم‌افزاری باید هنگام تحلیل latency،AMP و reproducibility در نظر گرفته شود.

3-27 کنترل بازتولیدپذیری

برای بازتولید نتایج باید taxonomy،dataset YAML نهایی، splitها، model configuration، وزن اولیه، batch،input size واقعی و مؤثر، checkpoint، seed، augmentation، learning rate،optimizer منتخب، log آموزش و نسخه کامل محیط نرم‌افزاری نگهداری شوند. برای هر سه مدل seed برابر 42 بوده است.

پیشنهاد می‌شود checksum یا شناسه نسخه برای snapshot نهایی dataset نیز نگهداری شود تا مشخص باشد نتایج دقیقاً مربوط به کدام نسخه داده هستند.

3-28 کنترل تصادفی‌بودن

استفاده از seed مشترک 42 کنترل بخشی از تصادفی‌بودن را فراهم می‌کند، اما یک اجرای منفرد را نمی‌توان معادل برآورد واریانس چند اجرای مستقل دانست. در صورت محدودبودن آزمایش‌ها به یک run، این مسئله باید در فصل بحث و محدودیت‌ها ذکر شود.

3-29 استقلال مجموعه آزمون

مجموعه Test پس از نهایی‌شدن configuration و checkpoint فقط برای ارزیابی نهایی استفاده می‌شود. استفاده از Test برای انتخاب checkpoint، تنظیم hyperparameter، انتخاب مدل یا اصلاح داده موجب نشت اطلاعات و کاهش اعتبار ارزیابی خواهد شد.

3-30 پروتکل ارزیابی نهایی

پس از انتخاب بهترین checkpoint بر اساس mAP@0.50:0.95 روی Validation، مدل روی Test مستقل اجرا می‌شود. mAP@0.50، Recall،Precision و mAP@0.50:0.95 به‌عنوان معیارهای اصلی گزارش می‌شوند و در صورت امکان AP کلاس‌به‌کلاس و شاخص‌های محاسباتی نیز ارائه خواهند شد.

3-31 تحلیل آماری و محدودیت روش‌شناسی

اگر فقط یک اجرای seed=42 برای هر مدل وجود داشته باشد، تفاوت مشاهده‌شده میان مدل‌ها باید به‌عنوان نتیجه تجربی یک configuration مشخص گزارش شود و نباید بدون replication کافی به تفاوت قطعی واریانس تصادفی نسبت داده شود. در صورت چند اجرای مستقل، میانگین، انحراف معیار و بازه عدم‌قطعیت می‌تواند گزارش شود.

محدودیت‌های اصلی این طراحی عبارت‌اند از تفاوت مقیاس مدل‌ها، تفاوت recipeهای آموزشی، استفاده از یک seed اصلی، وابستگی احتمالی میان تصاویر نزدیک، تفاوت frameworkها و وابستگی benchmark سرعت به سخت‌افزار و محیط اجرا. این محدودیت‌ها باید در فصل چهارم و پنجم هنگام تفسیر نتایج لحاظ شوند.

3-32 جدول خلاصه پروتکل تجربی

جدول 3-11. خلاصه پروتکل و تصمیم‌های روش‌شناختی پژوهش

تصمیم روش‌شناختی	مرحله
سه مدل روی dataset مشترک	Baseline training
بیشترین Validation mAP@0.50:0.95	Checkpoint selection
mAP@0.50:0.95	Primary reported metric
mAP@0.50	Secondary reported metric
AP و در صورت امکان precision/recall هر کلاس	Class analysis

Robustness	مقایسه clean با corruptionهای تعریف‌شده
Domain shift	Source→Target بدون adaptation
Adaptation	فقط مدل منتخب؛ با Test مستقل
Final test	فقط پس از قفل‌شدن configuration
Reproducibility	Seed=42 + ثبت کامل محیط و configuration

3-33 جمع‌بندی فصل

در این فصل، روش‌شناسی پژوهش و طراحی آزمایش برای مقایسه RT-DETR-L،YOLOv8n و RTMDet-Tiny تشریح شد. داده نهایی دارای 13 کلاس و splitهای ثابت Validation،Train و Test است و نسخه‌های audit،backup و کنترل کیفی برای ردیابی تغییرات annotation نگهداری شده‌اند.

سه مدل با اندازه ورودی 640×640، seed=42 و سقف 150 epoch در configurationهای ثبت‌شده آموزش داده شدند. به دلیل تفاوت معماری و optimizer،framework ،learning rate ،batch size ،AMP و برخی augmentationها یکسان نیستند و به عنوان تنظیمات اختصاصی مدل گزارش شده‌اند. ساختار معماری هر سه شبکه نیز برای مشخص‌شدن ماهیت مقایسه در این فصل ارائه شده است.

معیار اصلی انتخاب بهترین checkpoint در هر سه مدل، mAP@0.50:0.95 روی Validation است و mAP@0.50 نقش معیار ثانویه را دارد. Test از همه تصمیم‌های آموزشی مستقل نگه داشته می‌شود. این طراحی زمینه لازم را برای تحلیل عملکرد پایه، robustness، انتقال بین‌دامنه‌ای، adaptation و کارایی محاسباتی در فصل چهارم فراهم می‌کند؛ مشروط بر آنکه جزئیات سناریوهای robustness و adaptation دقیقاً مطابق اجرای واقعی پژوهش گزارش شوند.

فصل چهارم

یافته‌ها، تحلیل نتایج و آزمون فرضیه‌ها

4-1مقدمه

در این فصل، نتایج حاصل از اجرای چارچوب تجربی پژوهش ارائه و تحلیل می‌شود. هدف اصلی فصل، پاسخ‌گویی تجربی به پرسش‌های پژوهش و بررسی چهار محور شامل مقایسه عملکرد پایه مدل‌ها، مقاومت در برابر تخریب‌های تصویری، مقاومت در برابر جابه‌جایی دامنه و اثر سازگارسازی دامنه است.

سه مدلYOLOv8n ، RT-DETR-L و RTMDet-Tiny در چارچوب ارزیابی تعریف‌شده و با تقسیم‌بندی آزمون مشترک مورد بررسی قرار گرفتند. تحلیل‌های فرضیه‌ای عمدتاً بر F1-score در سطح تصویر و تغییر آن نسبت به شرایط مرجع استوار است. در اجرای اصلی از Seed برابر 42 و اندازه ورودی 640×640 استفاده شد. آموزش مدل‌ها نیز روی NVIDIA GeForce RTX 3060 Laptop GPU با حافظه 6 گیگابایت انجام شد.

ساختار فصل مطابق ترتیب فرضیه‌های H1 تا H4 تنظیم شده است. ابتدا عملکرد پایه، سپس robustness در برابر تخریب‌های کنترل‌شده، سپس رفتار تحت تغییر دامنه و در پایان نتیجه سازگارسازی مدل منتخب بررسی می‌شود. در پایان، نتایج از نظر علمی، محدودیت شواهد و وضعیت فرضیه‌ها جمع‌بندی خواهد شد.

4-2کنترل و ساختار داده‌های مورد استفاده در تحلیل

برای انجام مقایسه تجربی، ارزیابی‌ها بر روی مجموعه آزمونی با تقسیم‌بندی ثابت انجام شد تا تغییرات مشاهده‌شده تا حد امکان ناشی از تفاوت مدل یا شرایط آزمایش باشد و نه تغییر نمونه‌های مورد ارزیابی.

درH1 ، تعداد 2462 تصویر مشترک میان سه مدل استفاده شد و برای هر تصویر یک مقدار F1 در سطح تصویر استخراج گردید؛ در نتیجه 7386 مشاهده برای سه مدل ایجاد شد.

درH2 ، برای هر یک از 2462 تصویر، شش نوع تخریب شامل روشنایی، کنتراست، نویز گاوسی، تاری گاوسی، تاری حرکتی و فشرده‌سازی JPEG اعمال شد. این ساختار برای هر مدل 14772 مشاهده و در مجموع 44316 مشاهده ایجاد کرد.

یک شرط تغییر دامنه واقعی با عنوان uav_coastal_domain_shift بررسی شد

4-3نتایج فرضیه اول: مقایسه عملکرد پایه مدل‌ها(H1)

4-3-1هدفH1

هدف H1 مقایسه عملکردYOLOv8n ، RT-DETR-L و RTMDet-Tiny در شرایط پایه و بر روی تصاویر آزمون بدون اعمال تغییرات مصنوعی بود. معیار اصلی تحلیل، F1-score در سطح تصویر است تا Precision و Recallبه‌صورت هم‌زمان و در قالب یک معیار متوازن بررسی شوند.

تعداد مشاهدات H1 برابر با 7386 مورد بود که شامل 2462 تصویر برای هر مدل است.

4-3-2آمار توصیفی عملکرد مدل‌ها

جدول ۴-۱. Precision، Recall و mAP مدل‌ها در ارزیابی H۱

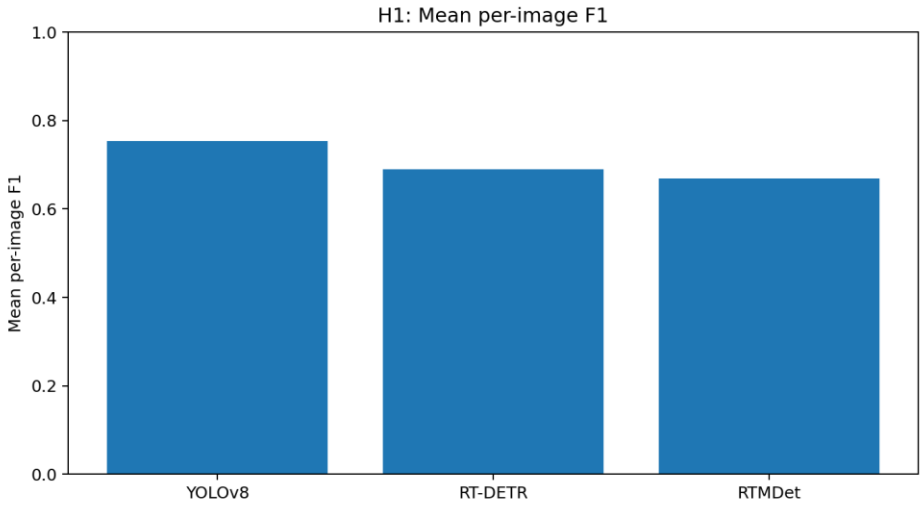
مدل	خروجی ارزیابی H1	Precision	Recall	mAP@0.50	mAP@0.50:0.95
YOLOv8n	2462تصویر مشترک آزمون	0.753039	0.778625	0.596348	0.412885
RT-DETR-L	2462تصویر مشترک آزمون	0.605565	0.914699	0.673446	0.466551
RTMDet-Tiny	2462تصویر مشترک آزمون	0.588914	0.880537	0.622064	0.411560

یادداشت :مقادیر جدول صرفاً از رکوردهای واقعی موجود در لاگ‌های آموزش استخراج شده‌اند .برای-RT DETR-L، رکوردهای قابل مشاهده در فایل ارائه‌شده تا epoch 33 ادامه دارند و ازepoch های مفقود داده‌سازی یا بازسازی عددی انجام نشده است .درRTMDet-Tiny ، رکورد گزارش‌شده مربوط به بهترین checkpoint در epoch 146است.

نتایج نشان داد YOLOv8n با میانگین F1 برابر 0.754021 بالاترین عملکرد پایه را به دست آورده است. میانگین F1 برای RT-DETR-L برابر 0.689369 و برای RTMDet-Tiny برابر 0.668807 بود. میانه F1 برای YOLOv8nبرابر 1.000000 و برای دو مدل دیگر 0.666667 گزارش شد.

جدول ۴-۲. آمار توصیفی F۱ در شرایط پایه

مدل	تعداد تصویر	میانگینF1	میانهF1	انحراف معیار
YOLOv8n	2462	0.754021	1.000000	0.368372
RT-DETR-L	2462	0.689369	0.666667	0.289404
RTMDet-Tiny	2462	0.668807	0.666667	0.294332



نمودار 4-1. مقایسه میانگین F1 مدل‌ها در شرایط پایه(H1)

بر اساس این نتایج، YOLOv8n در شرایط پایه رتبه اول، RT-DETR-L رتبه دوم و RTMDet-Tiny رتبه سوم را به دست آوردند. با این حال، اختلاف میانگین‌ها به‌تنهایی برای نتیجه‌گیری درباره معناداری آماری کافی نیست و تحلیل استنباطی نیز مورد استفاده قرار گرفت.

4-3-3آزمون فریدمن

با توجه به آنکه عملکرد هر سه مدل برای مجموعه تصاویر مشترک ثبت شده بود، آزمون فریدمن برای بررسی تفاوت کلی میان سه مدل به‌کار رفت .آماره فریدمن برابر 383.760418 و p برابر 4.650332×10^-84 به دست آمد .بنابراین، در سطح معناداری0.05 ، فرض برابری عملکرد سه مدل رد شد .Kendall’s W برابر 0.077937 بود که نشان می‌دهد اگرچه اختلاف آماری بسیار معنادار است، اندازه اثر رتبه‌ای کلی محدود است و نباید معناداری آماری را با اختلاف عملی بسیار بزرگ یکسان دانست.

4-3-4مقایسه‌های زوجی

پس از مشاهده تفاوت کلی، مقایسه‌های زوجی با آزمون Wilcoxon signed-rank انجام و برای کنترل تعدد آزمون‌ها اصلاح Holm اعمال شد. هر سه مقایسه پس از اصلاح Holm معنادار بودند.

جدول ۴-۳. مقایسه‌های زوجی H۱

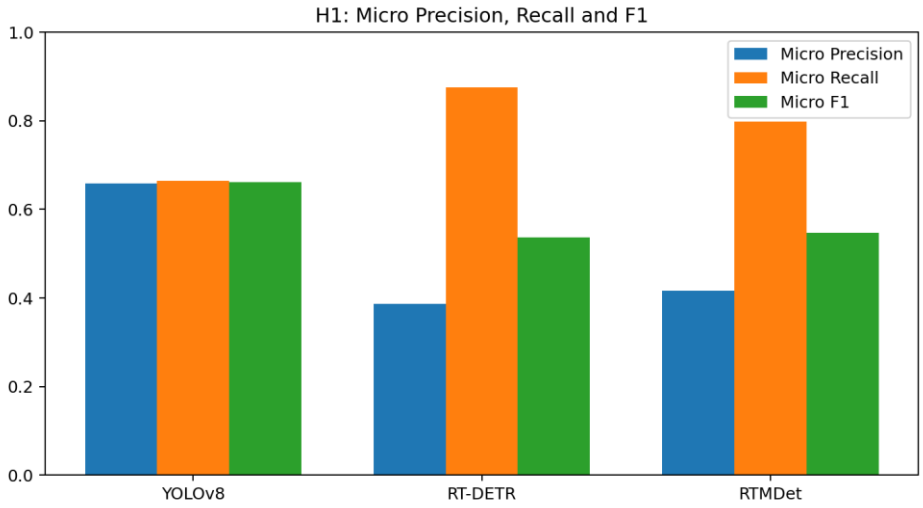
مقایسه	pخام	Rank-biserial r	pپس ازHolm	نتیجه
YOLOv8nدر برابر RT-DETR-L	1.505140×10^-24	0.309754	3.010280×10^-24	معنادار
YOLOv8nدر برابر-RTMDet Tiny	1.612297×10^-35	0.373443	4.836892×10^-35	معنادار
RT-DETR-Lدر برابر-RTMDet Tiny	5.316419×10^-05	0.137179	5.316419×10^-05	معنادار

4-3-5 Precision و Recall کلی

از فایل per-image مربوط به H1 ، مقادیر micro-averaged برایPrecision ، Recall و F1 نیز قابل استخراج بود. این مقادیر با mAP یکسان نیستند و نباید به‌عنوان mAP@0.50 یا mAP@0.50:0.95 گزارش شوند.

جدول ۴-۴. Precision، Recall و F۱ کلی در H۱

مدل	Micro Precision	Micro Recall	Micro F1
YOLOv8n	0.658602	0.664735	0.661654
RT-DETR-L	0.386279	0.876242	0.536187
RTMDet-Tiny	0.416235	0.798013	0.547106



نمودار 4-2. مقایسه Micro Precision ، Micro Recall و Micro F1 مدل‌ها در H1

RT-DETR-Lدارای Recall بالاتری است اما Precision پایین‌تری دارد، در حالی که YOLOv8n توازن مناسب‌تری میان این دو معیار ایجاد کرده و در نتیجه Micro F1 بالاتری نشان داده است.

4-3-6جمع‌بندی H1

در مجموع، H1 شواهد آماری به نفع تفاوت عملکرد پایه سه مدل ارائه کرد و YOLOv8n بالاترین Mean F1را داشت. بنابراین H1 در چارچوب تعریف‌شده پژوهش پشتیبانی می‌شود.

4-4نتایج فرضیه دوم: مقاومت در برابر تخریب‌های تصویری(H2)

4-4-1هدف H2

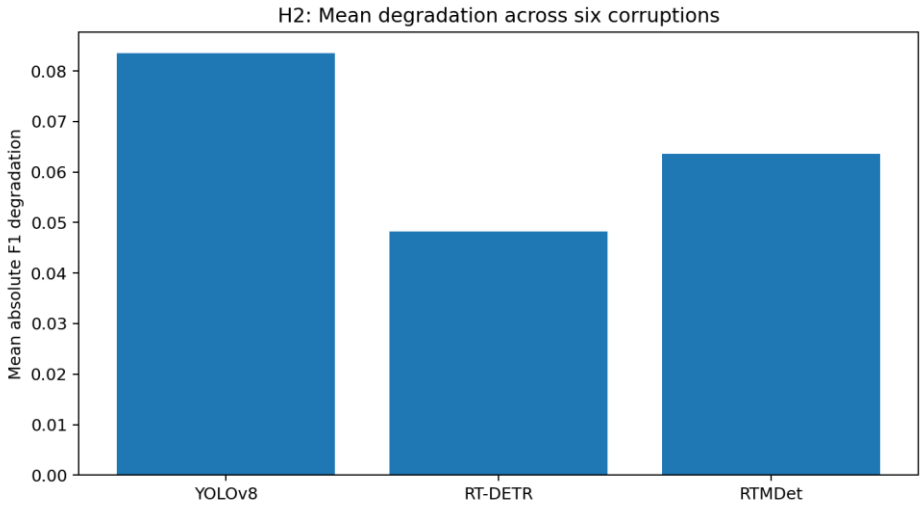
هدف H2 بررسی مقاومت مدل‌ها در برابر شش تخریب کنترل‌شده تصویری بود. در این مرحله عملکرد تصویر مرجع با نسخه تخریب‌شده همان تصویر مقایسه شد تا حساسیت مدل‌ها نسبت به تغییرات کنترل‌شده مشخص شود.

شاخص Degradation مورد استفاده در H2 و H3 به‌صورت $D = M_{clean} - M_{condition}$ تعریف شد؛ بنابراین مقدار مثبت نشان‌دهنده افت عملکرد و مقدار منفی نشان‌دهنده بهبود نسبت به شرایط مرجع است و مقدار پایین‌تر به‌عنوان افت کمتر/مقاومت بیشتر تفسیر می‌شود.

جدول ۴-۵. میانگین Degradation در H۲

مدل	تعداد	میانگین D	میانه	انحراف	افت نسبی٪	حفظ٪	رتبه
YOLOv8n	14772	0.083494	0.000000	0.296500	11.07	88.93	3
RTMDet-Tiny	14772	0.063644	0.000000	0.242640	9.52	90.48	2
RT-DETR-L	14772	0.048291	0.000000	0.218874	7.01	92.99	1

یادداشت: افت نسبی به‌صورت rel_Δ = (M_clean / D) × ۱۰۰ و حفظ عملکرد به‌صورت Retention = ۱۰۰ − rel_Δ محاسبه شده است؛ در آن D میانگین Degradation همین جدول و M_clean میانگین F۱ همان مدل در شرایط پایه مطابق جدول ۴-۲ است (YOLOv۸n: ۰٫۷۵۴۰۲۱، RT-DETR-L: ۰٫۶۸۹۳۶۹، RTMDet-Tiny: ۰٫۶۶۸۸۰۷).



نمودار 4-3. مقایسه میانگین Degradation مدل‌ها در H2

4-4-2تفسیر نتایج H2

بر اساس فایلper_image_degradation.csv ، میانگین افت مطلق F1 در کل شش خرابی برای RT-DETR-Lبرابر0.048291 ، برای RTMDet-Tiny برابر 0.063644 و برای YOLOv8n برابر 0.083494 بود . با تعریفD=M_clean−M_condition ، مقدار کمتر نشان‌دهنده افت کمتر است؛ بنابراین در این خروجی، RT-

DETR-Lکمترین افت توصیفی را داشت، سپس RTMDet-Tiny و سپس .YOLOv8n این نتیجه صرفاً توصیفی است، زیرا در بسته results2 آزمون استنباطی بین‌مدلی برای H2 ثبت نشده است.

4-4-3جمع‌بندی H2

بر اساس داده‌های موجود، RT-DETR-L کمترین میانگین Degradation را در برابر تخریب‌های تعریف شده نشان داد .این یافته از نظر توصیفی H2 را به نفع RT-DETR-L پشتیبانی می‌کند، اما شواهد آماری استنباطی رسمی برای تفاوت بین مدل‌ها در دسترس نیست.

4-5نتایج فرضیه سوم: جابه‌جایی دامنه و تغییر شرایط تصویری(H3)

4-5-1شرایط ارزیابی H3

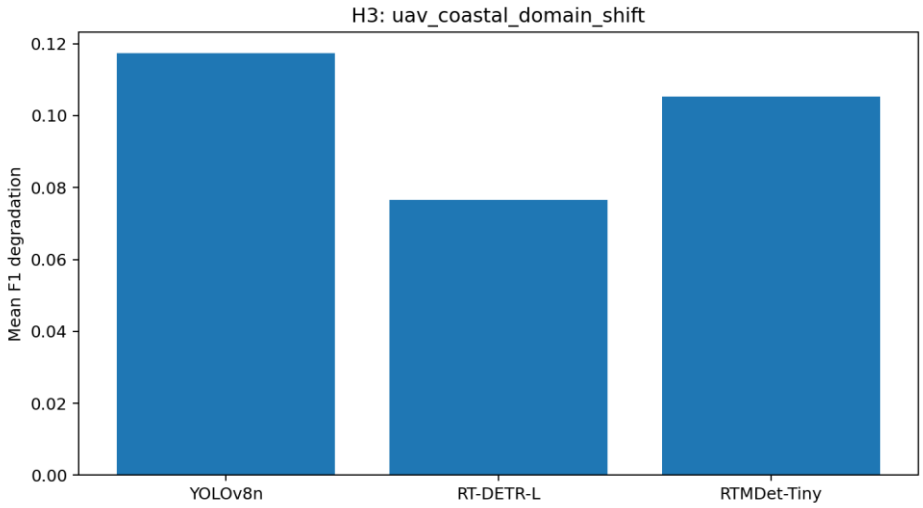
H3در بسته نتایج تحویلی فقط شامل یک شرط تغییر دامنه واقعی با عنوان uav_coastal_domain_shiftبود.

4-5-2نتیجه کلی H3

جدول ۴-۶. نتیجه کلی ۳H

مدل	تعداد	میانگین D	میانه	انحراف	افت نسبی٪	حفظ٪	رتبه
RT-DETR-L	2462	0.076483	0.000000	0.443847	11.09	88.91	1
RTMDet-Tiny	2462	0.105260	0.000000	0.432442	15.74	84.26	2
YOLOv8n	2462	0.117336	0.000000	0.388813	15.56	84.44	3

یادداشت: افت نسبی به‌صورت rel_Δ = (M_clean / D) × ۱۰۰ و حفظ عملکرد به‌صورت Retention = ۱۰۰ − rel_Δ محاسبه شده است؛ در آن D میانگین Degradation همین جدول و M_clean میانگین ۱F همان مدل در شرایط پایه مطابق جدول ۴-۲ است (n۸YOLOv: ۰٫۷۵۴۰۲۱، L-DETR-RT: ۰٫۶۸۹۳۶۹، Tiny-RTMDet: ۰٫۶۶۸۸۰۷).



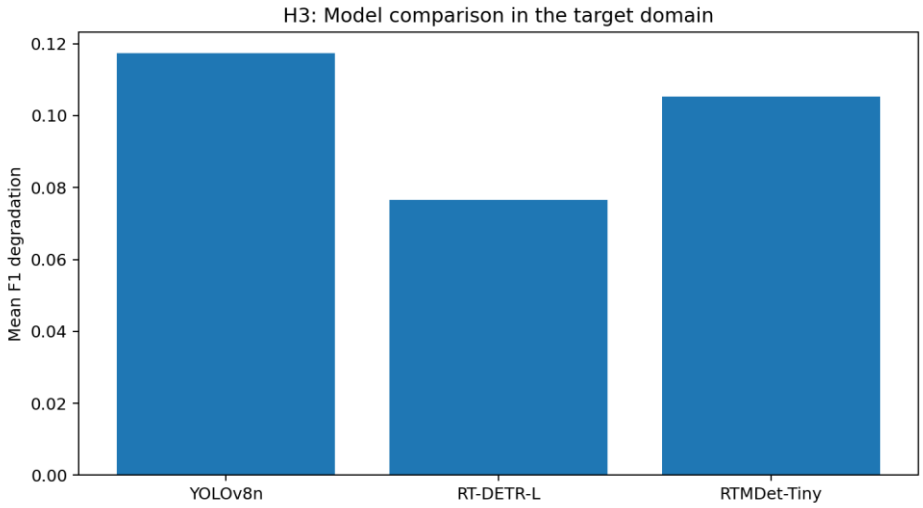
نمودار 4-4. مقایسه میانگین Degradation مدل‌ها درH3

در شرطuav_coastal_domain_shift ، میانگین Degradation برای RT-DETR-L برابر 0.076483، برای RTMDet-Tiny برابر 0.105260 و برای YOLOv8n برابر 0.117336 بود .بنابراین-RT DETR-Lکمترین افت را در این انتقال دامنه نشان داد.

4-5-3تحلیل شرط‌به‌شرط

جدول ۴-۷. مدل برتر در هر شرط ۳H

شرط	مدل برتر
uav_coastal_domain_shift	RT-DETR-L



نمودار .4-5 مقایسه میانگین Degradation مدل‌ها در uav_coastal_domain_shift

در بسته نتایج تحویلی فقط یک شرط تغییر دامنه ثبت شده است و RT-DETR-L در همین شرط کمترین میانگین Degradation را داشت؛ بنابراین ادعای 9» رتبه نخست از 12 شرط «با داده‌های موجود در results2 قابل پشتیبانی نیست.

4-5-4تفسیر علمی H3

درH3 ، علاوه بر آمار توصیفی، فایل‌های results2 آزمون‌های استنباطی را نیز ثبت کرده‌اند .آزمون Wilcoxonبرای Source در برابر Target در هر سه مدل معنادار بود YOLOv8n :با p_Holm=1.929088×10^-50، RT-DETR-L با p_Holm=2.678462×10^-43 و RTMDet-Tiny با p_Holm=2.121501×10^-56.در مقایسه سه مدل روی تصاویر هدف نیز آزمون فریدمن p=0.000559 و Kendall’s W=0.003042را نشان داد؛ مقایسه زوجی YOLOv8n در برابر RT-DETR-L پس از Holm معنادار بود(p=0.014243) ، مقایسه YOLOv8n در برابر RTMDet-Tiny معنادار نبود (p=0.980450) و مقایسه RT-DETR-L در برابر RTMDet-Tiny معنادار بود.(p=0.015879)

4-5-5جمع‌بندی H3

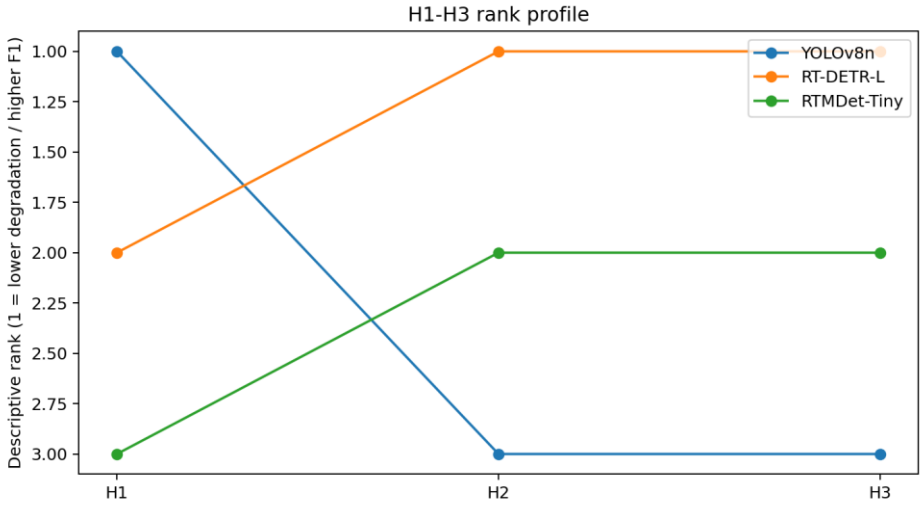
در H3 تحویلی، RT-DETR-L کمترین میانگین Degradation را در شرط uav_coastal_domain_shiftداشت .این نتیجه باید به همین شرط مشخص محدود شود و نباید به 12 وضعیت یا به همه انواع Domain Shift تعمیم داده شود.

4-6انتخاب مدل برای مرحله سازگارسازی

از آنجا که هیچ مدل واحدی در تمام آزمون‌ها رتبه نخست را کسب نکرد، انتخاب مدل برای H4 بر اساس تجمیع رتبه‌های H1 تا H3 انجام شد. این راهبرد برای جلوگیری از انتخاب مدل صرفاً بر مبنای یک بعد از عملکرد در نظر گرفته شد.

جدول ۴-۸. رتبه‌بندی تجمیعی مدل‌ها در مراحل ۱H تا ۳H

مدل	H1	H2	H3	مجموع	میانگین
YOLOv8n	1	3	3	7	2.333
RT-DETR-L	2	1	1	4	1.333
RTMDet-Tiny	3	2	2	7	2.333



نمودار .4-6 پروفایل رتبه‌ای مدل‌ها در H1 تا H3 بر اساس نتایج بسته results2

بر اساس رتبه‌بندی H1 تاH3 ، RT-DETR-L با رتبه‌های2 ، 1 و 1 مجموع رتبه 4 و میانگین رتبه 1.333333، YOLOv8n با رتبه‌های1 ، 3 و 3 مجموع رتبه 7 و میانگین رتبه 2.333333 و RTMDet-Tiny با رتبه‌های3 ، 2 و 2 مجموع رتبه 7 و میانگین رتبه 2.333333 را به دست آوردند .با وجود آنکه RT-DETR-L کمترین مجموع رتبه را داشت، آزمایش سازگارسازی (H4) روی YOLOv8n انجام شد .این انتخاب بر اساس برتری YOLOv8nدر عملکرد پایه (H1) و مجموعه نتایج سه مرحله نخست انجام گرفت .انتخاب YOLOv8n به معنای برتری مطلق آن در همه ابعاد نیست، بلکه تصمیمی بر اساس عملکرد پایه و شرایط پژوهش بوده است.

یادداشت :داده‌های عددی H4 شامل خروجیper-image ، آزمون آماری و لاگ آموزش از اجرای مستقل H4 استخراج شده‌اند و در فایل per_image_adaptation.csv با 2462 ردیف تأیید شده‌اند .این داده‌ها خارج از بسته results2.zipارائه شده‌اند، اما از منابع داده مجزای H4 تأیید شده‌اند .تنظیمات اجرای H4 نیز در فایل H4_run_configuration.jsonثبت شده است.

4-7نتایج فرضیه چهارم: سازگارسازی دامنه کنترل‌شده(H4)

4-7-1طراحی آزمایشH4

پس از انتخابYOLOv8n ، یک سناریوی controlled synthetic domain adaptation اجرا شد. برای سازگارسازی 3000 تصویر آموزشی و 500 تصویر اعتبارسنجی استفاده شد و مجموعه آزمون نهایی در فرایند adaptationوارد نشد Seed .برابر 42 بود.

تبدیلات مورد استفاده شامل کاهش روشنایی،Gamma=1.18، Contrast=0.82 ، جابه‌جایی دمای رنگ، Gaussian blurملایم و JPEG compression با کیفیت 90 بود. تبدیل هندسی فعال نبود. آموزش با اندازه ورودی 640، سقف 20 epoch، Batch Size برابر 10، AdamW و نرخ یادگیری اولیه 0.0001 انجام شد و patienceبرابر 10 در نظر گرفته شد.

جدول ۴-۹. پیکربندی adaptation در ۴H

پارامتر	مقدار
Train	3000
Validation	500
Testدرadaptation	خیر
Image size	640
Batch	10
Epochسقف	20
Optimizer	AdamW
LRاولیه	0.0001
Seed	42
Patience	10

پارامتر	مقدار
وضعیت برچسب‌گذاری داده adaptation	برچسب‌دار (labeled)

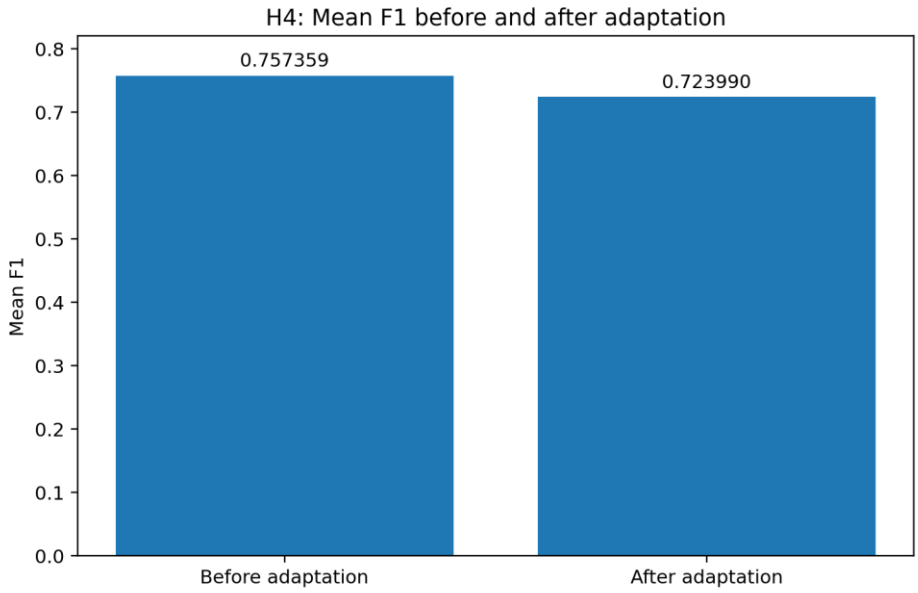
داده‌های مورد استفاده در adaptation (هر دو زیرمجموعه Train با 3000 تصویر و Validation با 500 تصویر) برچسب‌دار (labeled) هستند: این تصاویر نسخه‌های سنتتیک و تخریب‌شده همان تصاویر دارای annotation اصلی YOLO مجموعه‌داده پژوهش‌اند و برچسب‌های Truth Ground آن‌ها مستقیماً از annotation نسخه اصلی به تصاویر تخریب‌شده منتقل شده است، نه برچسب pseudo-label تولیدشده توسط مدل. به این ترتیب، سازگارسازی H4 یک سناریوی adaptation domain supervised روی داده‌های synthetic-shifted است، نه adaptation بدون برچسب (unsupervised).

از نظر آمار کلاسی، تحلیل خودکار برچسب‌های همین زیرمجموعه adaptation (Train + Validation، جمعاً 3500 تصویر) نشان می‌دهد که تعداد کل نمونه‌های برچسب‌خورده 12682 instance در قالب همان 13 کلاس تعریف‌شده در جدول 2-3 است؛ توزیع کلاس‌ها از نظر نسبت (غلبه trash_unknown_instance، trash_plastic و animal_etc) با توزیع مجموعه Train اصلی هم‌راستا است، اگرچه به دلیل کوچک‌تر بودن زیرمجموعه adaptation، مقادیر مطلق پایین‌تری دارد.

2-7-4مقایسه پیش و پس از سازگارسازی

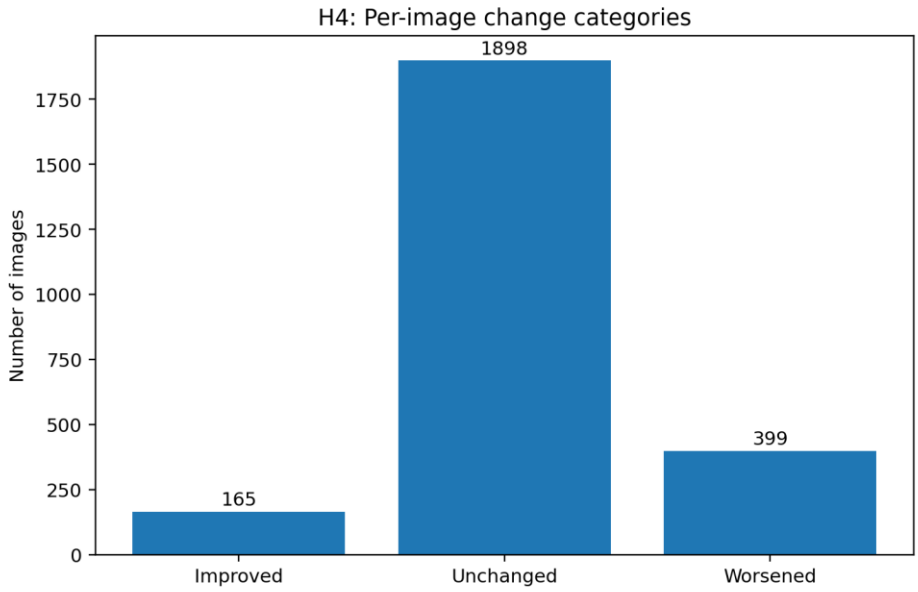
جدول ۴-۱۰. مقایسه عملکرد n۸YOLOv پیش و پس از سازگارسازی

وضعیت	میانگین F1
پیش از سازگارسازی	0.757359
پس از سازگارسازی	0.723990
تغییر میانگین	-0.033369



نمودار 4-7. مقایسه میانگین F1 پیش و پس از سازگارسازی H4

در سطح تصویر، 165 تصویر دارای بهبود، 399 تصویر دارای افت و 1898 تصویر بدون تغییر بودند. بنابراین تعداد تصاویر دارای افت بیش از دو برابر تصاویر دارای بهبود بود. میانه تغییر F1 برابر صفر بود؛ این موضوع نشان می‌دهد بخش بزرگی از تصاویر تغییر محسوس نداشته‌اند، اما در نمونه‌هایی که تغییر رخ داده است، جهت تغییر بیشتر منفی بوده است.



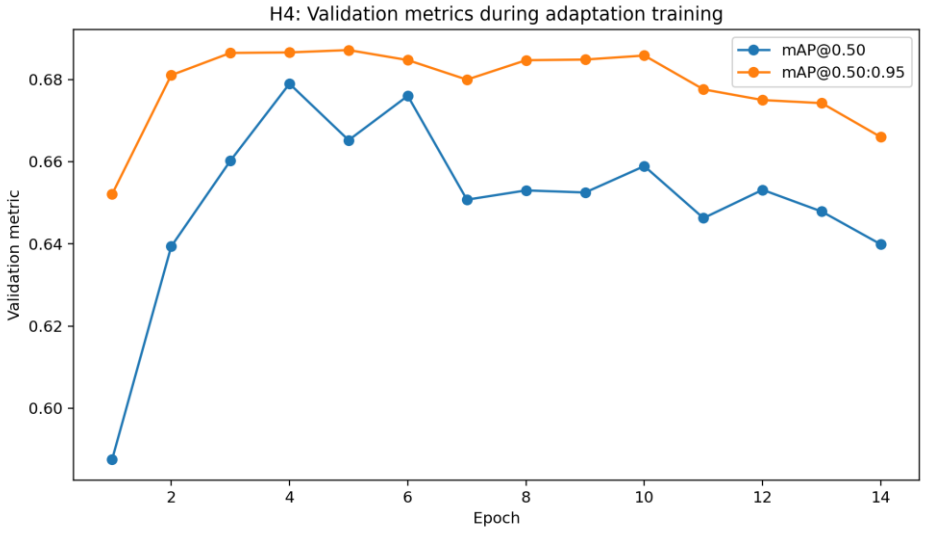
نمودار 4–8. توزیع تغییرات F1 در سطح تصویر درH4

4-7-3آزمون آماریH4

آزمون Wilcoxon زوجی برای مقایسه عملکرد پیش و پس از adaptation آماره 44977 و p برابر 2.90599×10^-19 را نشان داد. اندازه اثر Rank-biserial برابر -0.414894 و بازه اطمینان Bootstrap در سطح 95 درصد برابر [-0.042173, -0.024951] بود. چون فاصله اطمینان صفر را دربر نمی‌گیرد، افت عملکرد در چارچوب این آزمایش از نظر آماری معنادار است .Spearman rho برابر 0.821190 نیز نشان‌دهنده همبستگی بالای رتبه‌ای میان عملکرد پیش و پس از سازگارسازی بود.

4-7-4روند آموزشadaptation

در لاگ آموزشH4 ، بهترین mAP@0.50:0.95 در epoch 4 برابر 0.46912 و بهترین mAP@0.50 در epoch 5 برابر 0.68714 بود. در epoch 14 این مقادیر به ترتیب 0.44369 و 0.66597 رسیدند. در همین بازه، train/box_loss از 1.10186 به 0.92004 و train/cls_loss از 1.04663 به 0.75917 کاهش یافتند. بنابراین کاهش loss آموزشی به تنهایی معادل بهبود معیار validation نیست و انتخاب checkpoint باید بر اساس معیار validation تعریف‌شده انجام شود.



نمودار 4–9. روند معیارهای validation در طول آموزشadaptation H4

جدول ۴-۱۱. نقاط کلیدی لاگ validation در H۴

Epoch	mAP@0.50	mAP@0.50:0.95	Recall
4	0.68657	0.46912	0.67895
5	0.68714	0.46725	0.66522
14	0.66597	0.44369	0.63987

4-7-5تفسیر نتیجهH4

نتیجه H4 نشان می‌دهد سازگارسازی کنترل‌شده و مصنوعی در اجرای حاضر موجب بهبود YOLOv8n نشد؛ بلکه میانگین F1 را از 0.757359 به 0.723990 کاهش داد .این نتیجه با Negative Transfer سازگار است .با این حال، نباید از این یافته نتیجه گرفت که Domain Adaptation به‌طور کلی ناکارآمد است؛ نتیجه دقیق‌تر آن است که پروتکل سازگارسازی مشخص‌شده، با شدت و ترکیب تبدیلات و تنظیمات آموزشی انتخاب‌شده، در این مجموعه آزمایش مؤثر نبوده است.

مقدار baseline ثبت‌شده در اجرای H4 (0.757359) اندکی با مقدار canonical گزارش‌شده در بخش H1 (0.754021)تفاوت دارد .از آنجا که خروجی کامل evaluator مشترک برای بازتولید مجدد هر دو اجرا در دسترس نیست، این اختلاف به‌عنوان تفاوت جزئی بین اجرای مستقل H4 و benchmark canonical H1 حفظ شده و مبنای تحلیل paired قبل و بعد H4 همان داده‌های داخلی اجرای H4 است.

4-8مقایسه نهایی نتایج H1 تاH4

جدول ۴-۱۲. جمع‌بندی عملکرد مدل‌ها در چهار مرحله پژوهش

مرحله	مدل/نتیجه برتر	تفسیر اصلی
H1	YOLOv8n	بهترین Mean F1 پایه
H2	RT-DETR-L	کمترین Mean Degradation در ششcorruption
H3	RT-DETR-L	کمترین Mean Degradation در uav_coastal_domain_shift
H4	Negative Transfer	میانگین F1 از 0.757359 به 0.723990کاهش یافت

هیچ مدل واحدی در تمام شرایط بهترین عملکرد را نداشت YOLOv8n .در H1 برتری داشت،RT-DETR-Lدر H2 و H3 پایداری بیشتری نشان داد و H4 نشان داد که حتی برای مدل منتخب نیز سازگارسازی نامناسب می‌تواند به افت عملکرد منجر شود .این یافته از ارزیابی چندبعدی به‌جای اتکا به یک معیار منفرد پشتیبانی می کند.

4-9وضعیت فرضیه‌های پژوهش

جدول ۴-۱۳. وضعیت نهایی فرضیه‌های پژوهش

فرضیه	موضوع	وضعیت	مبنای تصمیم
H1	مقایسه عملکرد پایه	پشتیبانی می‌شود	YOLOv8nبالاترین Mean F1را داشت؛ Friedman pو هر سه مقایسه زوجی پس از Holm معنادار بودند.
H2	مقاومت در برابر corruption	شواهد توصیفی؛ بدون آزمون بین‌مدلی در بسته	RT-DETR-Lکمترین Mean Degradationبرابر 0.048291 را در شش corruption داشت.
H3	مقاومت در Domain Shift	پشتیبانی می‌شود، با دامنه محدود به شرط تحویلی	RT-DETR-Lکمترین Degradationبرابر 0.076483 را در uav_coastal_domain_shift داشت؛ آزمون‌هایSource–Target و Friedman بین‌مدلی نیز ثبت شده‌اند.
H4	بهبود باadaptation	تأیید نشد	میانگین F1 از 0.757359 به 0.723990کاهش یافت؛ آزمون Wilcoxonمعنادار بود (p=2.90599×10^-19).داده های H4 از اجرای مستقل

مبنای تصمیم	وضعیت	موضوع	فرضیه
استخراج شده‌اند.			

4-10بحث نتایج

یکی از مهم‌ترین یافته‌های پژوهش وابستگی عملکرد مدل به شرایط ارزیابی است. اگر تنها عملکرد پایه ملاک باشد، YOLOv8n انتخاب اول است؛ اما هنگام تغییر دامنه، RT-DETR-L پایداری بیشتری نشان می‌دهد.

این تفاوت میان عملکرد درون‌دامنه و پایداری برون‌دامنه بیان می‌کند که یک مدل با F1 پایه بالاتر لزوماً در همه شرایط واقعی بهترین گزینه نیست. در محیط‌های دریایی، تغییر روشنایی، کنتراست، رنگ، زاویه دید، مقیاس و سکوی تصویربرداری می‌تواند توزیع داده را تغییر دهد.

نتیجه H4 این تصویر را کامل می‌کند :حتی زمانی که یک مدل بر اساس شواهد چندبعدی انتخاب شده است، سازگارسازی دامنه الزاماً موفق نخواهد بود .در اجرای حاضر، synthetic adaptation موجب Negative Transfer شد و ازاین‌رو طراحی و شدت تغییرات و هماهنگی آن‌ها با دامنه هدف اهمیت دارد.

با توجه به محدودیت بسته نتایج، H2 و H3 را نمی‌توان با عبارت معناداری آماری توصیف کرد. همچنین benchmarkاستاندارد مشترک برای FPS و latency سه مدل که تمام مشخصات سخت‌افزار،batch ،precision ، warm-upو تکرار را هم‌زمان کنترل کرده باشد در فایل‌های موجود ثبت نشده است؛ بنابراین از ادعای برتری محاسباتی مدل‌ها خودداری می‌شود.

4-11ملاحظات مربوط به تفسیر و اعتبار نتایج

اولاً، F1 در سطح تصویر با mAP متفاوت است. بنابراین مقادیر Mean per-image F1 و Micro F1 نباید جایگزین mAP@0.50 یا mAP@0.50:0.95 شوند.

ثانیاً، Degradation در H2 و H3 به صورت $\text{clean} - \text{condition}$ تعریف شده است؛ مقدار مثبت به معنای افت و مقدار منفی به معنای بهبود نسبت به مرجع است.

ثالثاً، انتخاب YOLOv8n برای H4 به معنی تضمین موفقیت adaptation نیست H4 .صرفاً نشان داد که پروتکل سازگارسازی انتخاب‌شده در این آزمایش نتیجه مثبت ایجاد نکرد.

در نهایت، نبود داده معتبر برای برخی شاخص‌ها باعث شد از ارائه اعداد غیرقابل استناد خودداری شود. این محدودیت از نظر علمی ترجیح دارد بر اینکه جداول با اعداد فاقد پشتوانه تجربی تکمیل شوند.

4-12کارایی محاسباتی و محدودیتbenchmark

در فایل‌های موجود benchmark استاندارد و مشترکی برای FPS و latency سه مدل که سخت‌افزار، image size، batch، precision، warm-up ، تعداد تکرار و روش اندازه‌گیری را یکسان گزارش کند وجود ندارد. برای YOLOv8n adapted زمان‌های تقریبی preprocess برابر 0.3 ms، inference برابر 2.0 msو postprocessبرابر 1.0 msدر گزارش‌های قبلی موجود است، اما این مقادیر benchmark سه‌مدلی محسوب نمی‌شوند و برای رتبه‌بندی مدل‌ها استفاده نشده‌اند.

4-13جمع‌بندی فصل

درH1 ، YOLOv8n با Mean F1 برابر 0.754021 بالاترین عملکرد پایه را کسب کرد و آزمون فریدمن و مقایسه‌های زوجی Wilcoxon تفاوت آماری میان مدل‌ها را تأیید کردند.

درH2 ، میانگین افت مطلق F1 برای RT-DETR-L برابر0.048291 ، برای RTMDet-Tiny برابر 0.063644و برای YOLOv8n برابر 0.083494 بود؛ بنابراین RT-DETR-L کمترین افت توصیفی را داشت . برای H2 در بسته results2 آزمون استنباطی بین‌مدلی ثبت نشده است.

درH3 ، RT-DETR-L با Mean Degradation برابر 0.076483 در تنها شرط تحویلی (uav_coastal_domain_shift)کمترین افت را داشت .آزمون‌های Source–Target برای هر سه مدل معنادار بودند و مقایسه بین‌مدلی نیز تفاوت کلی معناداری را نشان داد، هرچند اندازه اثر کلی Kendall’s W برابر 0.003042بود.

بر اساس تجمیع رتبه‌های H1 تاH3 ، YOLOv8n برای H4 انتخاب شد، اما adaptation کنترل‌شده موجب کاهش Mean F1 از 0.757359 به 0.723990 شد و این کاهش از نظر آماری معنادار بود.

در مجموع، هیچ مدل واحدی در همه شرایط بهترین نبود YOLOv8n .در عملکرد پایه برتری داشت،-RT DETR-Lدر تخریب‌های مصنوعی و تغییر دامنه مقاوم‌تر بود و سازگارسازی مصنوعی بررسی‌شده برای YOLOv8n در این اجرای مشخص به بهبود منجر نشد .این نتایج مبنای بحث، نتیجه‌گیری و پیشنهادهای فصل پنجم خواهد بود.

منابع فنی مورد استفاده در تدوین بخش معماری

Zhao, Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). DETRs beat YOLOs on real-time object detection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 16965–16974.

Ultralytics. YOLO Architecture Documentation. مستندات رسمی معماری شامل ساختار Backbone، Neck و Detection Head و مشخصات head بدون anchor در YOLOv8n.

Lyu, C., Zhang, W., Huang, H., Zhou, Y., Wang, Y., Liu, Y., Zhang, S., & Chen, K. (2022). RTMDet-Tiny: An empirical study of designing real-time object detectors. arXiv:2212.07784.

فصل پنجم

نتیجه‌گیری، محدودیت‌ها و پیشنهادهای پژوهش

5-1مقدمه

هدف اصلی این پژوهش، بررسی و مقایسه عملکرد مدل‌های پیشرفته یادگیری عمیق در تشخیص زباله‌های دریایی و ارزیابی میزان پایداری آن‌ها در شرایطی فراتر از تصاویر استاندارد و نسبتاً ایده‌آل بوده است .در این راستا، سه مدلYOLOv8n ، RT-DETR-L و RTMDet-Tiny در یک چارچوب آزمایشی مشترک و بر روی یک تقسیم بندی ثابت از داده‌ها مقایسه شدند .علاوه بر مقایسه عملکرد پایه، رفتار مدل‌ها در برابر تخریب‌های مصنوعی تصویر و همچنین تغییرات دامنه و شرایط تصویربرداری بررسی شد .در ادامه، با استفاده از نتایج سه مرحله نخست، مدلی برای انجام یک آزمایش کنترل‌شده سازگارسازی دامنه انتخاب شد تا مشخص شود آیا آموزش تکمیلی با نمونه‌های مصنوعی نزدیک به شرایط هدف می‌تواند عملکرد مدل منتخب را در دامنه موردنظر بهبود دهد یا خیر.

ساختار آزمایش‌ها بر چهار محور اصلی بنا شد .محور نخست، مقایسه عملکرد پایه سه مدل در شرایط مشترک و استاندارد بود .محور دوم، سنجش استحکام مدل‌ها در برابر خرابی‌های مصنوعی شامل تغییر روشنایی، کنتراست، نویز گاوسی، محوشدگی گاوسی، محوشدگی حرکتی و فشرده‌سازی JPEG بود .محور سوم، بررسی افت عملکرد در برابر یک شرط تغییر دامنه واقعی با عنوان uav_coastal_domain_shift بود .محور چهارم نیز به سازگارسازی کنترل‌شده مدل منتخب با داده‌های مصنوعی اختصاص یافت.

نتایج کلی نشان دادند که هیچ مدل واحدی در تمامی ابعاد مورد بررسی برتری مطلق ندارد YOLOv8n .در شرایط پایه و در آزمون خرابی‌های مصنوعی عملکرد مطلوب‌تری نشان داد، در حالی که RT-DETR-L در آزمون تغییر دامنه از نظر میانگین افت عملکرد پایدارتر بود .همچنین، سازگارسازی مصنوعی اجراشده برای YOLOv8n نه‌تنها بهبود مورد انتظار را ایجاد نکرد، بلکه افت عملکرد معناداری را به دنبال داشت .بنابراین، یافته‌های پژوهش بر اهمیت تفکیک میان» عملکرد پایه«،» استحکام در برابر خرابی«،» پایداری در تغییر دامنه «و» اثربخشی سازگارسازی «تأکید می کنند.

5-2جمع‌بندی روند اجرای پژوهش

در این پژوهش، ابتدا مجموعه‌داده مورد استفاده از نظر ساختار، برچسب‌ها و کیفیت داده‌ها بررسی و نسخه نهایی داده‌ها برای آزمایش‌های اصلی تثبیت شد .برای مقایسه منصفانه مدل‌ها، تقسیم‌بندی داده‌ها در بین آزمایش‌های

اصلی ثابت نگه داشته شد تا اختلاف نتایج تا حد امکان ناشی از تفاوت مدل یا شرایط آزمایش باشد، نه تغییر در نمونه های آموزشی و آزمون.

سه مدلYOLOv8n ، RT-DETR-L و RTMDet-Tiny در چارچوبی یکسان مورد مطالعه قرار گرفتند .اندازه ورودی تصاویر 640×640 پیکسل در نظر گرفته شد و آموزش اصلی تا حداکثر 150 epoch انجام گرفت .بذر تصادفی آزمایش‌ها 42 در نظر گرفته شد .در فرایند آموزش، معیار اصلی برای انتخاب بهترین نقطه آموزش، mAP@0.50:0.95بود و mAP@0.50 نیز به‌عنوان معیار همراه مورد پایش قرار گرفت .با این حال، لازم است تأکید شود که آزمون‌های آماری فرضیه‌های پژوهش در سطح مقایسه‌های H1 تا H4 بر مبنای معیارهای per-image F1و شاخص‌های افت عملکرد انجام شدند و نباید این آزمون‌ها با معیار mAP مورد استفاده برای انتخاب checkpointیکسان تلقی شوند.

در مرحله نخست، عملکرد پایه مدل‌ها بر روی تصاویر مشترک آزمون مقایسه شد .در مرحله دوم، هر تصویر آزمون تحت شش خرابی مصنوعی قرار گرفت و میزان افت یا تغییر F1 نسبت به تصویر پاک محاسبه شد .در مرحله سوم، یک شرط تغییر دامنه واقعی با عنوان uav_coastal_domain_shift بررسی و رفتار سه مدل در برابر این تغییر مقایسه شد . در نهایت، بر اساس رتبه ترکیبی به‌دست‌آمده از سه مرحله نخست، YOLOv8n برای آزمایش سازگارسازی انتخاب شد و یک فرآیند آموزش تکمیلی کنترل‌شده با داده‌های مصنوعی اجرا گردید.

5-3نتیجه‌گیری نهایی بر اساس فرضیه اول

5-3-1مقایسه عملکرد پایه مدل‌ها

در آزمونH1 ، تعداد 2462 تصویر مشترک آزمون برای هر سه مدل مورد استفاده قرار گرفت و در مجموع 7386 رکورد per-image برای مقایسه سه مدل تولید شد. معیار اصلی این تحلیل، F1 در سطح تصویر بود که امکان مقایسه مستقیم رفتار مدل‌ها در سطح نمونه‌های یکسان را فراهم می‌کرد.

میانگین F1 برای YOLOv8n برابر با 0.754021، برای RT-DETR-L برابر با 0.689369 و برایRTMDet-Tinyبرابر با 0.668807 به دست آمد. بنابراین، در شرایط پایه، YOLOv8n بالاترین میانگین F1 را در میان سه مدل نشان داد. از منظر توصیفی نیز میانه F1 برای YOLOv8n برابر با 1.0 بود، در حالی که میانه F1 برای دو مدل RT-DETR-Lو RTMDet-Tiny برابر با 0.666667 گزارش شد.

برای بررسی وجود اختلاف معنادار میان توزیع عملکرد سه مدل، از آزمون فریدمن استفاده شد. مقدار آماره فریدمن برابر با 383.760418 و سطح معناداری برابر با 4.65033×10^-84 به دست آمد. این نتیجه نشان می‌دهد که اختلاف میان عملکرد مدل‌ها در سطح مقایسه انجام‌شده از نظر آماری بسیار معنادار است. اندازه اثر کلی با استفاده از Kendall’s Wبرابر با 0.077937 به دست آمد؛ از این رو، اگرچه اختلاف کلی مدل‌ها از نظر آماری قطعی بود، شدت توافق رتبه‌ای در کل مجموعه نسبتاً محدود ارزیابی می‌شود.

در مقایسه‌های زوجی، اختلاف YOLOv8n با RT-DETR-L و RTMDet-Tiny پس از اصلاح Holm معنادار بود. مقدار p اصلاح‌شده برای مقایسه YOLOv8n با RT-DETR-L برابر با 3.01028×10^-24 و برای مقایسه YOLOv8nبا RTMDet-Tiny برابر با 4.83689×10^-35 به دست آمد. اندازه اثر رتبه‌ای نیز برای این دو مقایسه به‌ترتیب 0.309754 و 0.373443 بود. همچنین اختلاف RT-DETR-L و RTMDet-Tiny نیز معنادار گزارش شد، هرچند شدت اثر آن کمتر بود؛ به‌طوری‌که p اصلاح‌شده برابر با 5.31642×10^-5 و اندازه اثر رتبه‌ای برابر با 0.137179 بود.

بنابراین، در چارچوب شرایط پایه و معیار مورد استفاده درH1 ، فرضیه مربوط به تفاوت عملکرد پایه مدل‌ها تأیید می‌شود و YOLOv8n رتبه نخست را به دست می‌آورد.

با این حال، این یافته نباید به معنای برتری مطلق YOLOv8n در همه معیارها یا همه شرایط تفسیر شود. در تحلیل میکرو، YOLOv8n دارای Precision برابر با 0.658602 و Recall برابر با 0.664735 بود، در حالی که RT-DETR-L Recallبالاتری معادل 0.876242 داشت اما Precision آن 0.386279 بود. بنابراین، رفتار مدل‌ها از منظر توازن بین کشف نمونه‌های مثبت و کنترل پیش‌بینی‌های نادرست متفاوت بوده است.

در مجموع، نتیجه H1 نشان می‌دهد که در شرایط استاندارد و بدون اعمال تغییرات محیطی یا دامنه‌ای، YOLOv8n انتخاب مناسب‌تری از نظر F1 در سطح تصویر بوده است؛ اما این مزیت به‌تنهایی برای انتخاب نهایی یک مدل عملیاتی کافی نیست و باید در کنار استحکام، تعمیم‌پذیری و هزینه محاسباتی تحلیل شود.

5-4نتیجه‌گیری نهایی بر اساس فرضیه دوم

5-4-1ارزیابی استحکام در برابر خرابی‌های مصنوعی

هدف H2 بررسی حساسیت مدل‌ها نسبت به تغییرات مصنوعی در کیفیت و ظاهر تصاویر بود .برای این منظور، شش نوع خرابی شامل تغییر روشنایی، کنتراست، نویز گاوسی، تاری گاوسی، تاری حرکتی و فشرده‌سازی JPEG اعمال شد .برای هر مدل، 2462 تصویر آزمون پاک با 6 نوع خرابی مقایسه شد و در نتیجه برای هر مدل 14772 مشاهده به دست آمد.

شاخص افت عملکرد به‌صورت اختلاف F1 تصویر پاک و F1 تصویر خراب تعریف شد .در این چارچوب، مقدار کمتر شاخص افت به معنای حفظ بهتر عملکرد در برابر خرابی بود .میانگین افت عملکرد برای RT-DETR-L برابر با 0.048291، برای RTMDet-Tiny برابر با 0.063644 و برای YOLOv8n برابر با 0.083494 گزارش شد. بر این اساس، رتبه‌بندی استحکام در برابر خرابی‌های مصنوعی به صورت زیر به دست آمد :RT-DETR-L در رتبه نخست، RTMDet-Tiny در رتبه دوم و YOLOv8n در رتبه سوم قرار گرفتند. نکته مهم در تفسیر این نتایج آن است که مقایسه میانگین Degradation صرفاً توصیفی است و آزمون استنباطی رسمی برای تفاوت بین مدل‌ها در H2 ثبت نشده است .بنابراین، برتری RT-DETR-L در این بخش نباید به‌عنوان برتری آماری قطعی تلقی گردد .همچنین، این نتایج بر اساس شش نوع خرابی مصنوعی به‌صورت مجزا به دست آمده‌اند و ممکن است در شرایطی که چندین خرابی به‌طور هم‌زمان رخ می‌دهند، رفتار متفاوتی مشاهده شود. همچنین، در مجموعه نتایج H2 آزمون استنباطی رسمی برای مقایسه معناداری میان مدل‌ها ارائه نشده است .بنابراین، نتیجه این بخش باید در سطح توصیفی بیان شود و نباید برتری RT-DETR-L از نظر H2 به‌عنوان برتری آماری قطعی تلقی گردد.

در مجموع، H2 نشان داد که RT-DETR-L در چارچوب خرابی‌های مصنوعی تعریف‌شده، کمترین افت متوسط عملکرد را داشته است .این نتیجه با یافته H1 هم‌جهت نیست و نشان می‌دهد مدلی که در شرایط پایه عملکرد بالاتری داشته است، در این مجموعه خاص از خرابی‌های تصویری لزوماً پایدارترین نبوده است .با این حال، نتیجه H2 درباره طیف محدود و کنترل‌شده‌ای از خرابی‌های مصنوعی معتبر است و نمی‌توان آن را بدون آزمون بیشتر به تمامی شرایط واقعی محیط دریایی تعمیم داد.

5-5نتیجه‌گیری نهایی بر اساس فرضیه سوم

5-5-1ارزیابی پایداری در برابر تغییر دامنه و شرایط تصویربرداری

در ارزیابیH3 ، یک شرط تغییر دامنه واقعی با عنوان uav_coastal_domain_shift بررسی شد .در این شرط، میانگین Degradation برای RT-DETR-L برابر0.076483 ، برای RTMDet-Tiny برابر 0.105260 و برای YOLOv8n برابر 0.117336 به دست آمد .بنابراین RT-DETR-L کمترین افت را در این انتقال دامنه نشان داد.

آزمون Wilcoxon برای مقایسه عملکرد Source و Target در هر سه مدل معنادار بود YOLOv8n :با p_Holm=1.929088×10^-50، RT-DETR-L با p_Holm=2.678462×10^-43 و RTMDet-Tiny با p_Holm=2.121501×10^-56.در مقایسه بین‌مدلی روی تصاویر هدف نیز آزمون فریدمن p=0.000559 و Kendall's W=0.003042را نشان داد .مقایسه زوجی YOLOv8n در برابر RT-DETR-L پس از اصلاح Holmمعنادار بود(p=0.014243) ، مقایسه YOLOv8n در برابر RTMDet-Tiny معنادار نبود (p=0.980450)و مقایسه RT-DETR-L در برابر RTMDet-Tiny معنادار بود.(p=0.015879) با توجه به محدود بودن ارزیابی H3 به یک شرط واحد، نمی‌توان از این نتیجه به همه انواع Domain Shift تعمیم داد .با این حال، در شرط بررسی‌شده، RT-DETR-L پایداری بیشتری از خود نشان داد.

5-6جمع‌بندی انتخاب مدل برای سازگارسازی دامنه

پس از اجرای H1 تاH3 ، انتخاب مدل برای آزمایش H4 صرفاً بر مبنای بیشترین عملکرد پایه انجام نشد، بلکه رتبه مدل‌ها در سه بعد عملکرد پایه، استحکام در برابر خرابی و پایداری در برابر تغییر دامنه به‌صورت ترکیبی در نظر گرفته شد.

در این رتبه‌بندی، RT-DETR-L با رتبه‌های2 ، 1 و 1 مجموع رتبه4 ، YOLOv8n با رتبه‌های1 ، 3 و 3 مجموع رتبه 7 و RTMDet-Tiny با رتبه‌های3 ، 2 و 2 مجموع رتبه 7 را به دست آوردند.

بنابراین، RT-DETR-L با میانگین رتبه 1.333333 در جایگاه اول، YOLOv8n با میانگین رتبه 2.333333 در جایگاه دوم) هم‌رده با (RTMDet-Tiny و RTMDet-Tiny با میانگین رتبه 2.333333 در جایگاه سوم قرار گرفتند.

با وجود آنکه RT-DETR-L کمترین مجموع رتبه را داشت، آزمایش سازگارسازی (H4) روی YOLOv8n انجام شد .این انتخاب بر اساس برتری YOLOv8n در عملکرد پایه (H1) و مجموعه نتایج سه مرحله نخست انجام گرفت.

5-7نتیجه‌گیری نهایی بر اساس فرضیه چهارم

5-7-1اجرای سازگارسازی کنترل‌شده

درH4 ، YOLOv8n به‌عنوان مدل منتخب وارد یک فرآیند سازگارسازی دامنه کنترل‌شده شد. داده سازگارسازی شامل 3000 تصویر آموزشی و 500 تصویر اعتبارسنجی بود و مجموعه آزمون نهایی در فرایند سازگارسازی مورد استفاده قرار نگرفت. هدف این طراحی، جلوگیری از آمیختن مستقیم داده آزمون با آموزش و حفظ استقلال ارزیابی نهایی بود.

تغییرات مصنوعی مورد استفاده شامل کاهش روشنایی، gamma برابر با 1.18، کاهش کنتراست تا 0.82، تغییر دمای رنگ، محوشدگی گاوسی ملایم و فشرده‌سازی JPEG با کیفیت 90 بود. در این مرحله، تغییر هندسی اعمال نشد. آموزش سازگارسازی با اندازه ورودی 640×640، حداکثر 20 epoch، batch size برابر با 10، بهینه‌سازAdamW ، نرخ یادگیری 0.0001، early stopping با patience برابر با 10 و seed برابر با 42 انجام شد.

این طراحی عمداً محدود و کنترل‌شده بود تا امکان بررسی یک سؤال مشخص فراهم شود: آیا مواجهه برنامه‌ریزی‌شده مدل با نمونه‌های مصنوعی نزدیک به شرایط هدف می‌تواند عملکرد آن را بهبود دهد؟

5-7-2نتایج پیش و پس از سازگارسازی

میانگین F1 مدل YOLOv8n پیش از سازگارسازی برابر با 0.757359 و پس از سازگارسازی برابر با 0.723990 به دست آمد. بنابراین، تغییر میانگین F1 برابر با -0.033369 بود.

در سطح نمونه‌ها نیز 165 تصویر پس از سازگارسازی بهبود یافتند، 399 تصویر افت عملکرد داشتند و 1898 تصویر تغییر محسوسی در F1 نشان ندادند.

برای بررسی آماری تغییرات زوجی، آزمون ویلکاکسون انجام شد. مقدار آماره برابر با 44977 و سطح معناداری برابر با 2.90599×10^-19 به دست آمد. همچنین اندازه اثر rank-biserial برابر با -0.414894 گزارش شد. فاصله اطمینان 95 درصد Bootstrap برای تغییر F1 نیز از -0.042173 تا -0.024951 به دست آمد.

این نتایج نشان می‌دهند که افت عملکرد پس از سازگارسازی نه‌تنها در سطح توصیفی مشاهده شده است، بلکه از نظر آماری نیز معنادار بوده است. بنابراین، فرضیه‌ای که انتظار بهبود عملکرد در نتیجه این پروتکل سازگارسازی را داشت، در این آزمایش تأیید نمی‌شود.

نکته دیگری که در تفسیر H4 اهمیت دارد، مقدار ضریب Spearman برابر با 0.821190 است. این مقدار بالا نشان می‌دهد که رتبه‌بندی نسبی نمونه‌ها تا حد زیادی پیش از سازگارسازی حفظ شده است، هرچند سطح F1 در بخش قابل‌توجهی از نمونه‌ها پس از سازگارسازی کاهش یافته است.

5-7-3تفسیر نتیجه منفی سازگارسازی

یکی از مهم‌ترین یافته‌های این پژوهش، نتیجه منفی H4 است. مشاهده کاهش آماری معنادار عملکرد نشان می‌دهد که افزایش شباهت مصنوعی داده‌های آموزشی به برخی شرایط هدف لزوماً به تعمیم بهتر منجر نمی‌شود.

یکی از تفسیرهای محتمل این است که سازگارسازی انجام‌شده ممکن است مدل را به ویژگی‌های مصنوعی و خاص فرایند تولید داده‌ها حساس‌تر کرده باشد. به بیان دیگر، داده مصنوعی ممکن است تنها بخشی از تنوع واقعی دامنه هدف را بازنمایی کرده باشد. در چنین وضعیتی، مدل به جای یادگیری ویژگی‌های عمومی و پایدار دامنه هدف، ممکن است بخشی از الگوهای ناشی از فرایند مصنوعی را جذب کرده باشد.

تفسیر دیگر می‌تواند تفاوت میان تغییرات مصنوعی و تغییرات واقعی موجود در تصاویر هدف باشد. تغییر روشنایی، گاما، دمای رنگ، تاری و فشرده‌سازی را می‌توان به‌طور مصنوعی ایجاد کرد، اما دامنه واقعی تصاویر دریایی می‌تواند شامل برهم‌کنش پیچیده‌تری میان بازتاب سطح آب، ذرات معلق، بازتاب نور، تغییر عمق، کدری، حرکت دوربین، زاویه دید و زمینه بصری باشد. بنابراین، شباهت ظاهری میان یک تصویر مصنوعی و یک تصویر واقعی الزاماً به معنای شباهت آماری و معنایی کامل نیست.

از منظر روش‌شناختی، نتیجه H4 باید به‌عنوان شواهد مربوط به «این پروتکل مشخص سازگارسازی» تفسیر شود. این نتیجه به‌تنهایی نشان نمی‌دهد که سازگارسازی دامنه به‌طور کلی بی‌اثر یا نامناسب است؛ بلکه نشان می‌دهد پروتکل آزمایش‌شده، با نوع تبدیل‌ها، حجم داده، تعدادepoch ها و ساختار آموزش مورد استفاده در این پژوهش، نتوانسته است مسئله تعمیم به دامنه هدف را حل کند و حتی منجر به افت عملکرد شده است.

این یافته از نظر پژوهشی اهمیت ویژه‌ای دارد، زیرا نشان می‌دهد افزودن داده مصنوعی بدون اعتبارسنجی دقیق شکاف میان دامنه مصنوعی و دامنه واقعی می‌تواند نتیجه معکوس ایجاد کند.

5-8پاسخ نهایی به پرسش‌های اصلی پژوهش

بر اساس مجموعه نتایج به‌دست‌آمده، نخستین پرسش پژوهش درباره بهترین مدل در شرایط استاندارد را می توان با انتخاب YOLOv8n پاسخ داد .این مدل بالاترین میانگین F1 را در مقایسه پایه به دست آورد و اختلاف آن با دو مدل دیگر از نظر آزمون‌های زوجی معنادار بود.

پرسش دوم، یعنی تعیین مدلی که در برابر شرایط غیرایده‌آل و تغییرات تصویری پایداری بیشتری داشته باشد، پاسخ یکسانی در همه سناریوها ندارد .در خرابی‌های مصنوعی H2 و در تغییر دامنهH3 ، RT-DETR-L کمترین افت میانگین را نشان داد .بنابراین، پاسخ علمی دقیق این است که مفهوم» مقاومت «وابسته به نوع تغییر و تعریف شرایط آزمون است و نمی‌توان تنها بر اساس یک سناریو درباره تعمیم‌پذیری مدل قضاوت کرد.

پرسش سوم درباره این موضوع بود که آیا سازگارسازی سبک و کنترل‌شده می‌تواند عملکرد مدل منتخب را در دامنه هدف بهبود دهد .نتایج H4 نشان داد که در طراحی انجام‌شده، پاسخ منفی است .میانگین F1 از 0.757359 به 0.723990کاهش یافت و این افت از نظر آماری معنادار بود.

بنابراین، یافته‌های این پژوهش سه پیام اصلی دارند :نخست، YOLOv8n از نظر عملکرد پایه مزیت دارد؛ دوم،-RT DETR-Lدر برابر خرابی‌های مصنوعی و تغییر دامنه پایداری بیشتری از خود نشان می‌دهد؛ و سوم، سازگارسازی مصنوعی ساده و محدود لزوماً موجب بهبود انتقال دامنه نمی‌شود.

5-9جمع‌بندی علمی یافته‌های پژوهش

بررسی هم‌زمان نتایج H1 تا H4 نشان می‌دهد که ارزیابی یک مدل تشخیص شیء برای کاربردهای دریایی را نمی‌توان تنها با یک شاخص یا یک مجموعه داده آزمون انجام داد .عملکرد یک مدل حداقل در چهار سطح قابل تحلیل است :توانایی تشخیص در شرایط پایه، مقاومت در برابر تخریب تصویری، پایداری در تغییر دامنه و واکنش به آموزش سازگاری.

در این چارچوب، YOLOv8n در شرایط پایه برتری روشنی داشت .با این حال، این برتری در H2 و H3 حفظ نشد و RT-DETR-Lکمترین افت عملکرد را در هر دو مرحله نشان داد.

از این رو، یافته‌های پژوهش به جای معرفی یک مدل به‌عنوان» بهترین مدل مطلق«، از یک تصویر چندبعدی حمایت می‌کنند .برای محیط‌هایی که شرایط تصویربرداری نسبتاً استاندارد است و عملکرد پایه اهمیت بیشتری دارد، YOLOv8nگزینه مطلوبی در میان سه مدل بررسی‌شده است .اما در شرایطی که تغییر روشنایی، رنگ، زاویه دید و انتقال میان دامنه‌های مختلف اهمیت بیشتری داشته باشد، RT-DETR-L ویژگی‌های پایداری مطلوب‌تری از خود نشان می‌دهد.

در نهایت، نتیجه H4 هشدار روش‌شناختی مهمی ارائه می‌کند :افزایش داده یا شبیه‌سازی شرایط هدف به‌صورت مصنوعی، بدون سنجش میزان شباهت و تنوع آن با دامنه واقعی، ممکن است نه‌تنها کافی نباشد بلکه موجب Negative Transferشود .بنابراین، هرگونه سازگارسازی دامنه باید با طراحی دقیق، کنترل شکاف دامنه و ارزیابی مستقل بر روی داده واقعی همراه باشد.

10-5محدودیت‌های پژوهش

با وجود تلاش برای طراحی یک چارچوب آزمایشی منسجم، این پژوهش با محدودیت‌هایی مواجه است که باید در تفسیر نتایج در نظر گرفته شوند.

نخستین محدودیت به مجموعه‌داده و میزان نمایندگی آن از شرایط واقعی محیط دریایی مربوط است. اگرچه داده‌ها برای آموزش و ارزیابی تشخیص زباله دریایی مناسب بوده‌اند، هر مجموعه‌داده تنها بخشی از تنوع واقعی محیط را پوشش می‌دهد. در نتیجه، نمی‌توان نتایج به‌دست‌آمده را بدون اعتبارسنجی بیرونی به تمام محیط‌های ساحلی، دریایی یا سامانه‌های تصویربرداری تعمیم داد.

محدودیت دوم به ماهیت مصنوعی بخشی از آزمایش‌های H2 و H3 مربوط است. این شرایط به‌صورت کنترل‌شده ایجاد شدند تا اثر هر تغییر جداگانه قابل بررسی باشد. چنین روشی برای تحلیل علمی بسیار مفید است، اما ممکن است تمامی پیچیدگی‌های شرایط واقعی را بازنمایی نکند. به‌ویژه، تغییرات محیطی در کاربرد واقعی ممکن است به‌طور هم‌زمان رخ دهند و برهم‌کنش آن‌ها رفتاری متفاوت از اعمال منفرد هر تبدیل ایجاد کند.

محدودیت سوم به تحلیل H2 و H3 مربوط می‌شود. در این دو بخش، نتایج اصلی بر پایه آمار توصیفی و رتبه‌بندی مدل‌ها گزارش شده‌اند و آزمون استنباطی رسمی برای مقایسه مستقیم مدل‌ها در مجموعه نتایج موجود ثبت نشده است. از این رو، برتری‌های مشاهده‌شده در این دو مرحله باید به‌صورت توصیفی و در محدوده طراحی آزمایش تفسیر شوند.

محدودیت چهارم به H4 مربوط است. سازگارسازی تنها با یک مدل، یعنیYOLOv8n ، انجام شد و تنها یک پروتکل مشخص از افزایش مصنوعی داده و آموزش تکمیلی آزمایش گردید. در نتیجه، افت مشاهده‌شده را نمی‌توان به همه روش‌های سازگارسازی دامنه یا همه مدل‌های تشخیص شیء تعمیم داد.

محدودیت پنجم به تعدادepoch ها و ساختار آموزش در H4 مربوط است. سازگارسازی با حداکثر 20 epochو شرایط آموزشی مشخص انجام شد. ممکن است پروتکل‌های دیگر شامل نرخ یادگیری متفاوت، freeze/unfreeze لایه‌ها، وزن‌دهی متفاوت، افزایش حجم داده یا تنظیمات طولانی‌تر به نتایج متفاوتی منجر شوند. بنابراین، H4 را باید ارزیابی یک پروتکل خاص دانست، نه ارزیابی جامع تمام راهکارهای.domain adaptation

محدودیت ششم به نبود برخی شاخص‌های جانبی در خروجی تحلیلی H1 تا H4 مربوط است. برای مثال، مجموعه نتایج مورد استفاده در آزمون فرضیه‌ها شامل خروجی کاملper-class AP ، ماتریس‌های درهم‌ریختگی و منحنی‌های PRبرای تمام مدل‌ها در همه سناریوها نبود. بنابراین، از این شاخص‌ها برای نتیجه‌گیری عددی استفاده نشده است.

محدودیت دیگری که در تفسیر نتایج اهمیت دارد، تفاوت میان معیارهای آموزشی و معیارهای آزمون فرضیه‌هاست. بهترین checkpoint بر مبنای mAP@0.50:0.95 با درنظرگرفتن mAP@0.50 انتخاب شد، در حالی که مقایسه‌های آماری H1 تا H4 بر اساس F1 در سطح تصویر و شاخص‌های افت انجام شدند. در نتیجه، نباید اعداد این دو چارچوب اندازه‌گیری با یکدیگر جایگزین یا مستقیماً معادل تلقی شوند.

در نهایت، بخشی از محدودیت پژوهش به هزینه محاسباتی و سخت‌افزار مورد استفاده بازمی‌گردد. آزمایش‌ها بر روی GPUنوع NVIDIA GeForce RTX 3060 Laptop با 6 GBحافظه انجام شده‌اند. بنابراین، امکان مقیاس‌دادن برخی آزمایش‌ها، آزمون تعداد بسیار بیشتری از پیکربندی‌ها و انجام جست‌وجوی گسترده ابرپارامترها محدود بوده است.

5-11پیشنهادهای پژوهشی برای تحقیقات آینده

یکی از مهم‌ترین مسیرهای آینده، استفاده از مجموعه‌داده‌های واقعی‌تر و متنوع‌تر از محیط‌های دریایی و ساحلی است. استفاده از داده‌هایی که شرایط نوری، عمق، کدری آب، فاصله دوربین، زاویه تصویربرداری و نوع پس‌زمینه را در طیف گسترده‌ای پوشش دهند، می‌تواند اعتبار بیرونی نتایج را افزایش دهد.

پیشنهاد دوم، گسترش ارزیابی خارج از توزیع و استفاده از یک مجموعه آزمون واقعی مستقل است. چنین طراحی‌ای می‌تواند مشخص کند آیا رتبه‌بندی مشاهده‌شده در H2 و H3 در مواجهه با تصاویر واقعی و نه فقط تغییرات مصنوعی حفظ می‌شود یا خیر.

پیشنهاد سوم، طراحی خرابی‌های ترکیبی است. در محیط واقعی، عواملی مانند کم‌نوری، کدری، تغییر رنگ، تاری و تغییر زاویه دید ممکن است هم‌زمان رخ دهند. بنابراین، آزمایش ترکیبی می‌تواند تصویر واقع‌بینانه‌تری از Robustness مدل‌ها ارائه کند.

پیشنهاد چهارم، تکرار آزمون‌های H2 و H3 با روش‌های استنباطی کامل‌تر است. استفاده از آزمون‌های زوجی مناسب، فاصله اطمینان، اندازه اثر و روش‌های اصلاح چندگانه می‌تواند قدرت نتیجه‌گیری آماری درباره تفاوت Robustness مدل‌ها را افزایش دهد.

پیشنهاد پنجم، اجرای H4 با چند راهبرد متفاوت سازگارسازی است. در پژوهش آینده می‌توان دامنه‌ای از روش‌های domain adaptationو domain generalization را مقایسه کرد؛ از جمله افزایش داده مبتنی بر مشاهده واقعی، آموزش با نمونه‌های مختلط پاک و مصنوعی، تطبیق ویژگی، pseudo-labeling و راهکارهای بدون نیاز به برچسب کامل دامنه هدف.

پیشنهاد ششم، بررسی علت Negative Transfer است. از آنجا که H4 کاهش معنادار عملکرد را نشان داد، یک مسیر پژوهشی مهم این است که مشخص شود کدام مؤلفه از تبدیل‌های مصنوعی یا فرآیند آموزش موجب افت شده است. می‌توان این بررسی را به‌صورت ablation study انجام داد؛ به‌گونه‌ای که روشن شود مثلاً کاهش روشنایی، تغییر گاما، تغییر رنگ، تاری یا JPEG به‌تنهایی و در ترکیب‌های مختلف چه اثری دارند.

پیشنهاد هفتم، بررسی روش‌های انتخاب داده برای سازگارسازی است. به‌جای استفاده از تعداد ثابتی تصویر مصنوعی،

می‌توان نمونه‌هایی را انتخاب کرد که از نظر توزیع ویژگی و ظاهر به داده واقعی هدف نزدیک‌تر باشند. این رویکرد احتمال انتقال منفی را کاهش می‌دهد.

پیشنهاد هشتم، مقایسه مدل‌ها از منظر هزینه محاسباتی در کنار دقت است. برای کاربردهای بلادرنگ و سامانه‌های پرنده یا ساحلی، معیارهایی مانند زمان استنتاج،FPS ، تعداد پارامترها، حافظه مصرفی و هزینه محاسباتی می‌توانند در انتخاب مدل اهمیت اساسی داشته باشند. این موضوع به‌ویژه در پژوهش‌های آینده که هدف آن‌ها استقرار عملی سامانه است، باید به‌صورت یک محور مستقل و با اندازه‌گیری مستقیم گزارش شود.

پیشنهاد نهم، بررسی انتقال مدل میان دوربین‌ها و موقعیت‌های تصویربرداری متفاوت است. برای مثال، آموزش روی تصاویر دوربین ثابت و آزمون روی تصاویر ثبت‌شده ازUAV ، یا آموزش روی تصاویر ساحلی و آزمون در محیط دریایی، می‌تواند معیار واقعی‌تری از generalization ارائه دهد.

پیشنهاد دهم، توسعه تحلیل در سطح کلاس است. میانگین کلی F1 می‌تواند اختلاف رفتار مدل‌ها در کلاس‌های خاص را پنهان کند. تحلیلper-class AP ، Recall و Precision می‌تواند مشخص کند که کدام انواع زباله، مانند شبکه، پوشاک، پلاستیک یا بقایای نامشخص، نسبت به تغییرات محیطی حساس‌تر هستند.

12-5پیشنهادهای کاربردی

از دید کاربردی، نتایج پژوهش نشان می‌دهد که انتخاب مدل تشخیص زباله دریایی باید بر اساس شرایط استفاده انجام شود. در یک سامانه‌ای که هدف آن دستیابی به عملکرد مناسب در شرایط نسبتاً استاندارد است، YOLOv8n به دلیل عملکرد پایه بالاتر گزینه جذابی است.

در مقابل، هنگامی که سامانه قرار است با تغییرات وسیع در نور، رنگ، زاویه دید و دامنه تصویربرداری مواجه شود، توجه بیشتر به مدل‌هایی مانند RT-DETR-L که در آزمایش تغییر دامنه افت کمتری نشان داده‌اند، منطقی خواهد بود.

همچنین، استفاده از داده مصنوعی برای سازگارسازی باید با احتیاط انجام شود. تولید داده مصنوعی نباید صرفاً بر شباهت ظاهری تمرکز داشته باشد، بلکه باید میزان شباهت آماری، تنوع و ارتباط آن با مسئله واقعی نیز ارزیابی شود. در غیر این صورت، احتمال آن وجود دارد که مدل به الگوهای مصنوعی بیش از ویژگی‌های واقعی دامنه هدف وابسته شود.

برای توسعه سامانه‌های واقعی، پیشنهاد می‌شود انتخاب نهایی مدل بر اساس یک معیار ترکیبی شامل دقت، Robustness، هزینه استنتاج، حافظه و نیازمندی‌های سخت‌افزاری انجام شود. چنین رویکردی از تصمیم‌گیری تک‌معیاره جلوگیری می‌کند.

5-13ملاحظات مربوط به اعتبار نتایج

اعتبار نتایج این پژوهش بیش از هر چیز به یکسان بودن شرایط مقایسه میان مدل‌ها وابسته است. استفاده از تقسیم‌بندی ثابت داده‌ها، اندازه ورودی یکسان، seed یکسان و چارچوب ارزیابی مشترک، امکان مقایسه منصفانه‌تری میان سه معماری فراهم کرده است.

با این حال، باید میان «اعتبار درون آزمایش» و «تعمیم به دنیای واقعی» تفاوت قائل شد. نتایج H1 با توجه به طراحی آزمایش برای مقایسه درون‌داده‌ای مناسب هستند، اما نتایج H2 و H3 عمدتاً نشان‌دهنده رفتار مدل‌ها در برابر تغییرات مصنوعی مشخص‌شده در پژوهش‌اند. بنابراین، اعتبار بیرونی آن‌ها به کیفیت و واقع‌گرایی سناریوهای طراحی‌شده وابسته است.

همچنین، نتیجه منفی H4 باید با همان دقت تفسیر شود. داده‌ها شواهد کافی برای رد موفقیت این پروتکل خاص سازگارسازی فراهم می‌کنند، اما شواهد کافی برای رد تمام راهکارهای domain adaptation فراهم نمی‌کنند.

5-14جمع‌بندی نهایی فصل

در آزمون خرابی‌های مصنوعیH2 ، میانگین افت مطلق F1 در کل شش خرابی برای RT-DETR-L برابر 0.048291، برای RTMDet-Tiny برابر 0.063644 و برای YOLOv8n برابر 0.083494 بود؛ بنابراین RT-DETR-Lکمترین افت توصیفی را داشت .در بسته نتایج H2 آزمون استنباطی بین‌مدلی ثبت نشده است.

5-15نتیجه نهایی

با توجه به مجموعه شواهد به‌دست‌آمده، می‌توان نتیجه نهایی پژوهش را در یک گزاره خلاصه کرد: هیچ یک از مدل‌های بررسی‌شده در تمامی ابعاد ارزیابی برتری مطلق نداشت، اما YOLOv8n بهترین عملکرد پایه را ارائه کرد، RT-DETR-Lبیشترین پایداری را در آزمون تغییر دامنه نشان داد و سازگارسازی مصنوعی کنترل‌شده برای YOLOv8nدر شکل آزمایش‌شده موجب Negative Transfer شد.

از این رو، پاسخ نهایی پژوهش نه انتخاب یک معماری به‌عنوان برنده مطلق، بلکه ارائه یک چارچوب تصمیم‌گیری چندبعدی برای تشخیص زباله‌های دریایی است؛ چارچوبی که در آن دقت، پایداری، تغییر دامنه و خطر انتقال منفی هم‌زمان در نظر گرفته می‌شوند.